

CERDAS MENGUASAI GIT

CERDAS MENGUASAI GIT

Dalam 24 Jam

Rolly M. Awangga
Informatics Research Center



Kreatif Industri Nusantara

Penulis:

Rolly Maulana Awangga

ISBN : 978-602-53897-0-2

Editor:

M. Yusril Helmi Setyawan

Penyunting:

Syafril Fachrie Pane

Khaera Tunnisa

Diana Asri Wijayanti

Desain sampul dan Tata letak:

Deza Martha Akbar

Penerbit:

Kreatif Industri Nusantara

Redaksi:

Jl. Ligar Nyawang No. 2

Bandung 40191

Tel. 022 2045-8529

Email : awangga@kreatif.co.id

Distributor:

Informatics Research Center

Jl. Sariasih No. 54

Bandung 40151

Email : irc@poltekpos.ac.id

Cetakan Pertama, 2019

Hak cipta dilindungi undang-undang

Dilarang memperbanyak karya tulis ini dalam bentuk dan dengan cara apapun tanpa ijin tertulis dari penerbit

*'Jika Kamu tidak dapat
menahan lelahnya
belajar, Maka kamu
harus sanggup menahan
perihnya Kebodohan.'*

Imam Syafi'i

CONTRIBUTORS

ROLLY MAULANA AWANGGA, Informatics Research Center., Politeknik Pos Indonesia, Bandung, Indonesia

CONTENTS IN BRIEF

DAFTAR ISI

DAFTAR GAMBAR

DAFTAR TABEL

Listings

FOREWORD

Sepatah kata dari Kaprodi, Kabag Kemahasiswaan dan Mahasiswa

KATA PENGANTAR

Buku ini diciptakan bagi yang awam dengan git sekalipun.

R. M. AWANGGA

*Bandung, Jawa Barat
Februari, 2019*

ACKNOWLEDGMENTS

Terima kasih atas semua masukan dari para mahasiswa agar bisa membuat buku ini lebih baik dan lebih mudah dimengerti.

Terima kasih ini juga ditujukan khusus untuk team IRC yang telah fokus untuk belajar dan memahami bagaimana buku ini mendampingi proses Internship.

R. M. A.

ACRONYMS

ACGIH	American Conference of Governmental Industrial Hygienists
AEC	Atomic Energy Commission
OSHA	Occupational Health and Safety Commission
SAMA	Scientific Apparatus Makers Association

GLOSSARY

git	Merupakan manajemen sumber kode yang dibuat oleh linus torvald.
bash	Merupakan bahasa sistem operasi berbasiskan *NIX.
linux	Sistem operasi berbasis sumber kode terbuka yang dibuat oleh Linus Torvald

SYMBOLS

- A Amplitude
 - $\&$ Propositional logic symbol
 - a Filter Coefficient
- \mathcal{B} Number of Beats

INTRODUCTION

ROLLY MAULANA AWANGGA, S.T., M.T.

Informatics Research Center
Bandung, Jawa Barat, Indonesia

Pada era disruptif saat ini. git merupakan sebuah kebutuhan dalam sebuah organisasi pengembangan perangkat lunak. Buku ini diharapkan bisa menjadi pengantar para programmer, analis, IT Operation dan Project Manajer. Dalam melakukan implementasi git pada diri dan organisasinya.

Rumusnya cuman sebagai contoh aja biar keren[?].

$$ABC\mathcal{DEF}\alpha\beta\Gamma\Delta \sum_{def}^{abc} \quad (I.1)$$

BAB 1

CHAPTER 1

1.1 1174035 - Luthfi Muhammad Nabil

Kecerdasan buatan merupakan kecerdasan yang dimasukkan ke sistem yang dapat diatur untuk kepentingan ilmiah. Kecerdasan buatan biasa disebut AI (Artificial Intelligence) yang didefinisikan sebagai kecerdasan ilmiah. AI memiliki kemampuan untuk menerjemahkan data dari luar, dan mempelajari data tersebut untuk dipelajari demi mencapai tujuan dan melakukan tugas tertentu sesuai hasil adaptasi berdasarkan data yang didapat.

1.1.1 Sejarah dan perkembangan Kecerdasan Buatan

AI mulai berkembang sesuai dengan konsep yang dikemukakan pada awal abad 17, Rene Descartes menyebutkan bahwa tubuh hewan bukanlah apa-apa melainkan mesin-mesin yang rumit. Lalu Blaise Pascal menciptakan mesin perhitungan digital mekanis pertama pada 1642. Selanjutnya pada abad ke 19, Charles Babbage dan Ada Lovelace menciptakan sebuah mesin penghitung mekanis yang dapat diprogram.

Pada tahun 1950-an, Program AI pertama yang sudah dapat difungsikan telah ditulis pada 1951 untuk menjalankan mesin Ferranti Mark I di University of Manchester yang merupakan sebuah program permainan naskah yang ditulis oleh Christopher Strachey. John McCarthy menyebutkan istilah kecerdasan buatan pada konferensi pertama yang disediakan untuk persoalan ini. Dilanjut pada tahun 1956, Beliau menemukan bahasa pemrograman yang bernama Lisp.

Jaringan saraf mulai digunakan secara luas pada tahun 1980-an, dimana algoritma perambatan balik pertama kali dijelaskan oleh Paul John Werbos pada tahun 1974. Selanjutnya di tahun 1982, para ahli fisika menganalisis sifat dari penyimpanan dan optimasi pada jaringan saraf menggunakan sistem statistika. Lalu dilanjutkan pada tahun 1985 sedikitnya empat kelompok riset menemukan algoritma pembelajaran propagansi balik. Algoritma ini berhasil diimplementasikan ke ilmu komputer dan psikologi. Dan pada tahun 1990, ditandai perolehan besar dalam berbagai bidang AI dan demonstrasi dari berbagai aplikasi yang sudah mengimplementasi. Seperti Deep Blue, sebuah komputer dari permainan catur yang dapat mengalahkan Garry Kasparov dalam sebuah pertandingan 6 game yang terkenal pada 1997.

1.1.2 Supervised Learning

Supervised learning adalah kondisi yang menggunakan variabel input dan output untuk dapat dilakukan pemetaan input output yang sudah didapat. Disebut Supervised Learning karena proses dari pembelajaran algoritma dari pembelajaran yang disumberkan dengan dataset dapat dipikirkan seperti seorang guru yang mengawasi proses pembelajaran. Proses pembelajaran dari algoritma akan berhenti saat algoritma sudah mendapatkan level dari performansi yang dapat diterima.

Masalah dari Supervised learning dapat dikelompokkan menjadi masalah dengan regresi dan klasifikasi

- Klasifikasi : Masalah dalam klasifikasi yang dimana output dari variable itu adalah kategori, seperti "Laki - laki" atau "Perempuan, dan "Muda" dan "Tua"
- Regresi : Masalah dalam regresi adalah jika pengeluaran dari variabel adalah sebuah nilai asli, seperti "suhu", dan "tinggi"

1.1.3 Unsupervised Learning

Unsupervised learning adalah kondisi dimana kamu hanya memiliki input data tanpa memiliki variabel output yang sesuai. Tujuan dari unsupervised learning adalah untuk memodelkan distribusi pada data untuk mengetahui lebih lanjut mengenai data. Disebut unsupervised learning karena pada metode ini, tidak ada jawaban yang tepat dan tidak ada pengarah. Sehingga algoritma

akan ditinggalkan sesuai rancangan demi menemukan dan dapat mengolah data yang menarik pada saat yang akan datang.

1.1.4 Jenis - Jenis Dataset

Dataset merupakan objek yang merepresentasikan data dan relasinya di memor. Strukturnya dapat mirip sesuai dengan struktur yang ada pada database namun bisa diubah sesuai dengan kebutuhan. Dataset juga berisi koleksi dari tabel data dan relasi data.

- Training set : merupakan sebuah dataset yang digunakan untuk kepentingan pembelajaran. Kepentingan tersebut akan disesuaikan dengan parameter yang ada.
- Test dataset : adalah sebuah dataset yang bersifat independen dibandingkan dengan training dataset, namun mengikuti probabilitas distribusi yang sama dengan training dataset. Jika model sudah sesuai dengan training dataset maka dataset sudah dapat disesuaikan dengan test dataset. Penyesuaian dari training dataset .

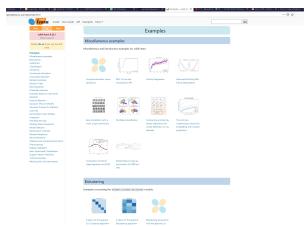
1.1.5 Instalasi dan Percobaan Kompilasi dari Library Scikit-learn

1. Buka anaconda prompt
2. Ketik di anaconda prompt yaitu : "pip install -U scikit-learn" untuk instalasi

```
(base) D:\Wallah\Python\KecerdasanBuatAnda>pip install -U scikit-learn
Collecting scikit-learn
  Downloading scikit-learn-0.22.1-pypi_0-py3-none-any.whl (6.3 MB)
Collecting scipy==1.7.0
  Downloading scipy-1.7.0-cp37-cp37m-win_amd64.whl (30.9 MB)
Collecting numpy==1.18.1
  Downloading numpy-1.18.1-cp37-cp37m-win_amd64.whl (12.8 MB)
Collecting joblib==0.14.1
  Downloading joblib-0.14.1-py3-none-any.whl (294 kB)
Collecting scikit-learn[scipy,numpy]
  Downloading scikit-learn-0.22.1-pypi_0-py3-none-any.whl (204 kB)
Successfully installed joblib-0.14.1 numpy-1.18.1 scikit-learn-0.22.1 scipy-1.4.1
(base) D:\Wallah\Python\KecerdasanBuatAnda>
```

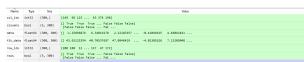
Gambar 1.1 Instalasi Scikit Learn

3. Setelah selesai instalasi, pilih salah satu example dari website Scikit (Contoh :)



Gambar 1.2 Daftar Example

4. Lalu coba jalankan aplikasi tersebut, bisa dicek hasil dari Variable explorernya



Gambar 1.3 Variable Explorer

5. Sample kode

```

1 print(__doc__)
2
3 # Author: Kemal Eren <kemal@kemaleren.com>
4 # License: BSD 3 clause
5
6 import numpy as np
7 from matplotlib import pyplot as plt
8
9 from sklearn.datasets import make_biclusters
10 from sklearn.cluster import SpectralCoclustering
11 from sklearn.metrics import consensus_score
12
13 data, rows, columns = make_biclusters(
14     shape=(300, 300), n_clusters=5, noise=5,
15     shuffle=False, random_state=0)
16
17 plt.matshow(data, cmap=plt.cm.Blues)
18 plt.title("Original dataset")
19
20 # shuffle clusters
21 rng = np.random.RandomState(0)
22 row_idx = rng.permutation(data.shape[0])
23 col_idx = rng.permutation(data.shape[1])
24 data = data[row_idx][:, col_idx]
25
26 plt.matshow(data, cmap=plt.cm.Blues)
27 plt.title("Shuffled dataset")
28
29 model = SpectralCoclustering(n_clusters=5, random_state=0)
30 model.fit(data)
31 score = consensus_score(model.biclusters_,
32                         (rows[:, row_idx], columns[:, col_idx]))
33
34 print("consensus score: {:.3f}".format(score))
35
36 fit_data = data[np.argsort(model.row_labels_)]
37 fit_data = fit_data[:, np.argsort(model.column_labels_)]
38
39 plt.matshow(fit_data, cmap=plt.cm.Blues)
40 plt.title("After biclustering; rearranged to show biclusters")
41

```

```
42 plt.show()
```

1.1.6 Mencoba Loading and example dataset

Disini akan dilakukan percobaan dengan menggunakan beberapa datasets seperti digits dan iris untuk bisa digunakan sebagai training set yang akan dipakai seluruh metode.

- Percobaan 1 (Memuat data iris dan digits dari datasets)

```
1 from sklearn import datasets #Untuk import class/fungsi
   dataset dari scikit-learn library
2 iris = datasets.load_iris() #Untuk memuat dan memasukkan
   dataset iris ke variabel bernama iris
3 digits = datasets.load_digits() #Untuk memuat dan memasukkan
   dataset digits ke variabel digits
```

```
In [18]: """
...: Created on Wed Feb 26 15:55:58 2020
...:
...: @author: Luthfi Muhammad Nabil
...: """
...:
...: from sklearn import datasets
...: iris = datasets.load_iris()
...: digits = datasets.load_digits()
```

Gambar 1.4 Hasil Percobaan 1

- Percobaan 2 (Menampilkan data dari digits)

```
1 print(digits.data) #Menampilkan object berformat Dictionary-
   like yang nanti akan ditampilkan pada console
```

```
In [19]: print(digits.data)
[[ 0.  0.  5. ... 0.  0.  0.]
 [ 0.  0.  0. ... 10. 0.  0.]
 [ 0.  0.  0. ... 16. 9.  0.]
 ...
 [ 0.  0.  1. ... 6.  0.  0.]
 [ 0.  0.  2. ... 12. 0.  0.]
 [ 0.  0. 10. ... 12. 1.  0.]]
```

Gambar 1.5 Hasil Percobaan 2

- Percobaan 3 (Menampilkan digits.target)

```
1 digits.target #Menunjukkan data angka yang berhubungan dengan
   setiap digit gambar yang sedang dipelajari
```

```
In [20]: digits.target
Out[20]: array([0, 1, 2, ..., 8, 9, 8])
```

Gambar 1.6 Hasil Percobaan 3

- Percobaan 4 (Menampilkan data 2 dimensi)

```
1 digits.images[0] #Akan mengambil data dengan berformat array
2 Dimensi, dengan bentuk parameter (n_samples, n_features)
```

```
In [22]: digits.images[0]
Out[22]:
array([[ 0.,  0.,  5., 13.,  9.,  1.,  0.,  0.],
       [ 0.,  0., 13., 15., 10., 15.,  5.,  0.],
       [ 0.,  3., 15.,  2.,  0., 11.,  8.,  0.],
       [ 0.,  4., 12.,  0.,  0.,  8.,  8.,  0.],
       [ 0.,  5.,  8.,  0.,  0.,  9.,  8.,  0.],
       [ 0.,  4., 11.,  0.,  1., 12.,  7.,  0.],
       [ 0.,  2., 14.,  5., 10., 12.,  0.,  0.],
       [ 0.,  0.,  6., 13., 10.,  0.,  0.,  0.]])
```

Gambar 1.7 Hasil Percobaan 4

- Full sample

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Wed Feb 26 15:55:58 2020
4
5 @author: Luthfi Muhammad Nabil
6 """
7
8 from sklearn import datasets #Untuk import class/fungsi
9      dataset dari scikit-learn library
10 iris = datasets.load_iris() #Untuk memuat dan memasukkan
11      dataset iris ke variabel bernama iris
12 digits = datasets.load_digits() #Untuk memuat dan memasukkan
13      dataset digits ke variabel digits
14 #%%
15 print(digits.data) #Menampilkan object berformat Dictionary-
16      like yang nanti akan ditampilkan pada console
17 #%%
18 digits.target #Menunjukkan data angka yang berhubungan dengan
19      setiap digit gambar yang sedang dipelajari
20 #%%
21 digits.images[0] #Akan mengambil data dengan berformat array
22 Dimensi, dengan bentuk parameter (n_samples, n_features)
```

**Gambar 1.8** Hasil pada variable explorer

1.1.7 Learning and Predicting

Disini akan dicoba untuk melakukan prediksi berupa angka yang inputnya berupa gambaran dataset.

- Percobaan 1

```

1 from sklearn import svm #Untuk mengimport class sv dari
   library sklearn
2 from sklearn import datasets #Untuk import class/fungsi
   dataset dari scikit-learn library
3 clf = svm.SVC(gamma=0.001, C=100) #Memasukkan implementasi
   dari "Support Vector Classification" ke variabel clf
4 iris = datasets.load_iris() #Untuk memuat dan memasukkan
   dataset iris ke variabel bernama iris

```

Gambar 1.9 Hasil Percobaan 1

- Percobaan 2

```

1 digits = datasets.load_digits() #Untuk memuat dan memasukkan
   dataset digits ke variabel digits
2 clf.fit(digits.data[:-1], digits.target[:-1]) #Untuk
   melakukan pengiriman data training set ke method fit

```

Gambar 1.10 Hasil Percobaan 2

- Percobaan 3

```

1 clf.predict(digits.data[-1:]) #Untuk melakukan prediksi nilai
   yang baru berdasarkan gambar terakhir dari digits.data

```

Gambar 1.11 Hasil Percobaan 3

- Full sample

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 10:32:23 2020
4
5 @author: Luthfi Muhammad Nabil
6 """
7
8 from sklearn import svm #Untuk mengimport class sv dari
9     library sklearn
10 from sklearn import datasets #Untuk import class/fungsi
11     dataset dari scikit-learn library
12 clf = svm.SVC(gamma=0.001, C=100) #Memasukkan implementasi
13     dari "Support Vector Classification" ke variabel clf
14 iris = datasets.load_iris() #Untuk memuat dan memasukkan
15     dataset iris ke variabel bernama iris
16 #%%
17 digits = datasets.load_digits() #Untuk memuat dan memasukkan
18     dataset digits ke variabel digits
19 clf.fit(digits.data[:-1], digits.target[:-1]) #Untuk
20     melakukan pengiriman data training set ke method fit
21 #%%
22 clf.predict(digits.data[-1:]) #Untuk melakukan prediksi nilai
23     yang baru berdasarkan gambar terakhir dari digits.data

```



Gambar 1.12 Hasil pada variable explorer

1.1.8 Model Persistence

Disini akan dilakukan persistensi model menggunakan built-in dari Python

- Percobaan 1

```

1 from sklearn import svm #Mengimport class SVM dari library
2     sklearn
3 from sklearn import datasets #Mengimport datasets dari
4     library sklearn
5 clf = svm.SVC() #Memasukkan implementasi dari "Support Vector
6     Classification" ke variabel clf
7 X, y = datasets.load_iris(return_X_y=True) #Untuk memuat dan
8     memasukkan dataset iris ke variabel bernama iris
9 clf.fit(X, y) #Untuk melakukan pengiriman data training set
10    ke method fit

```



Gambar 1.13 Hasil Percobaan 1

- Percobaan 2

```

1 import pickle #Mengimport pickle untuk implementasi protokol
   serializing dan de-serializing
2 s = pickle.dumps(clf) #Untuk serialize hirarki dari object
3 clf2 = pickle.loads(s) #Untuk memuat dan men de-serialize
   hirarki dari object
4 clf2.predict(X[0:1]) #Untuk melakukan prediksi nilai yang
   baru berdasarkan gambar terakhir dari digits.data

```

Gambar 1.14 Hasil Percobaan 2

- Percobaan 3

```
1 y[0] #Untuk menampilkan data iris koordinat y
```

Gambar 1.15 Hasil Percobaan 3

- Percobaan 4

```

1 from joblib import dump, load #Mengambil class dump dan load
   dari library joblib
2 dump(clf, 'filename.joblib') #Untuk memasukkan data ke dalam
   sebuah file

```

Gambar 1.16 Hasil Percobaan 4

- Percobaan 5

```
1 clf = load('filename.joblib') #Untuk memuat data dari file
```

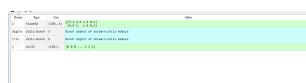
Gambar 1.17 Hasil Percobaan 5

- Full sample

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 10:37:49 2020
4
5 @author:Luthfi Muhammad Nabil
6 """
7
8 from sklearn import svm #Mengimport class SVM dari library
9      sklearn
10 from sklearn import datasets #Mengimport datasets dari
11      library sklearn
12 clf = svm.SVC() #Memasukkan implementasi dari "Support Vector
13      Classification" ke variabel clf
14 X, y = datasets.load_iris(return_X_y=True) #Untuk memuat dan
15      memasukkan dataset iris ke variabel bernama iris
16 clf.fit(X, y) #Untuk melakukan pengiriman data training set
17      ke method fit
18 #%%
19 import pickle #Mengimport pickle untuk implementasi protokol
20      serializing dan de-serializing
21 s = pickle.dumps(clf) #Untuk serialize hirarki dari object
22 clf2 = pickle.loads(s) #Untuk memuat dan men de-serialize
23      hirarki dari object
24 clf2.predict(X[0:1]) #Untuk melakukan prediksi nilai yang
25      baru berdasarkan gambar terakhir dari digits.data
26 #%%
27 y[0] #Untuk menampilkan data iris koordinat y
28 #%%
29 from joblib import dump, load #Mengambil class dump dan load
30      dari library joblib
31 dump(clf, 'filename.joblib') #Untuk memasukkan data ke dalam
32      sebuah file
33 #%%
34 clf = load('filename.joblib') #Untuk memuat data dari file

```



Gambar 1.18 Hasil pada variable explorer

1.1.9 Conventions

Seluruh metode akan dilakukan pengaturan untuk membuat tingkah laku lebih dapat diprediksi

- Percobaan 1

```

1 import numpy as np #Memuat library numpy yang akan
2      diinisialisasikan menjadi np
3 from sklearn import random_projection #Memuat class
4      random_projection dari library sklearn

```

```

4 rng = np.random.RandomState(0) #Memuat angka random dan
    mengekspos angka untuk menghasilkan dari berbagai
    probabilitas distribusi, angka tersebut dimasukkan ke
    variabel rng
5 X = rng.rand(10, 2000) #Membatasi jarak angka random
6 X = np.array(X, dtype='float32') #Memuat angka menjadi ke
    dalam array
7 X.dtype #Mengambil tipe data dari variabel X

```

```

In [1]: ...
Out[1]: float32
In [2]: ...
Out[2]: float32
In [3]: ...
Out[3]: float32
In [4]: ...
Out[4]: float32
In [5]: ...
Out[5]: float32
In [6]: ...
Out[6]: float32
In [7]: ...
Out[7]: float32

```

Gambar 1.19 Hasil Percobaan 1

▪ Percobaan 2

```

1 transformer = random_projection.GaussianRandomProjection() #
    Mengimplementasikan modul yang simpel dan efisien secara
    komputasi untuk mengurangi dimensi dari data
2 X_new = transformer.fit_transform(X) #Untuk membuat
    penengahan data
3 X_new.dtype #Mengambil tipe data dari variabel X

```

```

In [8]: ...
Out[8]: float32
In [9]: transformer = random_projection.GaussianRandomProjection() #Mengimpl...
... X_new = transformer.fit_transform(X) #Untuk membuat penengahan data
... X_new.dtype #Mengambil tipe data dari variabel X
Out[9]: float32

```

Gambar 1.20 Hasil Percobaan 2

▪ Percobaan 3

```

1 from sklearn import datasets #Mengimport datasets dari
    library sklearn
2 from sklearn.svm import SVC
3 iris = datasets.load_iris() #Untuk memuat dan memasukkan
    dataset iris ke variabel bernama iris
4 clf = SVC() #Memasukkan implementasi dari "Support Vector
    Classification" ke variabel clf
5 clf.fit(iris.data, iris.target) #Untuk melakukan pengiriman
    data training set ke method fit

```

```

In [10]: from sklearn import datasets
Out[10]: <function datasets.load_iris>
In [11]: from sklearn.svm import SVC
Out[11]: <class 'sklearn.svm._classes.SVC' at 0x10101010>
In [12]: clf = SVC()
Out[12]: SVC(C=1.0, cache_size=100, class_weight=None, decision_function_shape='ovr', dual=False, degree=3,
... gamma='auto', kernel='rbf', max_iter=-1, probability=False, random_state=None,
... shrinking=True, tol=0.001, verbose=False)

```

Gambar 1.21 Hasil Percobaan 3

- Percobaan 4

```
1 list(clf.predict(iris.data[:3])) #Untuk memuat dan men de-
    serialize hirarki dari object , data tersebut akan
    dimasukkan ke fungsi list
```

Gambar 1.22 Hasil Percobaan 4

- Percobaan 5

```
1 clf.fit(iris.data, iris.target_names[iris.target]) #Untuk
    melakukan pengiriman data training set ke method fit
```

Gambar 1.23 Hasil Percobaan 5

- Percobaan 6

```
1 list(clf.predict(iris.data[:3])) #Untuk memuat dan men de-
    serialize hirarki dari object , data tersebut akan
    dimasukkan ke fungsi list
```

Gambar 1.24 Hasil Percobaan 6

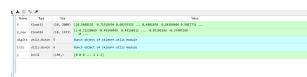
- Full sample

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 10:56:18 2020
4
5 @author: Luthfi Muhammad Nabil
```

```

6 """
7
8 import numpy as np #Memuat library numpy yang akan
9     diinisialisasikan menjadi np
9 from sklearn import random_projection #Memuat class
10    random_projection dari library sklearn
11
11 rng = np.random.RandomState(0) #Memuat angka random dan
12    mengeksplosi angka untuk menghasilkan dari berbagai
13    probabilitas distribusi, angka tersebut dimasukkan ke
14    variabel rng
12 X = rng.rand(10, 2000) #Membatasi jarak angka random
13 X = np.array(X, dtype='float32') #Memuat angka menjadi ke
14    dalam array
14 X.dtype #Mengambil tipe data dari variabel X
15 #%%
16 transformer = random_projection.GaussianRandomProjection() #
17     Mengimplementasikan modul yang simpel dan efisien secara
18     komputasi untuk mengurangi dimensi dari data
17 X_new = transformer.fit_transform(X) #Untuk membuat
18     penengahan data
18 X_new.dtype #Mengambil tipe data dari variabel X
19
20 #%%
21 from sklearn import datasets #Mengimport datasets dari
22     library sklearn
22 from sklearn.svm import SVC
23 iris = datasets.load_iris() #Untuk memuat dan memasukkan
24     dataset iris ke variabel bernama iris
24 clf = SVC() #Memasukkan implementasi dari "Support Vector
25     Classification" ke variabel clf
25 clf.fit(iris.data, iris.target) #Untuk melakukan pengiriman
26     data training set ke method fit
26 #%%
27 list(clf.predict(iris.data[:3])) #Untuk memuat dan men de-
28     serialize hirarki dari object, data tersebut akan
29     dimasukkan ke fungsi list
28 #%%
29 clf.fit(iris.data, iris.target_names[iris.target]) #Untuk
30     melakukan pengiriman data training set ke method fit
30 #%%
31 list(clf.predict(iris.data[:3])) #Untuk memuat dan de-
32     serialize hirarki dari object, data tersebut akan
33     dimasukkan ke fumgsi list

```



Gambar 1.25 Hasil pada variable explorer

1.1.10 Skrinsut Error

Gambar 1.26 Hasil Percobaan 6

1.1.11 Kode error dan jenis error tersebut

Error yang didapat berjenis name error, karena sebuah variabel tidak didefinisikan. Yaitu digits

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 10:56:18 2020
4
5 @author: Luthfi Muhammad Nabil
6 """
7
8 import numpy as np #Memuat library numpy yang akan
9     diinisialisasikan menjadi np
10 from sklearn import random_projection #Memuat class
11     random_projection dari library sklearn
12
13 rng = np.random.RandomState(0) #Memuat angka random dan
14     mengekspos angka untuk menghasilkan dari berbagai
15     probabilitas distribusi, angka tersebut dimasukkan ke
16     variabel rng
17 X = rng.rand(10, 2000) #Membatasi jarak angka random
18 X = np.array(X, dtype='float32') #Memuat angka menjadi ke dalam
19     array
20 X.dtype #Mengambil tipe data dari variabel X
21 """
22 transformer = random_projection.GaussianRandomProjection() #
23     Mengimplementasikan modul yang simpel dan efisien secara
24     komputasi untuk mengurangi dimensi dari data
25 X_new = transformer.fit_transform(X) #Untuk membuat peningangan
26     data
27 X_new.dtype #Mengambil tipe data dari variabel X
28 """
29
30 from sklearn import datasets #Mengimport datasets dari library
31     sklearn
32 from sklearn.svm import SVC
33 iris = datasets.load_iris() #Untuk memuat dan memasukkan dataset
34     iris ke variabel bernama iris
35 clf = SVC() #Memasukkan implementasi dari "Support Vector
36     Classification" ke variabel clf
37 clf.fit(iris.data, iris.target) #Untuk melakukan pengiriman data
38     training set ke method fit
39 """
40
```

```

27 list(clf.predict(iris.data[:3])) #Untuk memuat dan men de-
    serialize hirarki dari object, data tersebut akan dimasukkan
    ke fungsi list
28 #%%
29 clf.fit(iris.data, iris.target_names[iris.target]) #Untuk
    melakukan pengiriman data training set ke method fit
30 #%%
31 list(clf.predict(iris.data[:3])) #Untuk memuat dan men de-
    serialize hirarki dari object, data tersebut akan dimasukkan
    ke fungsi list

```

1.1.12 Penanganan Error

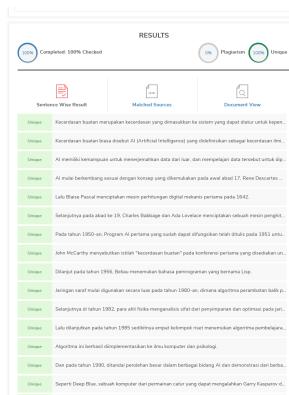
Untuk menangani error tersebut, bisa ditambahkan sesuai instruksi. Yaitu menambahkan sebuah variabel bernama digits. Selain itu, digits harus dapat bekerja sebagaimana mestinya. Berikut full kodingnya :

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 10:32:23 2020
4
5 @author: Luthfi Muhammad Nabil
6 """
7
8 from sklearn import svm #Untuk mengimport class sv dari library
    sklearn
9 from sklearn import datasets #Untuk import class/fungsi dataset
    dari scikit-learn library
10 clf = svm.SVC(gamma=0.001, C=100) #Memasukkan implementasi dari "
        Support Vector Classification" ke variabel clf
11 iris = datasets.load_iris() #Untuk memuat dan memasukkan dataset
    iris ke variabel bernama iris
12 #%%
13 digits = datasets.load_digits() #Untuk memuat dan memasukkan
    dataset digits ke variabel digits
14 clf.fit(digits.data[:-1], digits.target[:-1]) #Untuk melakukan
    pengiriman data training set ke method fit
15 #%%
16 clf.predict(digits.data[-1:]) #Untuk melakukan prediksi nilai
    yang baru berdasarkan gambar terakhir dari digits.data

```

1.1.13 Plagiarisme



Gambar 1.27 Hasil pada variable explorer

1.2 1174040 - Hagan Rowlenstino A. S

1.2.1 Teori

1.2.1.1 Definisi Kecerdasan Buatan Artificial Intelligence atau dapat disebut juga dengan kecerdasan buatan merupakan kecerdasan yang ditambahkan kepada suatu sistem yang dapat diatur dalam konteks ilmiah. Michael Haenlein dan Andreas Kaplan mendefinisikan bahwa AI adalah “sistem yang mempunyai kemampuan untuk menguraikan, belajar agar dapat digunakan untuk mencapai tujuan dengan melalui adaptasi yang fleksibel”. Kecerdasan ini dibuat dan dimasukkan ke dalam mesin agar dapat melakukan pekerjaan seperti yang dapat dilakukan manusia dengan cepat dan tepat. Bidang-bidang yang menggunakan kecerdasan buatan antara lain logika fuzzy, games, sistem pakar, jaringan saraf tiruan dan robotika.

1.2.1.2 Sejarah Kecerdasan Buatan Sejarah kecerdasan buatan ini dimulai dari zaman kuno, mitos ataupun cerita dan desas-desus tentang sebuah makhluk yang mempunyai kecerdasan serta kesadaran yang diberikan oleh pengrajin. Benih - benih nya mulai ditanam oleh para filsuf klasik yang mencari cara untuk menggambarkan proses berfikir manusia sebagai manipulasi simbol secara mekanis yang memuncak pada penemuan komputer digital di tahun 1940-an, yaitu sebuah mesin yang didasarkan penalaran matematika. Istilah kecerdasan buatan sendiri baru muncul pada tahun 1956, dan teori -teori nya sudah muncul sejak tahun 1941.

1.2.1.3 Perkembangan Kecerdasan Buatan

1. Perkembangan kecerdasan buatan dimulai dari Era Komputer Elektronik pada tahun 1941. dimana ditemukannya alat penyimpanan dan pemros-

esan informasi. Dilanjutkan pada tahun 1949, berhasilnya pembuatan komputer yang mampu menyimpan program yang memudahkan pekerjaan dalam memasukkan program menjadi lebih mudah.

2. Masa - masa persiapan AI terjadi pada tahun 1943 - 1956.
3. Awal Perkembangan AI terjadi pada 1952 - 1969
4. Perkembangan kecerdasan buatan melambat pada tahun 1966-1974
5. Sistem Berbasis Pengetahuan pada tahun 1969-1979
6. Kecerdasan Buatan menjadi sebuah industri pada tahun 1980-1988. Kembarinya Jaringan Syaraf tiruan pada tahun 1986-sekarang.

1.2.2 Instalasi

Membuka <https://scikit-learn.org/stable/tutorial/basic/tutorial.html> lalu mencobanya.

1.2.2.1 Instalasi library scikit, mencoba kompilasi dan ujicoba contoh kode

1. Buka anaconda prompt lalu ketikkan "pip install -U scikit-learn" untuk menginstall library scikit



Gambar 1.28 Install Library Scikit

2. Pilih salah satu example dari website tersebut lalu jalankan

```

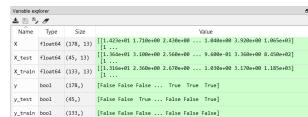
1 # -*- coding: utf-8 -*-
2 """
3 Created on Wed Feb 26 18:16:44 2020
4
5 @author: User
6 """
7
8 import matplotlib.pyplot as plt
9 from sklearn.svm import SVC
10 from sklearn.ensemble import RandomForestClassifier
11 from sklearn.metrics import plot_roc_curve
12 from sklearn.datasets import load_wine
13 from sklearn.model_selection import train_test_split
  
```

```

14
15 X, y = load_wine(return_X_y=True)
16 y = y == 2
17
18 X_train, X_test, y_train, y_test = train_test_split(X, y,
19 random_state=42)
20 svc = SVC(random_state=42)
21 svc.fit(X_train, y_train)

```

3. buka variable explolernya



Gambar 1.29 Variable Exploler

1.2.2.2 Mencoba loading an example dataset

1. mengambil data iris dan digit dari dataset

```

1 from sklearn import datasets #untuk mengimport dataset dari
    library learn-scikit
2 iris = datasets.load_iris() #membuat sebuah variable iris
    yang mempunyai isi yaitu dataset iris
3 digits = datasets.load_digits() #membuat sebuah variable
    digits yang mempunyai isi yaitu dataset digits

```

2. Menampilkan data digits

```

1 print(digits.data) #memberikan akses ke fitur yang dapat
    digunakan untuk mengklasifikasikan sampel digit dan
    menampilkannya di console

```

```

In [21]: runfile('D:/Semester6/AI/Chapter1/no2.py', wdir='D:/Semester6/AI/Chapter1')
[[ 0.,  0.,  5., ...,  0.,  0.]
 [ 0.,  0.,  10., ...,  0.,  0.]
 [ 0.,  0.,  15., ...,  0.,  0.]
 ...
 [ 0.,  0.,  1., ...,  5.,  0.]
 [ 0.,  0.,  2., ..., 12.,  0.]
 [ 0.,  0.,  0., ..., 12.,  1.]]

```

Gambar 1.30 Data Digits

3. menampilkan digits.target

```

1 digits.target #memberikan informasi tentang data yang
    berhubungan atau juga dapat dijadikan sebagai label

```

```
In [16]: digits.target
Out[16]: array([0, 1, 2, ..., 8, 9, 8])
```

Gambar 1.31 Digits Target

- menampilkan data bentuk 2D.

```
1 digits.images[0] #Data selalu berupa array 2D, shape (
    n_samples, n_features), meskipun data aslinya mungkin
    memiliki bentuk yang berbeda.
```

```
In [17]: digits.images[0]
Out[17]:
array([[0., 0., 5., 13., 9., 1., 0., 0.],
       [0., 0., 13., 15., 10., 15., 5., 0.],
       [0., 3., 15., 2., 0., 11., 8., 0.],
       [0., 1., 11., 13., 12., 12., 7., 0.],
       [0., 5., 8., 0., 0., 9., 8., 0.],
       [0., 4., 11., 0., 1., 12., 7., 0.],
       [0., 2., 14., 5., 10., 12., 0., 0.],
       [0., 0., 6., 13., 10., 0., 0., 0.]])
```

Gambar 1.32 Data 2D

1.2.2.3 Mencoba Learning and Predicting

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 22:20:55 2020
4
5 @author: User
6 """
7
8 from sklearn.linear_model import LogisticRegression #untuk
    mengimport linear-model dari library sklearn
9 from sklearn.datasets import make_blobs #untuk mengimport library
    datasets dari sklearn
10
11 X, y = make_blobs(n_samples=100, centers=2, n_features=2,
    random_state=1) # untuk generate dataset dengan klasifikasi 2
    D
12 model = LogisticRegression() #menggunakan metode loginstic
    regression
13 model.fit(X, y)
14
15 Xnew, _ = make_blobs(n_samples=3, centers=2, n_features=2,
    random_state=1) # menentukan 1 buah contoh baru dimana
    jawabannya tidak diketahui
16
17 ynew = model.predict_proba(Xnew) # membuat sebuah prediksi dan
    memasukkan nya kedalam variable ynew
18 for i in range(len(Xnew)):
19     print("X=%s, Predicted=%s" % (Xnew[i], ynew[i])) #menampilkan
        hasil prediksi
```

1.2.2.4 Mencoba Model Persistence

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 22:27:13 2020
4
5 @author: User
6 """
7
8 from sklearn import svm #menigimport svm dari library sklearn
9 from sklearn import datasets #menigimport datasets dari library
10    sklearn
11 clf = svm.SVC() #menggunakan method SVC
12 iris = datasets.load_iris() #menggunakan dataset iris
13 X, y = iris.data, iris.target #memasukkan x sebagai iris data ,
14      dan y sebagai iris target
15 clf.fit(X, y) #laalu menggunakan metod fit .

```

1.2.2.5 Mencoba Conventions

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 23:24:21 2020
4
5 @author: User
6 """
7
8 import numpy as npy #mengimport numpy sebagai npy
9 from sklearn import random_projection #mengimport
10    random_projection dari library sklearn
11 rng = npy.random.RandomState(0) #Menggunakan fungsi random dari
12      numpy
13 X = rng.rand(10, 2000) #membuat range random diantara 10 sampai
14      2000
15 X = npy.array(X, dtype='float32') #yang dijadikan array dengan
16      tipe data float32
17 X.dtype

```

1.2.3 Penanganan Error



context))
ValueError: Found array with 0 sample(s) (shape=(0, 2)) while a minimum of 1 is
required.

Gambar 1.33 Data 2D

1.2.3.1 Screenshot Error

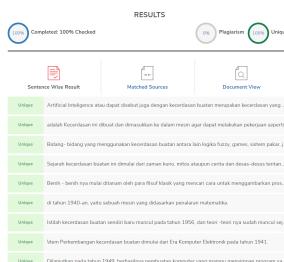
1.2.3.2 Kode error dan jenis error

Jenis errornya adalah value error

```
1 Xnew, _ = make_blobs(n_samples=3, centers=2, n_features=2,
    random_state=1) # menentukan 1 buah contoh baru dimana
    jawabannya tidak diketahui
```

1.2.3.3 Solusi Error Solusinya adalah dengan mengganti nilai n_samples nya agar tidak 0

1.2.4 Cek Plagiarism



Gambar 1.34 Cek Plagiarism

1.3 1174042 Faisal Najib Abdullah

1.3.1 Teori

- Definisi, sejarah, dan perkembangan kecerdasan buatan.

Definisi kecerdasan buatan adalah suatu pengetahuan yang dapat membuat komputer untuk meniru kecerdasan manusia yang berhubungan dengan penangkapan, pemodelan, dan penyimpanan kecerdasan manusia dalam sebuah sistem teknologi. Contohnya yaitu melakukan analisa penalaran untuk mengambil suatu kesimpulan atau penerjemahan atau keputusan dari satu bahasa satu ke bahasa lain.

Sejarah dan perkembangan kecerdasan buatan terjadi pada musim panas tahun 1956 tercatat adanya seminar mengenai AI di Darmouth College. Seminar pada waktu itu dihadiri oleh sejumlah pakar komputer dan membahas potensi komputer dalam meniru kepandaian manusia. Akan tetapi perkembangan yang sering terjadi semenjak diciptakannya LISP, yaitu bahasa kecerdasan buatan yang dibuat tahun 1960 oleh John McCarthy. Istilah pada kecerdasan buatan atau Artificial Intelligence diambil dari Marvin Minsky dari MIT. Dia menulis karya ilmiah berjudul Step towards Artificial Intelligence, The Institute of radio Engineers Proceedings 49, January 1961[?].

- Definisi supervised learning, klasifikasi, regresi, dan unsupervised learning. Data set, training set dan testing set.

Supervised learning merupakan sebuah pendekatan dimana sudah terdapat data yang dilatih, dan terdapat variable yang ditargetkan sehingga tujuan dari pendekatan ini adalah mengelompokan suatu data ke data yang sudah ada. Sedangkan unsupervised learning tidak memiliki data latih, sehingga dari data yang ada, kita mengelompokan data tersebut menjadi 2 bagian atau 3 bagian dan seterusnya.

Klasifikasi adalah salah satu topik utama dalam data mining atau machine learning. Klasifikasi yaitu suatu pengelompokan data dimana data yang digunakan tersebut mempunyai kelas label atau target.

Regresi adalah Supervised learning tidak hanya mempelajari classifier, tetapi juga mempelajari fungsi yang dapat memprediksi suatu nilai numerik. Contoh, ketika diberi foto seseorang, kita ingin memprediksi umur, tinggi, dan berat orang yang ada pada foto tersebut.

Data set adalah cabang aplikasi dari Artificial Intelligence/Kecerdasan Buatan yang fokus pada pengembangan sebuah sistem yang mampu belajar sendiri tanpa harus berulang kali di program oleh manusia.

Training set yaitu jika pasangan objek, dan kelas yang menunjuk pada objek tersebut adalah suatu contoh yang telah diberi label akan menghasilkan suatu algoritma pembelajaran.

Testing set digunakan untuk mengukur sejauh mana classifier berhasil melakukan klasifikasi dengan benar[?].

1.3.2 Instalasi

1.3.2.1 Instalasi Library Scikit dari Pycharm

Masuk pada menu settings terus pilih Project Interpreter kemudian tambah library lalu cari dan install scikit

Mencoba Library

```

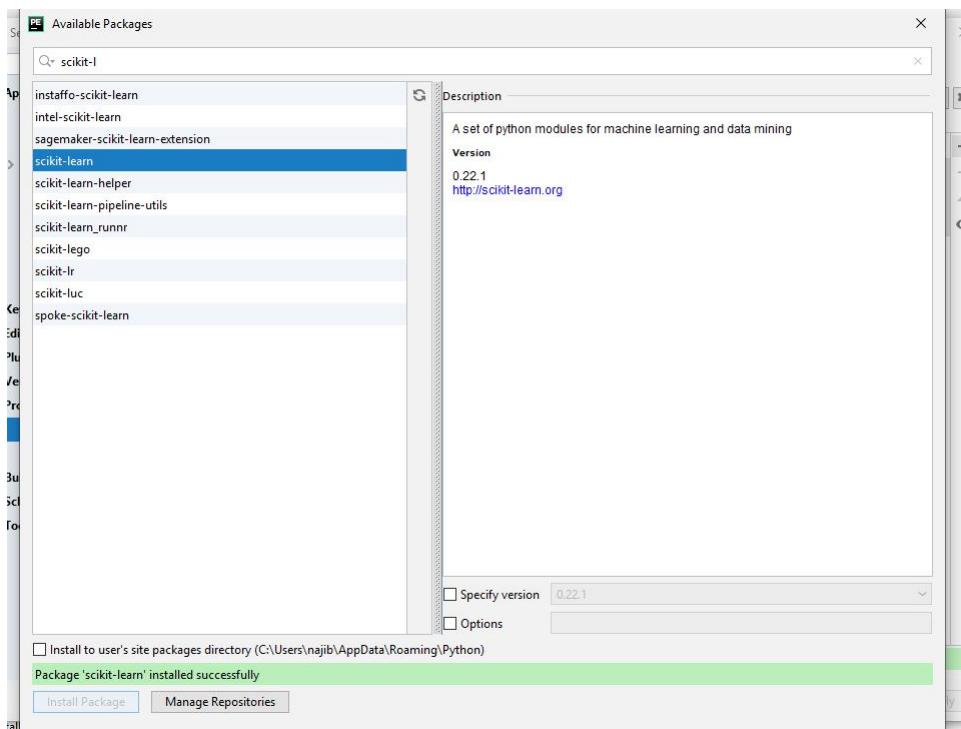
1 from sklearn import datasets
2 #pada baris ini merupakan sebuah perintah untuk mengimport class
   datasets dari packaged sklearn
3 iris = datasets.load_iris()
4 #pada baris kedua ini dimana iris merupakan suatu estimator/
   parameter yang berfungsi untuk mengambil data pada item
   datasets.load_iris
5 digits = datasets.load_digits()
6 #pada baris ketiga ini dimana digits merupakan suatu estimator/
   parameter yang berfungsi untuk mengambil data pada item
   datasets.load_digits

```

```

1 from sklearn import datasets
2 #pada baris ini merupakan sebuah perintah untuk mengimport class
   datasets dari packaged sklearn
3 iris = datasets.load_iris()
4 #pada baris kedua ini dimana iris merupakan suatu estimator/
   parameter yang berfungsi untuk mengambil data pada item
   datasets.load_iris

```



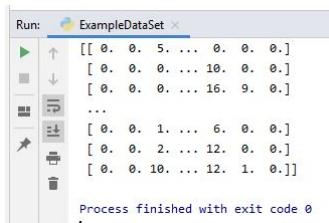
Gambar 1.35 Installasi

```

5 digits = datasets.load_digits()
6 #pada baris ketiga ini dimana digits merupakan suatu estimator/
  parameter yang berfungsi untuk mengambil data pada item
  datasets.load_digits
7 print(digits.data)
8 #pada baris keempat ini merupakan perintah yang berfungsi untuk
  menampilkan estimator/parameter yang dipanggil pada item
  digits.data dan menampilkan outputannya
9 digits.target
10 #barisan ini untuk mengambil target pada estimator/parameter
    digits dan menampilkan outputannya
11 digits.images[0]
12 #barisan ini untuk mengambil images[0] pada estimator/parameter
    digits dan menampilkan outputannya

from sklearn import svm
#pada baris ini merupakan sebuah perintah untuk mengimport class
  svm dari packaged sklearn
clf = svm.SVC(gamma=0.001, C=100.)

```

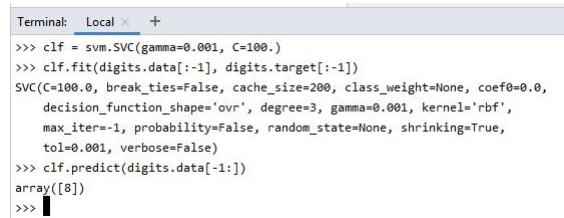


Gambar 1.36 Mencoba Loading an example Dataset

```

4 #pada baris kedua ini clf sebagai estimator/parameter , svm.SVC
   sebagai class , gamma sebagai parameter untuk menetapkan nilai
   secara manual
5 clf.fit(digits.data[:-1], digits.target[:-1])
6 #pada baris ketiga ini clf sebagai estimator/parameter , fit
   sebagai metode , digits.data sebagai item , [-1] sebagai
   syntax pythonnya dan menampilkan outputannya
7 clf.predict(digits.data[-1:])
8 #pada baris terakhir ini clf sebagai estimator/parameter , predict
   sebagai metode lainnya , digits.data sebagai item dan
   menampilkan outputannya

```



Gambar 1.37 Learning and Predicting

```

1 from sklearn import svm
2 #pada baris ini merupakan sebuah perintah untuk mengimport class
   svm dari packaged sklearn
3 from sklearn import datasets
4 #pada baris ini merupakan sebuah perintah untuk mengimport class
   datasets dari packaged sklearn
5 clf = svm.SVC(gamma='scale')
6 #pada baris ketiga ini clf sebagai estimator/parameter , svm.SVC
   sebagai class , gamma sebagai parameter untuk menetapkan nilai
   secara manual dengan nilai scale
7 iris = datasets.load_iris()
8 #pada baris keempat ini iris sebagai estimator/parameter ,
   datasets.load_iris() sebagai item dari suatu nilai
9 X, y = iris.data, iris.target
10 #pada baris kelima ini X, y sebagai estimator/parameter , iris.
    data, iris.target sebagai item dari 2 nilai yang ada

```

```

11 clf.fit(X, y)
12 #pada baris keenam ini clf sebagai estimator/parameter dengan
   menggunakan metode fit untuk memanggil estimator X, y dengan
   outputannya
13
14
15 import pickle
16 #pickle merupakan sebuah class yang di import
17 s = pickle.dumps(clf)
18 #pada baris ini s sebagai estimator/parameter dengan pickle.dumps
   merupakan suatu nilai/item dari estimator/parameter clf
19 clf2 = pickle.loads(s)
20 #pada baris ini clf2 sebagai estimator/parameter, pickle.loads
   sebagai suatu item, dan s sebagai estimator/parameter yang
   dipanggil
21 clf2.predict(X[0:1])
22 #pada baris ini clf2.predict sebagai suatu item dengan
   menggunakan metode predict untuk menentukan suatu nilai dari
   (X[0:1])
23 y[0]
24 #pada estimator/parameter y berapapun angka yang diganti nilainya
   akan selalu konstan yaitu 0
25
26
27 from joblib import dump, load
28 #pada baris berikut ini merupakan sebuah perintah untuk
   mengimport class dump, load dari packaged joblib
29 dump(clf, 'filename.joblib')
30 #pada baris berikutnya dump di sini sebagai class yang didalamnya
   terdapat nilai dari suatu item clf dan data joblib
31 clf = load('filename.joblib')
32 #pada baris terakhir clf sebagai estimator/parameter dengan suatu
   nilai load berfungsi untuk mengulang data sebelumnya

```

```

... clf.fit(X, y)
SVC(C=100.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
     decision_function_shape='ovr', degree=3, gamma=0.001, kernel='rbf',
     max_iter=-1, probability=False, random_state=None, shrinking=True,
     tol=0.001, verbose=False)

```

Gambar 1.38 Model Presistence

```

>>> clf2.predict(X[0:1])
array([0])
>>> #pada baris ini clf2.predict
... y[0]
0

```

Gambar 1.39 Model Presistence

```

1 #Type Casting
2 from sklearn import svm

```

```

2,4,1.JPG 26
2,4.JPG 27
2,4.py 28
2.JPG 29
3.JPG 30
ExampleDataSet.py 31
filename.joblib 32
Teori.tex 33

```

Gambar 1.40 Model Presistence

```

3 #pada baris ini merupakan sebuah perintah untuk mengimport class
   svm dari packaged sklearn
4 from sklearn import random_projection
5 #pada baris ini merupakan sebuah perintah untuk mengimport class
   random_projection dari packaged sklearn
6 rng = np.random.RandomState(0)
7 #rng sebagai estimator/parameter dengan nilai suatu itemnya yaitu
   np.random.RandomState(0)
8 X = rng.rand(10, 2000)
9 #X sebagai estimator/parameter dengan nilai item rng.rand
10 X = np.array(X, dtype='float32')
11 #X sebagai estimator/parameter dengan nilai item np.array
12 X.dtype
13 #X.dtype sebagai item pemanggil
14 transformer = random_projection.GaussianRandomProjection()
15 #transformer sebagai estimator/parameter dengan memanggil class
   random_projection
16 X_new = transformer.fit_transform(X)
17 #X new di sini sebagai estimator/parameter dan menggunakan metode
   fit
18 X_new.dtype
19 #X new.dtype sebagai item
20
21
22 from sklearn import datasets
23 #pada baris ini merupakan sebuah perintah untuk mengimport class
   datasets dari packaged sklearn
24 from sklearn.svm import SVC
25 #pada baris ini merupakan sebuah perintah untuk mengimport class
   SVC dari packaged sklearn.svm
26 iris = datasets.load_iris()
27 #iris sebagai estimator/parameter dengan item datasets.load_iris
   ()
28 clf = SVC(gamma='scale')
29 #clf sebagai estimator/parameter dengan nilai class SVC pada
   parameter gamma sebagai set penilaian
30 clf.fit(iris.data, iris.target)
31 #estimator/parameter clf menggunakan metode fit dengan itemnya
   list(clf.predict(iris.data[:3]))
32 #menambahkan item list dengan metode predict
33 clf.fit(iris.data, iris.target_names[iris.target])
34 #estimator/parameter clf menggunakan metode fit dengan itemnya
   list(clf.predict(iris.data[:3]))
35 #menambahkan item list dengan metode predict

```

```
39
40
41 #Refitting and Updating Parameters
42 import numpy as np
43 #pada baris ini merupakan sebuah perintah untuk mengimport class
44     svm dari np
45 from sklearn.svm import SVC
46 #pada baris ini merupakan sebuah perintah untuk mengimport class
47     SVC dari packaged sklearn.svm
48 rng = np.random.RandomState(0)
49 #rng sebagai estimator/parameter dengan nilai suatu itemnya yaitu
50     np.random.RandomState(0)
51 X = rng.rand(100, 10)
52 #X sebagai estimator/parameter dengan nilai item rng.rand
53 y = rng.binomial(1, 0.5, 100)
54 #y sebagai estimator/parameter dengan nilai item rng.binomial
55 X_test = rng.rand(5, 10)
56 #X test sebagai estimator/parameter dengan nilai item rng.rand
57 clf = SVC()
58 #clf sebagai estimator/parameter dan class SVC
59 clf.set_params(kernel='linear').fit(X, y)
60 #set params sebagai item
61 clf.predict(X_test)
62
63
64 #Multiclass vs. Multilabel Fitting
65 from sklearn.svm import SVC
66 #pada baris ini merupakan sebuah perintah untuk mengimport class
67     SVC dari packaged sklearn.svm
68 from sklearn.multiclass import OneVsRestClassifier
69 #pada baris ini merupakan sebuah perintah untuk mengimport class
70     OneVsRestClassifier dari packaged sklearn.multiclass
71 from sklearn.preprocessing import LabelBinarizer
72 #pada baris ini merupakan sebuah perintah untuk mengimport class
73     LabelBinarizer dari packaged sklearn.preprocessing
74 X = [[1, 2], [2, 4], [4, 5], [3, 2], [3, 1]]
75 y = [0, 0, 1, 1, 2]
76 classif = OneVsRestClassifier(estimator=SVC(gamma='scale',
77                                         random_state=0))
78 classif.fit(X, y).predict(X)
79 y = LabelBinarizer().fit_transform(y)
80 classif.fit(X, y).predict(X)
81
82
83 from sklearn.preprocessing import MultiLabelBinarizer
84 y = [[0, 1], [0, 2], [1, 3], [0, 2, 3], [2, 4]]
85 y = MultiLabelBinarizer().fit_transform(y)
86 classif.fit(X, y).predict(X)
```

1.3.3 Penanganan eror

```
>>> from joblib import dump, load
>>> #pada baris berikut ini merupakan sebuah perintah untuk mengimport class dump, load dari packaged joblib
... dump(clf, 'filename.joblib')
Traceback (most recent call last):
  File "<stdin>", line 2, in <module>
NameError: name 'clf' is not defined
>>> #pada baris berikutnya dump di sini sebagai class yang didalamnya terdapat nilai dari suatu item clf dan data joblib
... clf = load('filename.joblib')
```

Gambar 1.41 Error

1.3.3.1 ScreenShoot Eror

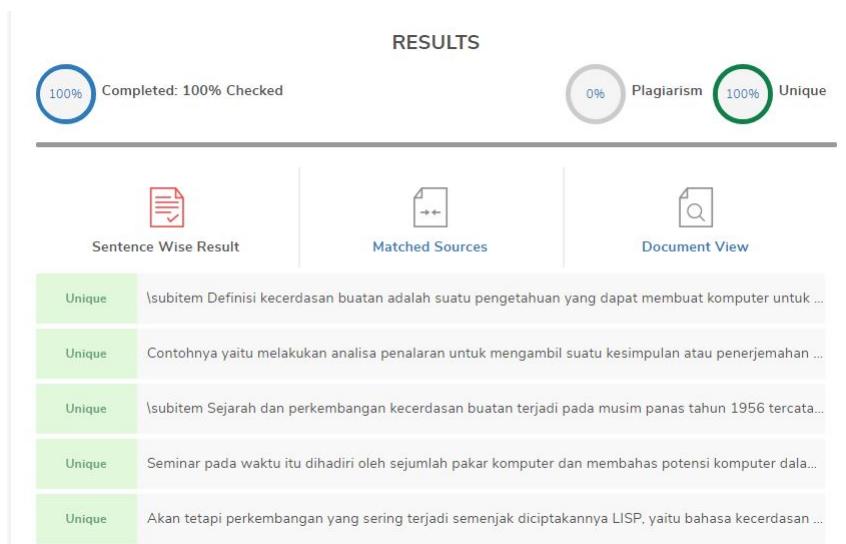
1.3.3.2 Tuliskan Kode Eror dan Jenis Erornya

File "<stdin>", line 2, in <module>
NameError: name 'clf' is not defined

1.3.3.3 Solusi Pemecahan Masalah Error

Ini karna kode di jalankan perbaris perbaris, jika kode dijanlankan bersamaan makan kode berjan sesuai prosedur.

1.3.4 Plagiat



Gambar 1.42 Error

1.3.5 Link

[Youtube](#)

1.4 1174043 - Irwan Rizkiansyah

1.4.1 Definisi Kecerdasan Buatan

Kecerdasan buatan atau biasa disebut AI (Artificial Intelligence) merupakan kecerdasan yang dibuat dan ditambahkan oleh manusia ke suatu sistem teknologi, yang diatur dan dikembangkan dalam konteks ilmiah, yang merupakan bentukan dari kecerdasan entitas ilmiah yang ada. Jadi pada intinya definisi AI dapat terus dikembangkan, namun yang menjadi poin utamanya adalah bagaimana manusia menciptakan sebuah teknologi yang dapat berpikir seperti selayaknya manusia itu sendiri.

1.4.2 Sejarah dan Perkembangan

- Program kecerdasan buatan atau Artificial Intelligence pertama kali diceritakan pada kisaran tahun 1951. Tidak bisa dipungkiri bahwa di tahun tersebut memang sedang gencar-gencarnya pembuatan cikal bakal, konsep, hingga teknologi berbasis AI. Dan, AI sendiri pertama kali digunakan di University of Manchester untuk menjalankan sebuah mesin bernama Ferranti Mark 1.
- Beberapa waktu kemudian, Christopher Strachey melanjutkan konsep kecerdasan buatan untuk menjalankan sebuah permainan catur, dimana bidak catur tersebut dapat berjalan secara otomatis dan mampu bermain melawan manusia sungguhan.
- Berlanjut pada tahun 1956, kecerdasan buatan tidak hanya dibuat untuk memudahkan bermain catur saja. Melainkan pada saat konferensi pertamanya, John McCharty menamai algoritma teknologi tersebut dengan sebutan “Artificial Intelligence”. Istilah tersebut masih digunakan hingga sekarang oleh para pakar teknologi.
- Terakhir, konsep dan teknologi kecerdasan buatan disempurnakan oleh seorang ahli yang namanya masih diingat sampai sekarang sebagai seorang pakar kecerdasan buatan, yaitu Alan Turin. Pada saat itu, Alan Turin meneliti dan menguji coba algoritma AI yang diberi nama dengan “Turing Test”. Hingga seiring berkembangnya waktu, konsep teknologi AI banyak digunakan di berbagai teknologi baik itu multimedia, search engine, dan masih banyak lainnya.

1.4.3 Supervised Learning

Supervised learning (Pembelajaran terawasi), dalam konteks kecerdasan buatan (AI) dan Machine Learning, adalah jenis sistem di mana input dan output data yang diinginkan disediakan. Input dan output data diberi label

untuk klasifikasi untuk memberikan dasar pembelajaran untuk pemrosesan data di masa depan.

1.4.4 Unsupervised Learning

Unsupervised learning merupakan pembelajaran yang tidak terawasi dimana tidak memerlukan target output. Pada metode ini tidak dapat ditentukan hasil seperti apa yang diharapkan selama proses pembelajaran, nilai bobot yang disusun dalam proses range tertentu tergantung pada nilai output yang diberikan. Tujuan metode unsupervised learning ini agar kita dapat mengelompokkan unit-unit yang hampir sama dalam satu area tertentu.

1.4.5 Teknik Klasifikasi

Teknik klasifikasi memprediksi respons diskrit, misalnya seperti apakah email itu asli atau spam, atau apakah tumor itu kanker atau tidak. Model klasifikasi mengklasifikasikan data masukan ke dalam kategori tersebut.

1.4.6 Regresi

Regresi yaitu pengeluaran nilai output yang konstan jika dipicu dengan parameter tertentu biasanya regresi disini berbentuk regresi linier. Regresi linier yaitu metode statistika yang digunakan untuk membentuk model hubungan antara variabel terikat(dependen,respon,Y) dengan satu atau lebih variabel bebas(independent, prdiktor, X). Apabila banyaknya variabel bebas hanya ada satu, disebut sebagai regresi linier sederhana, sedangkan apabila terdapat lebih dari satu variabel bebas, disebut sebagai regresi linier berganda.

1.4.7 Training Set

Training set adalah bagian dari dataset itu sendiri yang dilatih untuk membuat prediksi atau algoritma mesin learning lainnya sesuai keinginan atau tujuan data itu dibuat.

1.4.8 Testing Set

Testing set adalah bagian dari dataset yang di tes atau diujicoba untuk melihat keakuratannya dengan katalain melihat peformanya.

1.4.9 Instalasi dan Percobaan Kompilasi dari Library Scikit-learn

1. Buka anaconda prompt
2. kemudian Ketik di anaconda prompt yaitu : "pip install -U scikit-learn"



Gambar 1.43 Instalasi Scikit Learn


```
1 print(__doc__)
2
3 # Author: Nelle Varoquaux <nelle.varoquaux@gmail.com>
4 #          Alexandre Gramfort <alexandre.gramfort@inria.fr>
5 # License: BSD
6
7 import numpy as np
8 import matplotlib.pyplot as plt
9 from matplotlib.collections import LineCollection
10
11 from sklearn.linear_model import LinearRegression
12 from sklearn.isotonic import IsotonicRegression
13 from sklearn.utils import check_random_state
14
15 n = 100
16 x = np.arange(n)
17 rs = check_random_state(0)
18 y = rs.randint(-50, 50, size=(n,)) + 50. * np.log1p(np.arange(
19     n))
20 #
21 ######
22
23 # Fit IsotonicRegression and LinearRegression models
24
25 ir = IsotonicRegression()
26
27 y_ = ir.fit_transform(x, y)
28
29 lr = LinearRegression()
30 lr.fit(x[:, np.newaxis], y) # x needs to be 2d for
31 # LinearRegression
32 #
33 ######
34
35 # Plot result
36
37 segments = [[i, y[i]], [i, y_[i]]] for i in range(n)]
38 lc = LineCollection(segments, zorder=0)
39 lc.set_array(np.ones(len(y)))
40 lc.set_linewidths(np.full(n, 0.5))
41
42 fig = plt.figure()
```

```
39 plt.plot(x, y, 'r.', markersize=12)
40 plt.plot(x, y_, 'b.-', markersize=12)
41 plt.plot(x, lr.predict(x[:, np.newaxis]), 'b-')
42 plt.gca().add_collection(lc)
43 plt.legend(['Data', 'Isotonic Fit', 'Linear Fit'], loc='lower
        right')
44 plt.title('Isotonic regression')
45 plt.show()
```

5. Kemudian jalankan aplikasi tersebut, dan bisa dicek hasil dari Variable explorernya

Gambar 1.44 Variable Explorer

1.4.10 Mencoba Loading an example dataset


```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Wed Feb 26 19:32:36 2020
4
5 @author: lenovo
6 """
7
8 from sklearn import datasets #import class/fungsi dataset
9         dari scikit-learn library
10
11 import matplotlib.pyplot as plt #import matplotlib
12
13 #Load the digits dataset
14 digits = datasets.load_digits() #memuat dan memasukkan
15         dataset digits ke variabel digits
16
17 #menampilkan digit pertama
18 plt.figure(1, figsize=(3, 3))
19 plt.imshow(digits.images[-1], cmap=plt.cm.gray_r ,
20             interpolation='nearest')
21 plt.show()
```

2. Kemudian jalankan aplikasi tersebut



Gambar 1.45 Dataset

1.4.11 Mencoba Learning and Predicting

1. Sample	kode
-----------	------

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 19:07:08 2020
4
5 @author: lenovo
6 """
7
8 from sklearn.linear_model import LogisticRegression #import
9         dari library sklearn
10 from sklearn.datasets import make_blobs #import dari library
11         sklearn
12
13 X, y = make_blobs(n_samples=100, centers=2, n_features=2,
14                     random_state=1) # generate dataset klasifikasi 2d
15
16 # fit final model
17 model = LogisticRegression()
18 model.fit(X, y)
19
20 Xnew, _ = make_blobs(n_samples=3, centers=2, n_features=2,
21                     random_state=1) # menentukan 1 buah contoh baru dimana
22                     jawabannya tidak diketahui
23
24 ynew = model.predict_proba(Xnew) # membuat prediksi
25 for i in range(len(Xnew)):
26     print("X=%s, Predicted=%s" % (Xnew[i], ynew[i])) #
27             menampilkan hasil prediksi

```

2. Kemudian	jalankan	aplikasi	tersebut
-------------	----------	----------	----------

```

In [18]: runfile('C:/Users/lenovo/Desktop/simple_3.py', wdir='C:/Users/lenovo/Desktop')
X=[-0.3520228  2.38095117], Predicted:[0.9997159  0.0002840]
X=[-0.2529000  2.38095117], Predicted:[0.9997159  0.0002840]
X=[-2.18771168  3.3332125], Predicted:[0.90389073  0.09610927]

```

Gambar 1.46 Predicting

1.4.12 Mencoba Model Persistence

Sample	kode
--------	------

```

1 # -*- coding: utf-8 -*-

```

```

2 """
3 Created on Thu Feb 27 19:36:22 2020
4
5 @author: lenovo
6 """

7
8 from sklearn import svm #import dari library sklearn
9 from sklearn import datasets #import dari library sklearn
10 clf = svm.SVC() #menggunakan Support Vector Classifier
11 iris = datasets.load_iris() #menggunakan iris dataset
12 X, y = iris.data, iris.target
13 clf.fit(X, y)

```

1.4.13 Mencoba Conventions

Sample kode

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Feb 27 20:04:46 2020
4
5 @author: lenovo
6 """

7
8 import numpy as np #import dari library sklearn
9 from sklearn import random_projection #import dari library
   sklearn
10
11 rng = np.random.RandomState(0) #Menggunakan fungsi random
12 X = rng.rand(10, 2000) #mengambil nilai random
13 X = np.array(X, dtype='float32') #membuat array bertipe float32
14 X.dtype

```

1.5 1174050 Dika Sukma Pradana

1.5.1 Teori

1. Definisi, sejarah, dan perkembangan kecerdasan buatan.

Intelejenji buatan (AI) mengacu pada simulasi kecerdasan manusia dalam mesin yang diprogram untuk berpikir seperti manusia dan meniru tindakan mereka. Istilah ini juga dapat diterapkan pada mesin apa pun yang menunjukkan sifat-sifat yang terkait dengan pikiran manusia seperti pembelajaran dan pemecahan masalah.

Sejarah Kecerdasan Buatan (AI) bermula pada saat zaman kuno, dengan sejuta mitos, cerita dan desas-desus tentang makhluk buatan yang diberkahii dengan kecerdasan oleh pengrajin ahli. Benih-benih AI modern ditanam oleh para filsuf klasik yang mencoba menggam-

barkan proses pemikiran manusia sebagai manipulasi simbol secara mekanis. Karya ini memuncak dalam penemuan komputer digital yang dapat diprogram pada tahun 1940-an, sebuah mesin yang didasarkan pada esensi abstrak penalaran matematika. Perangkat ini dan ide-ide di belakangnya menginspirasi segenap ilmuwan untuk mulai serius membahas kemungkinan membangun otak elektronik. Bidang penelitian AI didirikan pada lokakarya yang diadakan di kampus Dartmouth College selama musim panas 1956. Mereka yang hadir akan menjadi pemimpin penelitian AI selama beberapa dekade. Banyak dari mereka meramalkan bahwa sebuah mesin yang secerdas manusia akan hidup tidak lebih dari satu generasi dan mereka diberi jutaan dolar untuk mewujudkan visi atau tujuan ini. Akhirnya, menjadi jelas bahwa mereka meremehkan kesulitan proyek. Pada tahun 1973, sebagai tanggapan atas kritik dari James Lighthill dan tekanan terus-menerus dari kongres, AS dan Pemerintah Inggris menghentikan pendanaan penelitian yang tidak diarahkan pada kecerdasan buatan, dan tahun-tahun sulit berikutnya akan dikenal sebagai musim dingin AI. Tujuh tahun kemudian, sebuah inisiatif visioner oleh Pemerintah Jepang mengilhami pemerintah dan industri untuk menyediakan miliaran dolar dalam AI, tetapi pada akhir 80-an investor menjadi kecewa dengan kurangnya daya komputer (perangkat keras) yang dibutuhkan dan menarik lebih banyak dana. Investasi dan minat pada AI tumbuh pesat pada dekade pertama abad ke-21, ketika pembelajaran mesin berhasil diterapkan pada banyak masalah di dunia akademis dan industri karena metode baru, penerapan perangkat keras komputer yang kuat, dan kumpulan data yang sangat besar.

2. Definisi supervised learning, klasifikasi, regresi, dan unsupervised learning. Data set, training set dan testing set.

Supervised learning adalah sebuah metode pendekatan yang mana sudah terdapat data yang dilatih, dan terdapat variabel yang ditargetkan atau yang menjadi tujuan sehingga tujuan dari pendekatan ini adalah mengelompokan suatu data ke data yang sudah ada. Sedangkan unsupervised learning tidak memiliki data latih, sehingga dari data yang ada, kita mengelompokan data tersebut menjadi dua bagian atau bahkan tiga bagian dan seterusnya.

Klasifikasi adalah salah satu topik utama dalam data mining atau machine learning. Klasifikasi yaitu suatu pengelompokan data dimana data yang digunakan tersebut mempunyai kelas label atau target.

Regresi adalah Supervised learning tidak hanya mempelajari classifier, tetapi juga mempelajari fungsi yang dapat memprediksi suatu nilai numerik.

Data set merupakan sebuah cabang aplikasi dari Artificial Intelligence(AI)/Kecerdasan Buatan yang terfokus kepada pengembangan se-

b. buah sistem yang mampu belajar sendiri tanpa harus berulang kali di program oleh manusia(programmer).

Training set yaitu jika pasangan objek, dan kelas yang menunjuk pada objek tersebut adalah suatu contoh yang telah diberi label akan menghasilkan suatu algoritma pembelajaran.

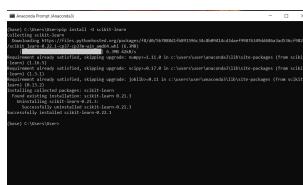
Testing set digunakan untuk mengukur sejauh mana classifier berhasil melakukan klasifikasi dengan benar[?].

1.5.2 Instalasi

1.5.2.1 Instalasi Library Scikit dari Anaconda

1. Download aplikasi Anaconda terlebih dahulu.
 2. Install aplikasi Anaconda yang sudah di download tadi.
 3. Simpan aplikasi sesuai folder yang kita pilih lalu next.
 4. Centang Keduanya lalu tekan tombol install.
 5. Setelah itu tunggu sampai proses instalasi selesai lalu jika sudah tekan tombol finish.
 6. Lalu buka command prompt anda dan tuliskan perintah berikut ini untuk mengecek apakah aplikasinya sudah terinstall.

```
pip install -U scikit-learn
```
 7. Kemudian ketikkan perinta pip install -U scikit-learn seperti gambar berikut.



Gambar 1.47 Instalasi

1.5.3 Percobaan

Mencoba Library

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Wed Feb 26 22:51:53 2020
4
5 @author: User
6 """
```

```

7
8 import matplotlib.pyplot as plt
9 from sklearn.svm import SVC
10 from sklearn.ensemble import RandomForestClassifier
11 from sklearn.metrics import plot_roc_curve
12 from sklearn.datasets import load_wine
13 from sklearn.model_selection import train_test_split
14
15 X, y = load_wine(return_X_y=True)
16 y = y == 2
17
18 X_train, X_test, y_train, y_test = train_test_split(X, y,
19 random_state=42)
20 svc = SVC(random_state=42)
21 svc.fit(X_train, y_train)
```

SVC(random_state=42)

Gambar 1.48 Variabel Explore

```

1 from sklearn import datasets
2 #perintah untuk mengimport class datasets dari packaged sklearn
3 iris = datasets.load_iris()
4 #iris merupakan suatu estimator/parameter yang berfungsi untuk
5 #mengambil data pada item datasets.load_iris
5 digits = datasets.load_digits()
6 #digits merupakan suatu estimator/parameter yang berfungsi untuk
7 #mengambil data pada item datasets.load_digits
7 print(digits.data)
8 #perintah yang berfungsi untuk menampilkan estimator/parameter
9 #yang dipanggil pada item digits.data dan menampilkan
10 #outputannya
10 digits.target
11 #untuk mengambil target pada estimator/parameter digits dan
12 #menampilkan outputannya
11 digits.images[0]
12 #untuk mengambil images[0] pada estimator/parameter digits dan
13 #menampilkan outputannya
```

```
In [13]: runfile('C:/Users/User/Documents/Sayler/1.py', wdir='C:/Users/User/Documents/')
Spicer
[[ 0, 0, 0, 5, ..., 0, 0, 0, 0],
 [ 0, 0, 0, 0, ..., 10, 0, 0, 0],
 [ 0, 0, 0, 0, 0, ..., 10, 0, 0, 0],
 ...,
 [ 0, 0, 0, 1, ..., 6, 0, 0, 0],
 [ 0, 0, 2, ..., 12, 0, 0, 0],
 [ 0, 0, 0, ..., 12, 1, 0, 0]]
```

Gambar 1.49 Datasets

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Wed Feb 26 22:17:01 2020
```

```
4
5 @author: User
6 """
7 from sklearn import svm
8 #merupakan sebuah perintah untuk mengimport class svm dari
9     packaged sklearn
10 # merupakan sebuah perintah untuk mengimport class datasets dari
11     packaged sklearn
12 clf = svm.SVC(gamma='scale')
13 #clf sebagai estimator/parameter, svm.SVC sebagai class , gamma
14     sebagai parameter untuk menetapkan nilai secara manual dengan
15     nilai scale
16 iris = datasets.load_iris()
17 #iris sebagai estimator/parameter, datasets.load_iris() sebagai
18     item dari suatu nilai
19 X, y = iris.data, iris.target
20 #X, y sebagai estimator/parameter, iris.data, iris.target sebagai
21     item dari 2 nilai yang ada
22 clf.fit(X, y)
23 #clf sebagai estimator/parameter dengan menggunakan metode fit
24     untuk memanggil estimator X, y dengan outputannya
```

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Wed Feb 26 23:06:05 2020
4
5 @author: User
6 """
7
8 import pickle
9 #pickle merupakan sebuah class yang di import
10 s = pickle.dumps(clf)
11 #s sebagai estimator/parameter dengan pickle.dumps merupakan
12     suatu nilai/item dari estimator/parameter clf
13 clf2 = pickle.loads(s)
14 #clf2 sebagai estimator/parameter, pickle.loads sebagai suatu
15     item, dan s sebagai estimator/parameter yang dipanggil
16 clf2.predict(X[0:1])
17 #clf2.predict sebagai suatu item dengan menggunakan metode
18     predict untuk menentukan suatu nilai dari (X[0:1])
19 y[0]
20 #pada estimator/parameter y berapapun angka yang diganti nilainya
21     akan selalu konstan yaitu 0
22
23
24 from joblib import dump, load
25 #sebuah perintah untuk mengimport class dump, load dari packaged
26     joblib
27 dump(clf, 'filename.joblib')
28 #dump di sini sebagai class yang didalamnya terdapat nilai dari
29     suatu item clf dan data joblib
30 clf = load('filename.joblib')
31 #clf sebagai estimato/parameter dengan suatu nilai load berfungsi
32     untuk mengulang data sebelumnya
```

1.5.3.4 Conventions Type Casting

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Wed Feb 26 22:45:29 2020
4
5 @author: User
6 """
7
8 #Type Casting
9 from sklearn import svm
10 #pada baris ini merupakan sebuah perintah untuk mengimport class
11 #svm dari packaged sklearn
12 from sklearn import random_projection
13 #pada baris ini merupakan sebuah perintah untuk mengimport class
14 #random projection dari packaged sklearn
15 rng = np.random.RandomState(0)
16 #rng sebagai estimator/parameter dengan nilai suatu itemnya yaitu
17 #np.random.RandomState(0)
18 X = rng.rand(10, 2000)
19 #X sebagai estimator/parameter dengan nilai item rng.rand
20 X = np.array(X, dtype='float32')
21 #X sebagai estimator/parameter dengan nilai item np.array
22 X.dtype
23 #X.dtype sebagai item pemanggil
24 transformer = random_projection.GaussianRandomProjection()
25 #transformer sebagai estimator/parameter dengan memanggil class
26 #random projection
27 X_new = transformer.fit_transform(X)
28 #X new di sini sebagai estimator/parameter dan menggunakan metode
29 #fit
30 X_new.dtype
31 #X new.dtype sebagai item
32
33
34 from sklearn import datasets
35 #pada baris ini merupakan sebuah perintah untuk mengimport class
36 #datasets dari packaged sklearn
37 from sklearn.svm import SVC
38 #pada baris ini merupakan sebuah perintah untuk mengimport class
39 #SVC dari packaged sklearn.svm
40 iris = datasets.load_iris()
41 #iris sebagai estimator/parameter dengan item datasets.load_iris
42 #()
43 clf = SVC(gamma='scale')
44 #clf sebagai estimator/parameter dengan nilai class SVC pada
45 #parameter gamma sebagai set penilaian
46 clf.fit(iris.data, iris.target)
47 #estimator/parameter clf menggunakan metode fit dengan itemnya
48 list(clf.predict(iris.data[:3]))
49 #menambahkan item list dengan metode predict
50 clf.fit(iris.data, iris.target_names[iris.target])
51 #estimator/parameter clf menggunakan metode fit dengan itemnya
52 list(clf.predict(iris.data[:3]))
53 #menambahkan item list dengan metode predict
```

Refitting and updating parameters

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Wed Feb 26 23:08:34 2020
4
5 @author: User
6 """
7
8 #Multiclass vs. Multilabel Fitting
9 from sklearn.svm import SVC
10 #pada baris ini merupakan sebuah perintah untuk mengimport class
11 #SVC dari packaged sklearn.svm
12 from sklearn.multiclass import OneVsRestClassifier
13 #pada baris ini merupakan sebuah perintah untuk mengimport class
14 #OneVsRestClassifier dari packaged sklearn.multiclass
15 from sklearn.preprocessing import LabelBinarizer
16 #pada baris ini merupakan sebuah perintah untuk mengimport class
17 #LabelBinarizer dari packaged sklearn.preprocessing
18 X = [[1, 2], [2, 4], [4, 5], [3, 2], [3, 1]]
19 y = [0, 0, 1, 1, 2]
20 classif = OneVsRestClassifier(estimator=SVC(gamma='scale',
21                                     random_state=0))
22 classif.fit(X, y).predict(X)
23 y = LabelBinarizer().fit_transform(y)
24 classif.fit(X, y).predict(X)
25
26 from sklearn.preprocessing import MultiLabelBinarizer
27 y = [[0, 1], [0, 2], [1, 3], [0, 2, 3], [2, 4]]
28 y = MultiLabelBinarizer().fit_transform(y)
29 classif.fit(X, y).predict(X)

```

Multiclass vs. multilabel fitting

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Wed Feb 26 23:10:03 2020
4
5 @author: User
6 """
7
8 #Refitting and Updating Parameters
9 import numpy as np
10 #pada baris ini merupakan sebuah perintah untuk mengimport class
11 #svm dari np
12 from sklearn.svm import SVC
13 #pada baris ini merupakan sebuah perintah untuk mengimport class
14 #SVC dari packaged sklearn.svm
15 rng = np.random.RandomState(0)
16 #rng sebagai estimator/parameter dengan nilai suatu itemnya yaitu
17 #np.random.RandomState(0)
18 X = rng.rand(100, 10)
19 #X sebagai estimator/parameter dengan nilai item rng.rand
20 y = rng.binomial(1, 0.5, 100)
21 #y sebagai estimator/parameter dengan nilai item rng.binomial
22 X_test = rng.rand(5, 10)
23 #X test sebagai estimator/parameter dengan nilai item rng.rand

```

```

21 clf = SVC()
22 #clf sebagai estimator/parameter dan class SVC
23 clf.set_params(kernel='linear').fit(X, y)
24 #set params sebagai item
25 clf.predict(X_test)
26 #menggunakan metode predict
27 clf.set_params(kernel='rbf', gamma='scale').fit(X, y)
28 clf.predict(X_test)

```

1.5.4 Penanganan eror

```

File "C:\Users\User\Anaconda3\lib\site-packages\spyder_kernels\customize
\spydercustomize.py", line 827, in runfile
execfile(filename, namespace)

File "C:\Users\User\Anaconda3\lib\site-packages\spyder_kernels\customize
\spydercustomize.py", line 110, in execfile
exec(compile(f.read(), filename, 'exec'), namespace)

File "C:/Users/User/Documents/Spyder/2.py", line 14
X, y = iris.data, iris.target
^
IndentationError: unexpected indent

```

Gambar 1.50 Error

1.5.4.1 ScreenShoot Eror

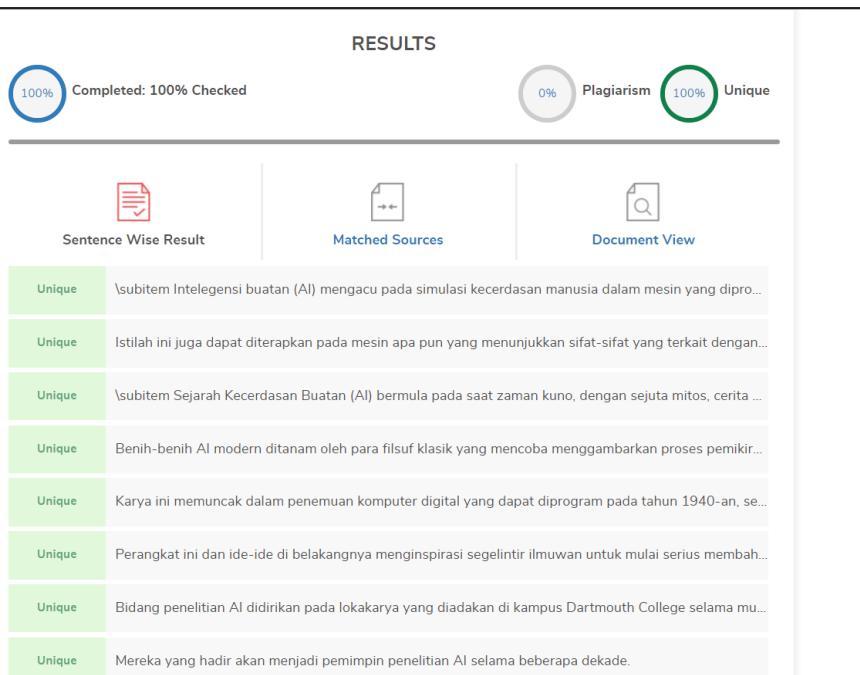
1.5.4.2 Tuliskan Kode Eror dan Jenis Erornya

IndentationError: unexpected indent

1.5.4.3 Solusi Pemecahan Masalah Error

Pastikan semua spasi pada koding sama. Menggunakan spasi atau tab.

1.5.5 Plagiarism



Gambar 1.51 Plagiarism

1.6 1174057 Alit Fajar Kurniawan

1.6.1 Teori

1.6.1.1 Sejarah Perkembangan dan Definisi Artificial Intelligence Kecerdasan buatan merupakan sebuah bidang dalam ilmu computer yang begitu penting di zaman ini dan masa yang akan datang guna mewujudkan sebuah sistem computer yang begitu cerdas. Artificial Intelligence atau biasa disingkat dengan AI berasal dari bahasa latin yang dimana intelligence berarti saya paham.

Pada tahun 1955, Newell dan juga Simon telah mengembangkan The Logic Theorist, yaitu program AI pertama. Dimana program tersebut mempresentasikan sebuah masalah sebagai model pohon, lalu diselesaikan dengan cara memilih cabang yang akan mewujudkan kesimpulan terbenar dan tepat. Program AI tersebut berdampak sangat besar dan dapat mendjadi batu loncatan yang cukup penting dalam mengembangkan bidang AI [?].

Masa Perkembangan AI dimulai pada awal era komputer elektronik pada tahun 1941. dimana ditemukannya alat penyimpanan dan pemrosesan in-

formasi. kemudian dilanjutkan pada masa-masa persiapan AI yang terjadi pada tahun 1943-1956. Pada sekitaran tahun 1952-1969 merupakan masa awal perkembangan AI terjadi, dan pada tahun 1966-1974 perkembangan AI mengalami penurunan atau melambatnya proses dalam melakukan pengembangan. pada tahun 1969 sampai 10 tahun kedepan kembali terjadi perkembangan yang menciptakan inovasi sistem berbasis pengetahuan. dan sekitaran tahun 1980-an AI kembali menjadi sebuah industri yang terus berkembang sampai sekarang ini.

1.6.1.2 learning, klasifikasi, regresi dan unsupervised learning. Data set, training set dan testing set

1. Definisi Supervised Learning Dan Unsupervised Learning

Supervised Learning merupakan suatu pendekatan yang dimana terdapat data dan variable yang telah ditargetkan sehingga pendekatan tersebut bertujuan untuk dapat mengelompokkan sebuah data ke data yang sudah ada, beda dengan Unsupervised learning yang tidak mempunyai data, sehingga data yang ada harus di kelompokkan menjadi beberapa bagian.

2. Definisi Klasifikasi Dan Regresi

Klasifikasi adalah sebuah kegiatan penggolongan atau pengelompokkan. Menurut kamus besar bahasa Indonesia yang dimana klasifikasi merupakan penyusunan sistem di dalam kelompok atau golongan berdasarkan kaidah atau standar yang telah ditetapkan. Regresi adalah sebuah metode analisis statistic yang akan digunakan untuk melihat pengaruh variable.

3. Devinisi Dataset, Training Set, Dan Testing Set

Dataset adalah sebuah objek yang akan mempresentasikan sebuah data dan relasinya di memory. Struktur pada dataset ini mirip dengan data yang ada di dalam database. Training set adalah bagian dari dataset yang berperan dalam membuat prediksi atau algoritma sesuai tujuan masing-masing. Testing set adalah bagian dari dataset yang akan di tes guna melihat keakuratan atau ketepatan datanya.

1.6.2 Praktek

1.6.2.1 Instalasi

1. Melakukan instalasi library scikit pada anaconda, ketik kan pip install -U scikit-learn pada terminal anaconda.

```
(base) C:\Users\alitf>pip install -U scikit-learn
Collecting scikit-learn
  Downloading https://files.pythonhosted.org/packages/f8/d0/5b7088d1fb891596c34c8b09414cd3daef99876349dd686a3ad536cf9820
/scikit_learn-0.22.1-cp37-cp37m-win_amd64.whl (6.3MB)
|██████████| 6.3MB 297KB/s
Requirement already satisfied, skipping upgrade: numpy>=1.11.0 in c:\users\alitf\anaconda3\lib\site-packages (from scikit-learn) (1.16.4)
Requirement already satisfied, skipping upgrade: joblib>=0.11 in c:\users\alitf\anaconda3\lib\site-packages (from scikit-learn) (0.13.2)
Requirement already satisfied, skipping upgrade: scipy>=0.17.0 in c:\users\alitf\anaconda3\lib\site-packages (from scikit-learn) (1.2.1)
Installing collected packages: scikit-learn
  Found existing installation: scikit-learn 0.21.2
    Uninstalling scikit-learn-0.21.2:
      Successfully uninstalled scikit-learn-0.21.2
Successfully installed scikit-learn-0.22.1

(base) C:\Users\alitf>
```

Gambar 1.52 Instalasi Scikit Learn

- Setelah selesai instalasi, pilih salah satu example dari website Scikit.

Examples

Miscellaneous examples

Miscellaneous and introductory examples for scikit-learn.

Compact estimator representations

ROC Curve with Visualization API

Isotonic Regression

Advanced Plotting With Partial Dependence

Logistic regression coefficients visualization

Decision regions for multiple classifiers

Non-linear dimensionality reduction

Partial dependence plots for a random forest model

Gambar 1.53 Example

```

1 print(__doc__)
2
3 from sklearn.linear_model import LogisticRegression
4 from sklearn import set_config
5
6
7 lr = LogisticRegression(penalty='l1')
8 print('Default representation:')
```

```

9 print(lr)
10 # LogisticRegression(C=1.0, class_weight=None, dual=False ,
11 #                         fit_intercept=True,
12 #                         max_iter=100,
13 #                         multi_class='auto', n_jobs=None, penalty
14 #                         ='l1',
15 #                         random_state=None, solver='warn', tol
16 #                         =0.0001, verbose=0,
17 #                         warm_start=False)
18
19 set_config(print_changed_only=True)
20 print('\nWith changed_only option:')
21 print(lr)
22 # LogisticRegression(penalty='l1')

```

kemudian coba jalankan, lihat hasilnya

@author: alitf

Default representation:

`LogisticRegression(penalty='l1')`

With changed_only option:

`LogisticRegression(penalty='l1')`

Gambar 1.54 Example

3. latihan 2 Mencoba Loading an example dataset

```

1 from sklearn import datasets #mengimport class dataset dari
2     scikit learn library
3 iris = datasets.load_iris() # memuat dan memasukkan dataset
4     iris ke variabel bernama iris
5 digits = datasets.load_digits() #memuat dan memasukkan
6     dataset digits ke variabel digits
7
8 print(digits.data) #memberikan akses ke fitur yang dapat
9     digunakan untuk mengklasifikasikan sampel digit dan
10    menampilkannya di console
11
12 digits.target #memberikan informasi tentang data yang
13    berhubungan atau juga dapat dijadikan sebagai label
14
15 digits.images[0] #Data selalu berupa array 2D, shape (
16     n_samples, n_features), meskipun data aslinya mungkin
17    memiliki bentuk yang berbeda.

```

hasil dari data digits

```
In [17]: runfile('C:/Users/alitf/OneDrive/Desktop/AI/src/1174057'
              wdir='C:/Users/alitf/OneDrive/Desktop/AI/src/1174057/chapter1')
[[ 0.  0.  5. ...  0.  0.  0.]
 [ 0.  0.  0. ... 10.  0.  0.]
 [ 0.  0.  0. ... 16.  9.  0.]
 ...
 [ 0.  0.  1. ...  6.  0.  0.]
 [ 0.  0.  2. ... 12.  0.  0.]
 [ 0.  0.  10. ... 12.  1.  0.]]
```

Gambar 1.55 Result Data Digits

hasil dari digits.target

```
In [19]: digits.target #memberikan informasi
          dijadikan sebagai Label
Out[19]: array([0, 1, 2, ..., 8, 9, 8])
```

Gambar 1.56 Result digits.target

hasil dari digits.image

```
In [20]: digits.images[0] #Data selalu berupa array 2D, s
          meskipun data aslinya mungkin memiliki bentuk yang berbeda
Out[20]:
array([[ 0.,  0.,  5., 13.,  9.,  1.,  0.,  0.],
       [ 0.,  0., 13., 15., 10., 15.,  5.,  0.],
       [ 0.,  3., 15.,  2.,  0., 11.,  8.,  0.],
       [ 0.,  4., 12.,  0.,  0.,  8.,  8.,  0.],
       [ 0.,  5.,  8.,  0.,  0.,  9.,  8.,  0.],
       [ 0.,  4., 11.,  0.,  1., 12.,  7.,  0.],
       [ 0.,  2., 14.,  5., 10., 12.,  0.,  0.],
       [ 0.,  0.,  6., 13., 10.,  0.,  0.,  0.]])
```


Gambar 1.57 Result digits.image

```

1 from sklearn import svm # perintah untuk mengimport class svm
    dari packaged sklearn
2
3 digits = datasets.load_digits() #memuat dan memasukkan
    dataset digits ke variabel digits
4
5 clf = svm.SVC(gamma=0.001, C=100.) #clf sebagai estimator/
    parameter , svm.SVC sebagai class , gamma sebagai
    parameter untuk menetapkan nilai secara manual
6
7 clf.fit(digits.data[:-1], digits.target[:-1]) # clf sebagai
    estimator/parameter , f i t sebagai metode , digits . data
    sebagai item , [:1] sebagai syntax pythonnya dan
    menampilkan outputannya
8
9 print(clf.predict(digits.data[-1])) #clf sebagai estimator/
    parameter , predict sebagai metode lainnya , digits . data
    sebagai item dan menampilkan outputannya

```

kemudian coba jalankan, lihat hasilnya



Gambar 1.58 Result Learning and predicting

5. latihan 4 Mencoba Model persistence

```

1 from sklearn import svm, datasets #mengimport class dataset
    dari scikit learn library

```

```

2 clf = svm.SVC(gamma=0.001, C=100.) #memanggil class SVC dan
   menyet argument constructor SVC serta ditampung di
   variable clf
3 X, y = datasets.load_iris(return_X_y=True) #meload datasets
   iris dan ditampung di variable x untuk data dan y untuk
   target
4 clf.fit(X, y) #memanggil method fit untuk melakukan training
   data dengan argumen data dan target dari datasets iris
5
6 #Pickle
7 import pickle #mengimport pickle
8 s = pickle.dumps(clf) #memanggil method dumps dengan argumen
   clf dan ditampung di variable s
9 clf2 = pickle.loads(s) #memanggil method loads dengan argumen
   s dan ditampung di variable clf2
10 print(clf2.predict(X[0:1])) #menampilkan hasil dari method
    predict dengan argumen data variable X pertama
11
12 #Joblib
13 from joblib import dump, load #mengimport dump dan load dari
   library joblib
14 dump(clf, '1174057.joblib') #memanggil method dumps dengan
   argumen clf dan nama file joblibnya
15 clf3 = load('1174057.joblib')#memanggil method loads dengan
   argumen nama file joblibnya dan ditampung di variable clf3
16 print(clf3.predict(X[0:1])) #menampilkan hasil dari method
    predict dengan argumen data variable X pertama

```

kemudian coba jalankan, lihat hasilnya

```

In [13]: runfile('D:/Data Alit/Kuliah,
modelpersistence.py', wdir='D:/Data A:
[0]
[0]

```

Gambar 1.59 Result Model persistence

6. latihan 5 Mencoba Conventions

```

1 #Type casting
2 import numpy as np
3 from sklearn import random_projection
4 rng = np.random.RandomState(0)
5 X = rng.rand(10, 2000)
6 X = np.array(X, dtype='float32')
7 print(X.dtype)
8 transformer = random_projection.GaussianRandomProjection()
9 X_new = transformer.fit_transform(X)

```

```
10 print(X_new.dtype)
11
12 from sklearn import datasets
13 from sklearn.svm import SVC
14 iris = datasets.load_iris()
15 clf = SVC(gamma=0.001, C=100.)
16 clf.fit(iris.data, iris.target)
17 print(list(clf.predict(iris.data[:3])))
18 clf.fit(iris.data, iris.target_names[iris.target])
19 print(list(clf.predict(iris.data[:3])))
20
21 #Refitting and updating parameters
22 import numpy as np
23 from sklearn.datasets import load_iris
24 from sklearn.svm import SVC
25 X, y = load_iris(return_X_y=True)
26 clf = SVC(gamma=0.001, C=100.)
27 clf.set_params(kernel='linear').fit(X, y)
28 print(clf.predict(X[:5]))
29 clf.set_params(kernel='rbf').fit(X, y)
30 print(clf.predict(X[:5]))
31
32 #Multiclass vs. Multilabel Fitting
33 from sklearn.svm import SVC
34 from sklearn.multiclass import OneVsRestClassifier
35 from sklearn.preprocessing import LabelBinarizer
36 X = [[1, 2], [2, 4], [4, 5], [3, 2], [3, 1]]
37 y = [0, 0, 1, 1, 2]
38 classif = OneVsRestClassifier(estimator=SVC(random_state=0,
                                              gamma=0.001, C=100.))
39 print(classif.fit(X, y).predict(X))
40 y = LabelBinarizer().fit_transform(y)
41 print(classif.fit(X, y).predict(X))
42
43 from sklearn.preprocessing import MultiLabelBinarizer
44 y = [[0, 1], [0, 2], [1, 3], [0, 2, 3], [2, 4]]
45 y = MultiLabelBinarizer().fit_transform(y)
46 print(classif.fit(X, y).predict(X))
```

kemudian coba jalankan, lihat hasilnya

```
In [20]: runfile('C:/Users/Alit/Desktop/KB3A/src/1174006/chapter1/coba4.py', wdir='C:/Users/Alit/Desktop/KB3A/src/1174006/chapter1')
float32
float64
[0, 0, 0]
['setosa', 'setosa', 'setosa']
[0 0 0 0]
[0 0 0 0]
[0 0 1 1 2]
[[1 0 0]
 [1 0 0]
 [0 1 0]
 [0 0 0]
 [0 0 0]]
[[1 0 1 0 0]
 [1 0 1 0 0]
 [1 0 1 1 0]
 [1 0 1 0 0]
 [1 0 1 0 0]]
```

Gambar 1.60 Result Conventions

1.6.3 Penanganan Error

1. Screenshot Error

```
File "D:/Data Alit/Kuliah/SEMESTER VI/AI/src/1174057/chapter1/learning.py", line 5, in
<module>
    clf.fit(digits.data[:-1], digits.target[:-1]) # clf sebagai estimator/parameter , f
i t sebagai metode , digits . data sebagai item , [:1] sebagai syntax pythonnya dan
menampilkan outputannya

NameError: name 'digits' is not defined
```

Gambar 1.61 Error

```
File "D:/Data Alit/Kuliah/SEMESTER VI/AI/src/1174057/chapter1/learning.py", line 3
    digits = datasets . load digits () #meload datasets digits dan ditampung di variable
digits
^
SyntaxError: invalid syntax
```

Gambar 1.62 Error

2. Tuliskan kode dan jenis error

is not defined, xception yang terjadi saat syntax melakukan eksekusi terhadap local name atau global name yang tidak terdefinisi.

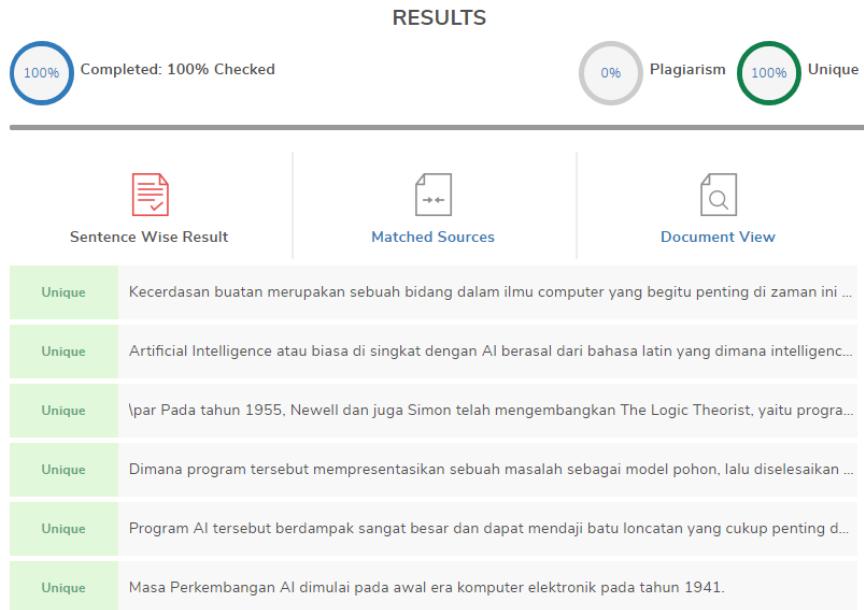
invalid syntax

3. Solusi penanganan error

Solusinya adalah memastikan variabel atau function yang dipanggil ada atau tidak salah ketik.

Periksa kembali syntax yang dibuat, bisa saja ada kesalahan dalam spasi.

1.6.4 Bukti Tidak Plagiat



Gambar 1.63 Plagiarisme

1.7 1174039 - Liyana Majdah Rahma

1.7.1 Teori

1.7.1.1 Definisi Kecerdasan Buatan Artificial Intelligence adalah kecerdasan yang ditambahkan pada suatu sistem yang dapat diatur dalam konteks secara ilmiah. Menurut Michael Haelein menyatakan bahwa AI merupakan “sistem yang mempunyai kemampuan untuk menguraikan, belajar agar dapat dgunakan untuk mencapai tujuan dengan melalui adaptasi yang fleksibel”. Kecerdasan buatan juga dapat dibuat dan dimasukkan ke dalam mesin agar dapat melakukan pekerjaan seperti yang dapat dilakukan manusia dengan cepat dan tepat.

1.7.1.2 Sejarah Kecerdasan Buatan Sejarah Kecerdasan buatan pertama kali terjadi pada zaman kuno, terdapat mitos ataupun cerita dan desas-desus tentang sebuah makhluk yang mempunyai kecerdasan serta kesadaran yang

diberikan oleh pengrajin. Benih - benih nya mulai ditanam oleh para filsuf klasik yang mencari cara untuk menggambarkan proses berfikir manusia sebagai manipulasi simbol secara mekanis yang memuncak pada penemuan komputer digital di tahun 1940-an, yaitu sebuah mesin yang didasarkan penalaran matematika. Istilah kecerdasan buatan sendiri baru muncul pada tahun 1956, dan teori -teori nya sudah muncul sejak tahun 1941. Dan Pada tahun 1973, sebagai tanggapan atas kritik dari James Lighthill dan tekanan terus-menerus dari kongres, AS dan Pemerintah Inggris menghentikan pendanaan penelitian yang tidak diarahkan pada kecerdasan buatan, dan tahun-tahun sulit berikutnya akan dikenal sebagai musim dingin AI. Tujuh tahun kemudian, sebuah inisiatif visioner oleh Pemerintah Jepang mengilhami pemerintah dan industri untuk menyediakan miliaran dolar dalam AI, tetapi pada akhir 80-an investor menjadi kecewa dengan kurangnya daya komputer (perangkat keras) yang dibutuhkan dan menarik lebih banyak dana.

1.7.1.3 Perkembangan Kecerdasan Buatan

1. Pada tahun 1958, McCarthy di MIT AI Lab Memo orang pertama yang mendefinisikan bahasa pemrograman pada tingkat tinggi yaitu LISP, yang sekarang mendominasi pembuatan program-program kecerdasan buatan.
2. Kemudian Pada tahun 1959, Nathaniel Rochester dari IBM serta mahasiswa-mahasiswanya mengeluarkan program kecerdasan buatan yaitu Geometry Theorem Prover. selain itu juga Program ini dapat mengeluarkan suatu teorema menggunakan aksioma-aksioma yang ada.
3. Sistem Berbasis Pengetahuan pada tahun 1969-1979
4. Kecerdasan Buatan menjadi sebuah industri pada tahun 1980-1988. Kembaliya Jaringan Syaraf tiruan pada tahun 1986-sekarang.

1.7.2 Instalasi

1.7.2.1 Instalasi Library Scikit dari Anaconda

1. Download aplikasi Anaconda terlebih dahulu.
2. Install aplikasi Anaconda yang sudah di download tadi.
3. Simpan aplikasi sesuai folder yang kita pilih lalu next.
4. Centang Keduanya lalu tekan tombol install.
5. Setelah itu tunggu sampai proses instalasi selesai lalu jika sudah tekan tombol finish.
6. Lalu buka command prompt anda dan tuliskan perintah berikut ini untuk mengecek apakah aplikasinya sudah terinstall.

7. Kemudian ketikkan perintah pip install -U scikit-learn seperti gambar berikut.



Gambar 1.64 Instalasi

1. Pilih salah satu example dari website tersebut lalu jalankan

```

1 import matplotlib.pyplot as plt
2 from sklearn.svm import SVC
3 from sklearn.ensemble import RandomForestClassifier
4 from sklearn.metrics import plot_roc_curve
5 from sklearn.datasets import load_wine
6 from sklearn.model_selection import train_test_split
7
8 X, y = load_wine(return_X_y=True)
9 y = y == 2
10
11 X_train, X_test, y_train, y_test = train_test_split(X, y,
12         random_state=42)
13 svc = SVC(random_state=42)
14 svc.fit(X_train, y_train)

```

2. buka variable explolernya



Gambar 1.65 Variable Exploler

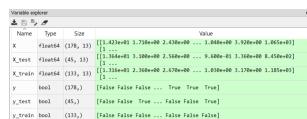
- salah satu example dari website tersebut lalu jalankan

```

1 import matplotlib.pyplot as plt
2 from sklearn.svm import SVC
3 from sklearn.ensemble import RandomForestClassifier
4 from sklearn.metrics import plot_roc_curve
5 from sklearn.datasets import load_wine
6 from sklearn.model_selection import train_test_split
7
8 X, y = load_wine(return_X_y=True)
9 y = y == 2
10
11 X_train, X_test, y_train, y_test = train_test_split(X, y,
12         random_state=42)
13 svc = SVC(random_state=42)
14 svc.fit(X_train, y_train)

```

buka variable explolernya



Gambar 1.66 Variable Exploler

8fcee3a95c7a660681b429f909ba80ac1a4fa418

1.7.2.2 Mencoba loading an example dataset

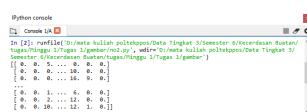
1. mengambil data iris dan digit dari dataset

```

1 iris = datasets.load_iris() # Dapat membuat sebuah variable
    iris yang mempunyai isi yaitu dataset iris
2 digits = datasets.load_digits() # Digunakan untuk membuat
    sebuah variable digits yang mempunyai isi yaitu dataset
    digits

```

2. Menampilkan data digits



Gambar 1.67 Data Digits

3. menampilkan digits.target

```

In [16]: digits.target
Out[16]: array([0, 1, 2, ..., 8, 9, 8])

```

Gambar 1.68 Digits Target

4. menampilkan data bentuk 2D.

```
In [17]: digits.images[0]
Out[17]:
array([[ 0.,  0.,  5., 13.,  9.,  1.,  0.,  0.],
       [ 0.,  0., 13., 15., 10., 15.,  5.,  0.],
       [ 0.,  3., 15.,  2.,  0., 11.,  8.,  0.],
       [ 0.,  4., 12.,  0.,  0.,  8.,  8.,  0.],
       [ 0.,  5.,  8.,  0.,  0.,  9.,  8.,  0.],
       [ 0.,  4., 11.,  0.,  1., 12.,  7.,  0.],
       [ 0.,  2., 14.,  5., 10., 12.,  0.,  0.],
       [ 0.,  0.,  6., 13., 10.,  0.,  0.,  0.]])
```

Gambar 1.69 Data 2D

1.7.2.3 Mencoba Learning and Predicting

```
1 from sklearn.linear_model import LogisticRegression # digunakan
   untuk mengimport linear_model dari library sklearn
2 from sklearn.datasets import make_blobs #digunakan untuk
   mengimport library datasets dari sklearn
3
4 X, y = make_blobs(n_samples=100, centers=2, n_features=2,
   random_state=1) # dapat untuk generate dataset dengan
   klasifikasi 2D
5 model = LogisticRegression() # dapat menggunakan metode loginstic
   regression
6 model.fit(X, y)
7
8 Xnew, _ = make_blobs(n_samples=3, centers=2, n_features=2,
   random_state=1) # dapat menentukan 1 buah contoh baru dimana
   jawabannya tidak dapat diketahui
9
10 ynew = model.predict_proba(Xnew) # membuat sebuah prediksi dan
   memasukkan nya kedalam variable ynew
11 for i in range(len(Xnew)):
12     print("X=%s, Predicted=%s" % (Xnew[i], ynew[i])) #menampilkan
   hasil prediksi
```

1.7.2.4 Mencoba Model Persistence

```
1 from sklearn import svm #dapat mengimport svm dari library
   sklearn
2 from sklearn import datasets #digunakan untuk mengimport datasets
   dari library sklearn
3 clf = svm.SVC() # digunakan dengan menggunakan method SVC
4 iris = datasets.load_iris() # digunakan dengan menggunakan
   dataset iris
5 X, y = iris.data, iris.target #memasukkan x sebagai iris data ,
   dan y sebagai iris target
6 clf.fit(X, y) #laalu menggunakan metod fit .
```

1.7.2.5 Mencoba Conventions

```
1 import numpy as npy #mengimport numpy sebagai npy
2 from sklearn import random_projection #mengimport
   random_projection dari library sklearn
```

```
3
4 rng = np.random.RandomState(0) #Menggunakan fungsi random dari
5     numpy
6 X = rng.rand(10, 2000) #membuat range random diantara 10 sampai
7     2000
8 X = np.array(X, dtype='float32') #yang dijadikan array dengan
9     tipe data float32
10 X.dtype
```

1.7.3 Penanganan Error

```
ValueError: Found array with 0 sample(s) (shape=(0, 2)) while a minimum of 1 is required.
```


Gambar 1.70 Data 2D

1.7.3.1 Screenshot Error

1.7.3.2 Kode error dan jenis error Jenis errornya adalah value error

1.7.3.3 Solusi Error Solusinya adalah dengan menggantikan nilai nya adalah n_samples nya agar tidak 0

1.7.4 Cek Plagiarism



Gambar 1.71 Cek Plagiarism

BAB 2

CHAPTER 2

2.1 1174042 Faisal Najib Abdullah

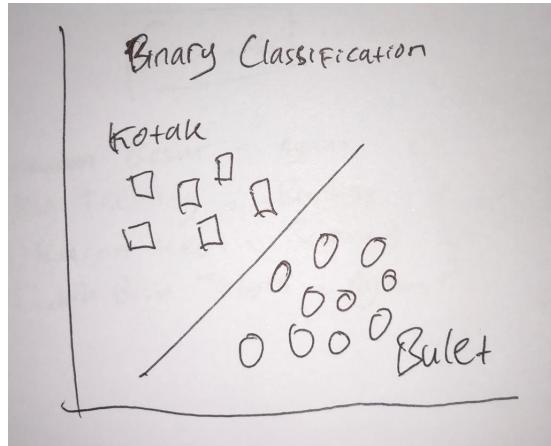
2.1.1 Teori

1. Jelaskan Apa Itu binari classification dilengkapi ilustrasi gambar sendiri.

Binary Classification atau biominal adalah tugas mengklasifikasikan unsur unsur dari himpunan yang diberikan kedalam kedua kelompok berdasarkan aturan klasifikasi yang telah ditetapkan. binari clasification juga dapat diartikan sebagai pembagi yang hanya memberikan dua pilihan contohnya benar dan salah atau klasifikasi tongkat panjang atau pendek. penjelasan lebih singkatnya binari classification merupakan kegiatan mengklasifikasikan yang hanya memberikan dua class.

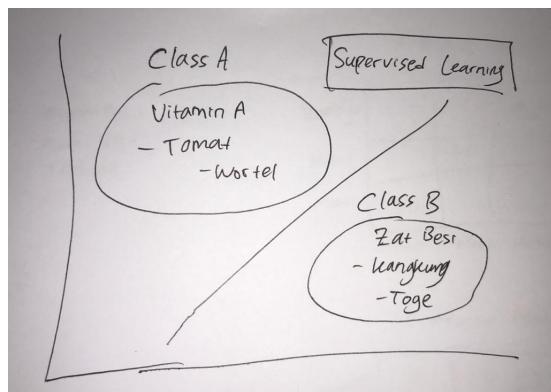
2. Jelaskan Apaitu supervised learning , unsupervised learning dan clustering dengan ilustrasi gambar sendiri.

supervised learning adalah cara untuk mengklasifikasikan suatu objek atau data yang telah di tentukan kelas kelasnya contoh pada sayuran tumbuhan wortel termasuk yang mengandung vitamin A berarti tum-



Gambar 2.1 contoh binari calssification

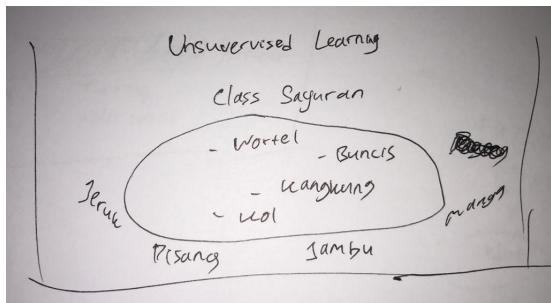
bahan wortel telah di kategorikan kedalam sayuran yang mengandung vitamin A. sedangkan kangkung mengandung zat besi yang berarti tumbuhan kangkung telah di kategorikan kedalam sayuran yang mengandung zat besi untuk lebih jelasnya dapat dilihat pada gambar.



Gambar 2.2 contoh supervised learning

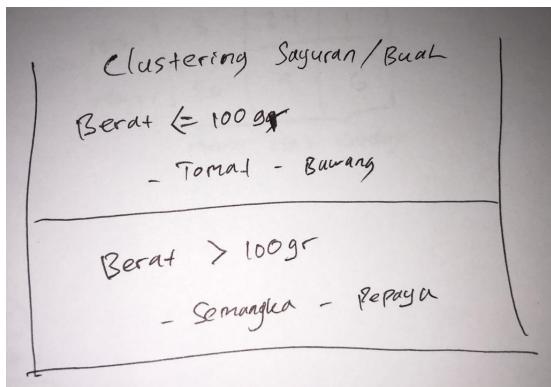
unsupervised learning merupakan cara untuk mengklasifikasi tanpa adanya kelas untuk menentukan jenisnya contoh sayuran berarti semua objek yang memiliki ciri ciri sayuran di kategorikan kedalam sayuran untuk lebih jelasnya dapat dilihat pada gambar.

clustering merupakan peroses mengklasifikasikan yang berdasarkan suatu parameter dalam penentuannya contoh pada berat sayuran sayuran A memiliki berat 100 gr dan sayuran B memiliki berat 120 gr yang berarti



Gambar 2.3 contoh unsupervised learning

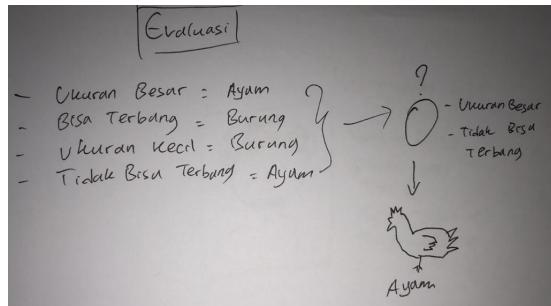
berat sayuran dibagi dua parameter yaitu lebih kecil samadengan 100 gram dan lebih besar dari gram contoh pada gambar.



Gambar 2.4 contoh clustering

3. Jelaskan apa itu evaluasi dan akurasi dan disertai ilustrasi contoh dengan gambar sendiri.

evaluasi adalah pengumpulan pengumpulan dan pengamatan dari berbagai macam bukti untuk mengukur dampak efektifitas dari suatu objek, program, atau proses berkaitan dengan spesifikasi atau persyaratan yang telah ditetapkan sebelumnya. sedangkan akurasi itu sendiri merupakan bagian dari evaluasi yang merupakan ketepatan data terhadap suatu objek berdasarkan kriteria tertentu. kita dapat mengevaluasi seberapa baik model bekerja dengan mengukur akurasinya. ketepatan akan definisikan sebagai persentase kasus yang di klasifikasikan dengan benar. hal ini berkaitan dengan confusion matrix pada materi selanjutnya. contoh evaluasi untuk membedakan burung dengan ayam terdapat parameter yaitu ukuran badan dan fungsi sayap pada hewan tersebut. lebih jelasnya pada gambar berikut:



Gambar 2.5 contoh evaluasi dan akurasi

4. Jelaskan bagaimana cara membuat Confusion Matrix, Buat confusion matrix sendiri.

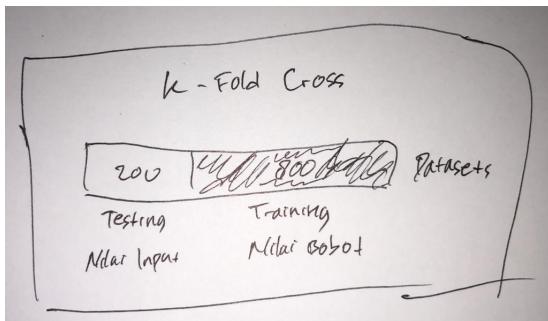
Dalam pembuatan confusion matrix tentukan parameter atau objek yang akan di evaluasi contoh bunga melati , bunga mawar, dan bunga kenangan buat tabel dengan baris dan kolom berjumlah tiga kemudian tentukan nilai miring pada setiap kolom tersebut disini saya memberi nilai 30 dengan ketentuan setiap baris harus berisi nilai 30 nilai tersebut jika terbagi ke kolom lain maka jumlahnya harus bernilai 30 jika tidak berarti data tersebut tidak akurat. untuk lebih jelanya dapat dilihat pada gambar berikut :

Confusion Matrix			
Kembang	Melati	30	
	Melati	30	
	Mawar	30	
Kembang	Melati	Kembang	

CONFUSION MATRIX			
Kembang	Melati	23	
	Melati	24	1
	Mawar	20	4
Kembang	Melati	Kembang	

Gambar 2.6 contoh Confusion Matrix

5. Jelaskan bagaimana K-fold cross validation bekerja dengan gambar ilustrasi contoh buatan sendiri. K-fold Cross Validation merupakan cara untuk melatih suatu mesin dimana di dalamnya terdapat data set yang dibagi menjadi dua yaitu untuk data testing dan data training contoh 1000 data merupakan data set dan 200 data digunakan untuk data testing kemudian 800 datanya digunakan untuk data training dimana data training tersebut digunakan untuk menentukan nilai bobot yang dimasukan kedalam rumus regresi linier. sedangkan nilai testing akan dijadikan nilai inputan untuk rumus regresi linier. contohnya dapat dilihat pada gambar berikut :



Gambar 2.7 contoh K-fold cross validation

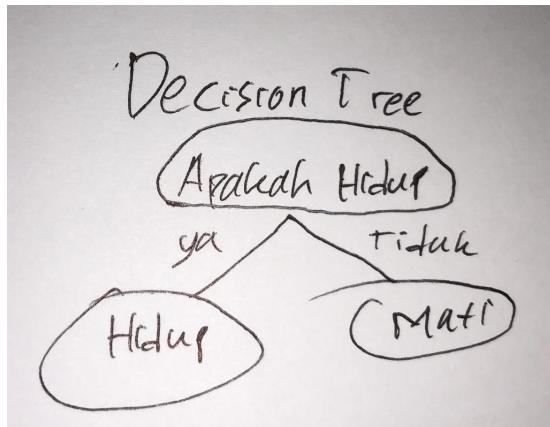
6. Jelaskan Apa itu decision tree dengan gambar ilustrasi contoh buatan sendiri.

Decision tree (pohon keputusan) merupakan implementasi dari binari clasification dimana pada pohon keputusan akan terdapat root atau akar dan cabang cabangnya yang nilainya seperti if contoh pada root berisi nilai jenis kelamin, apakah perempuan pada cabang satu bernilai iya dan pada cabang dua bernilai tidak jika nilainya iya berarti jenis kelamminya perempuan dan jika tidak maka bernilai laki-laki. agar lebih jelas dapat dilihat pada gambar decision tree berikut:

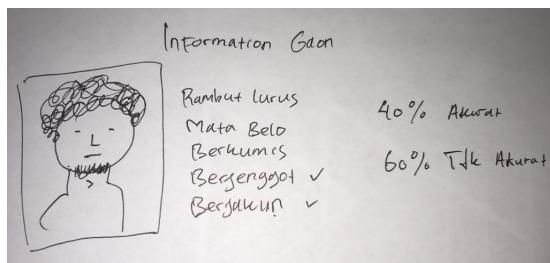
7. jelaskan apa itu information gain dan entropi dengan gambar ilustrasi buatan sendiri.

informasian gain merupakan informasi atau keriteria dalam pembagian sebuah objek contoh information gain pada laki-laki yaitu berrambut lurus, mata belo, berkumis, berjenggot, dan memiliki jakun. untuk lebih jelasnya dapat dilihat pada gambar berikut :

sedangkan entropi merupakan ukuran keacakan dari informasi semakin tinggi entropi maka semakin sulit dalam menentukan keputusan contoh dalam menentukan jenis kelamin semakin detail informasi maka akan semakin susah dalam menentukan keputusan.



Gambar 2.8 contoh decision tree



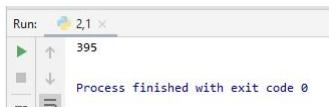
Gambar 2.9 contoh information gain

2.1.2 Sikic-Learn

1. pada surcode pertama yang dapat dilihat pada gambar pada baris pertama di tuliskan yang berarti mengimport library padas. selanjutnya pada baris ke dua codingan tersebut berisi pada code tersebut terdapat variabel muaraenim yang berisi inisialisasi padas dengan aksi untuk membaca vfile csv yang terdapat pada direktori pada komputer kemudian terdapat sep samadengan titik koma yang berarti pemisah field di dalam vile tersebut merupakan titik koma. kemudian pada bagian akhir terdapat code len (nama variabel) yang berarti akan menghotung jumlah baris pada file tersebut.

```

1 # load dataset (student mat pakenya)
2 import pandas as pd
3 muaraenim = pd.read_csv('D:/NAJIB/SEMESTER_6_NAJIB/AI/
Chapter2/dataset/student-mat.csv', sep=';')
4 print(len(muaraenim))
  
```



Gambar 2.10 hasil

2. Pada code selanjutnya akan ditambahkan fungsi untuk lulus atau gagal yang dibuat berupa kolom kolom yang di dalamnya terdapat nilai 0 dan 1 dimana 0 berarti gagal dan 1 berarti lulus. kemudian variabel pada codingan sebelumnya masih digunakan. dimana variabel muaraenim digunakan karena berisi file csv kemudian dilakukan ekseskuasi dengan parameter G1, G2, dan G3 dengan fungsi lambda yang berarti if bersarang atau if didalam if yang berarti nilai yang di eksekusi akan dilempar ke dalam setiap paramater sasuai dengan kriteria dan axis=1 yaitu nilai tersebut akan digunakan dari tiap baris data. sedangkan pada codingan selanjutnya variabel muaraenim di berikan aksi drop yaitu penurunan nilai pada bagian baris data. dan pada code muaraenim.head() yaitu untuk mengeksekusi codingan sebelumnya.

```

1 # generate binary label (pass/fail) based on G1+G2+G3
2 # (test grades, each 0–20 pts); threshold for passing is sum
   >=30
3 muaraenim[ 'pass' ] = muaraenim . apply (lambda row: 1 if (row[ 'G1'
   '] +row[ 'G2' ] +row[ 'G3' ]) 
4 >= 35 else 0, axis=1)
5 muaraenim = muaraenim . drop ([ 'G1' , 'G2' , 'G3' ], axis=1)
6 print (muaraenim . head ())

```

	school	sex	age	address	famsize	...	Dalc	Walc	health	absences	pass
0	GP	F	18	U	GT3	...	1	1	3	6	0
1	GP	F	17	U	GT3	...	1	1	3	4	0
2	GP	F	15	U	LE3	...	2	3	3	10	0
3	GP	F	15	U	GT3	...	1	1	5	2	1
4	GP	F	16	U	GT3	...	1	2	5	4	0

[5 rows x 31 columns]

Process finished with exit code 0

Gambar 2.11 hasil

3. pada kodingan selanjutnya diguanakan untuk menambahkan nilai numerik berupa 0 dan 1 yang dirubah dari nilai tidak dan iya hal ini merupakan fungsi dari codingan get_dummies pada baris pertama yang nilainya diambil dari variabel muaraenim yang telah di deklarasikan tadi banyaknya data numerik itu sendiri tergantung pada field dari kolom yang di cattumkan pada codingan dengan catatan field tersebut harus ada dalam data csv yang di import oleh codingan pertama tadi maka hasilnya akan merubah data dalam field tersebut menjadi 0 dan 1.

```

1 # use one-hot encoding on categorical columns
2 muaraenim = pd.get_dummies(muaraenim, columns=['sex', 'school'
    , 'address', 'famsize', 'Pstatus', 'Mjob', 'Fjob', ,
    reason', 'guardian', 'schoolsups', 'famsup', 'paid', ,
    activities', 'nursery', 'higher', 'internet', 'romantic'])
3 muaraenim.head()

```

	age	Medu	Fedu	...	internet_yes	romantic_no	romantic_yes
0	18	4	4	...	0	1	0
1	17	1	1	...	1	1	0
2	15	1	1	...	1	1	0
3	15	4	2	...	1	0	1
4	16	3	3	...	0	1	0

[5 rows x 59 columns]

Process finished with exit code 0

Gambar 2.12 hasil

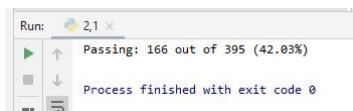
4. selanjutnya pada codingan selanjutnya yaitu menentukan data training dan data testing dari dataset dimana variabel muaraenim yang berisi data csv tadi dibuat perbandingan 500 untuk data training dan sisanya yaitu 149 digunakan untuk data testing hal ini di lakukan pada baris ke 1 sampai ke 3 pada gambar kemudian nilai tersebut di turunkan brdasarkan baris pada data set hal itu dapat dilihat pada baris ke 4 sampai ke 9 pada gambar kemudian selanjutnya mengimport library numpy yang berguna untuk oprasi vektor dan matrix karna data diatas berupa data matrix maka library ini di gunakan.

```

1 # shuffle rows
2 muaraenim = muaraenim.sample(frac=1)
3 # split training and testing data
4 muaraenim_train = muaraenim[:500]
5 muaraenim_test = muaraenim[500:]
6 muaraenim_train_att = muaraenim_train.drop(['pass'], axis=1)
7 muaraenim_train_pass = muaraenim_train['pass']
8 muaraenim_test_att = muaraenim_test.drop(['pass'], axis=1)
9 muaraenim_test_pass = muaraenim_test['pass']
10 muaraenim_att = muaraenim.drop(['pass'], axis=1)
11 muaraenim_pass = muaraenim['pass']
12 # number of passing students in whole dataset:
13 import numpy as np
14 print("Passing: %d out of %d (%.2f%%)" % (np.sum(
        muaraenim_pass), len(muaraenim_pass), 100*float(np.sum(
            muaraenim_pass)) / len(muaraenim_pass)))

```

5. selanjutnya yaitu membuat pohon keputusan pada baris pertama yairu memasukan librari tree kemudian pada baris kedua dibuat variabel palembang dengan nilai DecisionTreeClasifier yang merupakan paket atau fungsi dari scikit-learn yang merupakan class yang mampu melakukan multi

**Gambar 2.13** hasil

class. sedangkan max_depth=5 merupakan untuk penyesuaian data terhadap pohon keputusan itu sendiri.

```
1 # fit a decision tree
2 from sklearn import tree
3 palembang = tree.DecisionTreeClassifier(criterion="entropy",
   max_depth=5)
4 palembang = palembang.fit(muaraeni,_train_att,
   muaraeni_train_pass)
```

**Gambar 2.14** hasil

- selanjutnya yaitu pembuatan gambar dari pohon keputusan yang tadi dibuat pada codingan sebelumnya pada baris pertama codingan ya itu mengimport library graphviz kemudian pada baris ke dua yaitu pemberian nilai pada variabel baru dot data nilainya diambil dari pembuatan pohon keputusan tadi kemudian ditentukannya nilai benar dan salah dari codingan tersebut setelah itu dibuatlah sebuah variabel untuk menampung hasil eksekusi tersebut kemudian variabel tersebut di running.

```
1 # visualize tree
2 import graphviz
3 dot_data = tree.export_graphviz(palembang, out_file=None,
   label="all", impurity=False, proportion=True,
   feature_names=list(
      muaraenim_train_att), class_names=["fail", "pass"],
   filled=True, rounded=True)
5 graph = graphviz.Source(dot_data)
7 graph
```

- selanjutnya pembuatan method untuk menyimpan data pohon dengan menarik data langsung dari pohon keputusan.

```
1 # save tree
2 tree.export_graphviz(palembang, out_file="student-performance
   .dot", label="all", impurity=False, proportion=True,
   feature_names=list(muaraenim_train_att),
   class_names=["fail", "pass"], filled=True, rounded=True)
3
```

```

1  graph TD
2  node [shape=box, style="filled, rounded", color="black", fontname=helvetica];
3  edge [fontname=helvetica];
4  0 [label="failures <= 0.5\nsamples = 100.0%\nvalue = [0.58, 0.42]\nclass = fail", fillcolor="#f8dcc9"];
5  1 [label="schoolsуп_no <= 0.5\nsamples = 79.0%\nvalue = [0.519, 0.481]\nclass = fail", fillcolor="#fdf6f0"];
6  0 -> 1 [label=distance=2.5, labelangle=45, headlabel="True"];
7  2 [label="Mjob_services <= 0.5\nsamples = 10.1%\nvalue = [0.825, 0.175]\nclass = fail", fillcolor="#eb9c63"];
8  1 -> 2 ;
9  3 [label="reason_reputation <= 0.5\nsamples = 6.6%\nvalue = [0.923, 0.077]\nclass = fail", fillcolor="#e78c49"];
10 2 -> 3 ;
11  4 [label="samples = 4.3%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"];
12  3 -> 4 ;
13  5 [label="paid_no <= 0.5\nsamples = 2.3%\nvalue = [0.778, 0.222]\nclass = fail", fillcolor="#eca572"];
14  3 -> 5 ;
15  6 [label="samples = 1.0%\nvalue = [0.5, 0.5]\nclass = fail", fillcolor="#ffffff"];
16  5 -> 6 ;
17  7 [label="samples = 1.3%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"];
18  5 -> 7 ;
19  8 [label="health <= 2.5\nsamples = 3.5%\nvalue = [0.643, 0.357]\nclass = fail", fillcolor="#f3c7a7"];
20  2 -> 8 ;

```

Gambar 2.15 hasil

```

1  graph TD
2  node [shape=box, style="filled, rounded", color="black", fontname=helvetica];
3  edge [fontname=helvetica];
4  0 [label="failures <= 0.5\nsamples = 100.0%\nvalue = [0.58, 0.42]\nclass = fail", fillcolor="#f8dcc9"];
5  1 [label="schoolsуп_no <= 0.5\nsamples = 79.0%\nvalue = [0.519, 0.481]\nclass = fail", fillcolor="#fdf6f0"];
6  0 -> 1 [label=distance=2.5, labelangle=45, headlabel="True"];
7  2 [label="Mjob_services <= 0.5\nsamples = 10.1%\nvalue = [0.825, 0.175]\nclass = fail", fillcolor="#eb9c63"];
8  1 -> 2 ;
9  3 [label="reason_reputation <= 0.5\nsamples = 6.6%\nvalue = [0.923, 0.077]\nclass = fail", fillcolor="#e78c49"];
10 2 -> 3 ;
11  4 [label="samples = 4.3%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"];
12  3 -> 4 ;
13  5 [label="paid_no <= 0.5\nsamples = 2.3%\nvalue = [0.778, 0.222]\nclass = fail", fillcolor="#eca572"];
14  3 -> 5 ;
15  6 [label="samples = 1.0%\nvalue = [0.5, 0.5]\nclass = fail", fillcolor="#ffffff"];
16  5 -> 6 ;
17  7 [label="samples = 1.3%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"];
18  5 -> 7 ;
19  8 [label="health <= 2.5\nsamples = 3.5%\nvalue = [0.643, 0.357]\nclass = fail", fillcolor="#f3c7a7"];
20  2 -> 8 ;

```

Gambar 2.16 hasil

8. selanjutnya pada codingan berikut yaitu digunakan untuk mencetak nilai score rata-rata dari ketepatan data yang telah di olah.

```
1 palembang.score(muaraenim_test_att, muaraenim_test_pass)
```


9. selanjutnya yaitu digunakan untuk memeriksa akurasi dari ketepatan hasil pengolahan data tersebut maka akan didapat nilai rata-rata 60 persen dari hasil pengolahan data tersebut, pada codingan tersebut pada baris ke satu melakukan import library dari sklern kemudian pada baris selanjutnya mengisi nilai skor dengan nilai pada variabel palembang setelah hal tersebut dilakukan kemudian data tersebut di eksekusi.

```
1 from sklearn.model_selection import cross_val_score
```

```

2 scores = cross_val_score(palembang, muaraenim_att,
    muaraenim_pass, cv=5)
3 # show average score and +/- two standard deviations away
4 # (covering 95% of scores)
5 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
    std() * 2))

```



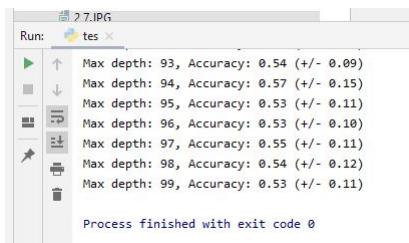
Gambar 2.17 hasil

10. membuat rank akurasi dari 1 sampai 100 untuk melihat akurasi data apakah datatersebut terdapat di rata rata 60 persen atau tidak dengan cara membuat lagi variabel baru dengan nilai tree diadalamnya jadi hampir mirip seperti membuat pohon keputusan namun ini langsung dalam bentuk rata rata akurasi yanlebih spesifik.

```

1 for max_depth in range(1, 100):
2     palembang = tree.DecisionTreeClassifier(criterion="entropy",
        max_depth=max_depth)
3     scores = cross_val_score(palembang, muaraenim_att,
        muaraenim_pass, cv=5)
4     print("Max depth: %d, Accuracy: %0.2f (+/- %0.2f)" % (
            max_depth, scores.mean(), scores.std() * 2))

```



Gambar 2.18 hasil

11. untuk selanjutnya yaitu menentukan nilai untuk grafik hampirsama dengan nilai akurasi tadi pertama tentukan rank atau batasan nilai itu disini batasannya di mulai dari 1 sampai 20 dengan menggunakan nilai tree tadi maka hasilnya dapat ditentuka kemudian buat variabel i untuk penomoran tiap record yang keluar atau record hadil dari eksekusi tree tersebut.

```

1 depth_acc = np.empty((19,3), float)
2 i = 0
3 for max_depth in range(1, 20):
4     palembang = tree.DecisionTreeClassifier(criterion="entropy",
        max_depth=max_depth)

```

```

5     scores = cross_val_score(palembang , muaraenim_att ,
6     muaraenim_pass , cv=5)
7     depth_acc[i , 0] = max_depth
8     depth_acc[i , 1] = scores.mean()
9     depth_acc[i , 2] = scores.std() * 2
10    i += 1
11 print(depth_acc)

```

```

[1.3000000e+01 5.72151899e-01 6.28337906e-02]
[1.4000000e+01 5.59493671e-01 6.28337906e-02]
[1.5000000e+01 5.51898734e-01 7.26718992e-02]
[1.6000000e+01 5.67088608e-01 6.28337906e-02]
[1.7000000e+01 5.77215190e-01 4.41407488e-02]
[1.8000000e+01 5.72151899e-01 1.21307833e-01]
[1.9000000e+01 5.56962025e-01 1.03766590e-01]

```

Process finished with exit code 0

Gambar 2.19 hasil

12. terakhir yaitu pembuatan grafik untuk pembuatan grafik diambil data dari codingan sebelumnya yang 20 record tadi dengan cara mengimport libray matplotlib.pyplot yang di inisialisasi menjadi bakwankemudian inisialisasi tersebut di eksekusi.

```

1 import matplotlib.pyplot as plt
2 fig , ax = plt.subplots()
3 ax.errorbar(depth_acc[:,0] , depth_acc[:,1] , yerr=depth_acc
4 [:,2])
5 plt.show()

```

2.1.3 Penanganan Error

- skrinsut error
- kode error dan jenis errornya .

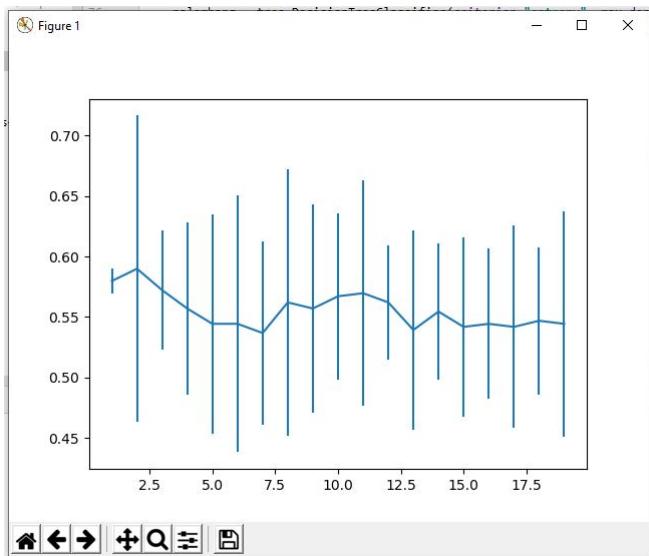
```

import graphviz
dot_data = tree.export_graphviz(palembang, out_file=None, label="all"
                                feature_names=list(muaraenim_train_a
                                filled=True, rounded=True)
graph = graphviz.Source(dot_data)
graph

```

pada codingan tersebut error karena graphiznya belu di istall

- Solusi pemecahan masalah
buka CMD komputer anda run as administrator koemudian masukan perintah conda install graphviz.

**Gambar 2.20** hasil

```

Run: tes
Traceback (most recent call last):
File "D:/NAJIB/SEMESTER_6 NAJIB/AI/Chapter2/tes.py", line 2, in <module>
    import graphviz
ModuleNotFoundError: No module named 'graphviz'

Process finished with exit code 1

```

Gambar 2.21 Error

2.1.4 Plagiat

2.2 1174035 Luthfi Muhammad Nabil

2.2.1 Teori

1. Jelaskan Apa Itu Binary Classification dilengkapi ilustrasi gambar sendiri.

Binary Classification adalah sebuah metode untuk menklasifikasikan elemen yang dibentuk seperti grup untuk dibagi menjadi 2 grup. Dari 2 grup tersebut diprediksi setiap anggota pada grup yang mana sesuai dengan yang diatur pada aturan klasifikasi. Data atau konteks yang didapat membutuhkan keputusan dari item tersebut memiliki properti kualitatif, karakteristik yang spesifik, atau tipikal klasifikasi biner.

RESULTS



Completed: 100% Checked



Plagiarism



Unique



Sentence Wise Result

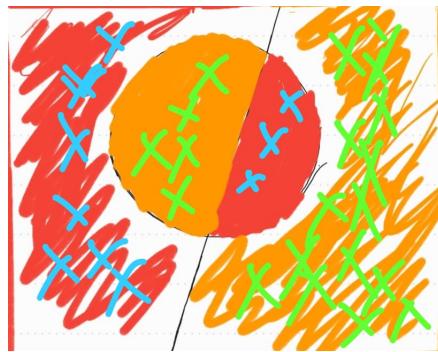


Matched Sources



Document View

Unique	\subitem Definisi kecerdasan buatan adalah suatu pengetahuan yang dapat membuat komputer untuk ...
Unique	Contohnya yaitu melakukan analisa penalaran untuk mengambil suatu kesimpulan atau penerjemahan ...
Unique	\subitem Sejarah dan perkembangan kecerdasan buatan terjadi pada musim panas tahun 1956 tercata...
Unique	Seminar pada waktu itu dihadiri oleh sejumlah pakar komputer dan membahas potensi komputer dala...
Unique	Akan tetapi perkembangan yang sering terjadi semenjak diciptakannya LISP, yaitu bahasa kecerdasan ...

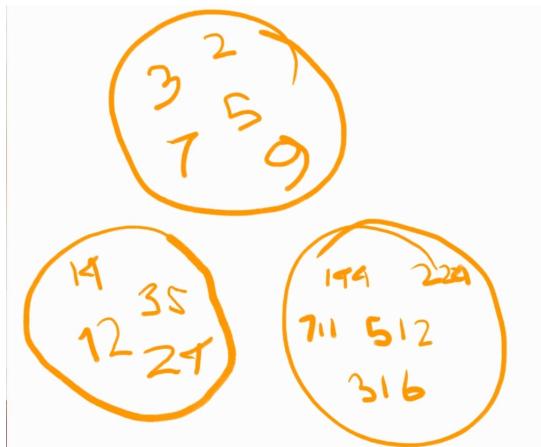
Gambar 2.22 Error**Gambar 2.23** contoh binary classification

2. Jelaskan Apa itu supervised learning , unsupervised learning dan clustering dengan ilustrasi gambar sendiri.

Supervised learning adalah kondisi yang menggunakan variabel input dan output untuk dapat dilakukan pemetaan input output yang sudah didapat. Disebut Supervised Learning karena proses dari pembelajaran algoritma dari pembelajaran yang disumberkan dengan dataset dapat dipikirkan seperti seorang guru yang mengawasi proses pembelajaran. Proses pembelajaran dari algoritma akan berhenti saat algoritma sudah mendapatkan level dari performansi yang dapat diterima.

Unsupervised learning adalah kondisi dimana kamu hanya memiliki input data tanpa memiliki variabel output yang sesuai. Tujuan dari unsupervised learning adalah untuk memodelkan distribusi pada data untuk mengetahui lebih lanjut mengenai data. Disebut unsupervised learning karena pada metode ini, tidak ada jawaban yang tepat dan tidak ada pengarah. Sehingga algoritma akan ditinggalkan sesuai rancangan demi menemukan dan dapat mengolah data yang menarik pada saat yang akan datang.

Clustering adalah sebuah metode untuk membedakan data - data menjadi kumpulan dari group yang isinya merupakan data yang serupa setiap grupnya. Basisnya dapat berupa kesamaan atau perbedaan dari setiap grup tersebut.



Gambar 2.24 contoh clustering

3. Jelaskan apa itu evaluasi dan akurasi dan disertai ilustrasi contoh dengan gambar sendiri.

Evaluasi adalah kegiatan yang dilakukan untuk menentukan sebuah nilai yang dapat diambil dari suatu hal. Beberapa contoh evaluasi diantaranya menilai sebuah barang, bahaya dari penyakit, dan lain sebagainya dengan parameter yang digunakan yaitu mengetahui faktor - faktor yang menyebabkan atau akibat yang akan terjadi jika dibiarkan.

4. Jelaskan bagaimana cara membuat Confusion Matrix, Buat confusion matrix sendiri.

Confusion Matrix merupakan metode untuk menghitung akurasi pada data mining atau Sistem Pendukung Keputusan. Untuk menggunakan Confusion Matrix, ada 4 istilah sebagai hasil proses dari klasifikasi. Di antaranya adalah :

- True Positive : Data positif yang terdeteksi memiliki hasil benar
- False Positive : Data Positif yang terdeteksi memiliki hasil salah
- True Negative : Data negatif yang terdeteksi memiliki hasil benar
- False Negative : Data negatif yang terdeteksi memiliki hasil salah

5. Jelaskan bagaimana K-fold cross validation bekerja dengan gambar ilustrasi contoh buatan sendiri. k-Fold Cross-Validation merupakan prosedur untuk mengambil sampel ulang yang digunakan untuk mengevaluasi sebuah "machine learning" model pada sampel data yang terbatas. Procedure yang ada memiliki satu parameter yang dipanggil k yang mengacu pada jumlah grup yang memberikan data sampel untuk dipisahkan. K-fold Cross-validation akan melakukan hal berikut :
- (a) Mengacak dataset secara random
 - (b) Memisahkan dataset menjadi k group
 - (c) Untuk setiap grup, akan disesuaikan dan dievaluasi
 - (d) Merekaphasil dari evaluasi dan penyesuaian menggunakan sampel dari model evaluasi



Gambar 2.25 contoh K-fold cross validation

6. Jelaskan Apa itu decision tree disertakan gambar ilustrasi contoh buatan sendiri.

Decision Tree merupakan sebuah struktur yang menentukan keputusan dan setiap konsekuensinya. Hasil dari setiap struktur biasanya menggunakan jawaban (True dan False) atau cabang lain yang akan menjadi pohon selanjutnya. Setiap keputusan diantaranya akan membandingkan

kondisi yang diberikan kepada struktur untuk dibandingkan kondisi apa saja yang sudah didapat pada sistem tersebut.

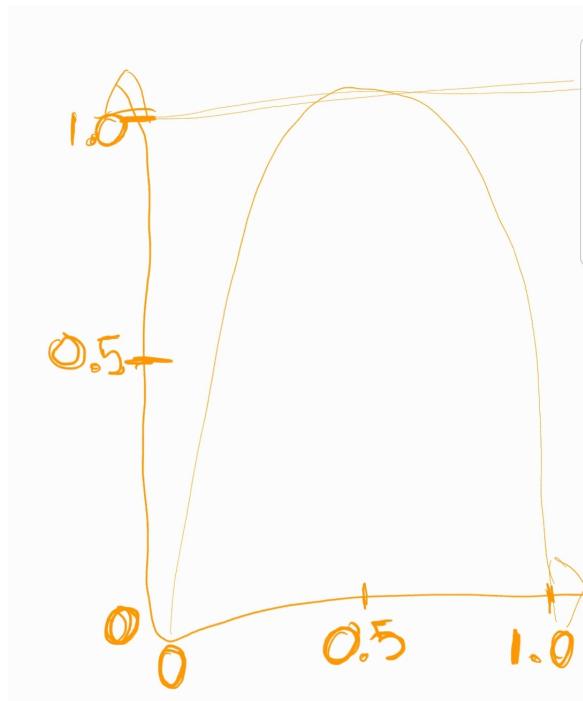
7. jelaskan apa itu information gain dan entropi dengan gambar ilustrasi buatan sendiri.

Information Gain merupakan total data yang didapat dari data - data acak yang data tersebut akan digunakan untuk analisis data lainnya. Information Gain ini digunakan pada decision tree sebagai label setiap aksi - aksi yang perlu dinilai validasinya.

		Coding	
		Ya	Tidak
Outlook	Fokus	3	2
	Normal	4	0
	Tidak Fokus	2	3

Gambar 2.26 contoh information gain

Entropi merupakan pengukuran sebuah data dan validnya data tersebut untuk dapat digunakan sebagai informasi yang akan dimasukkan ke Information Gain. Entropi menilai sebuah obyek berdasarkan kebutuhan di dunia nyata dan pengaruh pada sistem yang akan digunakan



Gambar 2.27 contoh information gain

2.2.2 Scikit-Learn

1.

```
1 import pandas as pd #mengimpor library pandas
2 cakue = pd.read_csv('student-mat.csv', sep=';') #data csv
    dibaca lalu dipisahkan dengan titik koma';
3 len(cakue) #menghitung total nilai(panjang kumpulan nilai/
    array) yang terpisahkan dari csv tersebut
```

In [5]: student-mat.csv (student-mat.csv, sep=',') Data cari di sini (file digunakan dengan nama 'cakue').
Out[5]: 393 Menghitung total nilai(panjang kumpulan nilai/array) yang terpisahkan dari csv tersebut

Gambar 2.28 Hasil Percobaan 1

2.

```
1 cakue[ 'pass' ] = cakue .apply(lambda row: 1 if (row[ 'G1' ]+row[ 'G2' ]+row[ 'G3' ]) >= 35 else 0, axis=1)
```

```

2 cakue = cakue.drop(['G1', 'G2', 'G3'], axis=1)
3 cakue.head()#mengambil baris pertama dari cakue

```

In [8]:	cakue[cols] + cakue.apply(lambda row: 1 if (row['G1'] > row['G2']) & (row['G1'] > row['G3']) else 0, axis=1)
Out[8]:	school sex age address family Debt male results absences pass
	0 0P 0 15 U 0.073 ... 1 3 1 1 28 0
	1 0P 0 15 U 0.073 ... 1 3 1 1 28 0
	2 0P 0 15 U 0.073 ... 1 3 1 1 28 0
	3 0P 0 15 U 0.073 ... 1 3 1 1 28 0
	4 0P 0 15 U 0.073 ... 1 3 1 1 28 0

[15 rows x 31 columns]

Gambar 2.29 Hasil Percobaan 2

3.

```

1 cakue = pd.get_dummies(cakue, columns=['sex', 'school', 'address', 'famsize', 'Pstatus', 'Mjob', 'Fjob', 'reason', 'guardian', 'schoolsup', 'famsup', 'paid', 'activities', 'nursery', 'higher', 'internet', 'romantic'])
2 cakue.head()#mengambil baris pertama dari cakue

```

In [9]:	cakue[cols] + cakue.apply(lambda row: 1 if (row['G1'] > row['G2']) & (row['G1'] > row['G3']) else 0, axis=1)
Out[9]:	school sex age address family Debt male results absences pass
	0 0P 0 15 U 0.073 ... 1 3 1 1 28 0
	1 0P 0 15 U 0.073 ... 1 3 1 1 28 0
	2 0P 0 15 U 0.073 ... 1 3 1 1 28 0
	3 0P 0 15 U 0.073 ... 1 3 1 1 28 0
	4 0P 0 15 U 0.073 ... 1 3 1 1 28 0

[15 rows x 31 columns]

Gambar 2.30 Hasil Percobaan 3

4.

```

1 # shuffle rows
2 cakue = cakue.sample(frac=1) #mengenerate sampel acak dari baris atau kolom dari cakue
3 # split training and testing data
4 cakue_train = cakue[:500]#Mengambil data array dengan batas index 500
5 cakue_test = cakue[500:] #Mengambil data array dengan awal index 500
6 cakue_train_att = cakue_train.drop(['pass'], axis=1) #
7 cakue_train_pass = cakue_train['pass'] #Mengambil data cakue_train dengan index object 'pass' dan dimasukkan ke variable cakue_train_pass
8 cakue_test_att = cakue_test.drop(['pass'], axis=1)
9 cakue_test_pass = cakue_test['pass'] #Mengambil data cakue_train dengan index object 'pass' dan dimasukkan ke variable cakue_test_pass
10 cakue_att = cakue.drop(['pass'], axis=1)
11 cakue_pass = cakue['pass']#Mengambil data cakue_train dengan index object 'pass' dan dimasukkan ke variable cakue_pass
12 # number of passing students in whole dataset:
13 import numpy as np #mengimport library numpy
14 print("Passing: %d out of %d (%.2f%%)" % (np.sum(cakue_pass), len(cakue_pass), 100*float(np.sum(cakue_pass)) / len(cakue_pass))) #Menampilkan hasil integer dan float untuk melihat passing datanya

```

```
In [20]: from sklearn import tree #Mengimport class tree dari library sklearn
In [21]: kwetiau = tree.DecisionTreeClassifier(criterion="entropy",
                                             max_depth=5) #Memanggil fungsi untuk melakukan prediksi dengan aturan keputusan yang simpel
In [22]: kwetiau = kwetiau.fit(cakue_train_att, cakue_train_pass) # Untuk melakukan pengiriman data training set ke method fit
```

Gambar 2.31 Hasil Percobaan 4

5.

```
1 from sklearn import tree #Mengimport class tree dari library sklearn
2 kwetiau = tree.DecisionTreeClassifier(criterion="entropy",
3                                     max_depth=5) #Memanggil fungsi untuk melakukan prediksi dengan aturan keputusan yang simpel
4 kwetiau = kwetiau.fit(cakue_train_att, cakue_train_pass) # Untuk melakukan pengiriman data training set ke method fit
```

```
In [20]: dot_data = tree.export_graphviz(kwetiau, out_file=None, label="all", impurity=False, proportion=True, feature_names=list(cakue_train_att), class_names=["fail", "pass"], filled=True, rounded=True) #Untuk mengekspor data ke format graphviz
In [21]: graph = graphviz.Source(dot_data) #Untuk mengambil sumber data berformat graphviz dan dimasukkan ke variable graph
```

Gambar 2.32 Hasil Percobaan 5

6.

```
1 import graphviz #mengimport class graphviz
2 dot_data = tree.export_graphviz(kwetiau, out_file=None, label="all", impurity=False, proportion=True, feature_names=list(cakue_train_att), class_names=["fail", "pass"], filled=True, rounded=True) #Untuk mengekspor data ke format graphviz
3 graph = graphviz.Source(dot_data) #Untuk mengambil sumber data berformat graphviz dan dimasukkan ke variable graph
4 graph #Menampilkan isi variable graph untuk di spyder
```

```
In [20]: dot_data = tree.export_graphviz(kwetiau, out_file=None, label="all", impurity=False, proportion=True, feature_names=list(cakue_train_att), class_names=["fail", "pass"], filled=True, rounded=True) #Untuk mengekspor data ke format graphviz
In [21]: graph = graphviz.Source(dot_data) #Untuk mengambil sumber data berformat graphviz dan dimasukkan ke variable graph
In [22]: graph #Menampilkan isi variable graph untuk di spyder
```

Gambar 2.33 Hasil Percobaan 6

7.

```
1 tree.export_graphviz(kwetiau, out_file="student-performance.dot", label="all", impurity=False, proportion=True, feature_names=list(cakue_train_att), class_names=["fail", "pass"], filled=True, rounded=True) #Untuk mengekspor data ke format graphviz
```

Gambar 2.34 Hasil Percobaan 7

8.

```
1 kwetiau.score(cakue_test_att, cakue_test_pass) #Untuk
   melakukan penilaian sesuai dengan drop – drop pada
   variable cakue_test_att dan cakue_test_pass
```

```
In [12]: kwetiau.score(cakue_test_att, cakue_test_pass)
Out[12]: 0.67
In [13]: #Untuk mengevaluasi nilai menggunakan metode cross-validation
In [14]: scores = cross_val_score(kwetiau, cakue_att, cakue_pass, cv=5)
In [15]: print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2))
Out[15]: Accuracy: 0.67 (+/- 0.21)
```

Gambar 2.35 Hasil Percobaan 8

9.

```
1 from sklearn.model_selection import cross_val_score # Mengambil class cross_val_score dari library sklearn.model_selection
2 scores = cross_val_score(kwetiau, cakue_att, cakue_pass, cv=5) #Untuk mengevaluasi nilai menggunakan metode cross-validation
3 # show average score and +/- two standard deviations away
4 #(covering 95% of scores)
5 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2)) #Menampilkan score
```

```
In [15]: print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2))
Out[15]: Accuracy: 0.67 (+/- 0.21)
```

Gambar 2.36 Hasil Percobaan 9

10.

```
1 for max_depth in range(1, 20): #Looping dengan for berdasarkan nilai dari 1 sampai 20 dengan variable index yaitu max_depth
2     kwetiau = tree.DecisionTreeClassifier(criterion="entropy", max_depth=max_depth) #Memanggil fungsi untuk melakukan prediksi dengan aturan keputusan yang simpel
3     scores = cross_val_score(kwetiau, cakue_att, cakue_pass, cv=5) #Untuk mengevaluasi nilai menggunakan metode cross-validation
4     print("Max depth: %d, Accuracy: %0.2f (+/- %0.2f)" % (max_depth, scores.mean(), scores.std() * 2)) #Menampilkan score
```



Gambar 2.37 Hasil Percobaan 10

11.

```

1 depth_acc = np.empty((19,3), float) #Mengembalikan array
    dengan format bentuk dan tipe
2 i = 0#Inisiasi variable
3 for max_depth in range(1, 20): #Looping dengan for
    berdasarkan nilai dari 1 sampai 20 dengan variable index
    yaitu max_depth
4 kwetiau = tree.DecisionTreeClassifier(criterion="entropy",
    , max_depth=max_depth) #Memanggil fungsi untuk melakukan
prediksi dengan aturan keputusan yang simpel
5 scores = cross_val_score(kwetiau, cakue_att, cakue_pass,
cv=5) #Untuk mengevaluasi nilai menggunakan metode cross-
validation
6 depth_acc[i,0] = max_depth
7 depth_acc[i,1] = scores.mean()
8 depth_acc[i,2] = scores.std() * 2
9 i += 1
10 depth_acc

```



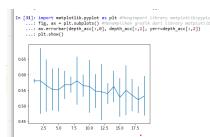
Gambar 2.38 Hasil Percobaan 11

12.

```

1 import matplotlib.pyplot as plt #Mengimport library
    matplotlib>pyplot
2 fig, ax = plt.subplots() #Menampilkan grafik dari library
    matplotlib
3 ax.errorbar(depth_acc[:,0], depth_acc[:,1], yerr=depth_acc
    [:,2])
4 plt.show()

```



Gambar 2.39 Hasil Percobaan 12

2.2.3 Skrinsut Error

Error yang didapat yaitu mengalami error tidak ada library graphviz yang terdeteksi



Gambar 2.40 Error

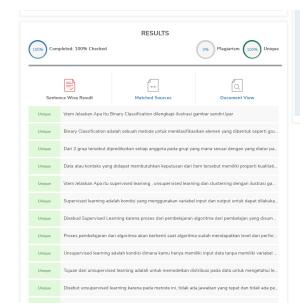
2.2.4 Penanganan Error

Solusinya adalah dengan menginstall library graphviz yang ada



Gambar 2.41 Error

2.2.5 Plagiarisme



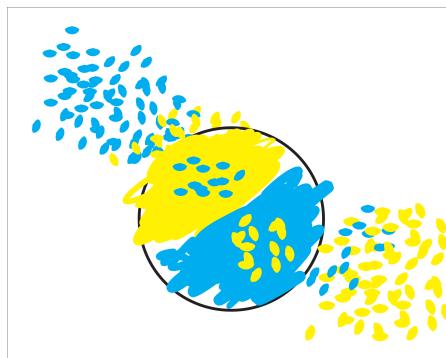
Gambar 2.42 Hasil Pengecekan Plagiarisme

2.3 1174057 - Alit Fajar Kurniawan

2.3.1 Teori

2.3.1.1 Jelaskan apa itu binary classification dilengkapi ilustrasi gambar sendiri

Binary classification merupakan jenis masalah pembelajaran mesin yang paling sederhana. mengklarifikasi elemen-elemen dari himpunan yang diberikan kedalam dua kelompok berdasarkan aturan klarifikasi. Contoh yang paling sederhana dalam binary classification yaitu mendeteksi dan mendiagnosa. Berikut contoh gambar Binary Classification, gambar 2.1



Gambar 2.43 Klasifikasi Binari

2.3.1.2 Jelaskan apa itu supervised learning dan unsupervised learning dan clustering dengan ilustrasi gambar sendiri

Supervised Learning merupakan paradigma belajar yang berkaitan dengan studi tentang bagaimana komputer dan sistem alami seperti manusia belajar [?]. Tujuannya untuk menyimpulkan pemetaan fungsional berdasarkan serangkaian pelatihan atau mengelompokkan suatu data ke data yang sudah ada. Berikut contoh gambar Supervised Learning

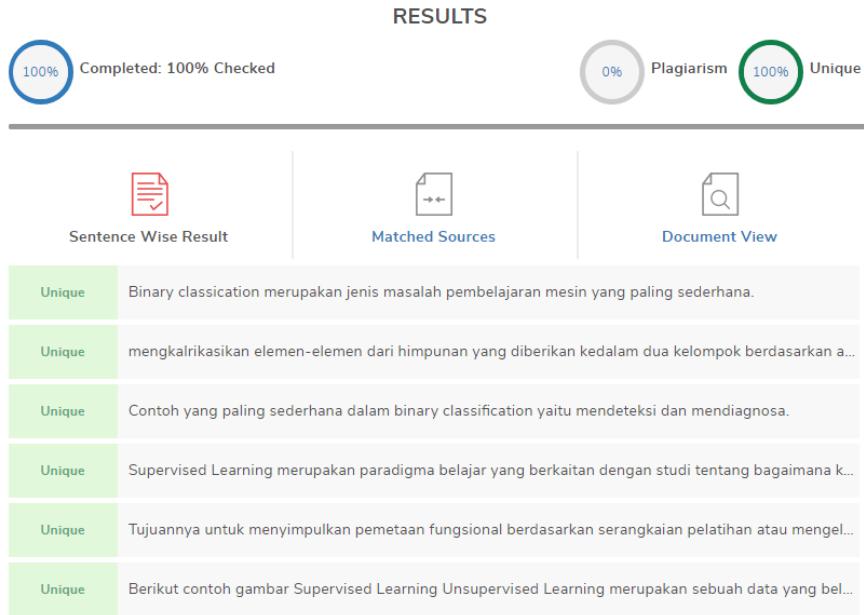
Unsupervised Learning merupakan sebuah data yang belum ditentukan variabelnya jadi hanya berupa data saja. Dalam sebuah kasus Unsupervised Learning adalah aggap saja anda belum pernah membeli buku sama sekali dan pada suatu hari anda telah membeli buku dengan sangat banyak dalam kategori yang berbeda. Sehingga buku tersebut belum di kategorikan dan hanya berupa data buku saja.

Clustering merupakan metode pengelompokan data, clustering juga suatu proses partisi satu set objek data ke dalam himpunan bagian yang disebut dengan cluster. Objek yang pada cluster memiliki kesamaan secara karakteristik antara satu sama lainnya dan berbeda dengan cluster yang lain.

2.3.2 Praktek

2.3.3 Penanganan Error

2.3.4 Bukti Tidak Plagiat



Gambar 2.44 Plagiarisme

2.4 1174050 Dika Sukma Pradana

2.4.1 Teori

1. Jelaskan Apa Itu binari calssification dilengkapi ilustrasi gambar sendiri.

Klasifikasi biner atau binomial adalah tugas untuk mengklasifikasikan elemen-elemen dari himpunan tertentu ke dalam dua kelompok (memprediksi kelompok mana yang masing-masing dimiliki) berdasarkan aturan klasifikasi.



Gambar 2.45 contoh binari calssification

2. Jelaskan Apaitu supervised learning , unsupervised learning dan clustering dengan ilustrasi gambar sendiri.

Supervised learning adalah sebuah metode pendekatan yang mana sudah terdapat data yang dilatih, dan terdapat variabel yang ditargetkan atau yang menjadi tujuan sehingga tujuan dari pendekatan ini adalah mengelompokan suatu data ke data yang sudah ada. contoh pada nasi termasuk yang mengandung karbohidrat berarti nasi telah di kategorikan kedalam karbohidrat. sedangkan ayam mengandung protein yang berarti ayam telah di kategorikan yang mengandung protein untuk lebih jelasnya dapat dilihat pada gambar.



Gambar 2.46 contoh supervised learning

Sedangkan unsupervised learning tidak memiliki data latih, sehingga dari data yang ada, kita mengelompokan data tersebut menjadi dua bagian atau bahkan tiga bagian dan seterusnya. contoh ayam di kategorikan kedalam karbohidrat untuk lebih jelasnya dapat dilihat pada gambar.



Gambar 2.47 contoh unsupervised learning

clustering merupakan proses mengklasifikasikan yang berdasarkan suatu parameter dalam penentuannya contoh pada berat protein memiliki berat 1000 gr dan karbohidrat memiliki berat 1200 gr yang berarti berat dibagi dua parameter yaitu lebih kecil samadengan 1000 gram dan lebih besar dari 1000gram contoh pada gambar.



Gambar 2.48 contoh clustering

3. Jelaskan apa itu evaluasi dan akurasi dan disertai ilustrasi contoh dengan gambar sendiri.

evaluasi adalah pengumpulan pengumpulan dan pengamatan dari berbagai macam bukti untuk mengukur dampak efektifitas dari suatu objek, program, atau proses berkaitan dengan spesifikasi atau persyaratan yang telah di tetapkan sebelumnya. sedangkan akurasi itu sendiri merupakan bagian dari evaluasi yang merupakan ketepatan data terhadap suatu objek berdasarkan keriteria tertentu. kita dapat mengevaluasi seberapa baik model bekerja dengan mengukur akurasiinya. ketepatan akan definisikan sebagai persentase kasus yang diklasifikasikan dengan benar. hal ini berkaitan dengan confusion matrix pada materi selanjutnya. contoh evaluasi untuk membedakan angsa dengan entok terdapat parameter yaitu panjang leher dan fungsi sifat dari hewan tersebut. lebih jelasnya pada gambar berikut:



Gambar 2.49 contoh evaluasi dan akurasi

4. Jelaskan bagaimana cara membuat Confusion Matrix, Buat confusion matrix sendiri.

Dalam pembuatan confusion matrix tentukan parameter atau objek yang akan di evaluasi contoh angsa, entok, bebek buat tabel dengan baris dan kolom berjumlah tiga kemudian tentukan nilai miring pada setiap kolom tersebut disini saya memberi nilai 15 dengan ketentuan setiap baris harus berisi nilai 15 nilai tersebut jika terbagi ke kolom lain maka jumlahnya harus bernilai 15 jika tidak berarti data tersebut tidak akurat. untuk lebih jelasnya dapat dilihat pada gambar berikut :

		Predicted	
		benar	salah
Actual	benar	15	0
	salah	0	15

Gambar 2.50 contoh Confusion Matrix

5. Jelaskan bagaimana K-fold cross validation bekerja dengan gambar ilustrasi contoh buatan sendiri. K-fold Cross Validation merupakan cara untuk melatih suatu mesin dimana dalamnya terdapat data set yang dibagi menjadi dua yaitu untuk data testing dan data training contoh 1000 data merupakan data set dan 300 data digunakan untuk data testing kemudian 700 datanya digunakan untuk data training dimana data training tersebut digunakan untuk menentukan nilai bobot yang dimasukkan kedalam rumus regresi linier. sedangkan nilai testing akan dijadikan nilai

inputan untuk rumus regresi linier. contohnya dapat dilihat pada gambar berikut :



Gambar 2.51 contoh K-fold cross validation

6. Jelaskan Apa itu decision tree dengan gambar ilustrasi contoh buatan sendiri.

Decision tree merupakan implementasi dari binari clasification dimana pada pohon keputusan akan terdapat root atau akar dan cabang cabangnya yang nilainya seperti if contoh pada root berisi nilai warna mawar, apakah merah pada cabang satu bernilai iya dan pada cabang dua bernilai tidak jika nilainya iya berarti mawar dan jika tidak maka bukan mawar. agar lebih jelas dapat dilihat pada gambar decision tree berikut:



Gambar 2.52 contoh decision tree

7. jelaskan apa itu information gain dan entropi dengan gambar ilustrasi buatan sendiri.

informasian gain merupakan informasi atau keriteria dalam pembagian sebuah objek contoh information gain pada llama leher panjang, ekor panjang, berkaki 4, buas, karnivora. untuk lebih jelasnya dapat dilihat pada gambar berikut :



Gambar 2.53 contoh information gain

sedangkan entropi merupakan ukuran keacakan dari informasi semakin tinggi entropi maka semakin sulit dalam menentukan keputusan contoh dalam menentukan satu gen semakin detail informasi maka akan semakin susah dalam menentukan keputusan.

2.4.2 Sikic-Learn

1. pada surcode pertama yang dapat dilihat pada gambar pada baris pertama di tuliskan import pandas as baso yang berarti mengimport library pandas. selanjutnya pada baris ke dua codingan tersebut berisi code tersebut terdapat variabel pecel yang berisi inisialisasi pandas dengan aksi untuk membaca vfile csv yang terdapat pada direktori pada komputer kemudian terdapat sep samadengan titik koma yang berarti pemisah field di dalam file tersebut merupakan titik koma. kemudian pada bagian akhir terdapat code len (nama variabel) yang berarti akan menghitung jumlah baris pada file tersebut. untuk hasilnya dapat dilihat pada gambar dibawah.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 21:32:13 2020
4
5 @author: User
6 """
7
8 # load dataset (student mat pakenya)
9 import pandas as pd
10 pecel = pd.read_csv('D:\\SEMESTER 6\\Python-Artificial-
    Intelligence-Projects-for-Beginners-master\\Chapter01\\
        dataset\\student-mat.csv', sep=';')
11 print(len(pecel))

```

In [1]: runfile('D:/SEMESTER 6/wert/untitled0.py', wdir='D:/SEMESTER 6/wert')
395

Gambar 2.54 hasil

2. Pada code selanjutnya akan ditambahkan fungsi untuk lulus atau gagal yang dibuat berupa kolom kolom yang di dalamnya terdapat nilai 0 dan 1 dimana 0 berarti gagal dan 1 berarti lulus. kemudian variabel pada codingan sebelumnya masih digunakan. dimana variabel pecel digunakan karena berisi nilai file csv kemudian dilakukan ekseskuasi dengan parameter G1, G2, dan G3 dengan fungsi lambda yang berarti if bersarang atau if didalam if yang berarti nilai yang di eksekusi akan dilempar ke dalam setiap paramater sasuai dengan kriteria dan axis=1 yaitu nilai tersebut akan digunakan dari tiap baris data. sedangkan pada codingan variabel pecel di berikan aksi drop yaitu penurunan nilai pada bagian baris data. dan pada code pecel.head yaitu untuk mengeksekusi codingan sebelumnya untuk lebih jelasnya dapat dilihat pada gambar dan hasilnya seperti pada gambar berikut :

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 21:36:23 2020
4

```

```

5 @author: User
6 """
7
8 # generate binary label (pass/fail) based on G1+G2+G3
9 # (test grades, each 0–20 pts); threshold for passing is sum
10    >=30
11 pecel[ 'pass' ] = pecelapply(lambda row: 1 if (row[ 'G1' ]+row[ 'G2' ]+row[ 'G3' ]) 
12 >= 35 else 0, axis=1)
13 pecel = pecel.drop([ 'G1' , 'G2' , 'G3' ], axis=1)
14 print(pecel.head())

```

```

In [4]: runfile('D:/SEMESTER 6/wert/2.py', wdir='D:/SEMESTER 6/wert')
   school sex age address famsize ... Dalc Walc health absences pass
0      GP   F  18      U    GT3 ...   1     1     3      6     0
1      GP   F  17      U    GT3 ...   1     1     3      4     0
2      GP   F  15      U    LE3 ...   2     3     3     10     0
3      GP   F  15      U    GT3 ...   1     1     5      2     1
4      GP   F  16      U    GT3 ...   1     2     5      4     0
[5 rows x 31 columns]

```

Gambar 2.55 hasil

3. pada kodingan selanjutnya diguanakan untuk menambahkan nilai numerik berupa 0 dan 1 yang dirubah dari nilai tidak dan iya hal ini merupakan fungsi dari codingan get_dummies pada baris pertama pada gambar yang nilainya diambil dari variabel pecel yang telah di dekralasikan tadi banyaknya data numerik itu sendiri tergantung pada field dari kolom yang di camtumkan pada codingan dengan catatan field tersebut harus ada dalam data csv yang di import oleh codingan pertama tadi maka hasilnya akan merubah data dalam field tersebut menjadi 0 dan 1 untuk lebih jelasnya dapat di lihat pada gambar berikut;

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 21:41:22 2020
4
5 @author: User
6 """
7
8 # use one-hot encoding on categorical columns
9 pecel = pd.get_dummies(pecel, columns=[ 'sex' , 'school' ,
10                           'address' , 'famsize' , 'Pstatus' , 'Mjob' , 'Fjob' , 'reason' ,
11                           'guardian' , 'schoolsup' , 'famsup' , 'paid' , 'activities' ,
12                           'nursery' , 'higher' , 'internet' , 'romantic' ])
13 pecel.head()

```

```

In [6]: runfile('D:/SEMESTER 6/wert/4.py', wdir='D:/SEMESTER 6/wert')
Passing: 166 out of 395 (42.03%)

```

Gambar 2.56 hasil

4. selanjutnya pada codingan selanjutnya yaitu menentukan data training dan data testing dari dataset dimana variabel pecel yang berisi data csv

tadi dibuat perbandingan 500 untuk data training dan sisanya yaitu 149 digunakan untuk data testing hal ini di lakukan pada baris ke 1 sampai ke 3 pada gambar kemudian nilai tersebut di turunkan brdasarkan baris pada data set hal itu dapat dilihat pada baris ke 4 sampai ke 9 pada gambar kemudian selanjutnya mengimport library numpy yang berguna untuk oprasi vektor dan matrix karna data diatas berupa data matrix maka library ini di gunakan. untuk hasilnya dapat dilihat pada gambar.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 21:42:26 2020
4
5 @author: User
6 """
7
8 # shuffle rows
9 pecel = pecel.sample(frac=1)
10 # split training and testing data
11 pecel_train = pecel[:500]
12 pecel_test = pecel[500:]
13 pecel_train_att = pecel_train.drop(['pass'], axis=1)
14 pecel_train_pass = pecel_train['pass']
15 pecel_test_att = pecel_test.drop(['pass'], axis=1)
16 pecel_test_pass = pecel_test['pass']
17 pecel_att = pecel.drop(['pass'], axis=1)
18 pecel_pass = pecel['pass']
19 # number of passing students in whole dataset:
20 import numpy as np
21 print("Passing: %d out of %d (%.2f%%)" % (np.sum(pecel_pass),
   len(pecel_pass), 100*float(np.sum(pecel_pass)) / len(
   pecel_pass)))

```

	school	sex	age	address	famsize	...	Dalc	Walc	health	absences	pass
0	GP	F	18	U	GT3	...	1	1	3	6	0
1	GP	F	17	U	GT3	...	1	1	3	4	0
2	GP	F	15	U	LE3	...	2	3	3	10	0
3	GP	F	15	U	GT3	...	1	1	5	2	1
4	GP	F	16	U	GT3	...	1	2	5	4	0

Gambar 2.57 hasil

- selanjutnya yaitu membuat pohon keputusan dapat lebih jelasnya dapat di lihat pada gambar. pada baris pertama yairu memasukan librari tree kemudian pada baris kedua dibuat variabel lontong dengan nilai DecisionTreeClasifier yang merupakan paket atau fungsi dari scikit-learn yang merupakan class yang mampu melakukan multi class. sedangkan max_depth=5 merupakan untuk penyesuaian data terhadap pohon keputusan itu sndiri. untuk hasilnya dapat dilihat pada gambar

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 21:56:41 2020
4

```

```

5 @author: User
6 """
7
8 # fit a decision tree
9 from sklearn import tree
10 lontong = tree.DecisionTreeClassifier(criterion="entropy",
11                                     max_depth=5)
12 lontong = lontong.fit(pecel,_train_att, pecel_train_pass)

```

In [18]: runfile('D:/SEMESTER 6/wert/4.py', wdir='D:/SEMESTER 6/wert')
Passing: 166 out of 395 (42.03%)

Gambar 2.58 hasil

6. selanjutnya yaitu pembuatan gambar dari pohon keputusan yang tadi di buta pada codingan sebelumnya pada baris pertama codingan ya itu mengimport library graphviz kemudian pada baris ke dua yaitu pem-berian nilai pada variabel baru dot data nilainya diambil dari pembuatan puhon keputusan tadi kemudian di tentukannya nilai benar dan salah dari codingan tersebut setelah itu dibuatlah sebuah variabel untuk menam-pung hasil eksekusi tersebut kemudian variabel tersebut di running untuk lebih jelasnya dapat di lihat pada gambar.kemudian hasilnya dapat dili-hat pada gambar.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 22:00:57 2020
4
5 @author: User
6 """
7
8 # visualize tree
9 import graphviz
10 dot_data = tree.export_graphviz(lontong, out_file=None, label
11                                 ="all", impurity=False, proportion=True,
12                                 feature_names=list(
13                                   pecel_train_att), class_names=["fail", "pass"],
14                                 filled=True, rounded=True)
15 graph = graphviz.Source(dot_data)
16 graph

```

7. selanjutnya pembuatasn method untuk menyimpan data pohon dengan menarik data langsung dari pohon keputusan di buat tadi untuk code lebih jelasnya dapat dilihat pada gambar. kemudian intuk hasilnya dapat dilihat pada gambar berikut.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 22:03:32 2020
4
5 @author: User
6 """

```

```

graph TD
    node [shape=box, style="filled, rounded", color="black", fontname=helvetica] ;
    edge [fontname=helvetica] ;
    0 [label="failures <= 0.5\nsamples = 100.0%\nvalue = [0.58, 0.42]\nclass = fail", fillcolor="#f8dcc9"] ;
    1 [label="schoolsup_no <= 0.5\nsamples = 79.0%\nvalue = [0.519, 0.481]\nclass = fail", fillcolor="#fdfef0"] ;
    0 --> 1 [label=distance:2.5, labelangle:45, headLabel="true"] ;
    2 [label="Mjob_services <= 0.5\nsamples = 10.1%\nvalue = [0.825, 0.175]\nclass = fail", fillcolor="#eb9c63"] ;
    1 --> 2 ;
    3 [label="Fedu <= 2.5\nsamples = 6.6%\nvalue = [0.923, 0.077]\nclass = fail", fillcolor="#e78c49"] ;
    2 --> 3 ;
    4 [label="famsize_LE3 <= 0.5\nsamples = 2.3%\nvalue = [0.778, 0.222]\nclass = fail", fillcolor="#eeca57"] ;
    3 --> 4 ;
    5 [label="samples = 1.0%\nvalue = [0.5, 0.5]\nclass = fail", fillcolor="#ffffff"] ;
    4 --> 5 ;
    6 [label="samples = 1.3%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"] ;
    4 --> 6 ;
    7 [label="samples = 4.3%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"] ;
    3 --> 7 ;
    8 [label="Walc <= 3.5\nsamples = 3.5%\nvalue = [0.643, 0.357]\nclass = fail", fillcolor="#f3c7a7"] ;
    2 --> 8 ;
    9 [label="famsup_no <= 0.5\nsamples = 2.8%\nvalue = [0.545, 0.455]\nclass = fail", fillcolor="#fbeade"] ;
    8 --> 9 ;
    10 [label="samples = 2.3%\nvalue = [0.667, 0.333]\nclass = fail", fillcolor="#f2c09c"] ;
    9 --> 10 ;
    11 [label="samples = 0.5%\nvalue = [0.0, 1.0]\nclass = pass", fillcolor="#399de5"] ;
    9 --> 11 ;
    12 [label="samples = 0.8%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"] ;
    8 --> 12 ;
    13 [label="famrel <= 1.5\nsamples = 68.9%\nvalue = [0.474, 0.526]\nclass = pass", fillcolor="#ecf5fc"] ;
    1 --> 13 ;
    14 [label="samples = 1.5%\nvalue = [0.0, 1.0]\nclass = pass", fillcolor="#399de5"] ;
    13 --> 14 ;
    15 [label="Mjob_services <= 0.5\nsamples = 67.3%\nvalue = [0.485, 0.515]\nclass = pass", fillcolor="#f3f9fd"] ;
    13 --> 15 ;
    16 [label="Mjob_health <= 0.5\nsamples = 52.7%\nvalue = [0.529, 0.471]\nclass = fail", fillcolor="#fcf1e9"] ;
    15 --> 16 ;
    17 [label="samples = 45.6%\nvalue = [0.567, 0.433]\nclass = fail", fillcolor="#f9e1d0"] ;
    16 --> 17 ;
    18 [label="samples = 7.1%\nvalue = [0.286, 0.714]\nclass = pass", fillcolor="#88c4e5"] ;
    16 --> 18 ;
    19 [label="goout <= 1.5\nsamples = 14.7%\nvalue = [0.328, 0.672]\nclass = pass", fillcolor="#99cdf2"] ;
    15 --> 19 ;
    20 [label="samples = 1.5%\nvalue = [0.833, 0.167]\nclass = fail", fillcolor="#ea9a61"] ;

```

Gambar 2.59 hasil

```

7
8 # save tree
9 tree.export_graphviz(lontong, out_file="student-performance.
    dot", label="all", impurity=False, proportion=True,
10                         feature_names=list(pecel_train_att),
    class_names=["fail", "pass"], filled=True, rounded=True)

```

8. selanjutnya pada codingan berikut yaitu digunakan untuk mencetak nilai score rata-rata dari ketepatan data yang telah diolah tadi lebih jelsnya dapat dilihat pada gambar kemudian untuk hasilnya dapat dilihat pada gambar tersebut:

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 22:03:35 2020
4
5 @author: User
6 """
7
8 lontong.score(pecel_test_att, pecel_test_pass)

```

9. selanjutnya yaitu digunakan untuk memeriksa akurasi dari ketepatan hasil pengolahan data tersebut maka akan didapat nilai rata-rata 60

```

graph TD
    node [shape=box, style="filled, rounded", color="black", fontname=helvetica];
    edge [fontname=helvetica];
    0 [label="failures <= 0.5\nsamples = 100.0%\nvalue = [0.58, 0.42]\nclass = fail", fillcolor="#f8dc99"];
    1 [label="schoolsup_no <= 0.5\nsamples = 79.0%\nvalue = [0.519, 0.481]\nclass = fail", fillcolor="#fdfe00"];
    0 --> 1 [label=distance:2.5, labelangle:45, headLabel="true"];
    2 [label="Mjob_services <= 0.5\nsamples = 10.1%\nvalue = [0.825, 0.175]\nclass = fail", fillcolor="#eb9c63"];
    1 --> 2 ;
    3 [label="Fedu <= 2.5\nsamples = 6.6%\nvalue = [0.923, 0.077]\nclass = fail", fillcolor="#e78c49"];
    2 --> 3 ;
    4 [label="famsize_LE3 <= 0.5\nsamples = 2.3%\nvalue = [0.778, 0.222]\nclass = fail", fillcolor="#eca572"];
    3 --> 4 ;
    5 [label="samples = 1.0%\nvalue = [0.5, 0.5]\nclass = fail", fillcolor="#ffffff"];
    4 --> 5 ;
    6 [label="samples = 1.3%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"];
    4 --> 6 ;
    7 [label="samples = 4.3%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"];
    3 --> 7 ;
    1 [label="Walc <= 3.5\nsamples = 3.5%\nvalue = [0.643, 0.357]\nclass = fail", fillcolor="#f3c7a7"];
    2 --> 8 ;
    9 [label="famsup_no <= 0.5\nsamples = 2.8%\nvalue = [0.545, 0.455]\nclass = fail", fillcolor="#fbeade"];
    8 --> 9 ;
    10 [label="samples = 2.3%\nvalue = [0.667, 0.333]\nclass = fail", fillcolor="#f2c09c"];
    9 --> 10 ;
    11 [label="samples = 0.5%\nvalue = [0.0, 1.0]\nclass = pass", fillcolor="#399de5"];
    9 --> 11 ;
    12 [label="samples = 0.8%\nvalue = [1.0, 0.0]\nclass = fail", fillcolor="#e58139"];
    8 --> 12 ;
    13 [label="famrel <= 1.5\nsamples = 68.9%\nvalue = [0.474, 0.526]\nclass = pass", fillcolor="#ecf5fc"];
    1 --> 13 ;
    14 [label="samples = 1.5%\nvalue = [0.0, 1.0]\nclass = pass", fillcolor="#399de5"];
    13 --> 14 ;
    15 [label="Mjob_services <= 0.5\nsamples = 67.3%\nvalue = [0.485, 0.515]\nclass = pass", fillcolor="#f3f9fd"];
    13 --> 15 ;
    16 [label="Mjob_health <= 0.5\nsamples = 52.7%\nvalue = [0.529, 0.471]\nclass = fail", fillcolor="#fcf1e9"];
    15 --> 16 ;
    17 [label="samples = 45.6%\nvalue = [0.567, 0.433]\nclass = fail", fillcolor="#f9e1d0"];
    16 --> 17 ;
    18 [label="samples = 7.1%\nvalue = [0.286, 0.714]\nclass = pass", fillcolor="#88c4ef"];
    16 --> 18 ;
    19 [label="goout <= 1.5\nsamples = 14.7%\nvalue = [0.328, 0.672]\nclass = pass", fillcolor="#99cdf2"];
    15 --> 19 ;
    20 [label="samples = 1.5%\nvalue = [0.833, 0.167]\nclass = fail", fillcolor="#ea9a61"];

```

Gambar 2.60 hasil

persen dari hasil pengolahan data tersebut untuk lebih jelasnya dapat di lihat pada gambar pada codingan tersebut pada baris ke satu melakukan import library dari sklern kemudian pada baris selanjutnya mengisi nilai skor dengan nilai pada variabel lontong setelah hal tersebut dilakukan kemudian data tersebut di eksekusi. berikut merupakan hasil dari code tersebut dapat dilihat pada gambar.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 22:03:36 2020
4
5 @author: User
6 """
7
8 from sklearn.model_selection import cross_val_score
9 scores = cross_val_score(lontong, pecel_att, pecel_pass, cv
10                          =5)
11 # show average score and +/- two standard deviations away
12 #(covering 95% of scores)
13 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
14                                         std() * 2))

```

```
In [61]: runfile('D:/SEMESTER 6/wert/9.py', wdir='D:/SEMESTER 6/wert')
Accuracy: 0.59 (+/- 0.05)
```

Gambar 2.61 hasil

10. membuat rank akurasi dari 1 sampai 20 untuk melihat akurasi data apakah datatersebut terdapat di rata rata 60 persen atau tidak dengan cara membuat lagi variabel baru dengan nilai tree diadalamnya jadi hampir mirip seperti membuat pohon keputusan namun ini langsung dalam bentuk rata rata akurasi yanlebih spesifik untuk lebih jelasnya dapat dilihat pada gambar codingan berikut. dan untuk hasilnya dapat dilihat pada gambar berikut.

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 22:03:38 2020
4
5 @author: User
6 """
7
8 for max_depth in range(1, 100):
9     lontong = tree.DecisionTreeClassifier(criterion="entropy",
10                                         , max_depth=max_depth)
11     scores = cross_val_score(lontong, pecel_att, pecel_pass,
12                               cv=5)
13     print("Max depth: %d, Accuracy: %0.2f (+/- %0.2f)" % (
14         max_depth, scores.mean(), scores.std() * 2))
```

```
Max depth: 1, Accuracy: 0.58 (+/- 0.01)
Max depth: 2, Accuracy: 0.58 (+/- 0.06)
Max depth: 3, Accuracy: 0.56 (+/- 0.06)
Max depth: 4, Accuracy: 0.56 (+/- 0.08)
Max depth: 5, Accuracy: 0.58 (+/- 0.05)
Max depth: 6, Accuracy: 0.62 (+/- 0.05)
Max depth: 7, Accuracy: 0.58 (+/- 0.05)
Max depth: 8, Accuracy: 0.60 (+/- 0.07)
Max depth: 9, Accuracy: 0.58 (+/- 0.10)
Max depth: 10, Accuracy: 0.57 (+/- 0.04)
Max depth: 11, Accuracy: 0.58 (+/- 0.06)
Max depth: 12, Accuracy: 0.57 (+/- 0.08)
Max depth: 13, Accuracy: 0.57 (+/- 0.10)
Max depth: 14, Accuracy: 0.55 (+/- 0.07)
Max depth: 15, Accuracy: 0.58 (+/- 0.08)
Max depth: 16, Accuracy: 0.58 (+/- 0.05)
Max depth: 17, Accuracy: 0.57 (+/- 0.09)
Max depth: 18, Accuracy: 0.57 (+/- 0.11)
Max depth: 19, Accuracy: 0.57 (+/- 0.09)
Max depth: 20, Accuracy: 0.57 (+/- 0.07)
Max depth: 21, Accuracy: 0.57 (+/- 0.06)
Max depth: 22, Accuracy: 0.58 (+/- 0.07)
Max depth: 23, Accuracy: 0.58 (+/- 0.10)
```

Gambar 2.62 hasil

11. untuk selanjutnya yaitu menentukan nilai untuk grafik hampirsama dengan nilai akurasi tadi pertama tentukan rank atau batasan nilai itu disini batasannya di mulai dari 1 sampai 20 dengan menggunakan nilai tree tadi maka hasilnya dapat ditentuka kemudian buat variabel i untuk penomoran tiap record yang keluar atau record hadil dari eksekusi tree tersebut. un-

tuk lebih jelasnya dapat dilihat pada gambar dan untuk hasilnya dapat dilihat pada gambar.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 22:07:50 2020
4
5 @author: User
6 """
7
8 depth_acc = np.empty((19,3), float)
9 i = 0
10 for max_depth in range(1, 20):
11     lontong = tree.DecisionTreeClassifier(criterion="entropy",
12                                            max_depth=max_depth)
13     scores = cross_val_score(lontong, pecel_att, pecel_pass,
14                               cv=5)
15     depth_acc[i,0] = max_depth
16     depth_acc[i,1] = scores.mean()
17     depth_acc[i,2] = scores.std() * 2
18     i += 1
19
20 print(depth_acc)

```

```

[[1.0000000e+00 5.79746835e-01 1.01265823e-02]
 [2.0000000e+00 5.69620253e-01 2.77327877e-02]
 [3.0000000e+00 5.82278481e-01 7.33740595e-02]
 [4.0000000e+00 5.77215190e-01 3.03797468e-02]
 [5.0000000e+00 5.84810127e-01 9.39100607e-02]
 [6.0000000e+00 5.56962025e-01 1.01265823e-01]
 [7.0000000e+00 5.92405063e-01 6.28337906e-02]
 [8.0000000e+00 6.0000000e-01 6.71721477e-02]
 [9.0000000e+00 5.79746835e-01 6.86818266e-02]
 [1.0000000e+01 6.10126582e-01 7.74534610e-02]
 [1.1000000e+01 6.07594937e-01 5.77304013e-02]
 [1.2000000e+01 5.94936709e-01 9.47255035e-02]
 [1.3000000e+01 5.97468354e-01 5.16356406e-02]
 [1.4000000e+01 5.82278481e-01 5.77304013e-02]
 [1.5000000e+01 5.77215190e-01 6.11799796e-02]
 [1.6000000e+01 5.82278481e-01 7.67886121e-02]
 [1.7000000e+01 5.82278481e-01 7.51007442e-02]
 [1.8000000e+01 6.02531646e-01 5.68353021e-02]
 [1.9000000e+01 5.92405063e-01 7.05234849e-02]]

```

Gambar 2.63 hasil

12. terakhir yaitu pembuatan grafik untuk pembuatan grafik diambil data dari codingan sebelumnya yang 20 record tadi dengan cara mengimport libray matplotlib.pyplot yang di inisialisasi menjadi bakwankemudian inisialisasi tersebut di eksekusi. untuk lebih jelasnya codingannya seperti gambar dan untuk hasilnya seperti gambar berikut.

```

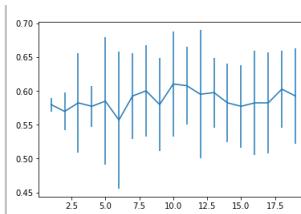
1 # -*- coding: utf-8 -*-
2 """
3 Created on Thu Mar  5 22:07:50 2020
4
5 @author: User
6 """
7
8 import matplotlib.pyplot as plt
9 fig, ax = plt.subplots()

```

```

10 ax.errorbar(depth_acc[:,0], depth_acc[:,1], yerr=depth_acc
11 [:,2])
plt.show()

```



Gambar 2.64 hasil

2.4.3 Penanganan Error

1. skrinsut error

```

In [2]: runfile('D:/SEMESTER 6/wert/2.py', wdir='D:/SEMESTER 6/wert')
Traceback (most recent call last):

  File "<ipython-input-2-4b3c06f7fd19>", line 1, in <module>
    runfile('D:/SEMESTER 6/wert/2.py', wdir='D:/SEMESTER 6/wert')

  File "C:\Users\User\Anaconda3\lib\site-packages\spyder_kernels\customize
\spydercustomize.py", line 827, in runfile
    execfile(filename, namespace)

  File "C:\Users\User\Anaconda3\lib\site-packages\spyder_kernels\customize
\spydercustomize.py", line 110, in execfile
    exec(compile(f.read(), filename, 'exec'), namespace)

  File "D:/SEMESTER 6/wert/2.py", line 10, in <module>
    pecel['pass'] = pecelapply(lambda row: 1 if (row['F1']+row['F2']+row['F3'])

NameError: name 'pecelapply' is not defined

```

Gambar 2.65 Error

2. kode error dan jenis errornya .

```

pecel['pass'] = pecelapply(lambda row: 1 if (row['G1']+row['G2']+row
>= 35 else 0, axis=1)
pecel = pecel.drop(['G1', 'G2', 'G3'], axis=1)
print(pecel.head())

```

NameError: name pecelapply is not defined

3. Solusi pemecahan masalah

pada codingan tersebut error karena pecelapply tergabung, seharusnya dipisahkan oleh titik



Date: 2020-03-05

PLAGIARISM SCAN REPORT



Exclude Url : None

Gambar 2.66 Error


2.4.4 Plagiat

2.5 1174039 Liyana Majdah Rahma

2.5.1 Teori

1. Jelaskan Apa Itu binari calssification dilengkapi ilustrasi gambar sendiri.

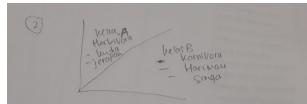
Klasifikasi biner merupakan tugas yang digunakan untuk mengklasifikasi suatu elemen-elemen dari himpunan tertentu yang terdiri dari dua kelompok yang ditentukan berdasarkan klasifikasi.



Gambar 2.67 contoh K-fold cross validation

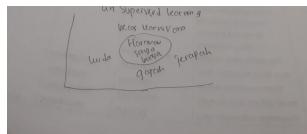
2. Jelaskan Apaitu supervised learning , unsupervised learning dan clustering dengan ilustrasi gambar sendiri.

supervised learning merupakan tipe learning dimana terdapat sebuah metode pendekatan yang mempunyai variable input dan output, serta terdapat variable yang ditargetkan dari pendekatan ini adalah mengelompokan suatu data ke data yang sudah ada sebelumnya. Dimana terdapat kelas A itu dikategorikan sebagai hewan herbivora seperti kuda, dan jerapah. Sedangkan kelas B dikategorikan sebagai hewan karnivora seperti harimau dan singa. Dilihat pada gambar.



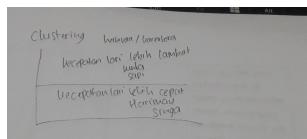
Gambar 2.68 contoh supervised learning

unsupervised merupakan tipe learning yang tidak memiliki data latih sehingga data yang sudah ada, kita kelompokkan data tersebut menjadi dua bagian ataupun menjadi tiga bagian. Untuk lebih jelasnya dapat dilihat pada gambar.



Gambar 2.69 contoh unsupervised learning

clustering merupakan proses yang mengklasifikasi berdasarkan suatu parameter dalam pententuannya. Untuk lebih jelasnya dilihat pada gambar berikut



Gambar 2.70 contoh clustering

3. Jelaskan apa itu evaluasi dan akurasi dan disertai ilustrasi contoh dengan gambar sendiri.

evaluasi merupakan suatu kegiatan yang dilakukan dari pengamatan berbagai macam bukti untuk mengukur dampak efektifitas dari objek atau proses yang berkaitan dengan spesifikasi yang telah ditentukan. sedangkan akurasi merupakan bagian dari evaluasi yang merupakan ketepatan

data terhadap suatu objek yang memiliki kriteria. Dapat dilihat pada gambar berikut

Evaluasi dan Akurasi	
Ojeng	Kemiripan 2 klas
Burung	Kemiripan 2 burung
Elang	Kemiripan 2 elang
Elang	Kemiripan 2 singa
Ojeng	Maximal 2 singa
Ojeng	Maximal 2 burung
Ojeng	Maximal 2 elang

Gambar 2.71 contoh evaluasi dan akurasi

4. Jelaskan bagaimana cara membuat Confusion Matrix, Buat confusion matrix sendiri.

Pada confusion matrix menentukan parameter yang akan di evaluasi contohnya elang,burung merpati,burung kakatua dengan tabel baris dan kolom berjumlah tida kemudian ditentukan dengan nilai miring pada setiap kolom saya beri nilai 12 dengan ketentuan setiap baris harus bernilai 12 jika kolom lain harus jumlah 15 jika tidak berarti data tidak akurat. Dapat dilihat pada gambar berikut

Confusion Matrix			
Ojeng	Burung	Elang	Singa
Ojeng	12	12	12
Burung	6	3	3
Elang	5	6	1
Singa	3	7	2

Gambar 2.72 contoh Confusion Matrix

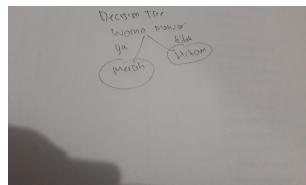
5. Jelaskan bagaimana K-fold cross validation bekerja dengan gambar ilustrasi contoh buatan sendiri. K-fold Cross Validation merupakan cara untuk melatih suatu mesin dimana di dalamnya terdapat data set yang dibagi menjadi dua yaitu untuk data testing dan data training contoh 1000 data merupakan data set dan 300 data digunakan untuk data testing kemudian 700 datanya. Sedangkan nilai testing akan dijadikan nilai inputan untuk rumus regresi linier. contohnya dapat dilihat pada gambar berikut :

K - Fold Cross	
1000	600
Testing Nilai Input	Training Nilai Label
	Bila Saja

Gambar 2.73 contoh K-fold cross validation

6. Jelaskan Apa itu decision tree dengan gambar ilustrasi contoh buatan sendiri.

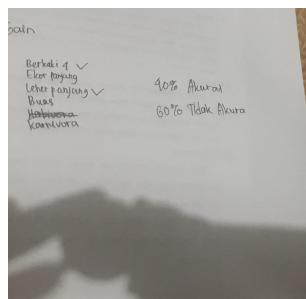
Decision tree merupakan implementasi dari binari clasification dimana pada pohon keputusan akan terdapat root atau akar dan cabang cabangnya yang nilainya seperti if contoh jika pada root berisi nilai warna mawar, apakah merah pada cabang satu bernilai iya dan pada cabang dua bernilai tidak jika nilainya iya berarti mawar dan jika tidak maka bukan mawar. agar lebih jelas dapat dilihat pada gambar decision tree berikut:



Gambar 2.74 contoh decision tree

7. jelaskan apa itu information gain dan entropi dengan gambar ilustrasi buatan sendiri.

information gain merupakan kriteria yang terdapat dalam pembagian sebuah objek seperti gigi tajam, berkaki 4, pemakan daging termasuk karnivora. untuk lebih jelasnya dapat dilihat pada gambar berikut :



Gambar 2.75 contoh information gain

sedangkan entropi merupakan ukuran keacakan dari informasi semakin tinggi entropi maka semakin sulit dalam menentukan keputusan contoh dalam menentukan satu gen semakin detail informasi maka akan semakin susah dalam menentukan keputusan.

2.5.2 Sikic-Learn

1. pada surcode pertama yang dapat dilihat pada gambar pada baris pertama di tuliskan import pandas as baso yang berarti mengimport library pandas. selanjutnya pada baris ke dua codingan tersebut berisi code tersebut terdapat variabel pecel yang berisi inisialisasi pandas dengan aksi untuk membaca vfile csv yang terdapat pada direktori pada komputer kemudian terdapat sep samadengan titik koma yang berarti pemisah field di dalam file tersebut merupakan titik koma. kemudian pada bagian akhir terdapat code len (nama variabel) yang berarti akan menghitung jumlah baris pada file tersebut. untuk hasilnya dapat dilihat pada gambar dibawah.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 22:56:28 2020
4
5 @author: Liyana
6 """
7
8 # load dataset (student mat pakenya)
9 import pandas as pd
10 jatibarang = pd.read_csv('D:\mata kuliah poltekppos\Python-
    Artificial-Intelligence-Projects-for-Beginners-master\
    Chapter01\dataset\student-mat.csv', sep=';')
11 print(len(jatibarang))

```



Gambar 2.76 hasil

2. Pada code selanjutnya akan ditambahkan fungsi untuk lulus atau gagal yang dibuat berupa kolom kolom yang di dalamnya terdapat nilai 0 dan 1 dimana 0 berarti gagal dan 1 berarti lulus. kemudian variabel pada codingan sebelumnya masih digunakan. dimana variabel pecel digunakan karena berisi nilai file csv kemudian dilakukan ekseskuji dengan parameter G1, G2, dan G3 dengan fungsi lambda yang berarti if bersarang atau if didalam if yang berarti nilai yang di eksekusi akan dilempar ke dalam setiap paramater sesuai dengan kriteria dan axis=1 yaitu nilai tersebut akan digunakan dari tiap baris data. sedangkan pada codingan variabel pecel di berikan aksi drop yaitu penurunan nilai pada bagian baris data. dan pada code pecel.head yaitu untuk mengeksekusi codingan sebelumnya untuk lebih jelasnya dapat dilihat pada gambar dan hasilnya seperti pada gambar berikut :

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 22:41:20 2020
4
5 @author: Liyana

```

```

6 """
7
8 # generate binary label (pass/fail) based on G1+G2+G3
9 # (test grades, each 0–20 pts); threshold for passing is sum
10 >=30
11 jatibarang[ 'pass' ] = jatibarang .apply(lambda row: 1 if (row[ 'G1' ]+row[ 'G2' ]+row[ 'G3' ]) 
12 >= 35 else 0, axis=1)
13 jatibarang = jatibarang .drop([ 'G1' , 'G2' , 'G3' ], axis=1)
14 print(jatibarang .head())

```

SCHOOL	sex	age	address	famsize	Pstatus	Mjob	Walc	health	absences	pass
G1	F	17	U	GT3 ...	L	T	3	4	0	
G2	F	15	U	LE3 ...	X	T	5	10	0	
G3	F	13	U	LE3 ...	X	T	3	2	1	
G4	F	16	U	GT3 ...	X	T	5	4	0	

Gambar 2.77 hasil

3. pada kodingan selanjutnya diguanakan untuk menambahkan nilai numerik berupa 0 dan 1 yang dirubah dari nilai tidak dan iya hal ini merupakan fungsi dari codingan get_dummies pada baris pertama pada gambar yang nilainya diambil dari variabel pecel yang telah di dekralasikan tadi banyaknya data numerik itu sendiri tergantung pada field dari kolom yang di camtumkan pada codingan dengan catatan field tersebut harus ada dalam data csv yang di import oleh codingan pertama tadi maka hasilnya akam merubah data dalam field tersebut menjadi 0 dan 1 untuk lebih jelasnya dapat di lihat pada gambar berikut;

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 22:54:20 2020
4
5 @author: Liyana
6 """
7
8 # use one-hot encoding on categorical columns
9 jatibarang = pd.get_dummies(jatibarang , columns=[ 'sex' , 'school' , 'address' , 'famsize' , 'Pstatus' , 'Mjob' , 'Fjob' , 'reason' , 'guardian' , 'schoolsups' , 'famsup' , 'paid' , 'activities' , 'nursery' , 'higher' , 'internet' , 'romantic' ])
10 jatibarang .head()

```

```
[15 rows x 31 columns]
Passing: 166 out of 395 (42.03%)
Traceback (most recent call last):
```

Gambar 2.78 hasil

4. selanjutnya pada codingan selanjutnya yaitu menentukan data training dan data testing dari dataset dimana variabel pecel yang berisi data csv tadi dibuat perbandingan 500 untuk data training dan sisanya yaitu 149 digunakan untuk data testing hal ini di lakukan pada baris ke 1 sampai ke 3 pada gambar kemudian nilai tersebut di turunkan brdasarkan baris

pada data set hal itu dapat dilihat pada baris ke 4 sampai ke 9 pada gambar kemudian selanjutnya mengimport library numpy yang berguna untuk oprasi vektor dan matrix karna data diatas berupa data matrix maka library ini di gunakan. untuk hasilnya dapat dilihat pada gambar.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 22:57:59 2020
4
5 @author: Liyana
6 """
7
8 # shuffle rows
9 jatibarang = jatibarang.sample(frac=1)
10 # split training and testing data
11 jatibarang_train = jatibarang[:500]
12 jatibarang_test = jatibarang[500:]
13 jatibarang_train.att = jatibarang_train.drop(['pass'], axis=1)
14 jatibarang_train.pass = jatibarang_train['pass']
15 jatibarang_test.att = jatibarang_test.drop(['pass'], axis=1)
16 jatibarang_test.pass = jatibarang_test['pass']
17 jatibarang.att = jatibarang.drop(['pass'], axis=1)
18 jatibarang.pass = jatibarang['pass']
19 # number of passing students in whole dataset:
20 import numpy as np
21 print("Passing: %d out of %d (%.2f%%)" % (np.sum(
    jatibarang.pass), len(jatibarang.pass), 100*float(np.sum(
        jatibarang.pass)) / len(jatibarang.pass)))

```

	school	sex	age	address	family size	...	Dalc	Walc	health	absences	pass
0	GP	F	18	U	G1	...	1	1	3	6	0
1	GP	F	19	U	G1	...	1	1	3	6	0
2	GP	F	15	U	L1	...	2	1	3	10	0
3	GP	F	15	U	G1	...	1	1	5	2	1
4	GP	F	16	U	G1	...	1	2	5	4	0

Gambar 2.79 hasil

- selanjutnya yaitu membuat pohon keputusan dapat lebih jelasnya dapat di lihat pada gambar. pada baris pertama yairu memasukan librari tree kemudian pada baris kedua dibuat variabel lontong dengan nilai DecisionTreeClasifier yang merupakan paket atau fungsi dari scikit-learn yang merupakan class yang mampu melakukan multi class. sedangkan max_depth=5 merupakan untuk penyesuaian data terhadap pohon keputusan itu sndiri. untuk hasilnya dapat dilihat pada gambar

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 23:01:08 2020
4
5 @author: Liyana
6 """
7
8 # fit a decision tree
9 from sklearn import tree

```

```
10 lobener = tree.DecisionTreeClassifier(criterion="entropy",  
           max_depth=5)  
11 lobener = lobener.fit(jatibarang_train_att,  
           jatibarang_train_pass)
```

[5 rows x 31 columns]
Passing: 166 out of 395 (42.03%)

Gambar 2.80 hasil

- selanjutnya yaitu pembuatan gambar dari pohon keputusan yang tadi di buta pada codingan sebelumnya pada baris pertama codingan ya itu mengimport library graphviz kemudian pada baris ke dua yaitu pem-berian nilai pada variabel baru dot data nilainya diambil dari pembuatan puhon keputusan tadi kemudian di tentukannya nilai benar dan salah dari codingan tersebut setelah itu dibuatlah sebuah variabel untuk menam-pung hasil eksekusi tersebut kemudian variabel tersebut di running untuk lebih jelasnya dapat di lihat pada gambar.kemudian hasilnya dapat dili-hat pada gambar.

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 23:05:14 2020
4
5 @author: Liyana
6 """
7
8 # visualize tree
9 import graphviz
10 dot_data = tree.export_graphviz(lobener, out_file=None, label=
11     ="all", impurity=False, proportion=True,
12                                     feature_names=list(
13                                         jatibarang_train_att), class_names=["fail", "pass"],
14                                         filled=True, rounded=True)
15 graph = graphviz.Source(dot_data)
16 graph
```

Gambar 2.81 hasil

7. selanjutnya pembuatan method untuk menyimpan data pohon dengan menarik data langsung dari pohon keputusan di buat tadi untuk code lebih jelasnya dapat dilihat pada gambar. kemudian intuk hasilnya dapat dilihat pada gambar berikut.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 23:08:17 2020
4
5 @author: Liyana
6 """
7
8 tree.export_graphviz(lobener, out_file="student-performance.
9         dot", label="all", impurity=False, proportion=True,
10                     feature_names=list(jatibarang_train_att)
11                     , class_names=["fail", "pass"], filled=True, rounded=True)
```

```

graph TD
    root[jatibarang] --> 1
    1 --> 2
    1 --> 3
    2 --> 4
    2 --> 5
    3 --> 6
    3 --> 7
    4 --> 8
    4 --> 9
    5 --> 10
    5 --> 11
    6 --> 12
    6 --> 13
    7 --> 14
    7 --> 15
    8 --> 16
    8 --> 17
    9 --> 18
    9 --> 19
    10 --> 20
    10 --> 21
    11 --> 22
    11 --> 23
    12 --> 24
    12 --> 25
    13 --> 26
    13 --> 27
    14 --> 28
    14 --> 29
    15 --> 30
    15 --> 31
    16 --> 32
    16 --> 33
    17 --> 34
    17 --> 35
    18 --> 36
    18 --> 37
    19 --> 38
    19 --> 39
    20 --> 40
    20 --> 41
    21 --> 42
    21 --> 43
    22 --> 44
    22 --> 45
    23 --> 46
    23 --> 47
    24 --> 48
    24 --> 49
    25 --> 50
    25 --> 51
    26 --> 52
    26 --> 53
    27 --> 54
    27 --> 55
    28 --> 56
    28 --> 57
    29 --> 58
    29 --> 59
    30 --> 60
    30 --> 61
    31 --> 62
    31 --> 63
    32 --> 64
    32 --> 65
    33 --> 66
    33 --> 67
    34 --> 68
    34 --> 69
    35 --> 70
    35 --> 71
    36 --> 72
    36 --> 73
    37 --> 74
    37 --> 75
    38 --> 76
    38 --> 77
    39 --> 78
    39 --> 79
    40 --> 80
    40 --> 81
    41 --> 82
    41 --> 83
    42 --> 84
    42 --> 85
    43 --> 86
    43 --> 87
    44 --> 88
    44 --> 89
    45 --> 90
    45 --> 91
    46 --> 92
    46 --> 93
    47 --> 94
    47 --> 95
    48 --> 96
    48 --> 97
    49 --> 98
    49 --> 99
    50 --> 100
    50 --> 101
    51 --> 102
    51 --> 103
    52 --> 104
    52 --> 105
    53 --> 106
    53 --> 107
    54 --> 108
    54 --> 109
    55 --> 110
    55 --> 111
    56 --> 112
    56 --> 113
    57 --> 114
    57 --> 115
    58 --> 116
    58 --> 117
    59 --> 118
    59 --> 119
    60 --> 120
    60 --> 121
    61 --> 122
    61 --> 123
    62 --> 124
    62 --> 125
    63 --> 126
    63 --> 127
    64 --> 128
    64 --> 129
    65 --> 130
    65 --> 131
    66 --> 132
    66 --> 133
    67 --> 134
    67 --> 135
    68 --> 136
    68 --> 137
    69 --> 138
    69 --> 139
    70 --> 140
    70 --> 141
    71 --> 142
    71 --> 143
    72 --> 144
    72 --> 145
    73 --> 146
    73 --> 147
    74 --> 148
    74 --> 149
    75 --> 150
    75 --> 151
    76 --> 152
    76 --> 153
    77 --> 154
    77 --> 155
    78 --> 156
    78 --> 157
    79 --> 158
    79 --> 159
    80 --> 160
    80 --> 161
    81 --> 162
    81 --> 163
    82 --> 164
    82 --> 165
    83 --> 166
    83 --> 167
    84 --> 168
    84 --> 169
    85 --> 170
    85 --> 171
    86 --> 172
    86 --> 173
    87 --> 174
    87 --> 175
    88 --> 176
    88 --> 177
    89 --> 178
    89 --> 179
    90 --> 180
    90 --> 181
    91 --> 182
    91 --> 183
    92 --> 184
    92 --> 185
    93 --> 186
    93 --> 187
    94 --> 188
    94 --> 189
    95 --> 190
    95 --> 191
    96 --> 192
    96 --> 193
    97 --> 194
    97 --> 195
    98 --> 196
    98 --> 197
    99 --> 198
    99 --> 199
    100 --> 200
    100 --> 201
    101 --> 202
    101 --> 203
    102 --> 204
    102 --> 205
    103 --> 206
    103 --> 207
    104 --> 208
    104 --> 209
    105 --> 210
    105 --> 211
    106 --> 212
    106 --> 213
    107 --> 214
    107 --> 215
    108 --> 216
    108 --> 217
    109 --> 218
    109 --> 219
    110 --> 220
    110 --> 221
    111 --> 222
    111 --> 223
    112 --> 224
    112 --> 225
    113 --> 226
    113 --> 227
    114 --> 228
    114 --> 229
    115 --> 230
    115 --> 231
    116 --> 232
    116 --> 233
    117 --> 234
    117 --> 235
    118 --> 236
    118 --> 237
    119 --> 238
    119 --> 239
    120 --> 240
    120 --> 241
    121 --> 242
    121 --> 243
    122 --> 244
    122 --> 245
    123 --> 246
    123 --> 247
    124 --> 248
    124 --> 249
    125 --> 250
    125 --> 251
    126 --> 252
    126 --> 253
    127 --> 254
    127 --> 255
    128 --> 256
    128 --> 257
    129 --> 258
    129 --> 259
    130 --> 260
    130 --> 261
    131 --> 262
    131 --> 263
    132 --> 264
    132 --> 265
    133 --> 266
    133 --> 267
    134 --> 268
    134 --> 269
    135 --> 270
    135 --> 271
    136 --> 272
    136 --> 273
    137 --> 274
    137 --> 275
    138 --> 276
    138 --> 277
    139 --> 278
    139 --> 279
    140 --> 280
    140 --> 281
    141 --> 282
    141 --> 283
    142 --> 284
    142 --> 285
    143 --> 286
    143 --> 287
    144 --> 288
    144 --> 289
    145 --> 290
    145 --> 291
    146 --> 292
    146 --> 293
    147 --> 294
    147 --> 295
    148 --> 296
    148 --> 297
    149 --> 298
    149 --> 299
    150 --> 300
    150 --> 301
    151 --> 302
    151 --> 303
    152 --> 304
    152 --> 305
    153 --> 306
    153 --> 307
    154 --> 308
    154 --> 309
    155 --> 310
    155 --> 311
    156 --> 312
    156 --> 313
    157 --> 314
    157 --> 315
    158 --> 316
    158 --> 317
    159 --> 318
    159 --> 319
    160 --> 320
    160 --> 321
    161 --> 322
    161 --> 323
    162 --> 324
    162 --> 325
    163 --> 326
    163 --> 327
    164 --> 328
    164 --> 329
    165 --> 330
    165 --> 331
    166 --> 332
    166 --> 333
    167 --> 334
    167 --> 335
    168 --> 336
    168 --> 337
    169 --> 338
    169 --> 339
    170 --> 340
    170 --> 341
    171 --> 342
    171 --> 343
    172 --> 344
    172 --> 345
    173 --> 346
    173 --> 347
    174 --> 348
    174 --> 349
    175 --> 350
    175 --> 351
    176 --> 352
    176 --> 353
    177 --> 354
    177 --> 355
    178 --> 356
    178 --> 357
    179 --> 358
    179 --> 359
    180 --> 360
    180 --> 361
    181 --> 362
    181 --> 363
    182 --> 364
    182 --> 365
    183 --> 366
    183 --> 367
    184 --> 368
    184 --> 369
    185 --> 370
    185 --> 371
    186 --> 372
    186 --> 373
    187 --> 374
    187 --> 375
    188 --> 376
    188 --> 377
    189 --> 378
    189 --> 379
    190 --> 380
    190 --> 381
    191 --> 382
    191 --> 383
    192 --> 384
    192 --> 385
    193 --> 386
    193 --> 387
    194 --> 388
    194 --> 389
    195 --> 390
    195 --> 391
    196 --> 392
    196 --> 393
    197 --> 394
    197 --> 395
    198 --> 396
    198 --> 397
    199 --> 398
    199 --> 399
    200 --> 400
    200 --> 401
    201 --> 402
    201 --> 403
    202 --> 404
    202 --> 405
    203 --> 406
    203 --> 407
    204 --> 408
    204 --> 409
    205 --> 410
    205 --> 411
    206 --> 412
    206 --> 413
    207 --> 414
    207 --> 415
    208 --> 416
    208 --> 417
    209 --> 418
    209 --> 419
    210 --> 420
    210 --> 421
    211 --> 422
    211 --> 423
    212 --> 424
    212 --> 425
    213 --> 426
    213 --> 427
    214 --> 428
    214 --> 429
    215 --> 430
    215 --> 431
    216 --> 432
    216 --> 433
    217 --> 434
    217 --> 435
    218 --> 436
    218 --> 437
    219 --> 438
    219 --> 439
    220 --> 440
    220 --> 441
    221 --> 442
    221 --> 443
    222 --> 444
    222 --> 445
    223 --> 446
    223 --> 447
    224 --> 448
    224 --> 449
    225 --> 450
    225 --> 451
    226 --> 452
    226 --> 453
    227 --> 454
    227 --> 455
    228 --> 456
    228 --> 457
    229 --> 458
    229 --> 459
    230 --> 460
    230 --> 461
    231 --> 462
    231 --> 463
    232 --> 464
    232 --> 465
    233 --> 466
    233 --> 467
    234 --> 468
    234 --> 469
    235 --> 470
    235 --> 471
    236 --> 472
    236 --> 473
    237 --> 474
    237 --> 475
    238 --> 476
    238 --> 477
    239 --> 478
    239 --> 479
    240 --> 480
    240 --> 481
    241 --> 482
    241 --> 483
    242 --> 484
    242 --> 485
    243 --> 486
    243 --> 487
    244 --> 488
    244 --> 489
    245 --> 490
    245 --> 491
    246 --> 492
    246 --> 493
    247 --> 494
    247 --> 495
    248 --> 496
    248 --> 497
    249 --> 498
    249 --> 499
    250 --> 500
    250 --> 501
    251 --> 502
    251 --> 503
    252 --> 504
    252 --> 505
    253 --> 506
    253 --> 507
    254 --> 508
    254 --> 509
    255 --> 510
    255 --> 511
    256 --> 512
    256 --> 513
    257 --> 514
    257 --> 515
    258 --> 516
    258 --> 517
    259 --> 518
    259 --> 519
    260 --> 520
    260 --> 521
    261 --> 522
    261 --> 523
    262 --> 524
    262 --> 525
    263 --> 526
    263 --> 527
    264 --> 528
    264 --> 529
    265 --> 530
    265 --> 531
    266 --> 532
    266 --> 533
    267 --> 534
    267 --> 535
    268 --> 536
    268 --> 537
    269 --> 538
    269 --> 539
    270 --> 540
    270 --> 541
    271 --> 542
    271 --> 543
    272 --> 544
    272 --> 545
    273 --> 546
    273 --> 547
    274 --> 548
    274 --> 549
    275 --> 550
    275 --> 551
    276 --> 552
    276 --> 553
    277 --> 554
    277 --> 555
    278 --> 556
    278 --> 557
    279 --> 558
    279 --> 559
    280 --> 560
    280 --> 561
    281 --> 562
    281 --> 563
    282 --> 564
    282 --> 565
    283 --> 566
    283 --> 567
    284 --> 568
    284 --> 569
    285 --> 570
    285 --> 571
    286 --> 572
    286 --> 573
    287 --> 574
    287 --> 575
    288 --> 576
    288 --> 577
    289 --> 578
    289 --> 579
    290 --> 580
    290 --> 581
    291 --> 582
    291 --> 583
    292 --> 584
    292 --> 585
    293 --> 586
    293 --> 587
    294 --> 588
    294 --> 589
    295 --> 590
    295 --> 591
    296 --> 592
    296 --> 593
    297 --> 594
    297 --> 595
    298 --> 596
    298 --> 597
    299 --> 598
    299 --> 599
    300 --> 600
    300 --> 601
    301 --> 602
    301 --> 603
    302 --> 604
    302 --> 605
    303 --> 606
    303 --> 607
    304 --> 608
    304 --> 609
    305 --> 610
    305 --> 611
    306 --> 612
    306 --> 613
    307 --> 614
    307 --> 615
    308 --> 616
    308 --> 617
    309 --> 618
    309 --> 619
    310 --> 620
    310 --> 621
    311 --> 622
    311 --> 623
    312 --> 624
    312 --> 625
    313 --> 626
    313 --> 627
    314 --> 628
    314 --> 629
    315 --> 630
    315 --> 631
    316 --> 632
    316 --> 633
    317 --> 634
    317 --> 635
    318 --> 636
    318 --> 637
    319 --> 638
    319 --> 639
    320 --> 640
    320 --> 641
    321 --> 642
    321 --> 643
    322 --> 644
    322 --> 645
    323 --> 646
    323 --> 647
    324 --> 648
    324 --> 649
    325 --> 650
    325 --> 651
    326 --> 652
    326 --> 653
    327 --> 654
    327 --> 655
    328 --> 656
    328 --> 657
    329 --> 658
    329 --> 659
    330 --> 660
    330 --> 661
    331 --> 662
    331 --> 663
    332 --> 664
    332 --> 665
    333 --> 666
    333 --> 667
    334 --> 668
    334 --> 669
    335 --> 670
    335 --> 671
    336 --> 672
    336 --> 673
    337 --> 674
    337 --> 675
    338 --> 676
    338 --> 677
    339 --> 678
    339 --> 679
    340 --> 680
    340 --> 681
    341 --> 682
    341 --> 683
    342 --> 684
    342 --> 685
    343 --> 686
    343 --> 687
    344 --> 688
    344 --> 689
    345 --> 690
    345 --> 691
    346 --> 692
    346 --> 693
    347 --> 694
    347 --> 695
    348 --> 696
    348 --> 697
    349 --> 698
    349 --> 699
    350 --> 700
    350 --> 701
    351 --> 702
    351 --> 703
    352 --> 704
    352 --> 705
    353 --> 706
    353 --> 707
    354 --> 708
    354 --> 709
    355 --> 710
    355 --> 711
    356 --> 712
    356 --> 713
    357 --> 714
    357 --> 715
    358 --> 716
    358 --> 717
    359 --> 718
    359 --> 719
    360 --> 720
    360 --> 721
    361 --> 722
    361 --> 723
    362 --> 724
    362 --> 725
    363 --> 726
    363 --> 727
    364 --> 728
    364 --> 729
    365 --> 730
    365 --> 731
    366 --> 732
    366 --> 733
    367 --> 734
    367 --> 735
    368 --> 736
    368 --> 737
    369 --> 738
    369 --> 739
    370 --> 740
    370 --> 741
    371 --> 742
    371 --> 743
    372 --> 744
    372 --> 745
    373 --> 746
    373 --> 747
    374 --> 748
    374 --> 749
    375 --> 750
    375 --> 751
    376 --> 752
    376 --> 753
    377 --> 754
    377 --> 755
    378 --> 756
    378 --> 757
    379 --> 758
    379 --> 759
    380 --> 760
    380 --> 761
    381 --> 762
    381 --> 763
    382 --> 764
    382 --> 765
    383 --> 766
    383 --> 767
    384 --> 768
    384 --> 769
    385 --> 770
    385 --> 771
    386 --> 772
    386 --> 773
    387 --> 774
    387 --> 775
    388 --> 776
    388 --> 777
    389 --> 778
    389 --> 779
    390 --> 780
    390 --> 781
    391 --> 782
    391 --> 783
    392 --> 784
    392 --> 785
    393 --> 786
    393 --> 787
    394 --> 788
    394 --> 789
    395 --> 790
    395 --> 791
    396 --> 792
    396 --> 793
    397 --> 794
    397 --> 795
    398 --> 796
    398 --> 797
    399 --> 798
    399 --> 799
    400 --> 800
    400 --> 801
    401 --> 802
    401 --> 803
    402 --> 804
    402 --> 805
    403 --> 806
    403 --> 807
    404 --> 808
    404 --> 809
    405 --> 810
    405 --> 811
    406 --> 812
    406 --> 813
    407 --> 814
    407 --> 815
    408 --> 816
    408 --> 817
    409 --> 818
    409 --> 819
    410 --> 820
    410 --> 821
    411 --> 822
    411 --> 823
    412 --> 824
    412 --> 825
    413 --> 826
    413 --> 827
    414 --> 828
    414 --> 829
    415 --> 830
    415 --> 831
    416 --> 832
    416 --> 833
    417 --> 834
    417 --> 835
    418 --> 836
    418 --> 837
    419 --> 838
    419 --> 839
    420 --> 840
    420 --> 841
    421 --> 842
    421 --> 843
    422 --> 844
    422 --> 845
    423 --> 846
    423 --> 847
    424 --> 848
    424 --> 849
    425 --> 850
    425 --> 851
    426 --> 852
    426 --> 853
    427 --> 854
    427 --> 855
    428 --> 856
    428 --> 857
    429 --> 858
    429 --> 859
    430 --> 860
    430 --> 861
    431 --> 862
    431 --> 863
    432 --> 864
    432 --> 865
    433 --> 866
    433 --> 867
    434 --> 868
    434 --> 869
    435 --> 870
    435 --> 871
    436 --> 872
    436 --> 873
    437 --> 874
    437 --> 875
    438 --> 876
    438 --> 877
    439 --> 878
    439 --> 879
    440 --> 880
    440 --> 881
    441 --> 882
    441 --> 883
    442 -->
```

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 23:09:58 2020
4
5 @author: Liyana
6 """
7
8 from sklearn.model_selection import cross_val_score
9 scores = cross_val_score(lobener, jatibarang_att,
10                         jatibarang_pass, cv=5)
11 # show average score and +/- two standard deviations away
12 #(covering 95% of scores)
13 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
14                                         std() * 2))

```

Accuracy: 0.59 (+/- 0.05)

Gambar 2.83 hasil

10. membuat rank akurasi dari 1 sampai 20 untuk melihat akurasi data apakah datatersebut terdapat di rata rata 60 persen atau tidak dengan cara membuat lagi variabel baru dengan nilai tree diadalamnya jadi ham-pir mirip seperti membuat pohon keputusan namun ini langsung dalam bentuk rata rata akurasi yanlebih spesifik untuk lebih jelasnya dpt dil-ihat pada gambar codingan berikut. dan untuk hasilnya dapat dilihat pada gambar berikut.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 23:10:49 2020
4
5 @author: Liyana
6 """
7
8 for max_depth in range(1, 100):
9     lobener= tree.DecisionTreeClassifier(criterion="entropy",
10                                         max_depth=max_depth)
11     scores = cross_val_score(lobener, jatibarang_att,
12                             jatibarang_pass, cv=5)
13     print("Max depth: %d, Accuracy: %0.2f (+/- %0.2f)" % (
14         max_depth, scores.mean(), scores.std() * 2))

```

```

Max depth: 1, Accuracy: 0.58 (+/- 0.01)
Max depth: 2, Accuracy: 0.58 (+/- 0.06)
Max depth: 3, Accuracy: 0.56 (+/- 0.06)
Max depth: 4, Accuracy: 0.56 (+/- 0.08)
Max depth: 5, Accuracy: 0.58 (+/- 0.05)
Max depth: 6, Accuracy: 0.58 (+/- 0.05)
Max depth: 7, Accuracy: 0.56 (+/- 0.05)
Max depth: 8, Accuracy: 0.56 (+/- 0.07)
Max depth: 9, Accuracy: 0.58 (+/- 0.18)
Max depth: 10, Accuracy: 0.57 (+/- 0.04)
Max depth: 11, Accuracy: 0.58 (+/- 0.06)
Max depth: 12, Accuracy: 0.57 (+/- 0.08)
Max depth: 13, Accuracy: 0.57 (+/- 0.10)
Max depth: 14, Accuracy: 0.55 (+/- 0.07)
Max depth: 15, Accuracy: 0.58 (+/- 0.08)
Max depth: 16, Accuracy: 0.56 (+/- 0.05)
Max depth: 17, Accuracy: 0.57 (+/- 0.09)
Max depth: 18, Accuracy: 0.57 (+/- 0.11)
Max depth: 19, Accuracy: 0.57 (+/- 0.09)
Max depth: 20, Accuracy: 0.57 (+/- 0.07)
Max depth: 21, Accuracy: 0.57 (+/- 0.06)
Max depth: 22, Accuracy: 0.58 (+/- 0.07)
Max depth: 23, Accuracy: 0.58 (+/- 0.10)

```

Gambar 2.84 hasil

11. untuk selanjutnya yaitu menentukan nilai untuk grafik hampir sama dengan nilai akurasi tadi pertama tentukan rank atau batasan nilai itu disini batasannya di mulai dari 1 sampai 20 dengan menggunakan nilai tree tadi maka hasilnya dapat ditentuka kemudian buat variabel i untuk penomoran tiap record yang keluar atau recod hadil dari eksekusi tree tersebut. untuk lebih jelasnya dapat dilihat pada gambar dan untuk hasilnya dapat dilihat pada gambar.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 23:11:44 2020
4
5 @author: Liyana
6 """
7
8 depth_acc = np.empty((19,3), float)
9 i = 0
10 for max_depth in range(1, 20):
11     lobener = tree.DecisionTreeClassifier(criterion="entropy",
12                                           max_depth=max_depth)
13     scores = cross_val_score(lobener, jatibarang_att,
14                             jatibarang_pass, cv=5)
15     depth_acc[i,0] = max_depth
16     depth_acc[i,1] = scores.mean()
17     depth_acc[i,2] = scores.std() * 2
18     i += 1
19
20 print(depth_acc)

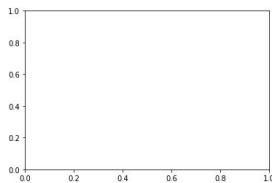
```

```
[[1.0000000e+00 5.79746835e-01 1.01265823e-02]
[2.0000000e+00 5.69620253e-01 2.77327877e-02]
[3.0000000e+00 5.82278481e-01 7.33740595e-02]
[4.0000000e+00 5.77215190e-01 3.03797468e-02]
[5.0000000e+00 5.84810127e-01 9.39106607e-02]
[6.0000000e+00 5.56962025e-01 1.01265823e-01]
[7.0000000e+00 5.92405063e-01 6.28337966e-02]
[8.0000000e+00 6.0000000e+00 6.71721477e-02]
[9.0000000e+00 5.79746835e-01 6.86618226e-02]
[1.0000000e+01 6.10126582e-01 7.74534610e-02]
[1.1000000e+01 6.07536337e-01 5.77304013e-02]
[1.2000000e+01 5.94938709e-01 9.40255035e-02]
[1.3000000e+01 5.82278481e-01 5.16250000e-02]
[1.4000000e+01 5.62278481e-01 5.77304013e-02]
[1.5000000e+01 5.77215190e-01 1.1799796e-02]
[1.6000000e+01 5.82278481e-01 7.67886121e-02]
[1.7000000e+01 5.82278481e-01 7.51007442e-02]
[1.8000000e+01 6.02531546e-01 5.68353021e-02]
[1.9000000e+01 5.92405063e-01 7.05234849e-02]]
```

Gambar 2.85 hasil

12. terakhir yaitu pembuatan grafik untuk pembuatan grafik diambil data dari codingan sebelumnya yang 20 record tadi dengan cara mengimport libray matplotlib.pyplot yang di inisialisasi menjadi bakwankemudian inisialisasi tersebut di eksekusi. untuk lebih jelasnya codingannya seperti gambar dan untuk hasilnya seperti gambar berikut.

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Sat Mar  7 23:12:39 2020
4
5 @author: Liyana
6 """
7
8 import matplotlib.pyplot as plt
9 fig , ax = plt.subplots()
10 ax.errorbar(depth_acc[:,0] , depth_acc[:,1] , yerr=depth_acc
11 [:,2])
12 plt.show()
```

**Gambar 2.86** hasil

2.5.3 Penanganan Error

- skrinsut error

```
Pada : C:\Users\laptop\PycharmProjects\untitled\src\main\java\com\example\untitled\Main.java", line 16, in method
    fig , ax = plt.subplots()
    ^
    No such variable 'plt' available.
  At : C:\Users\laptop\PycharmProjects\untitled\src\main\java\com\example\untitled\Main.java", line 16, in method
    fig , ax = plt.
```

Gambar 2.87 Error

- kode error dan jenis errornya .

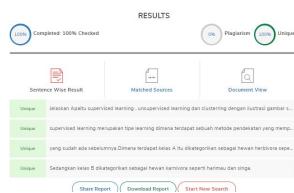
```
jatibarang['pass'] = jatibarangapply(lambda row: 1 if (row['G1']+row['G2']+row['G3'])>= 35 else 0, axis=1)
jatibarang = jatibarang.drop(['G1', 'G2', 'G3'], axis=1)
print(jatibarang.head())
```

NameError: name jatibarangapply is not defined

- Solusi pemecahan masalah

pada codingan tersebut error karena pecelapply tergabung, seharusnya dipisahkan oleh titik

2.5.4 Plagiat



Gambar 2.88 plagiat

2.6 1174043 Irvan Rizkiansyah

2.6.1 Teori

- Jelaskan Apa Itu binari classification dilengkapi ilustrasi gambar sendiri.

Binary Classification merupakan kegiatan yang berguna untuk mengklasifikasikan elemen-elemen dari sebuah himpunan tertentu ke dalam dua kelompok berbeda (memprediksi kelompok mana yang masing-masing dimiliki) berdasarkan dari aturan klasifikasi.



Gambar 2.89 contoh Binary Classification

- Jelaskan Apaitu supervised learning , unsupervised learning dan clustering dengan ilustrasi gambar sendiri.

Supervised learning adalah sebuah metode pendekatan yang mana sudah terdapat data yang dilatih, dan terdapat variabel yang ditargetkan

atau yang menjadi tujuan sehingga tujuan dari pendekatan ini adalah mengelompokan suatu data ke data yang sudah ada. contoh pada jeruk termasuk yang mengandung vitamin c maka jeruk telah di kategorikan kedalam vitamin c. sedangkan salmon mengandung vitamin d yang berarti salmon telah di kategorikan yang mengandung vitamin d untuk lebih jelasnya dapat dilihat pada gambar.



Gambar 2.90 contoh supervised learning

Sedangkan unsupervised learning tidak memiliki data latih, sehingga dari data yang ada, kita mengelompokan data tersebut menjadi dua bagian atau bahkan tiga bagian dan seterusnya. contoh Salmon di kategorikan ke dalam vitamin d untuk lebih jelasnya dapat dilihat pada gambar.



Gambar 2.91 contoh unsupervised learning

clustering merupakan peroses mengklasifikasikan yang berdasarkan suatu parameter dalam penentuannya contoh pada berat vitamin c memiliki berat 500 gr dan vitamin d memiliki berat 1000 gr yang berarti berat dibagi dua parameter yaitu lebih kecil samadengan 500 gram dan lebih besar dari 500 gram contoh pada gambar.



Gambar 2.92 contoh clustering

3. Jelaskan apa itu evaluasi dan akurasi dan disertai ilustrasi contoh dengan gambar sendiri.

evaluasi adalah pengumpulan pengumpulan dan pengamatan dari berbagai macam bukti untuk mengukur dampak efektifitas dari suatu objek, program, atau proses berkaitan dengan spesifikasi atau persyaratan yang telah di tetapkan sebelumnya. sedangkan akurasi itu sendiri merupakan bagian dari evaluasi yang merupakan ketepatan data terhadap suatu objek berdasarkan keriteria tertentu. kita dapat mengevaluasi seberapa baik model bekerja dengan mengukur akurasiinya. ketepatan akan di

definisikan sebagai persentase kasus yang diklasifikasikan dengan benar. hal ini berkaitan dengan confusion matrix pada materi selanjutnya. lebih jelasnya pada gambar berikut:



Gambar 2.93 contoh Evaluasi

- Jelaskan bagaimana cara membuat Confusion Matrix, Buat confusion matrix sendiri.

Dalam pembuatan confusion matrix tentukan parameter atau objek yang akan di evaluasi contoh udang, salmon, tuna buat tabel dengan baris dan kolom berjumlah tiga kemudian tentukan nilai miring pada setiap kolom tersebut disini saya memberi nilai 20 dengan ketentuan setiap baris harus berisi nilai 20 nilai tersebut jika terbagi ke kolom lain maka jumlahnya harus bernilai 20 jika tidak berarti data tersebut tidak akurat. untuk lebih jelanya dapat dilihat pada gambar berikut :

Confusion Matrix				
Actual	Udang	Salmon	Tuna	
Prediction	Udang	120	20	10
Udang	120	20	10	
Salmon	20	10	10	
Tuna	10	10	10	
Total	150	30	30	

Gambar 2.94 contoh Confusion Matrix

- Jelaskan bagaimana K-fold cross validation bekerja dengan gambar ilustrasi contoh buatan sendiri.

K-fold Cross Validation merupakan cara untuk melatih suatu mesin dimana di dalamnya terdapat data set yang dibagi menjadi dua yaitu untuk data testing dan data training contoh 1000 data merupakan data set dan 400 data digunakan untuk data testing kemudian 600 datanya digunakan untuk data training dimana data training tersebut digunakan untuk menentukan nilai bobot yang dimasukan kedalam rumus regresi linier. sedangkan nilai testing akan dijadikan nilai inputan untuk rumus regresi linier. contohnya dapat dilihat pada gambar berikut :



Gambar 2.95 contoh K-fold cross validation

- Jelaskan Apa itu decision tree dengan gambar ilustrasi contoh buatan sendiri.

Decision tree merupakan implementasi dari binari clasification dimana pada pohon keputusan akan terdapat root atau akar dan cabang cabangnya yang nilainya seperti if contoh pada root berisi nilai hidup di air, apakah ikan pada cabang satu bernilai iya dan pada cabang dua bernilai tidak jika nilainya iya berarti hidup di air dan jika tidak maka bukan hidup diair.



Gambar 2.96 contoh decision tree

7. jelaskan apa itu information gain dan entropi dengan gambar ilustrasi buatan sendiri.

informasian gain merupakan informasi atau keriteria dalam pembagian sebuah objek contoh information gain pada ikan yaitu hidup di air, berkoloni, berinsang. untuk lebih jelasnya dapat dilihat pada gambar berikut :



Gambar 2.97 contoh information gain

2.6.2 Scikit-Learn

- 1.

```

1 # load dataset (student mat pakenya)
2 import pandas as pd
3 jeruk = pd.read_csv('D:\student-mat.csv', sep=';')
4 print(len(jeruk))

```

```

In [19]: import pandas as pd
...: jeruk = pd.read_csv('D:\student-mat.csv', sep=';')
...: print(len(jeruk))
395

```

Gambar 2.98 Hasil Percobaan 1

- 2.

```

1 jeruk[ 'pass' ] = jeruk.apply(lambda row: 1 if (row[ 'G1']+row[ 'G2']+row[ 'G3']) >= 35 else 0, axis=1)
2 jeruk = jeruk.drop(['G1', 'G2', 'G3'], axis=1)
3 print(jeruk.head())

```

```
In [20]: jersk = pd.read_csv('jerks.csv')
jersk.groupby(lambda row: 1 if (row['G1']+row['G2']+row['G3'])>=15 else 0, axis=1)
.....
jersk = jersk.drop(['G1', 'G2', 'G3'], axis=1)
.....
print(jersk.head())
school sex age address famsize ... Dale health absences pass
0   GP   F  18    U   GT3 ...     1    1    3    3    0
1   GP   M  22    U   GT3 ...     1    1    3    3    0
2   GP   F  15    U   LT3 ...     2    3    3    3    10    0
3   GP   F  15    U   LT3 ...     1    1    5    2    1
4   GP   F  16    U   GT3 ...     1    2    5    4    0
```

15 rows x 21 columns

Gambar 2.99 Hasil Percobaan 2

3.

```
1 jeruk = pd.get_dummies(jeruk, columns=['sex', 'school', 'address', 'famsize', 'Pstatus', 'Mjob', 'Fjob', 'reason', 'guardian', 'schoolsupsup', 'famsup', 'paid', 'activities', 'nursery', 'higher', 'internet', 'romantic']) #  
Mongkonversi kategori variabel menjadi variabel indikator  
2 jeruk.head()#mengambil baris pertama dari cakue
```

Gambar 2.100 Hasil Percobaan 3

4.

```
1 jeruk = jeruk.sample(frac=1)
2 # split training and testing data
3 jeruk_train = jeruk [:500]
4 jeruk_test = jeruk [500:]
5 jeruk_train_att = jeruk_train.drop(['pass'], axis=1)
6 jeruk_train_pass = jeruk_train ['pass']
7 jeruk_test_att = jeruk_test.drop(['pass'], axis=1)
8 jeruk_test_pass = jeruk_test ['pass']
9 jeruk_att = jeruk.drop(['pass'], axis=1)
10 jeruk_pass = jeruk ['pass']
11 # number of passing students in whole dataset:
12 import numpy as np
13 print("Passing: %d out of %d (%.2f%%)" % (np.sum(jeruk_pass),
14     len(jeruk_pass),100*float(np.sum(jeruk_pass)) / len(
15         jeruk_pass)))
```

```
In [22]: jeruk = jeruk.sample(frac=1)
        # split training and testing data
        jeruk_train = jeruk[:100]
        jeruk_test = jeruk[100:]
        jeruk_train_pct = jeruk_train.drop(['pass'], axis=1)
        jeruk_train_pass = jeruk_train.drop(['pass'], axis=1)
        jeruk_test_pct = jeruk_test.drop(['pass'], axis=1)
        jeruk_test_pass = jeruk_test['pass'].values
        # print(jeruk_train_pct)
        # print(jeruk_train_pass)
        # print(jeruk_test_pct)
        # print(jeruk_test_pass)

        import numpy as np
        # print(Passing: 3d out of 3d (%d) (%.2f%%) (len(jeruk_pass)))
        Passing: 166 out of 395 (42%) (41.64%)
```

Gambar 2.101 Hasil Percobaan 4

5.

```

1 from sklearn import tree
2 anggur = tree.DecisionTreeClassifier(criterion="entropy",
3                                     max_depth=5)
4 anggur = anggur.fit(jeruk_train_att, jeruk_train_pass)
```

```
[In 28]: from sklearn import tree
...: anggur = tree.DecisionTreeClassifier(criterion="entropy", max_depth=5)
...: anggur = anggur.fit(jeruk_train_att, jeruk_train_pass)
```

Gambar 2.102 Hasil Percobaan 5

6.

```

1 import graphviz
2 dot_data = tree.export_graphviz(anggur, out_file=None, label=
3                                 "all", impurity=False, proportion=True,
4                                 feature_names=list(jeruk_train_att), class_names=["fail", "pass"],
5                                 filled=True, rounded=True)
6 graph = graphviz.Source(dot_data)
```

7.

```

1 tree.export_graphviz(anggur, out_file="student-performance.
2                               dot", label="all", impurity=False, proportion=True,
3                               feature_names=list(jeruk_train_att), class_names=["fail", "pass"], filled=True, rounded=True)
```

```
[In 47]: tree.export_graphviz(anggur, out_file="student-performance.dot", label="all",
...: impurity=False, proportion=True,
...: feature_names=list(jeruk_train_att), class_names=["fail",
...: "pass"], filled=True, rounded=True)
```

Gambar 2.103 Hasil Percobaan 7

8.

```
1 anggur.score(jeruk_test_att, jeruk_test_pass)
```

9.

```

1 from sklearn.model_selection import cross_val_score
2 scores = cross_val_score(anggur, jeruk_att, jeruk_pass, cv
3                           =5)
4 # show average score and +/- two standard deviations away
4 #(covering 95% of scores)
5 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
6                                         std() * 2))
```

```
In [52]: from sklearn.model_selection import cross_val_score
... scores = cross_val_score(anggur, jeruk_att, jeruk_pass, cv=5)
... print("Mean score: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2))
... print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2))

Accuracy: 0.58 (+/- 0.07)
```

Gambar 2.104 Hasil Percobaan 9

10.

```
1 for max_depth in range(1, 100):
2     anggur = tree.DecisionTreeClassifier(criterion="entropy",
3                                         max_depth=max_depth)
4     scores = cross_val_score(anggur, jeruk_att, jeruk_pass,
5                               cv=5)
5     print("Max depth: %d, Accuracy: %0.2f (+/- %0.2f)" % (
#%%%
```

```
In [53]: for max_depth in range(0, 100):
...     anggur = tree.DecisionTreeClassifier(criterion="entropy", max_depth=max_depth)
...     scores = cross_val_score(anggur, jeruk_att, jeruk_pass, cv=5)
...     print("Max depth: %d, Accuracy: %0.2f (+/- %0.2f)" % (max_depth, scores.mean(),
...     scores.std()))
...
Max depth: 0, Accuracy: 0.58 (+/- 0.01)
Max depth: 1, Accuracy: 0.58 (+/- 0.09)
Max depth: 2, Accuracy: 0.58 (+/- 0.07)
Max depth: 3, Accuracy: 0.57 (+/- 0.07)
Max depth: 4, Accuracy: 0.57 (+/- 0.04)
Max depth: 5, Accuracy: 0.57 (+/- 0.03)
Max depth: 6, Accuracy: 0.58 (+/- 0.05)
Max depth: 7, Accuracy: 0.58 (+/- 0.05)
Max depth: 8, Accuracy: 0.58 (+/- 0.07)
Max depth: 9, Accuracy: 0.58 (+/- 0.07)
Max depth: 10, Accuracy: 0.58 (+/- 0.07)
Max depth: 11, Accuracy: 0.58 (+/- 0.05)
Max depth: 12, Accuracy: 0.60 (+/- 0.09)
Max depth: 13, Accuracy: 0.60 (+/- 0.04)
Max depth: 14, Accuracy: 0.61 (+/- 0.09)
Max depth: 15, Accuracy: 0.61 (+/- 0.03)
Max depth: 16, Accuracy: 0.60 (+/- 0.09)
Max depth: 17, Accuracy: 0.60 (+/- 0.03)
Max depth: 18, Accuracy: 0.60 (+/- 0.08)
Max depth: 19, Accuracy: 0.60 (+/- 0.03)
Max depth: 20, Accuracy: 0.60 (+/- 0.10)
Max depth: 21, Accuracy: 0.60 (+/- 0.08)
Max depth: 22, Accuracy: 0.60 (+/- 0.08)
Max depth: 23, Accuracy: 0.60 (+/- 0.09)
Max depth: 24, Accuracy: 0.62 (+/- 0.10)
Max depth: 25, Accuracy: 0.62 (+/- 0.09)
Max depth: 26, Accuracy: 0.61 (+/- 0.06)
Max depth: 27, Accuracy: 0.61 (+/- 0.09)
Max depth: 28, Accuracy: 0.61 (+/- 0.07)
```

Gambar 2.105 Hasil Percobaan 10

11.

```
1 depth_acc = np.empty((19,3), float)
2 i = 0
3 for max_depth in range(1, 20):
4     anggur = tree.DecisionTreeClassifier(criterion="entropy",
5                                         max_depth=max_depth)
6     scores = cross_val_score(anggur, jeruk_att, jeruk_pass,
7                               cv=5)
8     depth_acc[i,0] = max_depth
9     depth_acc[i,1] = scores.mean()
10    depth_acc[i,2] = scores.std() * 2
11    i += 1
12
13 print(depth_acc)
```

Gambar 2.106 Hasil Percobaan 11

12.

```
1 import matplotlib.pyplot as plt
2 fig, ax = plt.subplots()
3 ax.errorbar(depth_acc[:,0], depth_acc[:,1], yerr=depth_acc
4 [:,2])
5 plt.show()
```

```
In [55]: import matplotlib.pyplot as plt
fig, ax = plt.subplots()
ax.errorbar(depth_acc[:,0], depth_acc[:,1], yerr=depth_acc[:,2])
plt.show()
```

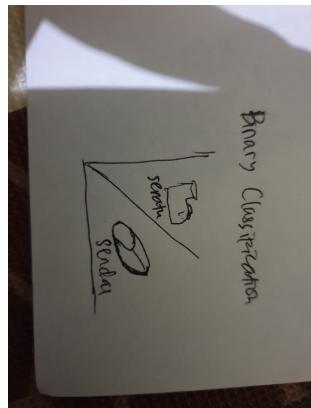
Gambar 2.107 Hasil Percobaan 12

2.7 1174040 - Hagan Rowlenstino A. S.

271 Teori

1. Jelaskan Apa Itu binari classification dilengkapi ilustrasi gambar sendiri.

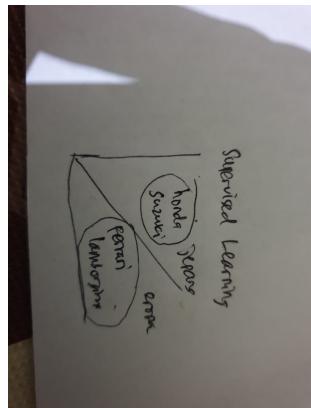
Binary Classification adalah sebuah aksi dimana dilakukannya klasifikasi dari sebuah kumpulan objek tertentu ke dalam dua buah kelompok yang berbeda berdasarkan beberapa fitur atau sifat-sifat.



Gambar 2.108 Binary Classification


2. Jelaskan Apaitu supervised learning , unsupervised learning dan clustering dengan ilustrasi gambar sendiri.

Supervised learning adalah sebuah cara untuk mengklasifikasikan kumpulan objek yang fitur ataupun sifat-sifatnya dari kelas nya sudah di tentukan sebelumnya. contoh pada merk mobil honda yang merupakan buatan jepang dan ferarri merupakan buatan eropa



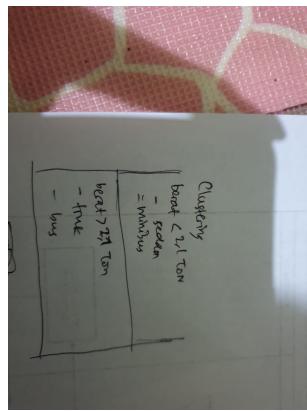
Gambar 2.109 Supervised

Unsupervised learning merupakan teknik pengklasifikasian tanpa perlu di supervised sebelumnya, dimana model tersebut yang akan bekerja sendiri untuk menemukan infomasi yang terkait. seperti pada contoh di gambar.



Gambar 2.110 Unsupervised

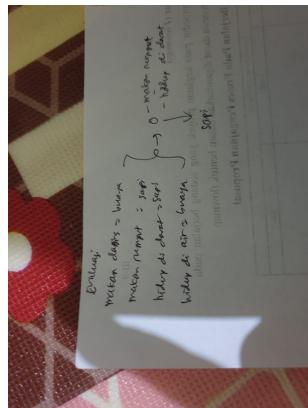
clustering merupakan metode pengelompokan data dengan membagi ke dalam beberapa kelompok. disini saya memberi contoh dengan kriteria kendaraan yang lebih dari 2,1 ton dan kurang dari 2,1 ton.



Gambar 2.111 clustering

3. Jelaskan apa itu evaluasi dan akurasi dan disertai ilustrasi contoh dengan gambar sendiri.

Evaluasi adalah proses yang sistematis yang ditujukan untuk menentukan ataupun membuat keputusan dengan memeriksa pernyataan-pernyataan yang telah ada sebelumnya. Akurasi adalah tingkat ketepatan dari sebuah data yang telah dihasilkan dari evaluasi yang telah dilakukan sebelumnya.



Gambar 2.112 Evaluasi

4. Jelaskan bagaimana cara membuat Confusion Matrix, Buat confusion matrix sendiri.

Untuk membuat confusion matrix kita perlu menentukan objek yang akan dievaluasi terlebih dahulu, setelah itu tentukan nilai miring pada setiap kolom objek tersebut lalu setiap baris dan jika lainnya di bagi baris dan kolom nya, harus bernilai sesuai nilai yang telah di tetapkan sebelumnya.

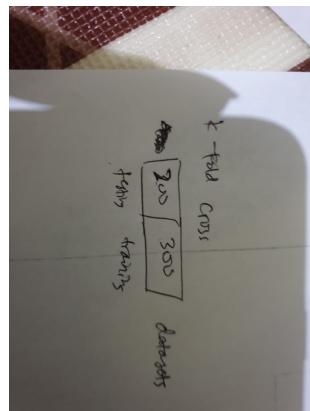
Confusion Matrix
 Contoh:
 Jika $TP = 10$, $FP = 5$, $TN = 15$, $FN = 5$
 Maka $Precision = \frac{TP}{TP + FP} = \frac{10}{10+5} = 0.6666$
 $Recall = \frac{TP}{TP + FN} = \frac{10}{10+5} = 0.6666$
 $F1-Score = \sqrt{Precision \cdot Recall} = \sqrt{0.6666 \cdot 0.6666} = 0.6666$

	Positif	Negatif
Positif	10	5
Negatif	5	15

Gambar 2.113 Confussion Matrix

5. Jelaskan bagaimana K-fold cross validation bekerja dengan gambar ilustrasi contoh buatan sendiri.

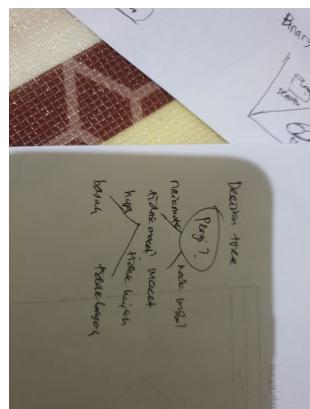
Melatih mesin dengan membagi data set yang akan diolah menjadi dua buah yaitu data testing dan training. sebagai contoh ada 500 data pada dataset, maka 200 sebagai data testing dan 300 akan menjadi data training.



Gambar 2.114 K-Fold

6. Jelaskan Apa itu decision tree dengan gambar ilustrasi contoh buatan sendiri.


Desicion tree adalah sebuah model prediksi yang menggunakan struktur yang menyerupai pohon ataupun sebuah hirarki



Gambar 2.115 Decision Tree

7. jelaskan apa itu information gain dan entropi dengan gambar ilustrasi buatan sendiri.

information Gain mengukur berapa banyak informasi yang sebuah fitur berikan kepada kita tentang kelas tersebut. sedangkan entropi menentukan bagaimana decision tree memilah data nya.



Gambar 2.116 Information Gain

2.7.2 scikit-learn

1. baris pertama yaitu mengimport library pandas. pada baris kedua ada fungsi read_csv untuk membaca file csv serta datanya dipisah dengan tanda titik koma lalu dimasukkan kedalam variable bernama pisang. fungsi pada baris terakhir yaitu untuk mengetahui panjang data / banyak data yang ada

```
1 import pandas as pd
2 pisang = pd.read_csv('student-mat.csv', sep=';')
3 print(len(pisang))
```

```
In [42]: import pandas as pd
....: pisang = pd.read_csv('student-mat.csv', sep=';')
....: print(len(pisang))
395
```

Gambar 2.117 No 1

2. Disini digunakan fungsi untuk menunjukkan lulus atau gagal dimana jika lulus ditandai dengan angka 1 dan gagal dengan angka 0. data yang diperlukan yaitu data dari csv yang sebelumnya karena itu masih digunakan variable pisang. yang selanjutnya akan dieksekusi.

```
1 pisang[ 'pass' ] = pisang.apply(lambda row: 1 if (row[ 'G1' ]+row
[ 'G2' ]+row[ 'G3' ]) >= 35 else 0, axis=1)
2 pisang = pisang.drop([ 'G1' , 'G2' , 'G3' ], axis=1)
3 print( pisang .head() )
```

#	school	sex	age	address	famsize	Pstatus	Mjob	Fjob	reason	guardian	schoolsup	famsup	paid	activities	nursery	higher	internet	romantic
0	GP	F	15	U	GT3	T	Atkin	Atkin	LE3	Atkin	N	N	0	0	0	0	0	
1	GP	F	17	U	GT3	T	Atkin	Atkin	LE3	Atkin	N	N	0	0	0	0	0	
2	GP	F	15	U	LE3	T	Atkin	Atkin	LE3	Atkin	N	N	0	0	0	0	0	
3	GP	F	15	U	GT3	T	Atkin	Atkin	LE3	Atkin	N	N	0	0	0	0	0	
4	GP	F	16	U	GT3	T	Atkin	Atkin	LE3	Atkin	N	N	0	0	0	0	0	

[5 rows x 31 columns]

Gambar 2.118 No 2

3. Disini yaitu mengkonversi kategori variable menjadi variable indikator

```

1 pisang = pd.get_dummies(pisang, columns=['sex', 'school', '',
2   address', 'famsize', 'Pstatus', 'Mjob', 'Fjob', 'reason', '',
3   guardian', 'schoolsup', 'famsup', 'paid', 'activities', '',
4   nursery', 'higher', 'internet', 'romantic']) #  
Mongkonversi kategori variabel menjadi variabel indikator
2 pisang.head()

```

#	age	Medu	Fedu	...	internet_yes	romantic_no	romantic_yes
0	18	4	4	...	0	1	0
1	17	3	3	...	1	1	0
2	15	1	1	...	1	1	0
3	15	2	2	...	1	0	1
4	16	3	2	...	0	1	0

[5 rows x 57 columns]

Gambar 2.119 No 3

4. bagian ini berfungsi untuk menentukan data training dan data testing dari dataset csv yang telah dimasukkan di dalam variable pisang tadi. lalu mengimport library numpy untuk operasi vektor serta matrix karena data diatas berupa matrix.

```

1 pisang = pisang.sample(frac=1)
2 # split training and testing data
3 pisang_train = pisang[:500]
4 pisang_test = pisang[500:]
5 pisang_train_att = pisang_train.drop(['pass'], axis=1)
6 pisang_train_pass = pisang_train['pass']
7 pisang_test_att = pisang_test.drop(['pass'], axis=1)
8 pisang_test_pass = pisang_test['pass']
9 pisang_att = pisang.drop(['pass'], axis=1)
10 pisang_pass = pisang['pass']
11 # number of passing students in whole dataset:
12 import numpy as np
13 print("Passing: %d out of %d (%.2f%%)" % (np.sum(pisang_pass),
14   , len(pisang_pass), 100*float(np.sum(pisang_pass)) / len(
15   pisang_pass)))

```

```

In [46]: pisang = pisang.sample(frac=1)
...: # split training and testing data
...: pisang_train = pisang[:500]
...: pisang_test = pisang[500:]
...: pisang_train_att = pisang_train.drop(['pass'], axis=1)
...: pisang_train_pass = pisang_train['pass']
...: pisang_test_att = pisang_test.drop(['pass'], axis=1)
...: pisang_test_pass = pisang_test['pass']
...: pisang_att = pisang.drop(['pass'], axis=1)
...: pisang_pass = pisang['pass']
...: # number of passing students in whole dataset:
...: import numpy as np
...: print("Passing: %d out of %d (%.2f%%)" % (np.sum(pisang_pass),
...: , len(pisang_pass), 100*float(np.sum(pisang_pass)) / len(pisang_pass)))
Passing: 166 out of 395 (42.05%)

```

Gambar 2.120 No 4

5. pada baris pertam kita mengimport tree dari library sklearn yang berfungsi untuk membuat desicion tree

```
1 from sklearn import tree
2 apel = tree.DecisionTreeClassifier(criterion="entropy",
3                                   max_depth=5)
4 apel = apel.fit(pisang_train_att, pisang_train_pass)
5 print(apel)
```

Gambar 2.121 No 5

- ## 6. mengimport library graphviz

```
1 import graphviz
2 dot_data = tree.export_graphviz(apel, out_file=None, label="all",
3                                 impurity=False, proportion=True, feature_names=list(
4                                     pisang_train.att), class_names=["fail", "pass"], filled=
5                                     True, rounded=True)
6 graph = graphviz.Source(dot_data)
7 graph
8 #%%
```

7. untuk menyimpan data dari tree dan menarik data langsung dari desicion tree

1 #%

```
In [54]: tree.export_graphviz(apel, out_file="student-performance.dot", label="all",
    impurity=False, proportion=True,
    ...
    feature_names=list(pisang_train_att),
    class_names=["fail", "pass"], filled=True, rounded=True)
```

Gambar 2.122 No 7

8. untuk mencari ketepatan data yang telah diolah

9. untuk menghitung akurasi ketepatan data

```
1 # show average score and +/- two standard deviations away
2 #(covering 95% of scores)
3 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
4 std() * 2))
5 #%%
```

```
In [54]: from sklearn.model_selection import cross_val_score
...: scores = cross_val_score(apel, pisang_att, pisang_pass, cv=5)
...: print("Meaningful 95% of scores")
...: print((scores.mean() - 30.21) / (-30.21) * (scores.mean(), scores.std() * 2))
Accuracy: 0.58 (+/- 0.06)
```

Gambar 2.123 No 9

10. membuat variable baru dengan nilai tree di dalamnya dengan bentuk akurasi yang spesifik

```
1 scores = cross_val_score(apel, pisang_att, pisang_pass,
2                         cv=5)
3 print("Max depth: %d, Accuracy: %0.2f (+/- %0.2f)" % (
4     max_depth, scores.mean(), scores.std() * 2))
#%%

```

```
Max depth: 88, Accuracy: 0.61 (+/- 0.05)
Max depth: 89, Accuracy: 0.61 (+/- 0.06)
Max depth: 90, Accuracy: 0.60 (+/- 0.07)
Max depth: 91, Accuracy: 0.62 (+/- 0.07)
Max depth: 92, Accuracy: 0.61 (+/- 0.09)
Max depth: 93, Accuracy: 0.61 (+/- 0.05)
Max depth: 94, Accuracy: 0.60 (+/- 0.08)
Max depth: 95, Accuracy: 0.60 (+/- 0.05)
Max depth: 96, Accuracy: 0.61 (+/- 0.08)
Max depth: 97, Accuracy: 0.62 (+/- 0.06)
Max depth: 98, Accuracy: 0.61 (+/- 0.06)
Max depth: 99, Accuracy: 0.61 (+/- 0.06)
```

Gambar 2.124 No 10

11. menentukan rank batasannya yaitu 1 sampai 20 dari nilai tree tadi yang digunakan untuk menentukan nilai untuk grafik

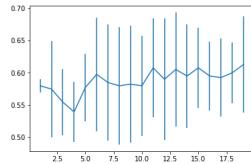
```
1 for max_depth in range(1, 20):
2     apel = tree.DecisionTreeClassifier(criterion="entropy",
3                                         max_depth=max_depth)
4     scores = cross_val_score(apel, pisang_att, pisang_pass,
5                               cv=5)
6     depth_acc[i, 0] = max_depth
7     depth_acc[i, 1] = scores.mean()
8     depth_acc[i, 2] = scores.std() * 2
9     i += 1
10 print(depth_acc)
#%
```

```
[{1.00000000e+00 5.79746835e-01 1.01265823e-02]
[2.00000000e+00 5.74683544e-01 7.44148783e-02]
[3.00000000e+00 5.54430580e-01 5.16356466e-02]
[4.00000000e+00 5.39240506e-01 4.69559304e-02]
[5.00000000e+00 5.24050532e-01 4.22762942e-02]
[6.00000000e+00 5.07468354e-01 3.82814976e-02]
[7.00000000e+00 5.04810127e-01 3.97221747e-02]
[8.00000000e+00 5.07946835e-01 9.11392405e-02]
[9.00000000e+00 5.82278481e-01 9.05749954e-02]
[1.00000000e+01 5.79746835e-01 7.74534610e-02]
[1.10000000e+01 5.80000000e-01 7.68245621e-02]
[1.20000000e+01 5.80573418e-01 7.61826597e-02]
[1.30000000e+01 6.05063201e-01 8.82814976e-02]
[1.40000000e+01 5.04936709e-01 8.00576623e-02]
[1.50000000e+01 6.0750494937e-01 6.20123986e-02]
[1.60000000e+01 5.04936709e-01 5.31042455e-02]
[1.70000000e+01 5.92405636e-01 5.07594937e-02]
[1.80000000e+01 6.00000000e-01 4.69559304e-02]
[1.90000000e+01 6.12658228e-01 7.44148783e-02]]
```

Gambar 2.125 No 11

12. mengimport matplotlib.pyplot yang akan digunakan untuk membuat grafik

```
1 ax.errorbar(depth_acc[:,0], depth_acc[:,1], yerr=depth_acc
              [:,2])
2 plt.show()
3 #%%
```

**Gambar 2.126** No 12

2.7.3 Penanganan Error

1. Screenshot

```
KeyError: "[('sex', 'school', 'address', 'famsize', 'Pstatus', 'Mjob', 'Fjob', 'reason', 'guardian', 'schoolsup', 'famsup', 'paid', 'activities', 'nursery', 'higher', 'internet', 'romantic') not in index"]
```

Gambar 2.127 Screenshot Error

2. Kode dan Jenis Error Jenis error adalah Key Error

```
1 pisang = pd.get_dummies(pisang, columns=['sex', 'school', 'address', 'famsize', 'Pstatus', 'Mjob', 'Fjob', 'reason', 'guardian', 'schoolsup', 'famsup', 'paid', 'activities', 'nursery', 'higher', 'internet', 'romantic']) #
Mongkonversi kategori variabel menjadi variabel indikator
2 kuda.head()
```

3. Solusi Penanganan Error Mengganti kuda dengan pisang

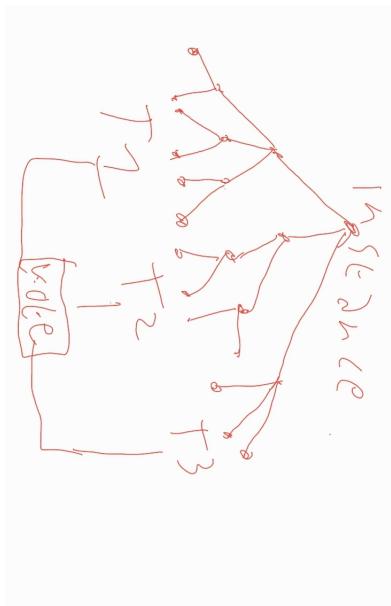
BAB 3

CHAPTER 3

3.0.1 Soal Teori

1. Jelaskan apa itu random forest, sertakan gambar ilustrasi buatan sendiri.

Random Forest atau hutan acak yaitu kumpulan dari pohon keputusan yang difungsikan untuk membaca objek tertentu sesuai dengan yang telah di sepakati untuk di baca pada sistem yang menggunakan pengkondisian seperti Artificial Intelligence. Pohon-pohon keputusan tersebut akan memunculkan hasil yang akan disimpulkan oleh random forest. Pembagian jumlah data yang dimasukan kedalam decision tree pada random forest akan di bagi sama rata sesuai dengan ketentuan tertentu yang disepakati saat sebelum membuat sebuah sistem tersebut.



Gambar 3.1 Contoh Confusion Matrix

2. Jelaskan cara membaca dataset khusus dan artikan makna setiap file dan isi field masing masing file. Yang harus dilakukan untuk membaca dataset adalah mendownload dataset yang sudah disediakan, lalu dibuka menggunakan IDE khusus dari python seperti Spyder untuk mengetahui isi dari dataset yang sudah didownload. Tergantung dari kebutuhan, file dapat berbentuk txt ataupun csv yang sudah sering digunakan karena bentuk datanya seperti tabel dan mudah untuk digunakan. Di dalam file akan mengandung class dari field atau kumpulan data hasil penilaian yang sudah dilakukan. Total datanya sendiri bisa sampai ribuan walaupun hanyalah kategori dan status seperti 0 dan 1.
3. Jelaskan apa itu Cross Validation. Cross Validation merupakan metode untuk mengevaluasi hasil dari sebuah penilaian yang telah digunakan dengan cara membagi dua bagian dari dataset menjadi data training dan data testing. Lalu data akan diolah sehingga muncul tingkat akurasi dari metode yang digunakan contoh pada metode random forest dataset nya dibagi menjadi dua menjadi data training dan data testing kemudian data tersebut diolah oleh mesin untuk melihat tingkat akurasinya maka akan muncul misalkan akurasi kebenaran sebesar 44 % begitu pula dengan menggunakan metode-metode yang lain seperti decision tree dan SVM.
4. Jelaskan apa arti score 44 % pada random forest, 27 % pada decision tree dan 29 % dari SVM. Maksud dari score 44 % tersebut yaitu nilai ketepatan atau kebenaran dari sebuah parameter, tingkat ketepatan

tersebut berpengaruh pada bagaimana mesin tersebut bisa menyatakan jenis burung tersebut dengan akurasi kebenaran 44 %. sedangkan pada metode decision tree yaitu 27 % yang berarti menunjukan bahwa tingkat akurasi ketepatan mesin jika mengerjakan sesuatu atau menyatakan keputusan dengan metode decision tree maka nilai kebenarannya bernilai 27 %. sedangkan dengan menggunakan metode SVM menunjukan hasil 29 % yang berarti nilai ketepatan atau kebenaran dalam memecahkan masalah menggunakan metode SVM ini sebesar 29 % . maka dari itu dapat di simpulkan bahwa dengan menggunakan metode random forest mesin dapat memecahkan masalah lebih akurat dibandingkan dengan menggunakan decision tree dan SVM.

5. Jelaskan bagaimana cara membaca confusion matriks dan contohnya memakai gambar atau ilustrasi sendiri. Cara untuk membaca confusion matrix adalah dengan cara memasukan parameter nilai yang ada pada datasets. Contohnya seperti pada dataset terdapat class yang disandingkan dengan nama burung untuk di normalisasi maka akan menunjukan nilai matrix yang mendekati nilai benar dalam bentuk angka misalkan 0,5 0,2 dan seterusnya mendekati nilai satu. di karenakan susahnya membaca nilai angka maka sering di ubah menjadi bentuk grafik. Untuk nilai - nilai yang ada, adalah sebagai berikut :


- True Positive : Data positif yang terdeteksi memiliki hasil benar
- False Positive : Data Positif yang terdeteksi memiliki hasil salah
- True Negative : Data negatif yang terdeteksi memiliki hasil benar
- False Negative : Data negatif yang terdeteksi memiliki hasil salah

		C ₁	C ₂
		Predict	Predict
Actual	C ₁	TP	FN
	C ₂	FP	TN

Gambar 3.2 Contoh Confusion Matrix

6. Jelaskan apa itu voting pada random forest disertai dengan ilustrasi gambar sendiri.

Voting merupakan data hasil dari decision tree yang terdapat pada random forest. Dimana hasil data tersebut di gunakan sebagai acuan untuk hasil dari random forest. sebagai contoh misalkan pada satu random forest terdapat enam decision tree untuk menentukan jenis pekerjaan orang, pada decision tree ke satu menyimpulkan bahwa pekerjaanya yaitu dosen , pada decision tree ke dua yaitu dosen kemudian pada decision tiga dosen , pada decision tree ke empat yaitu pekerja kantoran, pada decision tree ke lima yaitu pekerja kantoran dan pada decision tree ke enam yaitu dosen. maka pada random forest dapat menyimpulkan hasilnya yaitu dosen.



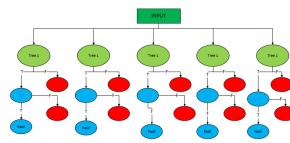
Gambar 3.3 Contoh Random Forest yang sudah Divote

3.1 Faisal Najib Abdullah / 1174042

3.1.1 Teori

1. Jelaskan apa itu random forest, sertakan gambar ilustrasi buatan sendiri.

Random Forest atau hutan acak yaitu kumpulan dari pohon-pohon keputusan yang digunakan untuk membaca objek tertentu yang telah di sepakati untuk di baca dalam AI. pohon-pohon keputusan tersebut akan memunculkan hasil-hasil yang akan disimpulkan oleh random forest. pembagian jumlah data yang dimasukan kedalam decision tree pada random forest akan di bagi sama rata sesuai codingan atau ketentuan tertentu yang di sepakati. misalkan data yang akan digunakan sebanyak 314 jika dalam satu decision tree di putuskan untuk memiliki 50 data maka pada satu random forest akan terdapat enam atau tujuh decision tree.



Gambar 3.4 contoh binari calssification

2. Jelaskan cara membaca dataset khusus dan artikan makna setiap file dan isi field masing masing file. langkah pertama download terlebih dahulu dataset nya kemudian buka menggunakan spyder bawaan anaconda untuk mengetahui isi dari dataset tersebut. biasanya data tersebut berisi

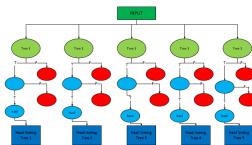
databerekstensi .txt yang di dalamnya terdapat class dari field atau data data yang ada data tersebut. contoh pada data burung ada field index dan angka, index biasanya berisi angka, angka angka tersebut memiliki makna yaitu pengganti nama atau jenis dari burung tersebut sedangkan pada field yang berisi nilai 0 dan 1 berarti menyatakan atau maknanya yaitu memberikan nilai ya dan tidak nilai tersebut di ubah menjadi angka nol dan satu karna data pada field tersebut harus berisi nilai boolean atau pilihan ya dan tidak di karenakan komputer susah membaca nilai dan tidak maka di ubahlah menjadi 0 dan 1 dengan 0 bernilai tidak dan 1 bernilai ya.

3. Jelaskan apa itu Cross Validation. Cross Validation merupakan cara untuk mengevaluasi hasil dari sebuah metode yang telah digunakan dengan cara membagi dua bagian dari dataset menjadi data training dan data testing kemudian data tersebut diolah hingga muncul tingkat akurasi dari metode yang digunakan contoh pada metode random forest dataset nya di bagi menjadi dua menjadi data training dan data testing kemudian data tersebut di olah oleh mesin untuk melihat tingkat akurasinya maka akan muncul misalkan akurasi kebenaran sebesar 44 % begitu pula dengan menggunakan metode-metode yang lain seperti decision tree dan SVM.
4. Jelaskan apa arti score 44 % pada random forest, 27 % pada decision tree dan 29 % dari SVM. maksud dari score 44 % tersebut yaitu nilai ketepatan atau kebenaran atau bisa disebut hasil dari random forest misalkan dengan metode random forest mesin membaca objek burung, mesin tersebut bisa menyatakan jenis burung tersebut dengan akurasi kebenaran 44 %. sedangkan pada metode decision tree yaitu 27 % yang berarti menunjukan bahwa tingkat akurasi ketepatan mesin jika mengerjakan sesuatu atau menyatakan keputusan dengan metode decision tree maka nilai kebenarannya bernilai 27 %. sedangkan dengan menggunakan metode SVM menunjukan hasil 29 % yang berarti nilai ketepatan atau kebenaran dalam memecahkan masalah menggunakan metode SVM ini sebesar 29 % . maka dari itu dapat di simpulkan bahwa dengan menggunakan metode random forest mesin dapat memecahkan masalah lebih akurat dibandingkan dengan menggunakan decision tree dan SVM.
5. Jelaskan bagaimana cara membaca confusion matriks dan contohnya memakai gambar atau ilustrasi sendiri. cara membaca confusio matrix dengan cara memasukan para meter nilai yang ada pada datasets contoh pada dataset terdapat class yang disandingkan dengan nama burung untuk di normalisasi maka akan menunjukan nilai matrix yang mendekati nilai benar dalam bentuk angka misalkan 0,5 0,2 dan seterusnya mendekati nilai satu. di karenakan susahnya membaca nilai angka maka sering di ubah menjadi bentuk grafik.
6. Jelaskan apa itu voting pada random forest disertai dengan ilustrasi gambar sendiri.

	Bueng 1	Bueng 2	Bueng 3	Bueng 4	Bueng 5	Bueng 6	Bueng 7	Bueng 8	Bueng 9	Bueng 10	Bueng 11
Bueng 1	1	0	0	0	0	0	0	0	0	0	0
Bueng 2	0	1	0	0	0	0	0	0	0	0	0
Bueng 3	0	0	1	0	0	0	0	0	0	0	0
Bueng 4	0	0	0	1	0	0	0	0	0	0	0
Bueng 5	0	0	0	0	1	0	0	0	0	0	0
Bueng 6	0	0	0	0	0	1	0	0	0	0	0
Bueng 7	0	0	0	0	0	0	1	0	0	0	0
Bueng 8	0	0	0	0	0	0	0	1	0	0	0
Bueng 9	0	0	0	0	0	0	0	0	1	0	0
Bueng 10	0	0	0	0	0	0	0	0	0	1	0
Bueng 11	0	0	0	0	0	0	0	0	0	0	1

Gambar 3.5 contoh binari calssification

Voting merupakan data hasil dari decision tree yang terdapat pada random forest. Dimana hasil data tersebut di gunakan sebagai acuan untuk hasil dari random forest. sebagai contoh misalkan pada satu random forest terdapat enam decision tree untuk menentukan jenis pekerjaan orang, pada decision tree ke satu menyimpulkan bahwa pekerjaanya yaitu dosen , pada decision tree ke dua yaitu dosen kemudian pada decision tiga dosen , pada decision tree ke empat yaitu pekerja kantoran, pada decision tree ke lima yaitu pekerja kantoran dan pada decision tree ke enam yaitu dosen. maka pada random forest dapat menyimpulkan hasilnya yaitu dosen.

**Gambar 3.6** contoh binari calssification

3.1.2 Praktikum

1. pandas

pada baris ke satu yaitu perintah mengimport library padas pada python atau anaconda kemudian di inisialisasikan menjadi kue. selanjutnya pada baris ke 3 terdapat nama variabel yaitu nama_kue_tradisional = yang di dalamnya terdapat tiga nama field yakni Name Kue, harga satuan dan terbilang kemudian pada baris ke tujuh terdapat variabel baru bernama Data_kue = kemudian didalamnya mendeskripsikan kue berdasarkan tipe DataFrame yang berisi variabel nama_kue_tradisional selanjutnya data tersebut di cetak pada console dengan perintah (Data_kue).

```

1 import pandas as kue
2 nama_kue = { 'Nama Kue' : [ 'Cuhcur' , 'Putri Noong' , 'Bugis' , 'Papais' , 'Ali-Ali' ] ,
3   'Harga Satuan' : [ 2000 , 5000 , 1500 , 2500 , 1000 ] , 'Terbilang' : [
4     'Dua Ribu Rupiah' , 'Lima Ribu Rupiah' ,
5     'Seribu Lima Ratus Rupiah' , 'Dua Ribu Limaratus Rupiah' , 'Seribu Rupiah' ] }
6 Data_kue = kue.DataFrame(nama_kue)
7 print(Data_kue)
  
```

	Nama Kue	Harga Satuan	Terbilang
0	Cucur	2000	Dua Ribu Rupiah
1	Putri Noong	5000	Lima Ribu Rupiah
2	Bugis	1500	Seribu Lima Ratus Rupiah
3	Papais	2500	Dua Ribu Limaratus Rupiah
4	Ali-Ali	1000	Seribu Rupiah

Process finished with exit code 0

Gambar 3.7 hasil

2. numpy

Arti tiap baris codingan pada aplikasi sederhana numpy adalah sebagai berikut : pada baris ke satu yaitu mengimport numpy yang di inisialisasi menjadi np kemudian pada baris ke tiga dibut variabel lala yang berisi numpy bertipekan arange 6 yang berarti berisi nilai array dari 0 sampai 5 kemudian pada baris ke empat di cetak hasilnya dengan memasukan perintah print (lala) selanjutnya yaitu membuat nilai array tiga dimensi pada baris ke tujuh dengan cara membuat variabel botak yang berisi rank nilainya kemudian dimensinya yaitu 4 3 3 kemudian variabel tersebut di print. selanjutnya pada baris ke 12 dibuat variabel nilai_array_1 dengan isian nilai array 1 2 3 4 kemudian pada baris ke 13 di buat variabe nilai_array_2 dengan nilai array 20 30 40 dan 50 selanjutnya pada baris ke 14 dibut nilai variabel Nilai_array_3 dengan rank 4 yang berarti berisi nilai dari 0 sampai 3 setelah itu di buat variabel hasil dimana isinya yaitu penjumlahan nilai_array_1+Nilai_array_3+Nilai_array_3 setelah itu nilai_array_1 , Nilai_array_3, dan Hasil di prin untuk melihat nilai dari array tersebut.

```

1 import numpy as np
2
3 lala = np.arange(6)
4 print(lala)
5
6 #array 3dimensi
7 lalae = np.arange(36).reshape(4,3,3)
8 print(lalae)
9
10 #penjumlahan array
11 nilai_array_1 = np.array([1,2,3,4])
12 nilai_array_2 = np.array([20,30,40,50])
13 nilai_array_3 = np.arange(4)
14 Hasil = nilai_array_1+nilai_array_3=nilai_array_3
15 print(nilai_array_1)
16 print(nilai_array_3)
17 print(Hasil)

```

3. matplotlib

Arti tiap baris aplikasi sederhana matplotlib pada baris ke satu yaitu memasukan library matplotlib.pyplot yang di definisikan menjadi plt ke-

```

Run: 2,2 <
[0 1 2 3 4 5]
[[[ 0  1  2]
 [ 3  4  5]
 [ 6  7  8]]]

[[[ 9 10 11]
 [12 13 14]
 [15 16 17]]]

[[[18 19 20]
 [21 22 23]
 [24 25 26]]]

[[[27 28 29]
 [30 31 32]
 [33 34 35]]]
[1 2 3 4]
[0 1 2 3]
[ 1 4 7 10]

Process finished with exit code 0

```

Gambar 3.8 hasil

mudian membuat variabel kelas_ti3 pada baris ke tiga yang berisi label setelah itu di buat variabel jumlah_mhs3 pada baris ke empat yang berisi nilai dari setiap label tersebut. begitu juga pada baris ke emam dan ke tujuh kemudian pada baris ke sembilan matplotlib mendefinisikan gambar dengan ukurannya dan pada baris ke 10 di dekralasikan subplot setelah itu pada baris ke 11 matplotlib mendefinisikan jenis grafik yang digunakan dan dimasukan variabel kelas dan jumlah_mhs. begitujuga oada baris ke 13 14 dan 15 setelah itu di buat title pada baris ke 17 dan matplotlib di show untuk mendapatkan hasil dari grafiknya.

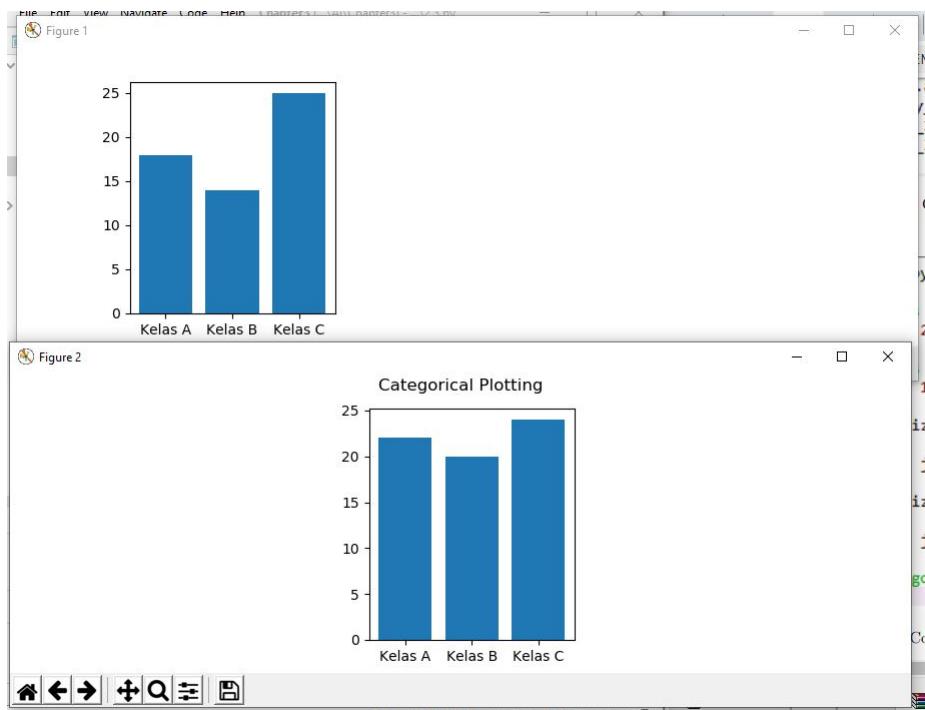
```

1 import matplotlib.pyplot as plt
2
3 kelas_ti3 = ['Kelas A', 'Kelas B', 'Kelas C']
4 jumlah_mhs3 = [18, 14, 25]
5
6 kelas_ti2 = ['Kelas A', 'Kelas B', 'Kelas C']
7 jumlah_mhs2 = [22, 20, 24]
8
9 plt.figure(1, figsize=(9,3))
10 plt.subplot(131)
11 plt.bar(kelas_ti3, jumlah_mhs3)
12 plt.figure(2, figsize=(9,3))
13 plt.subplot(132)
14 plt.bar(kelas_ti2, jumlah_mhs2)
15 plt.suptitle('Categorical Plotting')
16 plt.show()

```

4. Random Forest

Arti tiap baris hasil codingan random forest pada baris pertama random forest di import dari sklearn dengan ketentuan yaitu maksimal isi dari de-



Gambar 3.9 hasil

cision tree berisi 50 data dengan keadaan random dan dengan estimators 100 data ini berada dalam variabel clf kemudian setelah itu variabel clf di running berdasarkan data training dan data label yang telah di definisikan jumlahnya. kemudian variabel clf di running berdasarkan data training paling atas untuk memunculkan hasil data training lima paling atas. setelah itu data tersebut di di running scorenya untuk melihat tingkat akurasi yang dia kerjakan maka tingkat akurasi yang dihasilkan berada pada kisaran 0,437 atau kisaran 43 %.

```

1 from sklearn.ensemble import RandomForestClassifier
2 clf = RandomForestClassifier(max_features=50, random_state=0,
3     n_estimators=100)
4 clf.fit(df_train_att, df_train_label)
5 print(clf.predict(df_train_att.head()))
6 clf.score(df_test_att, df_test_label)

```

5. Confusion Matrix

arti codingan pada hasil tiap codingan confusion matrix pada baris pertama codingan tersebut mendeskripsikan atau mengimport confusion matrix dari sklearn kemudian dibuat variabel pred_labels dengan di isikan clf prdic df_test_att setelah itu membuat variabel cm yang isinya terdapat

```

Terminal: Local + 
>>>
>>> from sklearn.ensemble import RandomForestClassifier
>>> clf = RandomForestClassifier(max_features=50, random_state=0, n_estimators=100)
>>> clf.fit(df_train_att, df_train_label)
RandomForestClassifier(bootstrap=True, ccp_alpha=0.0, class_weight=None,
                      criterion='gini', max_depth=None, max_features=50,
                      max_leaf_nodes=None, max_samples=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, n_estimators=100,
                      n_jobs=None, oob_score=False, random_state=0, verbose=0,
                      warm_start=False)
>>> print(clf.predict(df_train_att.head()))
[[0 0 0 ... 0 0 1]
 [0 0 0 ... 0 0 1]
 [0 0 0 ... 0 0 1]
 [0 0 0 ... 0 1 0]
 [0 0 0 ... 0 0 0]]
>>> clf.score(df_test_att, df_test_label)
0.009503695881731784
>>> []

```

Gambar 3.10 hasil

data yang di buat confusion matrix berdasarkan data test setelah variabel cm akan di running yang mana akan menghasilkan gambar berupa matrix matrix tersebut berisi nilai nilai kebenaran yang mendekati nilai benar atau mutlak nilai benar.

```

1 from sklearn.metrics import confusion_matrix
2 pred_labels = clf.predict(df_test_att)
3 cm = confusion_matrix(df_test_label, pred_labels)
4 cm

```

```

>>> from sklearn.metrics import confusion_matrix
>>> pred_labels = clf.predict(df_test_att)
>>> cm = confusion_matrix(df_test_label, pred_labels)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
    File "C:\Users\najib\AppData\Local\Programs\Python\Python37\lib\site-packages\sklearn\metrics\_classification.py", line 270, in confusion_matrix
      raise ValueError("%s is not supported" % y_type)
ValueError: multilabel-indicator is not supported
>>> cm
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'cm' is not defined

```

Gambar 3.11 hasil

6. SVM dan Decision Tree

Arti dari setiap baris hasil codingan decision tree dan SVM pada tree masukan terlebih dahulu library tree setelah itu buat variabel clftree yang berisi decision tree setelah itu masukan nilai data training dan label yang telah di deklarasikan tadi setelah itu running variabel tersebut untuk mendapatkan score 0,266 kisaran 26 sampai 27 % akurasinya kemudian pada svm juga hampir sama masukan terlebih dahulu librarynya

setelah itu buat variabel clfsvm yang berarti berisi nilai data training dan data label dan pendeklarasian svm itu sendiri setelah itu di running untuk mendapatkan nilai akurasinya atau score sebesar 0,283 atau dalam kisaran 23 %.

```

1 from sklearn import tree
2 clftree = tree.DecisionTreeClassifier()
3 clftree.fit(df_train_att, df_train_label)
4 clftree.score(df_test_att, df_test_label)
5
6 from sklearn import svm
7 clfsvm = svm.SVC()
8 clfsvm.fit(df_train_att, df_train_label)
9 clfsvm.score(df_test_att, df_test_label)
```

```

>>> from sklearn import tree
>>> clftrree = tree.DecisionTreeClassifier()
>>> clftrree.fit(df_train_att, df_train_label)
DecisionTreeClassifier(ccp_alpha=0.0, class_weight=None, criterion='gini',
                      max_depth=None, max_features=None, max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=None,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, presort='deprecated',
                      random_state=None, splitter='best')
>>> clftrree.score(df_test_att, df_test_label)
0.0008044333214158026
>>> █
```

Gambar 3.12 hasil

7. Cross Validation

arti dari setiap baris hasil cross validation pada gambar?? tersebut diperlihatkan codingan error dikarenakan data training terlalu besar maka untuk mengatasinya dapat dilihat pada sub bab penanganan error

```

1 from sklearn.model_selection import cross_val_score
2 scores = cross_val_score(clf, df_train_att, df_train_label,
                           cv=5)
3 print("Accuracy: %.2f (+/- %.2f)" % (scores.mean(), scores.
                                         std() * 2))
```

```

>>> from sklearn.model_selection import cross_val_score
>>> scores = cross_val_score(clf, df_train_att, df_train_label, cv=5)
>>> print("Accuracy: %.2f (+/- %.2f)" % (scores.mean(), scores.std() * 2))
Accuracy: 0.00 (+/- 0.00)
>>> █
```

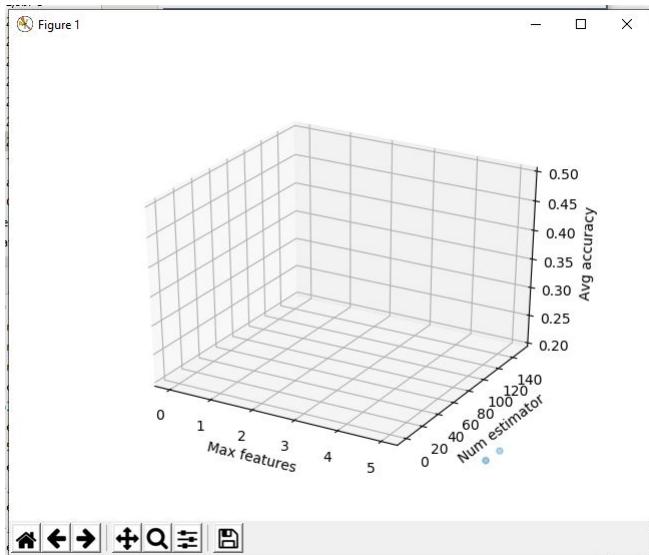
Gambar 3.13 hasil

8. program pengamatan arti dari hasil program pengamatan. perogram pengamatan ini menggunakan library matplotlib supaya hasil dari presentase hasil random forest, svm dan decision tree dapat di bandingkan dengan membuat variabel X Y Z kemudian memberikan label untuk setiap dimensinya untuk lebih jelas dapat dilihat gambar ?? yang menunjukan hasil perbandingan presentase dari tiga metode tersebut.

```

1 import matplotlib.pyplot as plt
2 from mpl_toolkits.mplot3d import Axes3D
3 from matplotlib import cm
4 fig = plt.figure()
5 fig.clf()
6 ax = fig.gca(projection='3d')
7 x = rf_params[:,0]
8 y = rf_params[:,1]
9 z = rf_params[:,2]
10 ax.scatter(x, y, z)
11 ax.set_zlim(0.2, 0.5)
12 ax.set_xlabel('Max features')
13 ax.set_ylabel('Num estimator')
14 ax.set_zlabel('Avg accuracy')
15 plt.show()

```



Gambar 3.14 hasil

3.1.3 Penanganan Error / cokro

Screenshot error

- Untuk gambar screenshot error

Code Errornya

- kode error pada screenshot ke satu yaitu dikarenakan `clfsvm.fit(df_train_att, df_train_label)` dikarenakan data trainingnya terlalu besar sehingga komputernya error.

```
In [48]: scoressvm = cross_val_score(clfsvm, df_train_att, df_train_label, cv=5)
...: print("Accuracy: %.2f (+/- %.2f)" % (scoressvm.mean(), scoressvm.std() * 2))
Traceback (most recent call last):

File "<ipython-input-48-d7a7153ce4e9>", line 1, in <module>
    scoressvm = cross_val_score(clfsvm, df_train_att, df_train_label, cv=5)

File "C:\ProgramData\Anaconda3\lib\site-packages\sklearn\model_selection\_validation.py", line 402, in cross_val_score
    error_score=error_score)

File "C:\ProgramData\Anaconda3\lib\site-packages\sklearn\model_selection\_validation.py", line 240, in cross_validate
    for train, test in cv.split(X, y, groups))

File "C:\ProgramData\Anaconda3\lib\site-packages\sklearn\externals\joblib\parallel.py", line 917, in __call__
    if self.dispatch_one_batch(iterator):

File "C:\ProgramData\Anaconda3\lib\site-packages\sklearn\externals\joblib\parallel.py", line 759, in dispatch_one_batch
    self._dispatch(tasks)

File "C:\ProgramData\Anaconda3\lib\site-packages\sklearn\externals\joblib\parallel.py", line 716, in _dispatch
    job = self._backend.apply_async(batch, callback=cb)

File "C:\ProgramData\Anaconda3\lib\site-packages\sklearn\externals\joblib\parallel_backends.py", line 182, in apply_async
    result = ImmediateResult(func)

File "C:\ProgramData\Anaconda3\lib\site-packages\sklearn\externals\joblib\parallel_backends.py", line 549, in __init__
    self.results = batch()

File "C:\ProgramData\Anaconda3\lib\site-packages\sklearn\externals\joblib\parallel.py", line 225, in __call__
    for func, args, kwargs in self.items]

File "C:\ProgramData\Anaconda3\lib\site-packages\sklearn\externals\joblib\parallel.py", line 225, in <listcomp>
```

Gambar 3.15 hasil

- untuk kode error pada screen shoot ke 2 sampai ke 4 dikarenakan pada kode berikut scores = cross_val_score(clf, df_train_att, df_train_label, cv=5) scorestree = cross_val_score(clftree, df_train_att, df_train_label, cv=5) dan scoressvm = cross_val_score(clfsvm, df_train_att, df_train_label, cv=5) hal ini di karenakan data trainingterlalu besar sehingga berdampak pada komputer sehingga library dari python tidak mampu mengolah data dan hasilnya menjadi error.

Solusi Untuk mengatasi Error

- solusinya untuk yang ke satu yaitu dengan cara merestart spyder atau mematikannya kemudian nyalakan kembali setelah itu jalankan code yang error tersebut di CMD cika dalam python CMD jalam maka bisa di running. setelah itu buka kembali spyder dan jalankan codingan dari awal hingga pada bagian SVM tunggu sebenar sampai muncul nilai akurasinya.
- solusi untuk mengatasi error tersebut yaitu dengan cara merubah bobot data pada data training.

```
df = imgatt2.join(imglabels)
df = df.sample(frac=1)
df_att = df.iloc[:, :312]
df_label = df.iloc[:, :312]
df_train_att = df_att[:600]
df_train_label = df_label[:600]
df_test_att = df_att[600:]
df_test_label = df_label[600:]
```

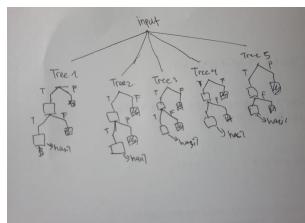
Gambar 3.16 hasil

3.2 1174040 - Hagan Rowlenstino A. S

3.2.1 Teori

1. Jelaskan apa itu random forest, sertakan gambar ilustrasi buatan sendiri.

Random forest adalah sebuah algoritma yang biasanya dipakai untuk mengklasifikasikan suatu data yang berjumlah besar. Dimana pengklasifikasianya itu menggunakan pohon atau tree yang digabungkan serta melewati training terlebih dahulu pada data sample nya. Akurasinya pun akan menjadi lebih baik apabila lebih banyak tree nya. Penentuan dari pengklasifikasianya sendiri diambil dari hasil voting yang terbentuk dan pemenangnya adalah tree atau pohon yang mempunyai voting terbanyak.



Gambar 3.17 Random Forest

2. Jelaskan cara membaca dataset khusus dan artikan makna setiap file dan isi field masing masing file

Download terlebih dulu data yang akan dibaca, lalu buka aplikasi spyder dan jalankan kode nya. data yang terdapat pada file tersebut adalah data folder ATTRIBUTE, IMAGES, PARTS yang memiliki kegunaannya sendiri yang dimana pada penggunaannya data yang dipakai adalah data image_attribute_label pada folder attribute, data image_class_labels dan data classes. file image_attribute_label berguna sebagai data awal yang digunakan untuk membaca data attribute yang terdapat pada masing - masing gambar burung yang ada. sedangkan file image_class_label berguna sebagai data yang akan membuat kolom baru pada dataset yang fungsinya adalah untuk memasukan hasil dari semua data yang dimiliki oleh imgatt2. dan file classes berguna sebagai dataset yang akan dipanggil oleh fungsi code untuk menampilkan nama dari data burung yang dimiliki. file image_attribute_label berisi tentang data attribute yang ada pada data gambar file burung yang dimiliki difolder image pada CUB-200-2011 file image_class_label berisi tentang data yang dimiliki oleh attribute dari image_attribute_label dimana data yang bernilai atau memiliki nilai disusun hingga menghasilkan data yang mudah dipahami. file classes berisi tentang data yang berguna untuk menampilkan data nama dari setiap data jenis burung yang dimiliki.

3. Jelaskan apa itu Cross Validation.

Cross Validation adalah teknik untuk memvalidasi sebuah model untuk menilai pengeneralisasian dari kumpulan data independen hasil statistik analis. Biasanya teknik ini digunakan untuk memprediksi dan memperkirakan keakuratan sebuah model pada saat di eksekusi.

4. Jelaskan apa arti score 44 % pada random forest, 27 % pada decision tree dan 29 % dari SVM.

arti score 27% pada decision tree adalah presentasi hasil dari perhitungan dataset acak, dan arti score 29% dari SVM adalah hasil pendekatan neural network. Hasil tersebut didapat dari hasil validasi silang untuk memastikan bahwa membagi training test dengan cara yang berbeda. Jadi 44% untuk random forest, 27% untuk pohon keputusan, dan 29% untuk SVM. Itu merupakan persentase keakuratan prediksi yang dilakukan pada saat testing menggunakan label pada dataset yang digunakan. Score mendefinisikan aturan evaluasi model.

5. Jelaskan bagaimana cara membaca confusion matriks dan contohnya memakai gambar atau ilustrasi sendiri.

Confusion matrix menggunakan rumus perhitungan dengan 4 keluaran, yang pertama adalah :

		Prediksi →	
		Negatif	Positive
Faktal	Mengalih	a	b
	Pompa	c	d

Gambar 3.18 Confusion Matrix

- Recall

$$d/(c + d) \quad (3.1)$$

- Precision

$$d/(b + d) \quad (3.2)$$

- Accuracy

$$(a + c)/(a + b + c + d) \quad (3.3)$$

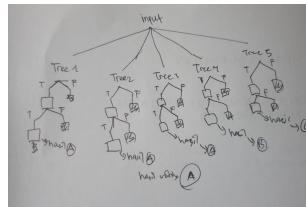
- Error Rate

$$(b + c)/(a + b + c + d) \quad (3.4)$$

6. Jelaskan apa itu voting pada random forest disertai dengan ilustrasi gambar sendiri.

Voting itu adalah hasil dari sebuah desicion tree, yang nanti akhirnya akan menjadi hasil dari random forest. sebagai contoh ada 5 desicion tree. Desicion tree pertama menyimpulkan A, yang ke dua juga A, dan ketiga

pun A, tetapi ke 4 B dan ke 5 C. maka random forest akan menyimpulkan hasilnya adalah A.



Gambar 3.19 Vote

3.2.2 Praktek

- Pandas Pada baris pertama kita mengimport library pandas dan menamainya sebagai pan , lalu memasukkan data kedalam variable data. setelah itu membuat dataframe dengan data yang telah di masukkan tadi, lalu membuat variable bernama cari untuk melihat semua data dari attribute Nama lalu print variable tersebut untuk melihat hasilnya pada console

```
import pandas as pan
data = {'Nama': ['Budi', 'Rina', 'Adi'], 'Umur':[12,13,11]}
pan.DataFrame(data)
cari = data['Nama']
print(cari)
```

Gambar 3.20 Pandas

```
In [6]: runfile('C:/Users/User/.spyder-py3/temp.py', wdir='C:/Users/User/.spyder-py3')
['Budi', 'Rina', 'Adi']
```

Gambar 3.21 hasil Pandas

- numpy Baris pertama adalah untuk mengimport library numpy dan menamainya sebagai num, lalu membuat sebuah variable bernama mat dan menggunakan fungsi arrange untuk membuat angka berurutan dari 1 sampai 25, mengapa ditulis satu sampai 26 karena urutan dimulai dari 0, lalu menggunakan reshape untuk mengubahnya menjadi matrix. dan terakhir print variable mat untuk menampilkan nya pada console

```
# 
# import numpy as num
# mat = num.arange(1,26).reshape(5,5)
# print(mat)
```

Gambar 3.22 Numpy


```
In [20]: runfile('C:/Users/l
[[ 1  2  3  4  5]
 [ 6  7  8  9 10]
[11 12 13 14 15]
[16 17 18 19 20]
[21 22 23 24 25]]
```

Gambar 3.23 Hasil Numpy

3. matplotlib Pertama import pyplot dari library matplotlib dan menamainya sebagai plt, lalu memasukkan data yang diinginkan kedalam variable x dan y . lalu menggunakan fungsi bar untuk membuat grafik bar yang isi datanya adalah x, dan y, lalu memberikan label pada sumbu x dan y dan memberikan judul pada grafik tersebut, dan menggunakan show() untuk menampilkan grafik

```
from matplotlib import pyplot as plt
x = [2012,2013,2014,2015,2016,2017]
y = [1000,2000,3000,4000,5000,6000]
plt.bar(x,y)
plt.xlabel('Tahun')
plt.ylabel('Jumlah Produksi')
plt.title('Jumlah Produksi Per Tahun')
plt.show()
```

Gambar 3.24 Matplotlib



Gambar 3.25 Hasil Matplotlib

4. Random Forest

Dari sklearn.ensamble mengimport RandomForestClassifier dan memberikan ketentuan dimana maksimal datanya adalah 50 dengan keadaan random serta estimatornya 100 dan dimasukkan kedalam variable clf lalu itu variabel clf di running berdasarkan data training dan data label yang telah di definisikan jumlahnya. kemudian variabel clf di running berdasarkan data training paling atas untuk memunculkan hasil data training lima paling atas. setelah itu data tersebut di di running scorenya untuk melihat tingkat akurasi yang dia kerjakan maka tingkat akurasi yang dihasilkan berada pada kisaran 0,448 atau 44%.

```
from sklearn.ensemble import RandomForestClassifier
clf = RandomForestClassifier(max_features=50, random_state=0, n_estimators=100)
clf.fit(df_train_att, df_train_label)
print(clf.predict(df_train_att.head()))
clf.score(df_test_att, df_test_label)
```

Gambar 3.26 Random Forest

```
In [112]: from sklearn.ensemble import RandomForestClassifier
...: clf = RandomForestClassifier(max_features=50, random_state=0,
...: n_estimators=100)
...: clf.fit(df_train_att, df_train_label)
...: print(clf.predict(df_train_att.head()))
...: clf.score(df_test_att, df_test_label)
[ 20  66  56  39 116]
Out[112]: 0.448257655750158
```

Gambar 3.27 Hasil Random Forest

5. Confussion Matrix dari sklearn.metrics mengimport confusion matrix kemudian dibuat variabel pred labels dengan di isikan clf prdic df test att setelah itu membuat variabel cm yang isinya terdapat data yang di buat confusion matrix berdasarkan data test setelah variabel cm akan di running yang mana akan menghasilkan gambar berupa matrix matrix tersebut berisi nilai nilai kebenaran yang mendekati nilai benar atau mutlak nilai benar.

```
from sklearn.metrics import confusion_matrix
pred_labels = clf.predict(df_test_att)
cm = confusion_matrix(df_test_label, pred_labels)
```

Gambar 3.28 Confusion Matrix

```
In [113]: from sklearn.metrics import confusion_matrix
...: pred_labels = clf.predict(df_test_att)
...: cm = confusion_matrix(df_test_label, pred_labels)
...: cm
Out[113]:
array([[ 7,  0,  0, ...,  0,  0,  0],
       [ 1, 12,  0, ...,  0,  1,  0],
       [ 1,  1,  7, ...,  0,  0,  0],
       ...,
       [ 0,  0,  1, ...,  4,  0,  0],
       [ 0,  0,  0, ...,  0, 11,  0],
       [ 0,  0,  0, ...,  0,  0, 16]], dtype=int64)
```

Gambar 3.29 Hasil Coonfusion Matrix

6. Decision Tree dan SVM masukan terlebih dahulu library tree setelah itu buat variabel clftree yang berisi decision tree setelah itu masukan nilai data training dan label yang telah di deklarasikan tadi setelah itu running variabel tersebut untuk mendapatkan score 0,266 kisaran 26 sampai 27% akurasinya

```
from sklearn import tree
clftree = tree.DecisionTreeClassifier()
clftree.fit(df_train_att, df_train_label)
clftree.score(df_test_att, df_test_label)
```

Gambar 3.30 Desicion Tree

```
In [114]: from sklearn import tree
...: clftree = tree.DecisionTreeClassifier()
...: clftree.fit(df_train_att, df_train_label)
...: clftree.score(df_test_att, df_test_label)
Out[114]: 0.26689545934530096
```

Gambar 3.31 Hasil Desicion Tree

Import terlebih dahulu library svm nya setelah itu buat variabel clfsvm yang berarti berisi nilai data training dan data label dan pendeklarasian svm itu sendiri setelah itu di running untuk mendapatkan nilai akurasinya atau score sebesar 0,283 atau dalam kisaran 23%.

```
from sklearn import svm
clfsvm = svm.SVC()
clfsvm.fit(df_train_att, df_train_label)
clfsvm.score(df_test_att, df_test_label)
```

Gambar 3.32 SVM

```
In [115]: from sklearn import svm
...: clfsvm = svm.SVC()
...: clfsvm.fit(df_train_att, df_train_label)
...: clfsvm.score(df_test_att, df_test_label)
Out[115]: 0.4799366420274551
```

Gambar 3.33 Hasil SVM

- Cross Validation mengimport cross_val_score dari sklearn.model_selection , lalu memasukkan variable variable yang akan di ukur keakuratan dari model yang digunakan lalu menampilkan nya di console, disini digunakan variable clf yaitu random forest.

```
:from sklearn.model_selection import cross_val_score
scores = cross_val_score(clf, df_train_att, df_train_label, cv = 5)
print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2))
```

Gambar 3.34 Cross Val Rand Forest

```
In [132]: from sklearn.model_selection import cross_val_score
...: scores = cross_val_score(clf, df_train_att, df_train_label, cv = 5)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2))
Accuracy: 0.45 (+/- 0.03)
```

Gambar 3.35 Hasil Cross Validaiton Random Forest

Disini memasukkan variable variable yang akan di ukur keakuratan dari model yang digunakan lalu menampilkan nya di console, disini digunakan variable clftree yaitu desicion Tree.

```
scoretree = cross_val_score(clftree, df_train_att, df_train_label, cv = 5)
print("Accuracy: %0.2f (+/- %0.2f)" % (scoretree.mean(), scoretree.std() * 2))
```

Gambar 3.36 Cross Vadation Desicion Tree

```
In [137]: scoresvm = cross_val_score(clfsvm, df_train_att, df_train_label, cv = 5)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scoresvm.mean(), scoresvm.std() * 2))
Accuracy: 0.26 (+/- 0.02)
```

Gambar 3.37 Hasil Cross Vadation Desicion Tree

Disini memasukkan variable variable yang akan di ukur keakuratan dari model yang digunakan lalu menampilkan nya di console, disini digunakan variable clfsvm yaitu svm.

```
scoresvm = cross_val_score(clfsvm, df_train_att, df_train_label, cv = 5)
print("Accuracy: %0.2f (+/- %0.2f)" % (scoresvm.mean(), scoresvm.std() * 2))
```

Gambar 3.38 Cross Vadation SVM

```
In [134]: scoresvm = cross_val_score(classif, df_train_att, df_train_label, cv = 5)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scoresvm.mean(), scoresvm.std() * 2))
Accuracy: 0.47 (+/- 0.03)
```

Gambar 3.39 Hasil Cross Vadation SVM

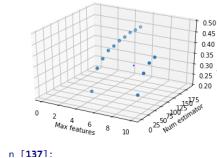
8. Program Pengamatan dan Hasil Pengamatan. perogram pengamatan ini menggunakan library matplotlib supaya hasil dari presentase hasil random forest, svm dan decision tree dapat di bandingkan dengan membuat variabel X Y Z kemudian memberikan label untuk setiap dimensinya untuk lebih jelas dapat dilihat gambar yang menunjukan hasil perbandingan presentase dari tiga metode tersebut.

```
max_estimators_opts = {'n_estimators': 10}
n_estimators_opts = {'n_estimators': 50}
n_estimators_opts = {'n_estimators': 100}
n_estimators_opts = {'n_estimators': 150}
n_estimators_opts = {'n_estimators': 200}
n_estimators_opts = {'n_estimators': 250}
n_estimators_opts = {'n_estimators': 300}
n_estimators_opts = {'n_estimators': 350}
n_estimators_opts = {'n_estimators': 400}
n_estimators_opts = {'n_estimators': 450}
n_estimators_opts = {'n_estimators': 500}
n_estimators_opts = {'n_estimators': 550}
n_estimators_opts = {'n_estimators': 600}
n_estimators_opts = {'n_estimators': 650}
n_estimators_opts = {'n_estimators': 700}
n_estimators_opts = {'n_estimators': 750}
n_estimators_opts = {'n_estimators': 800}
n_estimators_opts = {'n_estimators': 850}
n_estimators_opts = {'n_estimators': 900}
n_estimators_opts = {'n_estimators': 950}
n_estimators_opts = {'n_estimators': 1000}
n_estimators_opts = {'n_estimators': 1050}
n_estimators_opts = {'n_estimators': 1100}
n_estimators_opts = {'n_estimators': 1150}
n_estimators_opts = {'n_estimators': 1200}
n_estimators_opts = {'n_estimators': 1250}
n_estimators_opts = {'n_estimators': 1300}
n_estimators_opts = {'n_estimators': 1350}
n_estimators_opts = {'n_estimators': 1400}
n_estimators_opts = {'n_estimators': 1450}
n_estimators_opts = {'n_estimators': 1500}
n_estimators_opts = {'n_estimators': 1550}
n_estimators_opts = {'n_estimators': 1600}
n_estimators_opts = {'n_estimators': 1650}
n_estimators_opts = {'n_estimators': 1700}
n_estimators_opts = {'n_estimators': 1750}
n_estimators_opts = {'n_estimators': 1800}
n_estimators_opts = {'n_estimators': 1850}
n_estimators_opts = {'n_estimators': 1900}
n_estimators_opts = {'n_estimators': 1950}
n_estimators_opts = {'n_estimators': 2000}
n_estimators_opts = {'n_estimators': 2050}
n_estimators_opts = {'n_estimators': 2100}
n_estimators_opts = {'n_estimators': 2150}
n_estimators_opts = {'n_estimators': 2200}
n_estimators_opts = {'n_estimators': 2250}
n_estimators_opts = {'n_estimators': 2300}
n_estimators_opts = {'n_estimators': 2350}
n_estimators_opts = {'n_estimators': 2400}
n_estimators_opts = {'n_estimators': 2450}
n_estimators_opts = {'n_estimators': 2500}
n_estimators_opts = {'n_estimators': 2550}
n_estimators_opts = {'n_estimators': 2600}
n_estimators_opts = {'n_estimators': 2650}
n_estimators_opts = {'n_estimators': 2700}
n_estimators_opts = {'n_estimators': 2750}
n_estimators_opts = {'n_estimators': 2800}
n_estimators_opts = {'n_estimators': 2850}
n_estimators_opts = {'n_estimators': 2900}
n_estimators_opts = {'n_estimators': 2950}
n_estimators_opts = {'n_estimators': 3000}
n_estimators_opts = {'n_estimators': 3050}
n_estimators_opts = {'n_estimators': 3100}
n_estimators_opts = {'n_estimators': 3150}
n_estimators_opts = {'n_estimators': 3200}
n_estimators_opts = {'n_estimators': 3250}
n_estimators_opts = {'n_estimators': 3300}
n_estimators_opts = {'n_estimators': 3350}
n_estimators_opts = {'n_estimators': 3400}
n_estimators_opts = {'n_estimators': 3450}
n_estimators_opts = {'n_estimators': 3500}
n_estimators_opts = {'n_estimators': 3550}
n_estimators_opts = {'n_estimators': 3600}
n_estimators_opts = {'n_estimators': 3650}
n_estimators_opts = {'n_estimators': 3700}
n_estimators_opts = {'n_estimators': 3750}
n_estimators_opts = {'n_estimators': 3800}
n_estimators_opts = {'n_estimators': 3850}
n_estimators_opts = {'n_estimators': 3900}
n_estimators_opts = {'n_estimators': 3950}
n_estimators_opts = {'n_estimators': 4000}
n_estimators_opts = {'n_estimators': 4050}
n_estimators_opts = {'n_estimators': 4100}
n_estimators_opts = {'n_estimators': 4150}
n_estimators_opts = {'n_estimators': 4200}
n_estimators_opts = {'n_estimators': 4250}
n_estimators_opts = {'n_estimators': 4300}
n_estimators_opts = {'n_estimators': 4350}
n_estimators_opts = {'n_estimators': 4400}
n_estimators_opts = {'n_estimators': 4450}
n_estimators_opts = {'n_estimators': 4500}
n_estimators_opts = {'n_estimators': 4550}
n_estimators_opts = {'n_estimators': 4600}
n_estimators_opts = {'n_estimators': 4650}
n_estimators_opts = {'n_estimators': 4700}
n_estimators_opts = {'n_estimators': 4750}
n_estimators_opts = {'n_estimators': 4800}
n_estimators_opts = {'n_estimators': 4850}
n_estimators_opts = {'n_estimators': 4900}
n_estimators_opts = {'n_estimators': 4950}
n_estimators_opts = {'n_estimators': 5000}
```

Gambar 3.40 Program Pengamatan

```
...: for max_features in max_features_opts:
...:     for n_estimators in n_estimators_opts:
...:         if n_estimators > 10000:
...:             print("Max Features: %d, n_estimators: %d, accuracy: %0.2f (+/- %0.2f)" % (max_features, n_estimators, scoresvm.mean(), scoresvm.std() * 2))
...:         else:
...:             scoresvm = cross_val_score(classif, df_train_att, df_train_label, cv = 5)
...:             r1_params[1,2] = n_estimators
...:             r1_params[1,3] = scores.mean()
...:             r1_params[1,4] = scores.std()
...:             i += 1
...:             print("Max Features: %d, n_estimators: %d, accuracy: %0.2f (+/- %0.2f)" % (max_features, n_estimators, scoresvm.mean(), scoresvm.std() * 2))
...:             r2_params[1,2] = n_estimators
...:             r2_params[1,3] = scoresvm.mean()
...:             r2_params[1,4] = scoresvm.std()
...:             i += 1
...:             print("Max Features: %d, n_estimators: %d, accuracy: %0.2f (+/- %0.2f)" % (max_features, n_estimators, scoresrf.mean(), scoresrf.std() * 2))
...:             r3_params[1,2] = n_estimators
...:             r3_params[1,3] = scoresrf.mean()
...:             r3_params[1,4] = scoresrf.std()
...:             i += 1
...:             print("Max Features: %d, n_estimators: %d, accuracy: %0.2f (+/- %0.2f)" % (max_features, n_estimators, scoresdt.mean(), scoresdt.std() * 2))
...:             r4_params[1,2] = n_estimators
...:             r4_params[1,3] = scoresdt.mean()
...:             r4_params[1,4] = scoresdt.std()
```

Gambar 3.41 Hasil Program Pengamatan

**Gambar 3.42** Grafik Program Pengamatan

3.2.3 Penanganan Error

3.2.3.1 Skrinshoot error

1. Error 1

```
FileNotFoundError: File b'D:\Semester6\AI\Chapter3\UB_200_2011\07\Attributes\
\image_attribute_labels.txt' does not exist.
```

Gambar 3.43 Error 1

2. Error 2

```
File "c:\python-input-106-e6d717638a8a", line 1, in <module>
    image_labels = pd.read_csv('D:/Semester6/AI/Chapter3/UB_200_2011/
image_class_labels.txt', sep=' ', header=None, names=['imgId','label'])
NameError: name 'None' is not defined
```

Gambar 3.44 Error 2

3. Error 3

```
In [147]: from sklearn.ensemble import RandomForestClassifier
clf = RandomForestClassifier(max_features=50, random_state=0,
n_estimators=10)
...: clf.fit(df_train_attr, df_train_label)
...: pred_labels = clf.predict(df_test_attr)
...: clf.score(df_test_attr, df_test_label)
...: (clf.score(df_test_attr, df_test_label))
...: ---------------------------------------------------------------------------
ValueError: Input y has incorrect number of dimensions (1). Expected 2-dimensional array, got 1-dimensional array instead. Reshape y or (n_samples,), for example using ravel().
```

Gambar 3.45 Error 3

4. Error 4

```
File "c:\python-input-150-cb3ee086142", line 3, in <module>
    cm = confusion_matrix(df_test_label, pred_labels)
NameError: name 'confusion_matrix' is not defined
```

Gambar 3.46 Error 4

3.2.3.2 Kode Error dan Tipe Error

1. Error 1 type FileNotFoundError

```
input = pd.read_csv("D:\Semester6\AI\Chapter3\UB_200_2011\attributeImage_attributes_labels.txt", sep=",", header=None)
input.head()
```

Gambar 3.47 Kode Error 1

2. Error 2 type NameError

```
imglabels = pd.read_csv("D:\Semester6\AI\Chapter3\UB_200_2011\image_attributes_labels.txt", sep=",", header=None)
imglabels = imglabels.set_index('imgID')
```

Gambar 3.48 Kode Error 2

3. Error 3 type DataConversionWarning

```
from sklearn.ensemble import RandomForestClassifier
clf = RandomForestClassifier(max_features=50, random_state=0, n_estimators=100)
clf.fit(df_train_att, df_train_label)
pred_labels = clf.predict(df_test_att)
clf.score(df_test_att, df_test_label)
```

Gambar 3.49 Kode Error 3

4. Error 4 type NameError

```
from sklearn.metrics import confusion_matrix
pred_labels = clf.predict(df_test_att)
cm = confusion_matrix(df_test_label, pred_labels)
```

Gambar 3.50 Kode Error 4

3.2.3.3 Solusi

1. Mengganti back slash menjadi slash biasa

```
D:\Semester6\AI\Chapter3\UB_200_2011\attributeImage_attributes_labels.txt
```

Gambar 3.51 Fix Error 1

2. Mengubah huruf depan katan none menjadi huruf besar

Gambar 3.52 Fix Error 2

3. Menambahkan label kedalam variable

```

df_train_att = df_att[:8000]
df_train_label = df_label[:8000]
df_test_att = df_att[8000:]
df_test_label = df_label[8000:]

df_train_label = df_train_label['label']
df_test_label = df_test_label['label']

```

Gambar 3.53 Fix Error 3

- Mengilangkan 1 huruf s

```

cm = confusion_matrix(df_test_label, pred_labels)

```

Gambar 3.54 Fix Error 4


3.3 1174050 Dika Sukma Pradana

3.3.1 Teori

- Jelaskan apa itu random forest, sertakan gambar ilustrasi buatan sendiri.

Random Forest adalah konstruk data yang diterapkan pada machine learning yang mengembangkan sejumlah besar pohon keputusan acak yang menganalisis sekumpulan variabel. Jenis algoritma ini membantu meningkatkan cara teknologi menganalisis data yang kompleks. Juga merupakan algoritma machine learning yang fleksibel, mudah digunakan, bahkan tanpa penyetelan hyper-parameter, dengan hasil yang baik. Ini juga merupakan salah satu algoritma yang paling banyak digunakan, karena kesederhanaan dan faktanya dapat digunakan untuk tugas klasifikasi dan regresi.

Dibawah ini merupakan salah satu ilustrasi penggunaan Random Forest.

**Gambar 3.55** Random Forest

- Jelaskan cara membaca dataset khusus dan artikan makna setiap file dan isi field masing masing file. Dataset adalah kumpulan data. Paling umum

satu data set sesuai dengan isi tabel database tunggal, atau matriks data statistik tunggal, di mana setiap kolom tabel mewakili variabel tertentu, dan setiap baris sesuai dengan anggota tertentu dari dataset yang diperlukan.

- Gunakan librari Pandas pada python untuk dapat membaca dataset dengan format text file.
 - Setelah itu, buat variabel baru "dataset" yang berisikan perintah untuk membaca file csv.
 - Memanggil Librari Panda untuk membaca dataset
 - Membuat variabel "Dataset" yang berisikan pdreadcsv untuk membaca dataset. Pada contoh ini menggunakan txt tapi tetap bisa membaca datasetnya, mengapa? Karena pada saat dijalankan librari panda secara otomatis akan mengubah data dalam bentuk text file ke format csv.
3. Jelaskan apa itu Cross Validation. Cross Validation adalah prosedur resampling yang digunakan untuk mengevaluasi model machine learning pada sampel data yang terbatas. Prosedur ini memiliki parameter tunggal yang disebut k yang mengacu pada jumlah grup tempat sampel data yang akan dibagi. Karena itu, prosedur ini sering disebut k-fold cross-validation. Proses penentuan apakah hasil numerik yang mengukur hubungan yang dihipotesiskan antar variabel, dapat diterima sebagai deskripsi data, dikenal sebagai Validationi. Umumnya, estimasi kesalahan untuk model dibuat setelah training, lebih dikenal sebagai evaluasi residu. Dalam proses ini, estimasi numerik dari perbedaan respons yang diprediksi dan yang asli dilakukan, juga disebut kesalahan training. Namun, ini hanya memberi kita gambaran tentang seberapa baik model kita pada data yang digunakan untuk melatihnya. Sekarang mungkin bahwa model tersebut kurang cocok atau overfitting data. Jadi, masalah dengan teknik evaluasi ini adalah bahwa itu tidak memberikan indikasi seberapa baik pelajar akan menggeneralisasi ke set data independen / tidak terlihat. Model ini dikenal sebagai Cross Validation.
 4. Jelaskan apa arti score 44 % pada random forest, 27 % pada decision tree dan 29 % dari SVM. Itu merupakan presentase keakurasi prediksi yang dilakukan pada saat testing menggunakan label pada dataset yang digunakan. Score merupakan mendefinisikan aturan evaluasi model. Maka pada saat dijalankan akan muncul persentase tersebut yang menunjukkan keakurasi atau keberhasilan dari prediksi yang dilakukan. Jika menggunakan Random Forest maka hasilnya 40%, jika menggunakan Decission Tree hasil prediksinya yaitu 27% dan pada SVM 29% .
 5. Jelaskan bagaimana cara membaca confusion matriks dan contohnya memakai gambar atau ilustrasi sendiri. Perhitungan Confusion Matriks dapat di-

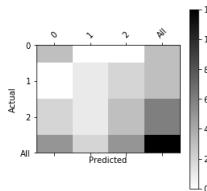
lakukan sebagai berikut. Disini saya menggunakan data yang dibuat sendiri untuk menampilkan data aktual dan prediksi.

- Import librari Pandas, Matplotlib, dan Numpy.
- Buat variabel y actu yang berisikan data aktual.
- Buat variabel y pred berisikan data yang akan dijadikan sebagai prediksi.
- Buat variabel df confusion yang berisikan crosstab untuk membangun tabel tabulasi silang yang dapat menunjukkan frekuensi kemunculan kelompok data tertentu.
- Pada variabel df confusion definisikan lagi nama baris yaitu Actual dan kolomnya Predicted
- Kemudian definisikan suatu fungsi yang diberi nama plot confusion matrix yang berisikan pendefinisian confusion matrix dan juga akan di plotting.

```

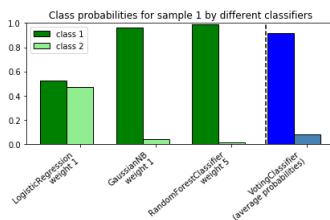
1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 16 20:29:09 2020
4
5 @author: User
6 """
7
8 import numpy as np
9 import matplotlib.pyplot as plt
10 import pandas as pd
11 y_actu = pd.Series([2, 0, 2, 2, 0, 1, 1, 2, 2, 0, 1, 2],
12                    name='Actual')
13 y_pred = pd.Series([0, 0, 2, 1, 0, 2, 1, 0, 2, 0, 2, 2],
14                    name='Predicted')
15 df_confusion = pd.crosstab(y_actu, y_pred)
16 df_confusion = pd.crosstab(y_actu, y_pred, rownames=['Actual'],
17                           colnames=['Predicted'], margins=True)
18 def plot_confusion_matrix(df_confusion, title='Confusion
19                           matrix', cmap=plt.cm.gray_r):
20     plt.matshow(df_confusion, cmap=cmap) # imshow
21     #plt.title(title)
22     plt.colorbar()
23     tick_marks = np.arange(len(df_confusion.columns))
24     plt.xticks(tick_marks, df_confusion.columns, rotation
25                =45)
26     plt.yticks(tick_marks, df_confusion.index)
27     #plt.tight_layout()
28     plt.ylabel(df_confusion.index.name)
29     plt.xlabel(df_confusion.columns.name)
30 plot_confusion_matrix(df_confusion)
31 plt.show()
```

6. Jelaskan apa itu voting pada random forest disertai dengan ilustrasi gambar sendiri.

**Gambar 3.56** Confusion Matriks

Voting yaitu suara untuk setiap target yang diprediksi pada saat melakukan Random Forest. Pertimbangkan target prediksi dengan voting tertinggi sebagai prediksi akhir dari algoritma random forest.

- Untuk menggunakan Voting pada Random Forest dapat dilihat code berikut. Disini saya mengilustrasikan voting untuk berbagai macam algoritma terutama Random Forest.

**Gambar 3.57** Voting

3.3.2 Praktikum

1. pandas

pada baris ke satu yaitu perintah mengimport library padas pada python atau anaconda kemudian di inisialisasikan menjadi karakter. selanjutnya ada sebuah array yang berisi a b c d. selanjutnya penggunaan array tipe series dan yang terakhir perintah print untuk menampilkan data pada karakter.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 16 21:00:21 2020
4
5 @author: User
6 """
7
8 import pandas as pd
9 data = np.array(['a', 'b', 'c', 'd'])

```

```

10 karakter = pd.Series(data)
11 print(karakter)
```

```

0    a
1    b
2    c
3    d
dtype: object
```

Gambar 3.58 hasil

2. numpy

Arti tiap baris codingan pada aplikasi sederhana numpy adalah sebagai berikut : pada baris ke satu yaitu mengimport numpy yang di inisialisasi menjadi np kemudian pada baris selanjutnya berisikan arange yang berarti membuat data yang berisi 12 dan ada reshape yang berfungsi merubah bentuk dari satu baris menjadi 2 baris data. Lalu yang terakhir ada perintah untuk print yaitu menampilkan data dari dika.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 16 21:08:52 2020
4
5 @author: User
6 """
7
8 import numpy as np
9 dika=np.arange(12).reshape(2,6)
10 print(dika)
```

```
In [11]: runfile('D:/SE
[[ 0  1  2  3  4  5]
 [ 6  7  8  9 10 11]]
```

Gambar 3.59 hasil

3. matplotlib

Arti tiap baris aplikasi sederhana matplotlib pada baris ke satu yaitu memasukan library matplotlib.pyplot yang di definisikan menjadi plt kemudian plt.plot untuk menentukan grafik yang akan dibuat. lalu membuat variabel y dengan nama some number yang terakhir untuk menampilkan data pada sebuah grafik.

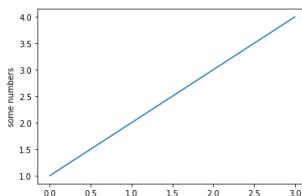
```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 16 21:18:45 2020
4
5 @author: User
6 """
7
8 import matplotlib.pyplot as plt
9 plt.plot([1, 2, 3, 4])
```

```

10 plt.ylabel('some numbers')
11 plt.show()

```



Gambar 3.60 hasil

4. Random Forest

Arti tiap baris hasil codingan random forest pada baris pertama random forest di import dari sklearn dengan ketentuan yaitu Nilai default untuk parameter yang mengontrol ukuran pohon (mis. Max_depth, min_samples_leaf, dll.) Mengarah ke pohon yang tumbuh besar dan tidak di-unsumed yang berpotensi sangat besar pada beberapa set data. Untuk mengurangi konsumsi memori, kompleksitas dan ukuran pohon harus dikontrol dengan menetapkan nilai parameter tersebut.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 16 21:32:01 2020
4
5 @author: User
6 """
7
8 from sklearn.ensemble import RandomForestClassifier
9 from sklearn.datasets import make_classification
10 X, y = make_classification(n_samples=1000, n_features=4,
11                           n_informative=2, n_redundant
12                           =0,
13                           random_state=0, shuffle=False)
14 clf = RandomForestClassifier(max_depth=2, random_state=0)
15 clf.fit(X, y)
16 print(clf.feature_importances_)
17 print(clf.predict([[0, 0, 0, 0]]))

```

5. Confusion Matrix

arti codingan pada hasil tiap codingan confusion matrix pada baris pertama codingan tersebut mendeskripsikan atau mengimport confusion matrix dari sklearn kemudian dibuat variabel y_true untuk nilai target ground truth (benar). y_pred untuk Taksiran target seperti yang dikembalikan oleh classifier. lalu menampilkan kedua variabel.

```

1 # -*- coding: utf-8 -*-
2 """

```

```
In [27]: X, y = make_classification(n_samples=1000, n_features=4,
...:                                     n_informative=2, n_redundant=0,
...:                                     random_state=0, shuffle=False)
...: clf = RandomForestClassifier(max_depth=2, random_state=0)
...: clf.fit(X, y)
Out[27]: RandomForestClassifier(bootstrap=True, ccp_alpha=0.0, class_weight=None,
                                 criterion='gini', max_depth=2, max_features='auto',
                                 max_leaf_nodes=None, max_samples=None,
                                 min_impurity_decrease=0.0, min_impurity_split=None,
                                 min_samples_leaf=1, min_samples_split=2,
                                 min_weight_fraction_leaf=0.0, n_estimators=100,
                                 n_jobs=None, oob_score=False, random_state=0, verbose=0,
                                 warm_start=False)

In [28]: print(clf.feature_importances_)
[0.14205973 0.76664038 0.0282433 0.06305659]

In [29]: print(clf.predict([[0, 0, 0, 0]]))
[1]
```

Gambar 3.61 hasil

```
3 Created on Mon Mar 16 21:42:41 2020
4
5 @author: User
6 """
7
8 from sklearn.metrics import confusion_matrix
9 y_true = [2, 0, 2, 2, 0, 1]
10 y_pred = [0, 0, 2, 2, 0, 2]
11 confusion_matrix(y_true, y_pred)
```

```
In [35]: from sklearn.metrics import confusion_matrix
...: y_true = [2, 0, 2, 2, 0, 1]
...: y_pred = [0, 0, 2, 2, 0, 2]
...: confusion_matrix(y_true, y_pred)
Out[35]:
array([[2, 0, 0],
       [0, 0, 1],
       [1, 0, 2]], dtype=int64)
```

Gambar 3.62 hasil

6. SVM dan Decision Tree

Seperi pengklasifikasi lainnya, DecisionTreeClassifier mengambil input dua array: array X, jarang atau padat, dengan ukuran n_samples, n_features memegang sampel pelatihan, dan array Y dari nilai integer, ukuran n_samples, Atau, probabilitas setiap kelas dapat diprediksi. Seperti pengklasifikasi lainnya, SVC, NuSVC dan LinearSVC mengambil input dua array: array X ukuran n_samples, n_features memegang sampel pelatihan, dan array y label kelas (string atau bilangan bulat), ukuran n_samples:

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 16 21:54:16 2020
4
5 @author: User
6 """
7 from sklearn import tree
```

```

8 X = [[0 , 0] , [1 , 1]]
9 Y = [0 , 1]
10 clf = tree.DecisionTreeClassifier()
11 clf = clf.fit(X, Y)
12 clf.predict([[2. , 2.]])
13
14 from sklearn import svm
15 X = [[0 , 0] , [1 , 1]]
16 y = [0 , 1]
17 clf = svm.SVC()
18 clf.fit(X, y)
19 clf.predict([[2. , 2.]])

```

```

In [40]: from sklearn import svm
...: X = [[0, 0], [1, 1]]
...: y = [0, 1]
...: clf = svm.SVC()
...: clf.fit(X, y)
...: clf.predict([[2., 2.]])
Out[40]: array([1])

In [41]: from sklearn import tree
...: X = [[0, 0], [1, 1]]
...: Y = [0, 1]
...: clf = tree.DecisionTreeClassifier()
...: clf = clf.fit(X, Y)
...: clf.predict([[2., 2.]])
Out[41]: array([1])

```

Gambar 3.63 hasil

7. Cross Validation

digunakan untuk memeriksa akurasi dari ketepatan hasil pengolahan data tersebut maka akan didapat nilai rata-rata 60 persen dari hasil pengolahan data tersebut untuk lebih jelasnya dapat di lihat pada gambar pada codingan tersebut pada baris ke satu melakukan import library dari sklern kemudian pada baris selanjutnya mengisi nilai skor dengan nilai pada variabel lontong setelah hal tersebut dilakukan kemudian data tersebut di eksekusi. berikut merupakan hasil dari code tersebut dapat dilihat pada gambar.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 16 22:05:46 2020
4
5 @author: User
6 """
7
8 from sklearn.model_selection import cross_val_score
9 scores = cross_val_score(lontong, pecel_att, pecel_pass, cv
10 =5)
# show average score and +/- two standard deviations away
11 #(covering 95% of scores)
12 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
std() * 2))

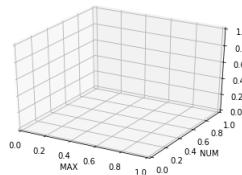
```

```
In [61]: runfile('D:/SEMESTER 6/wert/9.py', wdir='D:/SEMESTER 6/wert')
Accuracy: 0.59 (+/- 0.05)
```

Gambar 3.64 hasil

8. program pengamatan arti dari hasil program pengamatan. perogram pengamatan dapat mengamati dari 3 aspek diatas yaitu svm, random, dan decision tree. Yang memiliki variabel X Y Z dan di tampilkan dalam bentuk grafik.

```
1 import matplotlib.pyplot as plt
2 from mpl_toolkits.mplot3d import Axes3D
3 from matplotlib import cm
4 fig = plt.figure()
5 fig.clf()
6 ax = fig.gca(projection='3d')
7 plt.xlabel('MAX')
8 plt.ylabel('NUM')
9 plt.zlabel('AVG')
10 ax.scatter(x, y, z)
11 ax.set_zlim(0.2, 0.5)
12 ax.set_xlabel('Max features')
13 ax.set_ylabel('Num estimator')
14 ax.set_zlabel('Avg accuracy')
15 plt.show()
```

**Gambar 3.65** hasil

3.3.3 Penanganan Error

Screenshot error

- Untuk gambar screenshot error

Code Errornya

```
import matplotlib.pyplot as plt
plt.plot([1, 2, 3, 4])
plt.ylabel(some numbers)
plt.show()
```

```

File "<ipython-input-60-d14a3944647a>", line 1, in <module>
  runfile('D:/SEMESTER 6/wert/1/5.py', wdir='D:/SEMESTER 6/wert/1')

File "C:\Users\User\Anaconda3\lib\site-packages\spyder_kernels\customize
\spydercustomize.py", line 827, in runfile
  execfile(filename, namespace)

File "C:\Users\User\Anaconda3\lib\site-packages\spyder_kernels\customize
\spydercustomize.py", line 110, in execfile
  exec(compile(f.read(), filename, 'exec'), namespace)

File "D:/SEMESTER 6/wert/1/5.py", line 10
  plt.ylabel(some numbers)
          ^
SyntaxError: invalid syntax

```

Gambar 3.66 hasil

pada kode ylabel memiliki nama atau isi some numbers tetapi pada tipe data tertentu harus di awali dan diakhiri dengan tanda petik 2 atau 1. Pada kodingnya hanya kurang tanda petik 1.

3.4 1174057 Alit Fajar Kurniawan

3.4.1 Teori

1. Jelaskan apa itu random forest, sertakan gambar ilustrasi buatan sendiri.

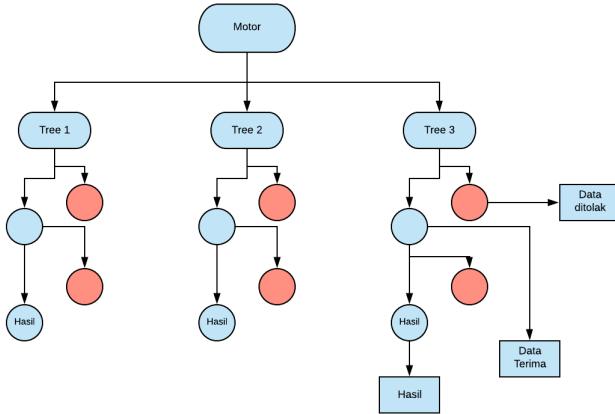
Random Forest merupakan algoritma yang digunakan terhadap klasifikasi data dalam jumlah yang besar. Klasifikasi pada random forest dilakukan dengan penggabungan dicision tree dengan melakuakn training terhadap sempel data yang dimiliki. Semakin banyak dicision tree maka data yang di dapat akan semakin akurat. Dibawah ini merupakan salah satu ilustrasi penggunaan Random Forest..

2. Jelaskan cara membaca dataset khusus dan artikan makna setiap file dan isi field masing masing file

Pertama download dataset terlebih dahulu lalu buka dengan menggunakan software spyder guna melihat isi dari dataset tersebut. Data tersebut memiliki extensi file bernama .txt dan didalamnya terdapat class dari field. Misalnya saja pada data jenis burung memiliki file index dan angka, dimana index berisi angka yang memiliki makna berupa jenis burung atau bahkan nama burung sedangkan field memiliki isi nilai berupa 0 dan 1 yang dimana sifatnya boolean atau Ya dan Tidak. Hal ini dikarenakan komputer hanya dapat membaca bilangan biner maka dari itu field yang di isikan berupa angka. Artinya angka 0 berarti tidak dan angka 1 berarti Ya.

3. Jelaskan apa itu Cross Validation

Cross Validation merupakan sebuah teknik validasi model yang digunakan untuk menilai bagaimana hasil analisis statistik akan digeneralisasi



Gambar 3.67 Random Forest

ke kumpulan data independen. Cross validation digunakan dengan tujuan prediksi, dan bila kita ingin memperkirakan seberapa akurat model model prediksi yang dilakukan dalam sebuah praktek. Tujuan dari cross validation yaitu untuk mendefinisikan dataset guna menguji dalam fase pelatihan untuk membatasi masalah seperti overfitting dan underfitting serta mendapatkan wawasan tentang bagaimana model akan digeneralisasikan ke set data independen.

4. Jelaskan apa arti score 44 % pada random forest, 27 % pada decision tree dan 29 % dari SVM

Dimana Score 44 % diperoleh dari hasil pengelahan dataset jenis burung. Dimana akan dilakukan proses pembagian data testing dan data training lalu diproses dan menghasilkan score sebanyak 44 % dimana menjelaskan bahwa score tersebut digunakan sebagai pembanding dalam tingkat keakuratannya. Pada decision tree akan memperoleh data lebih kecil yaitu sebanyak 27 % hal ini dikarenakan data yang diolah menggunakan decision tree dibagi menjadi beberapa tree dan lalu disimpulkan untuk mendapatkan data yang akurat. Pada SVM akan memperoleh score sebanyak 29 % hal ini dikarenakan data yang dimiliki masih bernilai netral sehingga tingkat keakuratannya masih belum jelas.

5. Jelaskan bagaimana cara membaca confusion matriks dan contohnya memakai gambar atau ilustrasi sendiri. Untuk membaca confusion matriks dapat menggunakan source code sebagai berikut,

```
import numpy as np
```

```
np.set_printoptions(precision=2)
plt.figure(figsize=(60,60), dpi=300)
plot_confusion_matrix(cm, classes=birds, normalize=True)
plt.show()
```

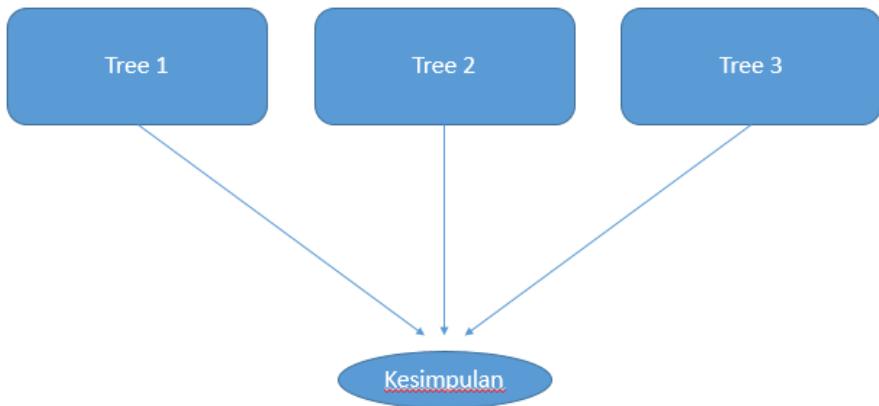
Dimana numpy akan mengurus semua data yang berhubungan dengan matrix. Pada source code tersebut digunakan dalam melakukan read pada dataset burung dengan menggunakan metode confusion matrix. Dalam confusion matrix memiliki 4 istilah yaitu True Positive yang merupakan data positif yang terditeksi benar, True Negatif yang merupakan data negatif akan tetapi terditeksi benar, False Positif merupakan data negatif namun terditeksi sebagai data positif, False Negatif merupakan data positif namun terditeksi sebagai data negatif. Adapun contoh hasil read dataset menggunakan confusion matrix dapat dilihat pada figure ??

		True Values	
		True	False
Prediction	True	TP Correct result	FP Unexpected result
	False	FN Missing result	TN Correct absence of result

Gambar 3.68 Confusion Matrix.

6. Jelaskan apa itu voting pada random forest disertai dengan ilustrasi gambar sendiri.

Voting merupakan proses pemilihan dari tree yang dimana akan dimunculkan hasilnya dan disimpulkan menjadi informasi yang pasti. Untuk kebih jelasnya saya akan memberikan sebuah contoh bagaimana voting bekerja.



Gambar 3.69 Voting.

Dimana ditunjukkan pada figure ?? terdapat 3 tree. Dalam tree tersebut akan dilakukan proses voting. Saya akan memberikan contoh kasus, dimana akan diadakan voting untuk menentukan sebuah mobil. Dalam tree akan diberikan sejumlah data misalnya saja data tersebut berupa gambar, yang dimana data tersebut akan dipilih dengan cara voting. Hasil voting akhir dari setiap tree menunjukkan mobil jazz, yang berarti kesimpulan dari data yang telah diberikan menyatakan gambar tersebut adalah mobil jazz. Bagaimana apabila terjadi perbedaan data misalnya saja pada tree 1 dan 2 menyatakan mobil jazz sedangkan pada tree 3 menyatakan mobil yaris, maka kesimpulan yang di ambil adalah mobil jazz dikarenakan hasil voting terbanyak adalah mobil jazz.

3.4.2 Praktikum

1. pandas

pada baris ke satu yaitu perintah mengimport library padas pada python atau anaconda kemudian di inisialisasikan menjadi karakter. selanjutnya ada sebuah array yang berisi nama cewek. selanjutnya penggunaan array tipe series dan yang terakhir perintah print untuk menampilkan data pada karakter ??.

```
1 import pandas as alit
2 cewek = {"List Nama Cewek Alit" : [ 'Triya' , 'Mirla' , 'Alit' , '
   Merita' ]}
3 af = alit.DataFrame(cewek)
4 print('Alit sayang ' + af)
```

```
In [9]: runfile('D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapt
wdir='D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3')
          Nama Cewek
0    Alit sayang Triya
1    Alit sayang Mirla
2    Alit sayang Alit
3    Alit sayang Merita
```

Gambar 3.70 hasil

2. numpy

Source Code baris pertama menjelaskan akan melakukan import pada library numpy dan di rename dengan alit. Selanjutnya kita akan membuat matrix dengan numpy dengan menggunakan fungsi eye. baris kedua selanjutnya kita akan memanggil matrix identitas 10x10. Fungsi eye disini berguna untuk memanggil matrix identitas dengan jumlah colom dan baris sesuai yang ditentukan. Disini saya telah menentukan 10 colom

dan baris maka dari itu hasilnya akan memunculkan matrix identitas 10x10, untuk lebih jelasnya dapat dilihat pada figure ??

```

1 import numpy as alit
2 matrix_one = alit.eye(10)
3 matrix_one
4 print (matrix_one)
```

```
In [11]: runfile('D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3/2.py',
wdir='D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3')
[[1. 0. 0. 0. 0. 0. 0. 0. 0.]
[0. 1. 0. 0. 0. 0. 0. 0. 0.]
[0. 0. 1. 0. 0. 0. 0. 0. 0.]
[0. 0. 0. 1. 0. 0. 0. 0. 0.]
[0. 0. 0. 0. 1. 0. 0. 0. 0.]
[0. 0. 0. 0. 0. 1. 0. 0. 0.]
[0. 0. 0. 0. 0. 0. 1. 0. 0.]
[0. 0. 0. 0. 0. 0. 0. 1. 0.]
[0. 0. 0. 0. 0. 0. 0. 0. 1.]
[0. 0. 0. 0. 0. 0. 0. 0. 0. 1.]]
```

Gambar 3.71 hasil


3. matplotlib

Arti tiap baris aplikasi sederhana matplotlib item Pada baris pertama akan melakukan import library Matplotlib dan di rename menjadi fajar. Pada baris kedua kita akan memberikan nilai plot atau grafik pada library fajar. Pada baris ketiga kita akan memberikan nama atau label pada grafik tersebut. Pada baris terakhir kita akan melakukan show sehingga grafik dapat kita lihat. Jalankan source code diatas dengan spyder sehingga hasilnya akan nampak seperti pada figure ??

```

1 import matplotlib.pyplot as fajar
2 fajar.plot([1,4,2,4,5,2,1])
3 fajar.ylabel('kurniawan 1174057')
4 fajar.show()
```

```
In [12]: runfile('D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3/3.py',
wdir='D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3')
```



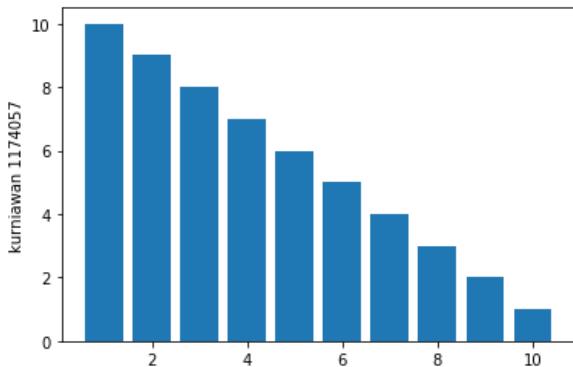
Gambar 3.72 hasil

Selanjutnya perhatikan source code berikut ini,

```
1 import matplotlib.pyplot as alit
2 a = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]
3 f = [10, 9, 8, 7, 6, 5, 4, 3, 2, 1]
4 alit.bar(a, f)
5 alit.ylabel('kurniawan 1174057')
6 alit.show()
```

Pada baris pertama akan melakukan import library Matplotlib dan di rename menjadi alit. Pada baris kedua dan ketiga kita akan menentukan nilai pada variabel a dan f. Pada baris keempat kita akan membuat diagram batang dengan fungsi bar. Pada baris kelima kita akan memberikan nama atau label pada diagram batang tersebut. Pada baris terakhir kita akan melakukan show sehingga kita dapat melihat hasilnya. Jalankan source code tersebut di dalam spyder maka hasilnya akan nampak seperti pada figure ??

```
In [18]: runfile('D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3/4.py', wdir='D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3')
```



Gambar 3.73 Aplikasi Sederhana Dengan Matplotlib Diagram Batang

4. Random Forest

Arti tiap baris hasil codingan random forest pada baris pertama random forest di import dari sklearn dengan ketentuan yaitu Nilai default untuk parameter yang mengontrol ukuran pohon (mis. Max_depth, min_samples_leaf, dll.) Mengarah ke pohon yang tumbuh besar dan tidak di-unsun yang berpotensi sangat besar pada beberapa set data. Untuk mengurangi konsumsi memori, kompleksitas dan ukuran pohon harus dikontrol dengan menetapkan nilai parameter tersebut. hasil pada gambar ?? .

```
1 from sklearn.ensemble import RandomForestClassifier  
2 from sklearn.datasets import make_classification  
3 X, y = make_classification(n_samples=1000, n_features=4,  
4 n_informative=2, n_redundant=0
```

```

5         random_state=0, shuffle=False)
6 clf = RandomForestClassifier(max_depth=2, random_state=0)
7 clf.fit(X, y)
8 print(clf.feature_importances_)
9 print(clf.predict([[0, 0, 0, 0]]))

```

```

In [19]: runfile('D:/Data Alit/Kuliah/SEMESTER VI/KB38/src/1174057/chapter3/5.py',
wdir='D:/Data Alit/Kuliah/SEMESTER VI/KB38/src/1174057/chapter3')
[0.17287856 0.80608704 0.01884792 0.00218648]
[1]
C:\ProgramData\Anaconda3\lib\site-packages\sklearn\ensemble\forest.py:245:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20 to
100 in 0.22.
"10 in version 0.20 to 100 in 0.22.", FutureWarning)

```

Gambar 3.74 hasil

5. Confusion Matrix

arti codingan pada hasil tiap codingan confusion matrix pada baris pertama codingan tersebut mendeskripsikan atau mengimport confusion matrix dari sklearn kemudian dibuat variabel y_true untuk nilai target ground truth (benar). y_pred untuk Taksiran target seperti yang dikembalikan oleh classifier. lalu menampilkan kedua variabel. hasil pada gambar ?? .

```

1 from sklearn.metrics import confusion_matrix
2 y_true = [2, 0, 2, 2, 0, 1]
3 y_pred = [0, 0, 2, 2, 0, 2]
4 confusion_matrix(y_true, y_pred)

```

```

In [26]: from sklearn.metrics import confusion_matrix
...: y_true = [2, 0, 2, 2, 0, 1]
...: y_pred = [0, 0, 2, 2, 0, 2]
...: confusion_matrix(y_true, y_pred)
Out[26]:
array([[2, 0, 0],
       [0, 0, 1],
       [1, 0, 2]], dtype=int64)

```

Gambar 3.75 hasil

6. SVM dan Decision Tree

Seperti pengklasifikasi lainnya, DecisionTreeClassifier mengambil input dua array: array X, jarang atau padat, dengan ukuran n_samples, n_features memegang sampel pelatihan, dan array Y dari nilai integer, ukuran n_samples, Atau, probabilitas setiap kelas dapat diprediksi. Seperti pengklasifikasi lainnya, SVC, NuSVC dan LinearSVC mengambil input dua array: array X ukuran n_samples, n_features memegang sampel pelatihan, dan array y label kelas (string atau bilangan bulat), ukuran n_samples:. hasil pada gambar ?? .

```

1 from sklearn import tree
2 X = [[0, 0], [1, 1]]
3 Y = [0, 1]
4 clf = tree.DecisionTreeClassifier()
5 clf = clf.fit(X, Y)

```

```

6 clf.predict([[2., 2.]])
7
8 from sklearn import svm
9 X = [[0, 0], [1, 1]]
10 y = [0, 1]
11 clf = svm.SVC()
12 clf.fit(X, y)
13 clf.predict([[2., 2.]])

```

In [39]: `from sklearn import tree`
`....: X = [[0, 0], [1, 1]]`
`....: Y = [0, 1]`
`....: clf = tree.DecisionTreeClassifier()`
`....: clf = clf.fit(X, Y)`
`....: clf.predict([[2., 2.]])`

Out[39]: `array([1])`

In [40]: `from sklearn import svm`
`....: X = [[0, 0], [1, 1]]`
`....: y = [0, 1]`
`....: clf = svm.SVC()`
`....: clf.fit(X, y)`
`....: clf.predict([[2., 2.]])`

C:\ProgramData\Anaconda3\lib\site-packages\sklearn\svm\base.py:193: FutureWarning: default value of gamma will change from 'auto' to 'scale' in version 0.22. This warning is shown because 'gamma' is set to its default value. It will be better for unscaled features. Set gamma explicitly to 'auto' or 'scale'.
"avoid this warning.", FutureWarning)
Out[40]: `array([1])`

Gambar 3.76 hasil

7. Cross Validation

digunakan untuk memeriksa akurasi dari ketepatan hasil pengolahan data tersebut maka akan didapat nilai rata-rata 60 persen dari hasil pengolahan data tersebut untuk lebih jelasnya dapat dilihat pada gambar pada codingan tersebut pada baris ke satu melakukan import library dari sklern kemudian pada baris selanjutnya mengisi nilai skor dengan nilai pada variabel lontong setelah hal tersebut dilakukan kemudian data tersebut di eksekusi. berikut merupakan hasil dari code tersebut dapat dilihat pada gambar ?? .

```

1 from sklearn.model_selection import cross_val_score
2 scores = cross_val_score(bdg, dago_att, dago_pass, cv=5)
3 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
   std() * 2))

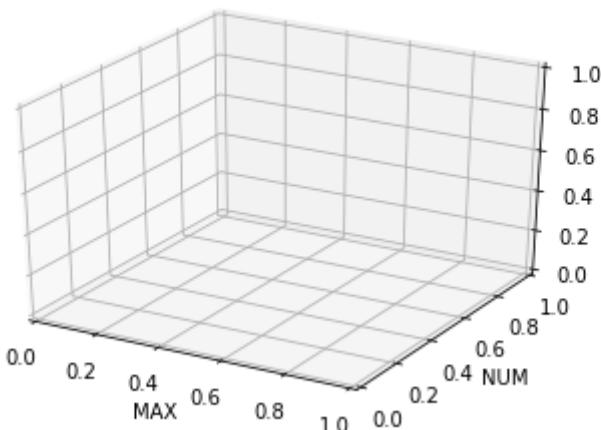
```

In [61]: runfile('D:/SEMESTER 3/ML/ML PRACTICE/ML PRACTICE.ipynb', 1)
Accuracy: 0.59 (+/- 0.05)

Gambar 3.77 hasil

8. program pengamatan arti dari hasil program pengamatan. perogram pengamatan dapat mengamati dari 3 aspek diatas yaitu svm, random, dan decision tree. Yang memiliki variabel X Y Z dan di tampilkan dalam bentuk grafik pada gambar ??.

```
1 import matplotlib.pyplot as plt
2 from mpl_toolkits.mplot3d import Axes3D
3 from matplotlib import cm
4 fig = plt.figure()
5 fig.clf()
6 ax = fig.gca(projection='3d')
7 plt.xlabel('MAX')
8 plt.ylabel('NUM')
9 plt.zlabel('AVG')
10 ax.scatter(x, y, z)
11 ax.set_zlim(0.2, 0.5)
12 ax.set_xlabel('Max features')
13 ax.set_ylabel('Num estimator')
14 ax.set_zlabel('Avg accuracy')
15 plt.show()
```



Gambar 3.78 hasil

3.4.3 Penanganan Error

Screenshot error

1. Gambar error

```
In [63]: runfile('D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chap-
  wdir='D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3')
Traceback (most recent call last):

  File "C:\ProgramData\Anaconda3\lib\site-packages\IPython\core\interacti-
line 3325, in run_code
    exec(code_obj, self.user_global_ns, self.user_ns)

  File "<ipython-input-63-6971754af445>", line 1, in <module>
    runfile('D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3'
Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3')

  File "C:\ProgramData\Anaconda3\lib\site-packages\spyder_kernels\custo-
\spydercustomize.py", line 827, in runfile
    execfile(filename, namespace)

  File "C:\ProgramData\Anaconda3\lib\site-packages\spyder_kernels\custo-
\spydercustomize.py", line 110, in execfile
    exec(compile(f.read(), filename, 'exec'), namespace)

  File "D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter3/1.py"
    print('Alit sayang + af)
                           ^
SyntaxError: EOL while scanning string literal
```

Gambar 3.79 hasil

Code Errornya

```
import pandas as alit
cewek = {"List Nama Cewek Alit" : ['Triya','Mirla','Alit','Merita']}
af = alit.DataFrame(cewek)
print('Alit sayang + af)
```

pada bagian print, perintah ketika akan menjalankan program. terdapat kesalahan pada tanda petik yang kurang sehingga program tidak dapat dijalankan.

perbaiki code error

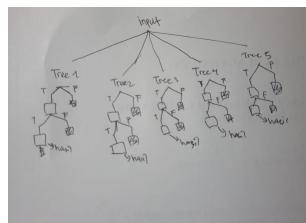
```
import pandas as alit
cewek = {"List Nama Cewek Alit" : ['Triya','Mirla','Alit','Merita']}
af = alit.DataFrame(cewek)
print('Alit sayang ' + af)
```

3.5 1174039 - Liyana Majdah Rahma

3.5.1 Teori

1. Jelaskan apa itu random forest, sertakan gambar ilustrasi buatan sendiri.

Random forest adalah sebuah algoritma yang biasanya dipakai untuk mengklasifikasikan suatu data yang berjumlah besar. Dimana pengklasifikasianya itu dapat menggunakan pohon yang digabungkan serta melewati training terlebih dahulu sebelum pada data sample nya. Dapat dijelaskan dari gambar dibawah bahwa klasifikasi tree ini diambil dari data yang paling banyak.



Gambar 3.80 Random Forest

2. Jelaskan cara membaca dataset khusus dan artikan makna setiap file dan isi field masing masing file

langkah pertama Download terlebih dulu data yang akan dibaca, lalu buka aplikasi spyder kemudian jalankan kode nya. data yang terdapat pada file tersebut adalah data folder ATTRIBUTE, IMAGES, PARTS yang memiliki kegunaannya sendiri yang dimana pada penggunaannya data yang dipakai adalah data image_attribute_label pada folder attribute, data image_class_labels dan data classes. file image_attribute_label berguna sebagai data awal yang digunakan untuk membaca data attribute yang terdapat pada masing - masing gambar burung yang ada. sedangkan file image_class_label berguna sebagai data yang akan membuat kolom baru pada dataset yang fungsinya adalah untuk memasukan hasil dari semua data yang dimiliki oleh imgatt2. dan file classes berguna sebagai dataset yang akan dipanggil oleh fungsi code untuk menampilkan nama dari data burung yang dimiliki. file image_attribute_label berisi tentang data attribute yang ada pada data gambar file burung yang dimiliki difolder image pada CUB-200-2011 file image_class_label berisi tentang data yang dimiliki oleh attribute dari image_attribute_label dimana data yang bernilai atau memiliki nilai disusun hingga menghasilkan data yang mudah dipahami. file classes berisi tentang data yang berguna untuk menampilkan data nama dari setiap data jenis burung yang dimiliki.

3. Jelaskan apa itu Cross Validation.

Cross Validation adalah suatu teknik yang digunakan untuk memvalidasi sebuah model serta untuk menilai pengeneralisasian dari kumpulan data independen hasil statistik analis.

- Jelaskan apa arti score 44 % pada random forest, 27 % pada decision tree dan 29 % dari SVM.

arti score 27% pada decision tree adalah presentasi hasil dari perhitungan dataset acak, dan arti score 29% dari SVM adalah hasil pendekatan neural network. Hasil tersebut didapat dari hasil validasi silang untuk memastikan bahwa membagi training test dengan cara yang berbeda. Jadi 44% untuk random forest, 27% untuk pohon keputusan, dan 29% untuk SVM. Itu merupakan persentase keakurasi prediksi yang dilakukan pada saat testing menggunakan label pada dataset yang digunakan. Score mendefinisikan aturan evaluasi model.

- Jelaskan bagaimana cara membaca confusion matrix dan contohnya memakai gambar atau ilustrasi sendiri.

Confusion matrix menggunakan rumus perhitungan dengan 4 keluaran, yang pertama adalah :

		Prediksi	
		Negative	Positive
Fakta	Negative	a	b
	Positive	c	d

Gambar 3.81 Confusion Matrix

- Recall

$$d/(c + d) \quad (3.5)$$

- Precision

$$d/(b + d) \quad (3.6)$$

- Accuracy

$$(a + c)/(a + b + c + d) \quad (3.7)$$


- Error Rate

$$(b + c)/(a + b + c + d) \quad (3.8)$$

- Jelaskan apa itu voting pada random forest disertai dengan ilustrasi gambar sendiri.

Voting itu adalah sebuah hasil dari sebuah decision tree, yang nanti hasil akhirnya akan menjadi hasil dari random forest. Dijelaskan bahwa terdapat 5 buah tree dimana masing-masing terdapat tree satu, tree dua, tree tiga, tree empat, dan tree 5. tree satu menghasilkan A, sedangkan

tree empat dan lima menghasilkan data C. Maka dapat disimpulkan data yang paling banyak diperoleh adalah data A.



Gambar 3.82 Vote

3.5.2 Praktek

1. Pandas Pada baris pertama kita mengimport library pandas dan menamainya sebagai pan , lalu memasukkan data kedalam variable data. setelah itu membuat dataframe dengan data yang telah di masukkan tadi, lalu membuat variable bernama cari untuk melihat semua data dari attribute Nama lalu print variable tersebut.

```
1 Import pandas as pd
2 data = {'Film' : ['Dora', 'Doraemon', 'Barbie'], 'Tahun' : [2011, 2015, 2016]}
3 pan.DataFrame(data)
4 b = data['Film']
5 print(b)
```

Gambar 3.83 Pandas

[D] [E] -refIDC01-dest-NODE-pc3-MediaData-Right-3-Sender-NODE-Data[Type:Image] to Application-Left-1-NODE-Dest-NODE-pc3-MediaData-Right-3-Sender-NODE-Data[Type:Image] to Application-Left-1-NODE

2. numpy Baris pertama adalah untuk mengimport library numpy dan menamainya sebagai num, lalu membuat sebuah variable bernama mat dan menggunakan fungsi arrange untuk membuat angka berurutan dari 1 sampai 25, mengapa ditulis satu sampai 26 karena urutan dimulai dari 0, lalu menggunakan reshape untuk mengubahnya menjadi matrix. dan terakhir print variable mat.


```
8 import numpy as num  
9 mat = num.arange(1,26).reshape(5,5)  
10 print(mat)
```

Gambar 3.85 Numpy

3. matplotlib Pertama import pyplot dari library matplotlib dan menamainya sebagai plt, lalu memasukkan data yang diinginkan kedalam variable x dan y . lalu menggunakan fungsi bar untuk membuat grafik bar yang isi datanya adalah x, dan y, lalu memberikan label pada sumbu x dan y dan memberikan judul pada grafik tersebut, dan menggunakan show() untuk menampilkan grafik

```
In [4]: from matplotlib import pyplot as plt
In [4]: x = [2017, 2018, 2019]
In [4]: y = [1000, 2000, 3000]
In [4]: plt.xlabel('tahun')
In [4]: plt.ylabel('hasil produksi')
In [4]: plt.title('jelajah hasil produksi per tahun')
In [4]: plt.show()
```

Gambar 3.87 Matplotlib



Gambar 3.88 Hasil Matplotlib

4. Random Forest

Dari sklearn.ensamble mengimport RandomForestClassifier dan memberikan ketentuan dimana maksimal datanya adalah 50 dengan keadaan random serta estimatornya 100 dan dimasukkan kedalam variable clf lalu itu variabel clf di running berdasarkan data training dan data label yang telah di definisikan jumlahnya. kemudian variabel clf di running berdasarkan data training paling atas untuk memunculkan hasil data training lima paling atas. setelah itu data tersebut di di running scorenya untuk melihat tingkat akurasi yang dia kerjakan maka tingkat akurasi yang dihasilkan berada pada kisaran 0,448 atau kisaran 44%.

```
In [112]: from sklearn.ensemble import RandomForestClassifier
clf = RandomForestClassifier(max_features=50, random_state=0, n_estimators=100)
clf.fit(df_train_att, df_train_label)
print(clf.predict(df_train_att.head()))
clf.score(df_test_att, df_test_label)
```

Gambar 3.89 Random Forest

```
In [112]: from sklearn.ensemble import RandomForestClassifier
...: clf = RandomForestClassifier(max_features=50, random_state=0,
...: n_estimators=100)
...: print(clf.predict(df_train_att, df_train_label))
...: print(clf.predict(df_train_att.head()))
...: print(clf.score(df_test_att, df_test_label))
[ 20  66  54  101  101]
Out[112]: 0.44825705575581586
```

Gambar 3.90 Hasil Random Forest

5. Confussion Matrix dari sklearn.metrics mengimport confusion matrix kemudian dibuat variabel pred_labels dengan di isikan clf prdic df test att setelah itu membuat variabel cm yang isinya terdapat data yang di buat confusion matrix berdasarkan data test setelah variabel cm akan di running yang mana akan menghasilkan gambar berupa matrix matrix tersebut berisi nilai kebenaran yang mendekati nilai benar.

```
from sklearn.metrics import confusion_matrix
pred_labels = clf.predict(df_test_att)
cm = confusion_matrix(df_test_label, pred_labels)
```

Gambar 3.91 Confusion Matrix

```
In [113]: from sklearn.metrics import confusion_matrix
...: pred_labels = clf.predict(df_test_att)
...: cm = confusion_matrix(df_test_label, pred_labels)
...: cm
Out[113]:
array([[ 7,  0,  0, ...,  0,  0,  0],
       [ 1, 12,  0, ...,  0,  1,  0],
       [ 1,  1,  7, ...,  0,  0,  8],
       ...,
       [ 0,  0,  1, ...,  4,  0,  0],
       [ 0,  0,  0, ...,  0, 11,  0],
       [ 0,  0,  0, ...,  0,  0, 10]], dtype=int64)
```

Gambar 3.92 Hasil Coonfusion Matrix

6. Decision Tree dan SVM masukan terlebih dahulu library tree setelah itu buat variabel clftree yang berisi decision tree setelah itu masukan nilai data training dan label yang telah di deklarasikan tadi setelah itu running variabel tersebut untuk mendapatkan score 0,266 kisaran 26 sampai 27% akurasinya

```
from sklearn import tree
clftree = tree.DecisionTreeClassifier()
clftree.fit(df_train_att, df_train_label)
clftree.score(df_test_att, df_test_label)
```

Gambar 3.93 Desicion Tree

```
In [114]: from sklearn import tree
...: clftree = tree.DecisionTreeClassifier()
...: clftree.fit(df_train_att, df_train_label)
...: clftree.score(df_test_att, df_test_label)
Out[114]: 0.26689545934530096
```

Gambar 3.94 Hasil Desicion Tree

Import terlebih dahulu library svm nya setelah itu buat variabel clfsvm yang berarti berisi nilai data training dan data label dan pendeklarasian svm itu sendiri setelah itu di running untuk mendapatkan nilai akurasinya atau score sebesar 0,283 atau dalam kisaran 23%.

```
from sklearn import svm
clfsvm = svm.SVC()
clfsvm.fit(df_train_att, df_train_label)
clfsvm.score(df_test_att, df_test_label)
```

Gambar 3.95 SVM

```
In [115]: from sklearn import svm
...: clfsvm = svm.SVC()
...: clfsvm.fit(df_train_att, df_train_label)
...: clfsvm.score(df_test_att, df_test_label)
Out[115]: 0.4799366420274551
```

Gambar 3.96 Hasil SVM

7. Cross Validation mengimport cross_val_score dari sklearn.model_selection , lalu memasukkan variable variable yang akan di ukur keakuratan dari model yang digunakan lalu menampilkan nya di console, disini digunakan variable clf yaitu random forest.

```
:from sklearn.model_selection import cross_val_score
scores = cross_val_score(clf, df_train_att, df_train_label, cv = 5)
print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2))
```

Gambar 3.97 Cross Val Rand Forest

```
In [132]: from sklearn.model_selection import cross_val_score
...: scores = cross_val_score(clf, df_train_att, df_train_label, cv = 5)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.std() * 2))
Accuracy: 0.45 (+/- 0.01)
```

Gambar 3.98 Hasil Cross Validaiton Random Forest

- Disini memasukkan variable variable yang akan di ukur keakuratan dari model yang digunakan lalu menampilkan nya di console, disini digunakan variable clftree yaitu desicion Tree.

```
scoretree = cross_val_score(clftree, df_train_att, df_train_label, cv = 5)
print("Accuracy: %0.2f (+/- %0.2f)" % (scoretree.mean(), scoretree.std() * 2))
```

Gambar 3.99 Cross Vadation Desicion Tree

```
In [137]: scoretree = cross_val_score(clftree, df_train_att, df_train_label, cv = 5)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scoretree.mean(), scoretree.std() * 2))
Accuracy: 0.26 (+/- 0.02)
```

Gambar 3.100 Hasil Cross Vadation Desicion Tree

- Disini memasukkan variable variable yang akan di ukur keakuratan dari model yang digunakan lalu menampilkan nya di console, disini digunakan variable clfsvm yaitu svm.

```
scoresvm = cross_val_score(clfsvm, df_train_att, df_train_label, cv = 5)
print("Accuracy: %0.2f (+/- %0.2f)" % (scoresvm.mean(), scoresvm.std() * 2))
```

Gambar 3.101 Cross Vadation SVM

```
In [134]: scoresvsm = cross_val_score(clfsvm, df_train_att, df_train_label, cv = 5)
...: print("Accuracy: %.2f (+/- %.2f)" % (scoresvsm.mean(), scoresvsm.std() * 2))
Accuracy: 0.87 (+/- 0.01)
```

Gambar 3.102 Hasil Cross Vadation SVM

8. Program Pengamatan dan Hasil Pengamatan. perogram pengamatan ini menggunakan library matplotlib supaya hasil dari presentase hasil random forest, svm dan decision tree dapat di bandingkan dengan membuat variabel X Y Z kemudian memberikan label untuk setiap dimensinya untuk lebih jelas dapat dilihat gambar yang menunjukan hasil perbandingan presentase dari tiga metode tersebut.

```

max_features_ratio = np.arange(0.05, 0.5)

def cross_val_scores(max_features_ratio, features, labels, n_estimators, oob_error):
    scores = np.zeros(len(max_features_ratio))
    for i, max_features in enumerate(max_features_ratio):
        estimator = RandomForestClassifier(n_estimators=n_estimators, max_features=max_features)
        scores[i] = cross_val_score(estimator, features, labels, cv=5).mean()
    return scores

def get_oob_error(max_features_ratio, features, labels, n_estimators):
    scores = np.zeros(len(max_features_ratio))
    for i, max_features in enumerate(max_features_ratio):
        estimator = RandomForestClassifier(n_estimators=n_estimators, max_features=max_features)
        estimator.fit(features, labels)
        scores[i] = estimator.oob_error_
    return scores

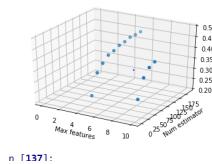
def get_max_features_ratio(max_features_ratio, features, labels, n_estimators, oob_error):
    scores = np.zeros(len(max_features_ratio))
    for i, max_features in enumerate(max_features_ratio):
        estimator = RandomForestClassifier(n_estimators=n_estimators, max_features=max_features)
        estimator.fit(features, labels)
        scores[i] = estimator.score(features, labels)
    return scores

def get_max_features_ratio_oob(max_features_ratio, features, labels, n_estimators):
    scores = np.zeros(len(max_features_ratio))
    for i, max_features in enumerate(max_features_ratio):
        estimator = RandomForestClassifier(n_estimators=n_estimators, max_features=max_features)
        estimator.fit(features, labels)
        scores[i] = estimator.oob_score_
    return scores

```

Gambar 3.103 Program Pengamatan

Gambar 3.104 Hasil Program Pengamatan



Gambar 3.105 Grafik Program Pengamatan

3.5.3 Penanganan Error

3.5.3.1 Skrinshoot error

1. Error 1

FileNotFoundException: File b'0:\\Semester6\\AI\\Chapter3\\(CUB_200_2011)x07ttributes\\

Gambar 3.106 Error 1

3.5.3.2 Kode Error dan Tipe Error

1. Error 1 type FileNotFoundError

```
imgatt = pd.read_csv("D:\Semester1\AI\Chapter9\08_200_2011\attributes\image_attribute_labels.txt", sep='\t', encoding='utf-8')

imgatt.head()
imgatt.shape
```

Gambar 3.107 Kode Error 1

3.5.3.3 Solusi

1. Mengganti back slash menjadi slash biasa

BAB 4

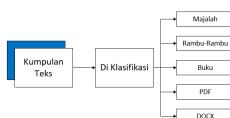
CHAPTER 4

4.1 Faisal Najib Abdullah / 1174042

4.1.1 Teori

1. Jelaskan apa itu klasifikasi teks, sertakan gambar ilustrasi buatan sendiri.

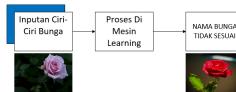
klasifikasi teks adalah cara untuk memilah-milah teks berdasarkan parameter tertentu baik itu jenis teks atau jenis dari dokumen yang terdapat kumpulan teks didalamnya, sedangkan teks itu sendiri merupakan sekumpulan kata yang dapat dibaca. bisa berupa buku, majalah, rambu-rambu dan lain sebagainya.



Gambar 4.1 contoh klasifikasi teks

2. Jelaskan mengapa klasifikasi bunga tidak bisa menggunakan machine learning, sertakan ilustrasi sendiri.

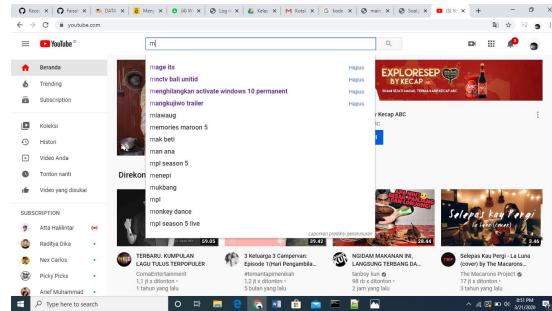
Klasifikasi bunga tidak dapat menggunakan mesin learning dikarenakan jenis-jenis bunga banyak yang mirip bahkan banyak bunga yang serupa tetapi tidak sama. oleh karena itu klasifikasi bunga tidak bisa di gunakan oleh mesin learning dikarenakan jika salah satu inputan ciri-ciri dari siatu bunga di inputkan kemungkinan jawaban dari mesin learning itu tidak tepat contoh dimasukan inputan ciri ciri bunga mawar putih kemudian mesin learning menjawab bahwa itu bunga mawar merah.



Gambar 4.2 contoh klasifikasi bunga

3. Jelaskan bagaimana teknik pembelajaran mesin pada teks pada kata-kata yang digunakan di youtube, jelaskan arti per atribut data csv dan sertakan ilustrasi buatan sendiri.

cara pembelajaran teks yang di gunakan youtube yaitu dengan cara merekam data yang sering di inputkan oleh user pada menu pencarian youtube. sehingga pada saat user akan mencari data yang serupa seringkali youtube menyediakan opsi atau rekomendasi-rekomendasi dari pencaharian. contoh saya menuliskan m maka muncul opsi pilihan master chep dan lainya yang berawalan m rekomendasi yang muncul merupakan kata-kata yang sering di cari oleh banyak user atau sering di buka oleh user itu sendiri.



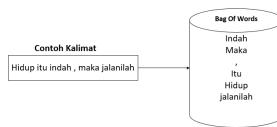
Gambar 4.3 contoh teknik pembelajaran mesin

4. Jelaskan apa yang dimaksud vektorisasi data.

vektorisasi data merupakan pemecahan data menjadi bagian-bagian yang lebih sederhana contoh pada satu paragraf terdiri dari 200 kata kemu-

dian dilakukan vektorisasi dengan cara membagi-bagi kata dalam paragraf tersebut ke dalam kalimat-kalimat yang terpisah kemudian dipecah lagi menjadi data dalam perkata selanjutnya kata-kata tersebut dijemahkan.

- Jelaskan apa itu bag of words dengan kata-kata yang sederhana dan ilustrasi sendiri. bag of words merupakan proses penyederhanaan kata-kata yang asalnya tersirat dalam satu kalimat atau satu paragraf diubah menjadi perkataan kemudian kata-kata tersebut dikumpulkan menjadi satu kelompok tanpa ada arti dari kata-kata yang telah dikumpulkan tersebut lalu dihitung frekuensi kemunculan dari kata tersebut.



Gambar 4.4 contoh bag of words

- Jelaskan apa itu TF-IDF, ilustrasikan dengan gambar sendiri. TF-IDF merupakan metode untuk menghitung bobot dari kata yang sering muncul pada suatu kalimat. metode ini menghitung nilai TF atau Term Frequency dan IDF atau Inverse Document Frequency pada setiap kata pada kalimat yang dijadikan acuan kata pada metode ini sering disebut token adapun rumus dari metode ini.



Gambar 4.5 contoh TF-IDF

4.1.2 Praktek Program

- import data pandas dan 500 baris data dummy kemudian dijelaskan tiap barisnya.

```

1 # In [1]: mengimport librari padas yang di gunakan
2 # untuk membaca file tex atau csv
3 import pandas as pd
4 #membaca file csv menggunakan fungsi read csv dari padas
5 data_forest = pd.read_csv("D:/NAJIB/SEMESTER_6_NAJIB/AI/
  Chapter4/Salaries.csv")
6 # In [2]: untuk melihat jumlah dari baris data yang telah di
  import
  
```

```

7 print(len(data_forest))
8 # In[3]: untuk melihat lima baris pertama data yang telah di
     import
9 print(data_forest.head())
10 # In[4]: untuk mengetahui banyak baris dan kolom dari data
      yang
11 # telah di import.
12 print(data_forest.shape)

```

	Id	EmployeeName	Agency	Status
0	1	NATHANIEL FORD	San Francisco	NaN
1	2	GARY JIMENEZ	San Francisco	NaN
2	3	ALBERT PARDINI	San Francisco	NaN
3	4	CHRISTOPHER CHONG	San Francisco	NaN
4	5	PATRICK GARDNER	San Francisco	NaN

[5 rows x 13 columns]
(148654, 13)

Process finished with exit code 0

Gambar 4.6 hasil

2. memecah data prame menjadi dua yag pertama 450 dan kedua sisanya

```

1 # In [5]: membuat data training dan data testing
2 # jumlah baris data training sebanyak 450 baris
3 data_training = data_forest[:450]
4 # jumlah baris data testing dari hasil pengurangan 523 - 450
5 data_testing = data_forest[450:]

```

	Id	EmployeeName	Agency	Status
443	444	SANDRA HUANG	San Francisco	NaN
444	445	SAHIR PUTRUS	San Francisco	NaN
445	446	ELAINE COLEMAN	San Francisco	NaN
446	447	DENISE BAILEY	San Francisco	NaN
447	448	ANNETTE HOBRUCKER-PFEIFER	San Francisco	NaN
448	449	WENDY STILL	San Francisco	NaN
449	450	CHUTEH KOTAKE	San Francisco	NaN

[450 rows x 13 columns]

Process finished with exit code 0

Gambar 4.7 hasil

3. praktek vektorisasi

berikut merupakan codingan untuk melakukan vektorisasi data berupa teks dalam vormat csv

```

1 # In [1]:
2 #melakukan import pandas untuk membaca file csv
3 import pandas as pd
4 data_komen=pd.read_csv("D:/NAJIB/SEMESTER_6_NAJIB/AI/Chapter4
   /Youtube04-Eminem.csv")

```

	ID	CLASS	CONTENT	Joann Anderson	...	San Francisco	NaN
▶	148647	148648		Leon Walker	...	San Francisco	NaN
↑	148648	148649		Roy I Tillary	...	San Francisco	NaN
↓	148649	148650		Not provided	...	San Francisco	NaN
☰	148650	148651		Not provided	...	San Francisco	NaN
⟳	148651	148652		Not provided	...	San Francisco	NaN
🖨️	148652	148653		Joe Lopez	...	San Francisco	NaN
ⓧ	148653	148654					

[148204 rows x 13 columns]

Process finished with exit code 0

Gambar 4.8 hasil

```

5 # In [2]:
6 #mengelompokkan komentar spam dan bukan spam
7 spam=data_komen.query('CLASS == 1')
8 nospam=data_komen.query('CLASS == 0')
9 # In [3]: memanggil lib vektorisasi
10 #melakukan fungsi bag of word dengan cara menghitung semua
   kata
11 #yang terdapat dalam file
12 from sklearn.feature_extraction.text import CountVectorizer
13 vectorizer = CountVectorizer()
14 # In [3]: memilih colom CONTENT untuk dilakukan vektorisasi
15 #melakukan bag of word pada dataframe pada colom CONTENT
16 data_vektorisasi = vectorizer.fit_transform(data_komen['
   CONTENT'])
17 # In [4]: melihat isi vektorisasi
18 data_vektorisasi
19 # In [5]: melihat isi data pada baris ke 349
20 print(data_komen['CONTENT'][349])
21 # In [6]: melihat daftar kata yang di vektorisasi
22 #feature_names merupakan digunakan untuk mengambil nama
23 #kolomnya ada apa saja
24 dk=vectorizer.get_feature_names()
25 # In [7]: akan melakukan randomisasi pada database nya supaya
26 #semipurna saat melakukan klasifikasi
27 acak_acak = data_komen.sample(frac=1)
28 # In [8]: membuat data traning dan testing
29 dk_train=acak_acak[:300]
30 dk_test=acak_acak[300:]
31 # In [9]: melakukan training pada data training dan di
   vektorisasi
32 dk_train_att=vectorizer.fit_transform(dk_train['CONTENT'])
33 print(dk_train_att)
34 # In [10]: melakukan testing pada data testing dan di
   vektorisasi
35 dk_test_att=vectorizer.transform(dk_test['CONTENT'])
36 print(dk_test_att)
37 # In [11]: Dimana akan mengambil label spam dan bukan spam
38 dk_train_label=dk_train['CLASS']
39 print(dk_train_label)
40 dk_test_label=dk_test['CLASS']
41 print(dk_test_label)

```

The screenshot shows a Jupyter Notebook interface. On the left, there's a sidebar with icons for file operations like Run, Save, and Cell. A text cell titled '2,1' contains a message from a duo about recording freestyles on YouTube. Below it, a code cell titled '2,3' displays a list of tuples representing data points, likely for training a machine learning model.

```

Run: 2,3
Hi everyone. We are a duo and we are starting to record freestyles and put them on youtube. If any of you could check it out and like we love doing this. We may not have the best recording equipment but if you listen to our lyrics and rhymes I think you'll like because we love making these videos and we want you to like them as much as possible so feel free to comment and give us pointers!
(0, 217) 1
(0, 762) 1
(0, 318) 1
(0, 575) 1
(0, 1049) 1
(0, 987) 1
(0, 519) 1
(0, 283) 1
(2, 217) 1
(2, 762) 1
(2, 519) 1
(2, 487) 1
(2, 452) 1
(2, 618) 1
(2, 523) 3
(2, 139) 1
(2, 947) 1
(2, 113) 4
(2, 546) 2
(2, 789) 1
(2, 775) 2
(2, 736) 1
(2, 192) 1
(2, 795) 1
(2, 992) 1

```

Gambar 4.9 hasil

lakukan import library pandas yang diinisialisasi menjadi pd setelah itu ada dibuat class data_komen dengan method read_csv untuk membaca file berekstensikan csv yang dimasukan alamatnya pada kurung, lakukan klasifikasi atau pemilihan komentar yang berisi spam atau bukan spam dengan parameter class samadengan 1 merupakan spam dan class samadengan 0 bukan spam setelah itu masukan librari CountVektorizer yang digunakan untuk vektorisasi data kemudian dilanjutkan pada bagian In[103] dibuat variabel yang berisi vektorisasi dari data pada data_komen di field content setelah itu variabel tersebut di running hasilnya menunjukan 350 baris di kali 1738 kolom selanjutnya dicoba untuk memunculkan isi record pada baris ke 349 maka akan muncul isian dari baris tersebut. selanjutnya dibuat variabel dk atau daftar yang berisi data hasil vektorisasi setelah yang terdiri dari variabel acak_acak yang berisi data komen yang di dalamnya dibuat random yang nantinya akan dibut data training dan data testing dengan ketentuan data training 300 dan data testing sebanyak 50 setelah itu data training dilakukan vektorisasi dan data testing juga dilakukan vektorisasi setelah itu kedua data training dan testing tersebut dibuat label dengan parameter field CLASS pada tabel.

4. klasifikasi SVM berikut ini merupakan codingan klasifikasi SVM

```

1 # In [18]:
2 from sklearn import svm

```

```

3 clfsvm = svm.SVC()
4 clfsvm.fit(dk_train_att, dk_train_label)
5 clfsvm.score(dk_test_att, dk_test_label)

```

```

Run: Run2
we love doing this. We may not have the best recording equipment but if you like
because we love making these videos and we want you to like them as much as we
SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
      decision_function_shape='ovr', degree=3, gamma='scale', kernel='rbf',
      max_iter=-1, probability=False, random_state=None, shrinking=True,
      tol=0.001, verbose=False)
0.918918918918919

Process finished with exit code 0

```

Gambar 4.10 hasil

melakukan verifikasi import librari svm dari sklearn kemudian membuat variabel clfsvm berisikan method svc setelah itu variabel tersebut di berikan method fit dengan isian data train vektorisasi dan data training label yang berguna untuk melatih data tersebut setelah itu di coba untuk memunculkan score atau akurasi dari data tersebut menggunakan data testing vektorisasi dan data testing label.

5. klasifikasi decision tree berikut ini merupakan codingan klasifikasi decision tree

```

1 # In [17]:
2 from sklearn import tree
3 clftree = tree.DecisionTreeClassifier()
4 clftree.fit(dk_train_att, dk_train_label)
5 clftree.score(dk_test_att, dk_test_label)

```

```

Run: Run2
DecisionTreeClassifier(ccp_alpha=0.0, class_weight=None, criterion='gini',
                       max_depth=None, max_features=None, max_leaf_nodes=None,
                       min_impurity_decrease=0.0, min_impurity_split=None,
                       min_samples_leaf=1, min_samples_split=2,
                       min_weight_fraction_leaf=0.0, presort='deprecated',
                       random_state=None, splitter='best')
0.918918918918919

Process finished with exit code 0

```

Gambar 4.11 hasil

melakukan verifikasi import librari tree dari sklearn kemudian membuat variabel clftree berisikan method DecisionTreeClasifier setelah itu variabel tersebut di berikan method fit dengan isian data train vektorisasi dan data training label yang berguna untuk melatih data tersebut agar dapat digunakan pada codingan selanjutnya setelah itu di coba untuk memunculkan score atau akurasi dari data tersebut menggunakan data testing vektorisasi dan data testing label.

6. plot confusion matrix berikut merupakan codingan untuk confusion matrix

```
1 # In [15]: Membuat confusion Matrix dan menampilkannya
2 from sklearn.metrics import confusion_matrix
3 pred_labels = clf.predict(dk_test_att)
4 cm = confusion_matrix(dk_test_label, pred_labels)
5 cm
```

Gambar 4.12 hasil

lakukan import library comfusion matrix selanjutnya dilakukan prediksi pada pada data tes nya kemudian data tersebut di masukan kedalam variabel cm dengan method confusion matrix yang di dalamnya terdapat data dari variabel perd label dan dk test label setelah itu variabel cm tersebut di running maka akan memunculkan nilai matrixnya.

7. cross valodation berikut merupakan code untuk cross validation pada codingan pertama yaitu melakukan split 5 kali yaoti mengitung tingkat akurasi menggunakan data training.

```
1 # In [16]: Dimana akan melakukan cross validation dengan 5
  split
2 from sklearn.model_selection import cross_val_score
3 scores = cross_val_score(clf, dk_train_att, dk_train_label, cv
  =5)
4 scorerata2=scores.mean()
5 scorersd=scores.std()
6 # In [21]:
7 from sklearn.model_selection import cross_val_score
8 scores = cross_val_score(clf, dk_train_att, dk_train_label,
  cv=5)
9 # show average score and +/- two standard deviations away (covering 95
10 # of scores)
11 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(),
12 scores.std() * 2))
13 # In [22]:
14 scorestree = cross_val_score(clftree, dk_train_att,
  dk_train_label, cv=5)
15 print("Accuracy: %0.2f (+/- %0.2f)" % (scorestree.mean(),
16 scorestree.std() * 2))
17 # In [23]:
18 scoresvm = cross_val_score(clfsvm, dk_train_att,
  dk_train_label, cv=5)
```

```

19 print("Accuracy: %.2f (+/- %.2f)" % (scoressvm.mean() ,
20 scoressvm.std() * 2))

```

```

Run: Run2
Hi everyone. We are a duo and we are sta
we love doing this. We may not have the
because we love making these videos and
Accuracy: 0.95 (+/- 0.04)
Accuracy: 0.96 (+/- 0.02)
Accuracy: 0.98 (+/- 0.06)
Process finished with exit code 0

```

Gambar 4.13 hasil

memunculkan nilai akurasi dari tiga metode yaitu random forest, decision tree, dan klasifikasi svm (support vector machine) di mana akan dibandingkan tingkat akurasi dari semua hasil akurasi mana yang terbaik dan lebih akurat pada hasilnya data yang paling akurat yaitu random forest.

8. Pengamatan program

```

1 # In [24]:
2 max_features_opts = range(1, 10, 1)
3 n_estimators_opts = range(2, 40, 4)
4 rf_params = np.empty((len(max_features_opts)*len(
    n_estimators_opts),4) , float)
5 i = 0
6 for max_features in max_features_opts:
7     for n_estimators in n_estimators_opts:
8         clf = RandomForestClassifier(max_features=
            max_features, n_estimators=n_estimators)
9         scores = cross_val_score(clf, dk_train_att,
        dk_train_label, cv=5)
10        rf_params[i,0] = max_features
11        rf_params[i,1] = n_estimators
12        rf_params[i,2] = scores.mean()
13        rf_params[i,3] = scores.std() * 2
14        i += 1
15        print("Max features: %d, num estimators: %d, accuracy
            : %.2f (+/- %.2f)")
16 % (max_features, n_estimators, scores.mean(), scores.std() *
2))
17 # In [25]:
18 import matplotlib.pyplot as plt
19 from mpl_toolkits.mplot3d import Axes3D
20 from matplotlib import cm
21 fig = plt.figure()
22 fig.clf()
23 ax = fig.gca(projection='3d')
24 x = rf_params[:,0]
25 y = rf_params[:,1]
26 z = rf_params[:,2]
27 ax.scatter(x, y, z)
28 ax.set_zlim(0.6, 1)

```

```

29 ax.set_xlabel('Max features')
30 ax.set_ylabel('Num estimators')
31 ax.set_zlabel('Avg accuracy')
32 plt.show()

```

```

Max features: 7, num estimators: 6, accuracy: 0.91 (+/- 0.08)
Max features: 7, num estimators: 10, accuracy: 0.91 (+/- 0.05)
Max features: 7, num estimators: 14, accuracy: 0.93 (+/- 0.05)
Max features: 7, num estimators: 18, accuracy: 0.94 (+/- 0.04)
Max features: 7, num estimators: 22, accuracy: 0.94 (+/- 0.05)
Max features: 7, num estimators: 26, accuracy: 0.95 (+/- 0.06)
Max features: 7, num estimators: 30, accuracy: 0.93 (+/- 0.06)
Max features: 7, num estimators: 34, accuracy: 0.94 (+/- 0.03)
Max features: 7, num estimators: 38, accuracy: 0.95 (+/- 0.03)
Max features: 8, num estimators: 2, accuracy: 0.83 (+/- 0.10)
Max features: 8, num estimators: 6, accuracy: 0.88 (+/- 0.07)
Max features: 8, num estimators: 10, accuracy: 0.92 (+/- 0.06)
Max features: 8, num estimators: 14, accuracy: 0.93 (+/- 0.05)
Max features: 8, num estimators: 18, accuracy: 0.93 (+/- 0.04)
Max features: 8, num estimators: 22, accuracy: 0.93 (+/- 0.06)
Max features: 8, num estimators: 26, accuracy: 0.94 (+/- 0.03)
Max features: 8, num estimators: 30, accuracy: 0.95 (+/- 0.04)
Max features: 8, num estimators: 34, accuracy: 0.94 (+/- 0.05)
Max features: 8, num estimators: 38, accuracy: 0.94 (+/- 0.04)
Max features: 9, num estimators: 2, accuracy: 0.80 (+/- 0.17)
Max features: 9, num estimators: 6, accuracy: 0.88 (+/- 0.06)
Max features: 9, num estimators: 10, accuracy: 0.93 (+/- 0.05)
Max features: 9, num estimators: 14, accuracy: 0.93 (+/- 0.05)
Max features: 9, num estimators: 18, accuracy: 0.94 (+/- 0.04)
Max features: 9, num estimators: 22, accuracy: 0.94 (+/- 0.03)
Max features: 9, num estimators: 26, accuracy: 0.93 (+/- 0.04)
Max features: 9, num estimators: 30, accuracy: 0.94 (+/- 0.06)
Max features: 9, num estimators: 34, accuracy: 0.93 (+/- 0.06)
Max features: 9, num estimators: 38, accuracy: 0.94 (+/- 0.06)

```

Gambar 4.14 hasil

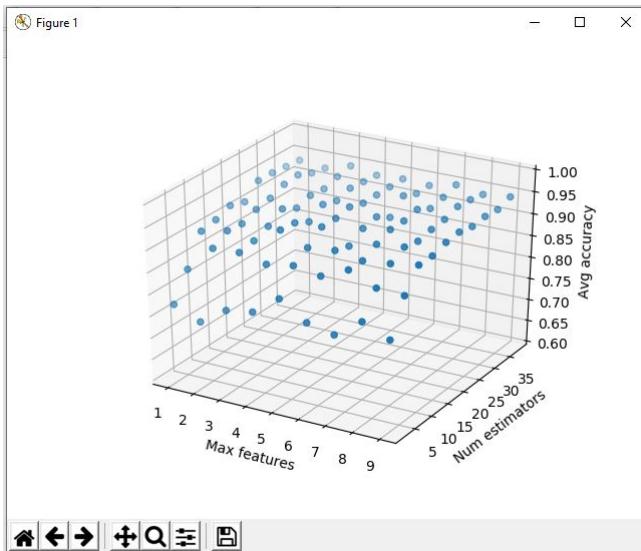
terdapat grafik data yang terdapat dari grafik tersebut di dapat dari codingan dengan cara pengulangan data masing masing 10 kali setelah itu di eksekusi menjadi grafik berbentuk 3D pada gambar tersebut menunjukan rasio dari yang terrendah yaitu data SVM kemudian data decision tree dan hasil random forest.

4.1.3 Penanganan Error

1. screnn shoot error
2. codingan yang errornya terdapat pada

```
clfsvm.fit(dk_train_att, d_train_label)
```

3. solusinya
- ```
clfsvm.fit(dk_train_att, dk_train_label)
```

**Gambar 4.15** hasil

```

Run: Run2
Traceback (most recent call last):
File "D:/NAJIB/SEMESTER_6_NAJIB/AI/Chapter4/Run2.py", line 47, in <module>
 clfsvm.fit(dk_train_att, d_train_label)
NameError: name 'd_train_label' is not defined
Process finished with exit code 1

```

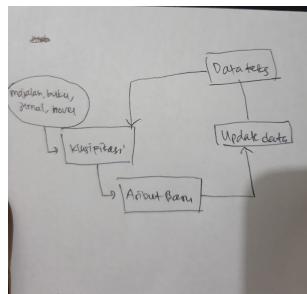
**Gambar 4.16** hasil

## 4.2 1174040 - Hagan Rowlenstino A. S

### 4.2.1 Teori

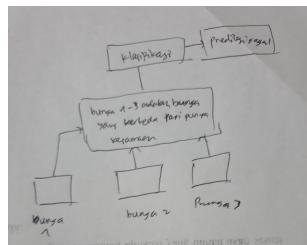
#### 1. Klasifikasi Text

Penggolongan teks atau biasa disebut pengklasifikasian teks biasanya sangat dibutuhkan pada aplikasi yang mempunyai jumlah dokumen yang biasanya bertambah dengan cepat. Klasifikasi teks itu sendiri merupakan cara dalam memilah milah data teks berdasarkan parameter tertentu dengan data yang bersifat dokumen ataupun teks yang memiliki kumpulan teks di dalamnya, serta teks itu sendiri bertipe data char atau string yang mudah untuk diolah.



**Gambar 4.17** Klasifikasi Text

- Mengapa Klasifikasi Bunga tidak dapat menggunakan Machine Learning karena klasifikasinya menggunakan tipe data yang dimana attributnya memiliki nilai data berupa vektor dengan perbandingan masing - masing data yang dimiliki memiliki sedikit perbedaan, sehingga program atau sistem tidak dapat membedakan dengan tepat antara gambar 1 dan gambar 2 dikarenakan memiliki perbedaan yang hampir tidak dapat dilihat pada beberapa contoh gambar. untuk ilustrasi dapat dilihat pada gambar



**Gambar 4.18** Klasifikasi Bunga

- Teknik Pembelajaran machine learning pada teks kata-kata di youtube Contohnya pada saat kita membuka sebuah video maka di sebelah kanan ada list "berikutnya", pada saat itu mesin melakukan ujicoba dan apabila anda menekan salah satu dari video tersebut maka hal tersebut akan direkam dan disimpan oleh mesin tersebut




**Gambar 4.19** Machine Learning Youtube

4. Jelaskan apa yang dimaksud vektorisasi data.

vektorisasi data merupakan pemecahan data menjadi bagian-bagian yang lebih sederhana contoh ada sebuah paragraf, dari paragraf tersebut akan dibagi-bagi menjadi kalimat, yang nantinya akan dibagi-bagi kembali menjadi perkata.

5. Jelaskan apa itu bag of words dengan kata-kata yang sederhana dan ilustrasi sendiri

Bag of words merupakan penyajian sederhana yang biasanya digunakan pada aplikasi text mining pada saat mengenalkan struktur ke sebuah kumpulan dokumen yang berbasis teks untuk diklasifikasikan kembali menjadi dua atau lebih kelas yang telah ditentukan. Dalam model ini teks, paragraf, dokumen, ataupun kalimat dimuat dalam kumpulan kata yang mengabaikan tata bahasa ataupun urutan dari kata-kata tersebut muncul.



**Gambar 4.20** Bag of Words

6. Jelaskan apa itu TF-IDF, ilustrasikan dengan gambar sendiri.

TF-IDF merupakan metode untuk menghitung bobot dari kata yang sering muncul pada suatu kalimat. metode ini menghitung nilai TF atau Term Frequency dan IDF atau Inverse Document Frequency pada setiap kata pada kalimat yang dijadikan acuan kata pada metode ini sering disebut token adapun rumus dari metode ini dapat dilihat pada gambar.

Gambar 4.21 TF-IDF

## 4.2.2 Praktek

1. import data pandas dan 500 baris data dumy kemudian di jelaskan tiap barisnya.

```
1 import pandas as pd #mengimport library pandas dan menamainya
pd
2 %%
3 hagan = pd.read_csv("D:/ Semester6/AI/Chapter4/1174040.csv") #
 membuat variable bernama hagan dan mengisinya dengan data
 dari dataset dummy yang telah dibuat
```

```

4 a = hagan.head() #untuk melihat 5 baris pertama dari data
 hagan
5 hagan.shape #untuk mengetahui berapa banyak baris data
6 print(a) #menampilkan isi dari varibale a pada console

```

The screenshot shows the Jupyter Notebook interface with the following content:

- Variable explorer**, **File explorer**, **Help**
- Python console** tab is active.
- In [42]:** shows the command: `Removing all variables...`
- In [42]:** shows the output of the command: `...Created on Mon Mar 23 13:20:30 2020`
- In [42]:** shows the command: `...: Author: User`
- In [42]:** shows the command: `...: import pandas as pd`
- In [42]:** shows the command: `hagan = pd.read_csv("D:/semester6/AI/Chapter4/11Data.csv")`
- In [42]:** shows the command: `a = hagan.head()`
- In [42]:** shows the command: `print(a)`
- In [42]:** shows the output of the command, displaying the first 5 rows of the DataFrame:

|   | id | first_name | last_name         | email                  | gender |
|---|----|------------|-------------------|------------------------|--------|
| 0 | 1  | Godard     | Addiein           | gaddelin@blablist.com  | Male   |
| 1 | 2  | Angela     | Bonje             | abonje@outlook.com     | Male   |
| 2 | 3  | Tobias     | ktdoben@spipol.de | Female                 |        |
| 3 | 4  | Giana      | Ortege            | gortegah@medialy.com   | Female |
| 4 | 5  | Celia      | Vite              | civite@reverberate.com | Female |

Gambar 4.22 Data Dummy

2. memecah data prame menjadi dua yag pertama 450 dan kedua sisanya

```

1 #%%
2 dtra = hagan[:450] #memasukkan 450 data pertama ke dalam
 variable dtra
3 dtes = hagan[450:] #memasukkan 50 data terakhir kedalam
 variable dtes

```

The screenshot shows the Jupyter Notebook interface with the following content:

- Variable explorer**, **File explorer**, **Help**
- Python console** tab is active.
- In [43]:** shows the command: `dtes DataFrame (50, 5) Column names: id, first_name, last_name, email, gender`
- In [43]:** shows the command: `dtra DataFrame (450, 5) Column names: id, first_name, last_name, email, gender`

Gambar 4.23 Pisah Data

3. praktek vektorisasi

```

1 #%% memasukkan data dari file csv tersebut ke dalam variable
 data
2 data=pd.read_csv("D:/ Semester6/AI/Chapter4/Youtube02-
 KatyPerry.csv")
3 spam=data.query('CLASS == 1')
4 nospam=data.query('CLASS == 0')
5 #%% melakukan fungsi bag of word dengan cara menghitung semua
 kata
6 from sklearn.feature_extraction.text import CountVectorizer
7 vectorizer = CountVectorizer()
8 #%% melakukan bag of word pada dataframe pada colom CONTENT
9 data_vektorisasi = vectorizer.fit_transform(data['CONTENT'])
10 #%% melihat isi vektorisasi
11 data_vektorisasi

```

```

12 #%% melihat isi data pada baris ke 345
13 print(data['CONTENT'][345])
14 #%% untuk mengambil apa saja nama kolom yang tersedia
15 dk=vectorizer.get_feature_names()
16 #%%: melakukan randomisasi agar hasil sempurna pada saat
 klasifikasi
17 dshuf = data.sample(frac=1)
18 #%%: membuat data tranning dan testing
19 dk_train=dshuf[:300]
20 dk_test=dshuf[300:]
21 #%%: melakukan training pada data training dan di vektorisasi
22 dk_train_att=vectorizer.fit_transform(dk_train['CONTENT'])
23 print(dk_train_att)
24 #%% melakukan testing pada data testing dan di vektorisasi
25 dk_test_att=vectorizer.transform(dk_test['CONTENT'])
26 print(dk_test_att)
27 #%%: Dimana akan mengambil label spam dan bukan spam
28 dk_train_label=dk_train['CLASS']
29 print(dk_train_label)
30 dk_test_label=dk_test['CLASS']
31 print(dk_test_label)

```

lakukan import library pandas yang di inisialisasi menjadi pd setelah itu ada dibuat variable data dengan method read\_csv untuk membaca file berekstensikan csv yang di masukan alamatnya pada kurung, lakukan klasifikasi atau pemilihan komentar yang berisi spam atau bukan spam dengan parameter class samadengan 1 merupakan spam dan class samadengan 0 bukan spam setelah itu masukan librari CountVektorizer yang digunakan untuk vektorisasi data kemudian dilanjutkan pada bagian In[103] dibuat variabel yang berisi vektorisasi dari data pada data di field content setelah itu variabel tersebut di running hasilnya menunjukan 350 baris di kali 1738 kolom selanjutnya dicoba untuk memunculkan isi recod pada baris ke 345 maka akan muncul isian dari baris tersebut. selanjutnya dibuat variabel dk atau daftar yang berisi data hasil vektorisasi setelah yang terdiri dari variabel dshuf yang berisi data komen yang di dalamnya di buat random yang nantinya akan dibut data training dan data testing dengan ketentuan data training 300 dan data testing sebanyak 50 setelah itu data training di lakukan vektorisasi dan data testing juga dilakukan vektorisasi setelah itu kedua data training dan testing tersebut dibuat label dengan parameter field CLASS pada tabel.

```

... : dk_train_label=dk_train['CLASS']
... : dk_test_label=dk_test['CLASS']
... :
who is going to reach the billion first : katy or taylor ?
(9, 1557) 1
(9, 1558) 1
(9, 1559) 1
(9, 1560) 1
(9, 1561) 1
(9, 1562) 1
(9, 1563) 1
(9, 1564) 1
(9, 1565) 1
(9, 1566) 1
(9, 1567) 1
(9, 1568) 1
(9, 1569) 1
(9, 1570) 1
(9, 1571) 1
(9, 1572) 1
(9, 1573) 1
(9, 1574) 1
(9, 1575) 1
(9, 1576) 1
(9, 1577) 1
(9, 1578) 1
(9, 1579) 1
(9, 1580) 1
(9, 1581) 1
(9, 1582) 1
(9, 1583) 1
(9, 1584) 1
(9, 1585) 1
(9, 1586) 1
(9, 1587) 1
(9, 1588) 1
(9, 1589) 1
(9, 1590) 1
(9, 1591) 1
(9, 1592) 1
(9, 1593) 1
(9, 1594) 1
(9, 1595) 1
(9, 1596) 1
(9, 1597) 1
(9, 1598) 1
(9, 1599) 1
(9, 1600) 1
(9, 1601) 1
(9, 1602) 1
(9, 1603) 1
(9, 1604) 1
(9, 1605) 1
(9, 1606) 1
(9, 1607) 1
(9, 1608) 1
(9, 1609) 1
(9, 1610) 1
(9, 1611) 1
(9, 1612) 1
(9, 1613) 1
(9, 1614) 1
(9, 1615) 1
(9, 1616) 1
(9, 1617) 1
(9, 1618) 1
(9, 1619) 1
(9, 1620) 1
(9, 1621) 1
(9, 1622) 1
(9, 1623) 1
(9, 1624) 1
(9, 1625) 1
(9, 1626) 1
(9, 1627) 1
(9, 1628) 1
(9, 1629) 1
(9, 1630) 1
(9, 1631) 1
(9, 1632) 1
(9, 1633) 1
(9, 1634) 1
(9, 1635) 1
(9, 1636) 1
(9, 1637) 1
(9, 1638) 1
(9, 1639) 1
(9, 1640) 1
(9, 1641) 1
(9, 1642) 1
(9, 1643) 1
(9, 1644) 1
(9, 1645) 1
(9, 1646) 1
(9, 1647) 1
(9, 1648) 1
(9, 1649) 1
(9, 1650) 1
(9, 1651) 1
(9, 1652) 1
(9, 1653) 1
(9, 1654) 1
(9, 1655) 1
(9, 1656) 1
(9, 1657) 1
(9, 1658) 1
(9, 1659) 1
(9, 1660) 1
(9, 1661) 1
(9, 1662) 1
(9, 1663) 1
(9, 1664) 1
(9, 1665) 1
(9, 1666) 1
(9, 1667) 1
(9, 1668) 1
(9, 1669) 1
(9, 1670) 1
(9, 1671) 1
(9, 1672) 1
(9, 1673) 1
(9, 1674) 1
(9, 1675) 1
(9, 1676) 1
(9, 1677) 1
(9, 1678) 1
(9, 1679) 1
(9, 1680) 1
(9, 1681) 1
(9, 1682) 1
(9, 1683) 1
(9, 1684) 1
(9, 1685) 1
(9, 1686) 1
(9, 1687) 1
(9, 1688) 1
(9, 1689) 1
(9, 1690) 1
(9, 1691) 1
(9, 1692) 1
(9, 1693) 1
(9, 1694) 1
(9, 1695) 1
(9, 1696) 1
(9, 1697) 1
(9, 1698) 1
(9, 1699) 1
(9, 1700) 1
(9, 1701) 1
(9, 1702) 1
(9, 1703) 1
(9, 1704) 1
(9, 1705) 1
(9, 1706) 1
(9, 1707) 1
(9, 1708) 1
(9, 1709) 1
(9, 1710) 1
(9, 1711) 1
(9, 1712) 1
(9, 1713) 1
(9, 1714) 1
(9, 1715) 1
(9, 1716) 1
(9, 1717) 1
(9, 1718) 1
(9, 1719) 1
(9, 1720) 1
(9, 1721) 1
(9, 1722) 1
(9, 1723) 1
(9, 1724) 1
(9, 1725) 1
(9, 1726) 1
(9, 1727) 1
(9, 1728) 1
(9, 1729) 1
(9, 1730) 1
(9, 1731) 1
(9, 1732) 1
(9, 1733) 1
(9, 1734) 1
(9, 1735) 1
(9, 1736) 1
(9, 1737) 1
(9, 1738) 1

```

Gambar 4.24 Vektorisasi

#### 4. klasifikasi SVM

```

1 from sklearn import svm
2 clfsvm = svm.SVC()
3 clfsvm.fit(dk_train_att, dk_train_label)
4 clfsvm.score(dk_test_att, dk_test_label)

```

import librari svm dari sklearn kemudian membuat variabel clfsvm berisikan method svc setelah itu variabel tersebut di berikan method fit dengan isian data train vektorisasi dan data training label yang berguna untuk melatih data tersebut setelah itu di coba untuk memunculkan score atau akurasi dari data tersebut menggunakan data testing vektorisasi dan data testing label.

```

In [66]: from sklearn import svm
...: clfsvm = svm.SVC()
...: clfsvm.fit(dk_train_att, dk_train_label)
...: clfsvm.score(dk_test_att, dk_test_label)
Out[66]: 0.94

```

**Gambar 4.25** SVM

#### 5. klasifikasi decision tree

```

1 from sklearn import tree
2 clftree = tree.DecisionTreeClassifier()
3 clftree.fit(dk_train_att, dk_train_label)
4 clftree.score(dk_test_att, dk_test_label)

```

import librari tree dari sklearn kemudian membuat variabel clftree berisikan method DecisionTreeClasifier setelah itu variabel tersebut di berikan method fit dengan isian data train vektorisasi dan data training label yang berguna untuk melatih data tersebut agar dapat digunakan pada codingan selanjutnya setelah itu di coba untuk memunculkan score atau akurasi dari data tersebut menggunakan data testing vektorisasi dan data testing label.

```

In [67]: from sklearn import tree
...: clftree = tree.DecisionTreeClassifier()
...: clftree.fit(dk_train_att, dk_train_label)
...: clftree.score(dk_test_att, dk_test_label)
Out[67]: 0.96

```

**Gambar 4.26** Desicion Tree

#### 6. plot comfusion matrix

```

1 from sklearn.metrics import confusion_matrix
2 pred_labels = clftree.predict(dk_test_att)
3 cm = confusion_matrix(dk_test_label, pred_labels)
4 cm

```

import library comfusion matrix selanjutnya dilakukan prediksi pada pada data tes nya kemudian data tersebut di masukan kedalam variabel cm dengan method confusion matrix yang di dalamnya terdapat data dari variabel perd label dan dk test label setelah itu variabel cm tersebut di running maka akan memunculkan nilai matrixnya.

```
In [80]: from sklearn.metrics import confusion_matrix
...: pred_labels = clftree.predict(dk_test_att)
...: cm = confusion_matrix(dk_test_label, pred_labels)
...: cm
Out[80]:
array([[25, 1],
 [1, 23]], dtype=int64)
```

**Gambar 4.27** Confussion Matrix

## 7. cross valodation

```
1 #%%%
2 from sklearn.model_selection import cross_val_score
3 scores = cross_val_score(clftree, dk_train_att, dk_train_label,
 cv=5)
4 scorerata2=scores.mean()
5 scorersd=scores.std()
6 #%%:
7 from sklearn.model_selection import cross_val_score
8 scores = cross_val_score(clftree, dk_train_att,
 dk_train_label, cv=5)
9 # show average score and +/- two standard deviations away (
 covering 95
10 #% of scores)
11 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(),
12 scores.std() * 2))
13 #%%:
14 scorestree = cross_val_score(clftree, dk_train_att,
 dk_train_label, cv=5)
15 print("Accuracy: %0.2f (+/- %0.2f)" % (scorestree.mean(),
16 scorestree.std() * 2))
17 #%%:
18 scoressvm = cross_val_score(clfsvm, dk_train_att,
 dk_train_label, cv=5)
19 print("Accuracy: %0.2f (+/- %0.2f)" % (scoressvm.mean(),
20 scoressvm.std() * 2))
```

memunculkan nilai akurasi dari tiga metode yaitu random forest, decision tree, dan klasifikasi svm (suport vector machine) diamana akan di bandingkan tingkat akurasi dari semua hasil akurasi mana yang terbaik dan lebih akurat pada hasilnya data yang paling akurat yaitu random forest.

```
In [82]: from sklearn.model_selection import cross_val_score
...: scores = cross_val_score(ciftree, dk_train_att, dk_train_label, cv=5)
...: scores = scores.mean()
...: scores+=scores.std()
In [83]: from sklearn.model_selection import cross_val_score
...: scores = cross_val_score(ciftree, dk_train_att, dk_train_label, cv=5)
...: scores = scores.mean()
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(),
...: scores.std() * 2))
Accuracy: 0.73 (+/- 0.07)

In [84]: scores = cross_val_score(lfsvm, dk_train_att, dk_train_label, cv=5)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scoresvm.mean(),
...: scoresvm.std() * 2))
Accuracy: 0.85 (+/- 0.07)

In [85]: scoresvm = cross_val_score(lfsvm, dk_train_att, dk_train_label, cv=5)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (coresvm.mean(),
...: coresvm.std() * 2))
Accuracy: 0.91 (+/- 0.08)
```

**Gambar 4.28** Cross Validation

## 8. Pengamatan program

```
1 #%%%
2 import numpy as np
3 max_features_opts = range(1, 10, 1)
4 n_estimators_opts = range(2, 40, 4)
5 rf_params = np.empty((len(max_features_opts)*len(
6 n_estimators_opts),4) , float)
7 i = 0
8 for max_features in max_features_opts:
9 for n_estimators in n_estimators_opts:
10 clf = RandomForestClassifier(max_features=
11 max_features , n_estimators=n_estimators)
12 scores = cross_val_score(clf , dk_train_att ,
13 dk_train_label , cv=5)
14 rf_params[i,0] = max_features
15 rf_params[i,1] = n_estimators
16 rf_params[i,2] = scores.mean()
17 rf_params[i,3] = scores.std() * 2
18 i += 1
19 print("Max features: %d, num estimators: %d, accuracy
20 : %0.2f (+/- %0.2f)"
21 % (max_features , n_estimators , scores.mean() , scores.std() *
22))
```

terdapat grafik data yang terdapat dari grafik tersebut di dapat dari codingan dengan cara pengulangan data masing masing 10 kali setelah itu di eksekusi menjadi grafik berbentuk 3D pada gambar tersebut menunjukan rasio dari yang terrendah yaitu data SVM kemudian data decision tree dan hasil random forest.

```
...: clf = RandomForestClassifier(max_features=max_features,
...: n_estimators=n_estimators)
...: scores = cross_val_score(clf, dk_train_att, dk_train_label, cv=5)
...: rf_params[i,0] = max_features
...: rf_params[i,1] = n_estimators
...: rf_params[i,2] = scores.mean()
...: rf_params[i,3] = scores.std() * 2
...: i += 1
...: print("Max features: %d, num estimators: %d, accuracy: %0.2f (+/- %0.2f)"
...: % (max_features, n_estimators, scores.mean(), scores.std() * 2))
Max features: 1, num estimators: 2, accuracy: 0.73 (+/- 0.06)
Max features: 1, num estimators: 4, accuracy: 0.73 (+/- 0.06)
Max features: 1, num estimators: 10, accuracy: 0.86 (+/- 0.05)
Max features: 1, num estimators: 14, accuracy: 0.88 (+/- 0.12)
Max features: 1, num estimators: 18, accuracy: 0.88 (+/- 0.05)
Max features: 1, num estimators: 22, accuracy: 0.87 (+/- 0.07)
Max features: 1, num estimators: 26, accuracy: 0.86 (+/- 0.05)
Max features: 1, num estimators: 30, accuracy: 0.86 (+/- 0.05)
Max features: 1, num estimators: 34, accuracy: 0.89 (+/- 0.03)
Max features: 2, num estimators: 2, accuracy: 0.69 (+/- 0.03)
Max features: 2, num estimators: 10, accuracy: 0.86 (+/- 0.05)
Max features: 2, num estimators: 18, accuracy: 0.86 (+/- 0.05)
Max features: 2, num estimators: 22, accuracy: 0.87 (+/- 0.07)
Max features: 2, num estimators: 26, accuracy: 0.86 (+/- 0.05)
Max features: 2, num estimators: 30, accuracy: 0.86 (+/- 0.05)
Max features: 2, num estimators: 34, accuracy: 0.89 (+/- 0.03)
```


**Gambar 4.29** Pengamatan Program

Berikut adalah untuk grafik

```

1 import matplotlib.pyplot as plt
2 from mpl_toolkits.mplot3d import Axes3D
3 from matplotlib import cm
4 fig = plt.figure()
5 fig.clf()
6 ax = fig.gca(projection='3d')
7 x = rf_params[:,0]
8 y = rf_params[:,1]
9 z = rf_params[:,2]
10 ax.scatter(x, y, z)
11 ax.set_zlim(0.6, 1)
12 ax.set_xlabel('Max features')
13 ax.set_ylabel('Num estimators')
14 ax.set_zlabel('Avg accuracy')
15 plt.show()

```



**Gambar 4.30** Grafik

### 4.2.3 Penanganan Error

#### 4.2.3.1 Screenshoot Error

##### 1. Error 1

```

rf_params = np.empty((len(max_features_opts)*len(n_estimators_opts),4), float)
NameError: name 'np' is not defined

```

**Gambar 4.31** Error1

##### 2. Error 2

```

File "pandas_libs\hashtable_class_helper.pxi", line 1492, in
pandas._libs.hashtable.PyObjectHashTable.get_item
File "pandas_libs\hashtable_class_helper.pxi", line 1500, in
pandas._libs.hashtable.PyObjectHashTable.get_item
KeyError: 'CONTENT'

```

**Gambar 4.32** Error2

##### 3. Error 3

```

File "pandas_libs\parsers.pyx", line 695, in
pandas._libs.parsers.read_csv_cython._read_file
FileNotFoundError: File b'D:\Semester6\AI\Chapter404080.csv' does not exist

```

**Gambar 4.33** Error3

#### 4. Error 4

```
File "pandas\libs\hashtable_class_helper.pxi", line 964, in
pandas._libs.hashtable.Int64HashTable.get_item
KeyError: 5000
```

**Gambar 4.34** Error4

##### 4.2.3.2 Kode Error dan Jenisnya

###### 1. Kode Error 1 jenis Name Error

```
max_features_opts = range(1, 10, 1)
n_estimators_opts = range(2, 40, 2)
rf_params = np.empty((len(max_features_opts)*len(n_estimators_opts), 4), float)
i = 0
```

**Gambar 4.35** Error1

###### 2. Kode Error 2 jenis Key Error

```
data_vektorisasi = vectorizer.fit_transform(data['CONTENTz'])
```

**Gambar 4.36** Error2

###### 3. Kode Error 3 jenis FileNotFoundError

```
#%%%
hagen = pd.read_csv("D:\\Semester5\\AI\\Chapter4\\L174040.csv") #membuat
a = hagen.head() #ambil sebanyak 5 baris pertama dari data hagen
hagen.shape #untuk mengetahui berapa banyak baris data
print(a) #menampilkan isi dari variabel a pada console
```

**Gambar 4.37** Error3

###### 4. Kode Error 4 Key Error

```
#%%
print(data['CONTENT'][5000])
```

**Gambar 4.38** Error4

##### 4.2.3.3 Solusi

###### 1. Mengimport library numpy sebagai np

```
import numpy as np
max_features_opts = range(1, 10, 1)
n_estimators_opts = range(2, 40, 2)
rf_params = np.empty((len(max_features_opts)*len(n_estimators_opts), 4), float)
i = 0
```

**Gambar 4.39** Solusi 1

###### 2. Mengganti CONTENTz menjadi CONTENT

**Gambar 4.40** Solusi 2

- Merubah backslash menjadi slash biasa

```
data_vektorisasi = vectorizer.fit_transform(data['CONTENT'])
data_vektorisasi
```

**Gambar 4.41** Solusi 3

- Merubah data menjadi dibawah 350

```
#%%%
print(data['CONTENT'][349])
%%%
```

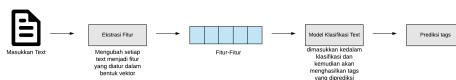
**Gambar 4.42** Solusi 4

### 4.3 Alit Fajar Kurniawan 1174057

#### 4.3.1 Teori

- Jelaskan apa itu klasifikasi teks, sertakan gambar ilustrasi buatan sendiri.

Klasifikasi teks adalah proses pemberian tag atau kategori ke teks sesuai dengan isinya. Teks dapat menjadi sumber informasi yang sangat kaya, tetapi mengekstraksi wawasan darinya bisa sulit dan memakan waktu karena sifatnya yang tidak terstruktur. berikut contoh gambar ?? .

**Gambar 4.43** contoh klasifikasi teks

- Jelaskan mengapa klasifikasi bunga tidak bisa menggunakan machine learning, sertakan ilustrasi sendiri.

Untuk klasifikasi bunga tidak dapat menggunakan machine learning dikarenakan memiliki masalah input yang sama namun keluarannya (output) yang berbeda, biasanya output atau error ini disebut dengan istilah 'noise'. Noise sendiri merupakan output yang disimpan / ditangkap maupun direkam bukan seperti seharusnya ( keluaran yang diinginkan ).

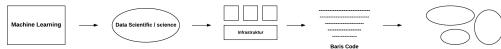
Apabila diberikan contoh, maka contohnya yaitu kita berasumsi secara implisit bahwa klarifikasi bunga yang kita lakukan sudah tepat dan kita melakukannya seperti seorang ahli tanaman. Namun pada hasilnya masih saja terjadi kesalahan. Selain itu, selalu ada peluang untuk memperkenalkan kesalahan saat merekam ataupun menyimpan data, maka harus dilakukan penelitian yang lebih rinci sehingga tidak menimbulkan 'noise' itu sendiri. Berikut ilustrasi gambar ??



**Gambar 4.44** gambar bunga

3. Jelaskan bagaimana teknik pembelajaran mesin pada teks pada kata-kata yang digunakan di youtube,jelaskan arti per atribut data csv dan sertakan ilustrasi buatan sendiri.

Kita ambil sebuah kasus yang semua orang telah ketahui dan juga pahami. Kasus tersebut yaitu perekendasian video dari pencarian menggunakan "text / kata" di Youtube. Pada saat menggunakan Youtube terdapat Machine Learning yang bekerja dan memproses perintah ataupun aktivitas tersebut, dimana akan memfilter secara otomatis video yang disesuaikan dengan "keyword" yang kita masukkan sehingga memberikan keluaran video dengan keyword yang benar. Adapula fitur yang dapatkan ketika sedang menonton Youtube. Tampilan sebelah kanan terdapat pilihan 'Next' atapun 'Suggestion' yang menampilkan beberapa video serupa sesuai dengan yang dicari atau sedang ditonton. Ketika menglik salah satu video dari baris tersebut, maka Youtube akan mengingat dan menggunakan kata yang tertera sebagai referensi kembali sehingga akan memberikan kemudahan pada pencarian yang lainnya, Dan disitulah mesin belajar sendiri dan menyimpan data secara berkala sehingga berkembang. contoh pada gambar ??



**Gambar 4.45** pembelajaran mesin

4. Jelaskan apa yang dimaksud vektorisasi data.

Pembagian dan pemecahan data, kemudian dilakukan perhitungan. Vektorisasi juga dapat dimaksudkan dengan setiap data yang mungkin dipetakan ke integer tertentu. jika kita memiliki array yang cukup besar maka setiap kata / data cocok dengan slot unik dalam array (nilai pada indeks adalah nomor satu kali kata itu muncul).

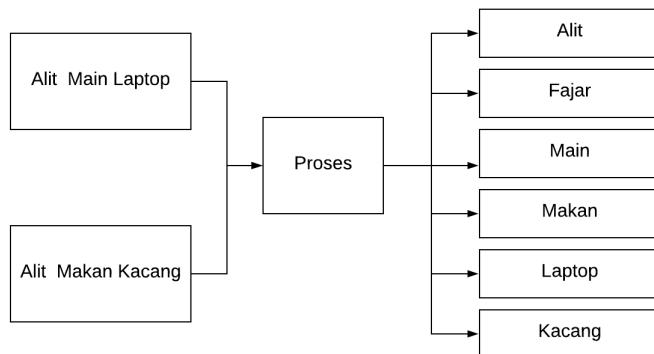
Array angka floating point ( Mewakili data ) :

- teks
- audio
- gambar

Contoh : -[1.0, 0.0, 1.0, 0.5]

5. Jelaskan apa itu bag of words dengan kata-kata yang sederhana dan ilustrasi sendiri.

bag-of-words adalah representasi penyederhanaan yang digunakan dalam pemrosesan bahasa alami dan pengambilan informasi. Model bag-of-words sederhana untuk dipahami dan diterapkan dan telah melihat kesuksesan besar dalam masalah seperti pemodelan bahasa dan klasifikasi dokumen.Pada model ini, tiap kalimat dalam dokumen digambarkan sebagai token, mengabaikan tata bahasa dan bahkan urutan kata namun menghitung frekuensi kejadian atau kemunculan kata dari dokumen. berikut contoh gambar ??

**Gambar 4.46** bag of words

6. Jelaskan apa itu TF-IDF, ilustrasikan dengan gambar sendiri

TF-IDF memberi kita frekuensi kata dalam setiap dokumen dalam korpus atau mengganti data jadi number. Ini adalah rasio berapa kali kata itu muncul dalam dokumen dibandingkan dengan jumlah total kata dalam dokumen itu. Itu meningkat seiring jumlah kemunculan kata itu di dalam dokumen meningkat. Setiap dokumen memiliki tf sendiri.

|       | Alit | Fajar | Main | Makan | Laptop | Kacang |
|-------|------|-------|------|-------|--------|--------|
| Doc 1 | 1    |       | 1    |       |        | 1      |
| Doc 2 | 1    | 1     | 1    | 1     |        |        |
| Doc 3 |      | 1     |      |       | 1      |        |

**Gambar 4.47** TF-IDF

### 4.3.2 Praktek Program

1. import data pandas dan 500 baris data dummy kemudian di jelaskan tiap barisnya.

```

1 #mengimport library pandas dan menamainya pd
2 import pandas as pd
3 #%%
4 #membuat variable bernama alit dan mengisinya dengan data
 dari dataset dummy yang telah dibuat
5 alit = pd.read.csv("D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src
 /1174057/chapter4/1174057.csv")
6 #untuk melihat 5 baris pertama dari data alit
7 c = alit.head()
8 #untuk mengetahui berapa banyak baris data

```

```

9 alit.shape
10 #menampilkan isi dari varibale c pada console
11 print(c)

```

```

In [15]: runfile('D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter4/1.py',
wdir='D:/Data Alit/Kuliah/SEMESTER VI/KB3B/src/1174057/chapter4')
first_name ... web
0 James ... http://www.bentonjohnbjr.com
1 Josephine ... http://www.chanayjeffreyaesq.com
2 Art ... http://www.chemeljameslcpa.com
3 Lenna ... http://www.feltzprintingservice.com
4 Donette ... http://www.printingdimensions.com

[5 rows x 12 columns]

```

**Gambar 4.48** hasil

2. dari dataframe tersebut dipecah menjadi dua dataframe yaitu 450 row pertama dan 50 row sisanya

```

1
2
3 #%%
4 #memasukkan 450 data pertama ke dalam variable dtra
5 dtra = alit [:450]

```

```

In [78]: data=pd.read_csv("D:/Data Alit/Kuliah/SEMESTER VI/AI_KB3B/
Python-Artificial-Intelligence-Projects-for-Beginners-master/Chapter04/
Youtube03-LMFAO.csv")
....: spam=data.query('CLASS == 1')
....: nospam=data.query('CLASS == 0')

```

**Gambar 4.49** hasil

|      |                     |                                                                            |
|------|---------------------|----------------------------------------------------------------------------|
| dtes | DataFrame (50, 12)  | Column names: first_name, last_name, company_name, address, city, coun ... |
| dtra | DataFrame (450, 12) | Column names: first_name, last_name, company_name, address, city, coun ... |

**Gambar 4.50** hasil

3. praktek vektorisasi

```

1 #%% memasukkan data dari file Youtube03-LMFAO.csv tersebut ke
 dalam variable data
2 data=pd.read_csv("D:/Data Alit/Kuliah/SEMESTER VI/AI_KB3B/
 Python-Artificial-Intelligence-Projects-for-Beginners-
 master/Chapter04/Youtube03-LMFAO.csv")
3 spam=data.query('CLASS == 1')
4 nospam=data.query('CLASS == 0')
5 #%% melakukan fungsi bag of word dengan cara menghitung semua
 kata

```

```
6 from sklearn.feature_extraction.text import CountVectorizer
7 vectorizer = CountVectorizer()
8 %% melakukann bag of word pada dataframe pada colom CONTENT
9 data_vektorisasi = vectorizer.fit_transform(data['CONTENT'])
10 %% melihat isi vektorisasi
11 data_vektorisasi
12 %% menampilkan isi data pada baris ke 300
13 print(data['CONTENT'][300])
14 %% untuk mengambil apa saja nama kolom yang tersedia
15 dk=vectorizer.get_feature_names()
16 %%: randomisasi agar hasil sempurna pada saat klasifikasi
17 dshuf = data.sample(frac=1)
18 %%: membuat data tranning dan testing
19 dk_train=dshuf[:300]
20 dk_test=dshuf[300:]
21 %%: melakukan training pada data training dan di vektorisasi
22 dk_train_att=vectorizer.fit_transform(dk_train['CONTENT'])
23 print(dk_train_att)
24 %%: melakukan testing pada data testing dan di vektorisasi
25 dk_test_att=vectorizer.transform(dk_test['CONTENT'])
26 print(dk_test_att)
27 %%: Dimana akan mengambil label spam dan bukan spam
28 dk_train_label=dk_train['CLASS']
29 print(dk_train_label)
30 dk_test_label=dk_test['CLASS']
31 print(dk_test_label)
```

lakukan import library pandas yang di inisialisasi menjadi pd setelah itu ada dibuat variable data dengan method read\_csv untuk membaca file berekstensikan csv yang di masukan alamatnya pada kurung, lakukan klasifikasi atau pemilihan komentar yang berisi spam atau bukan spam dengan parameter class samadengan 1 merupakan spam dan class samadengan 0 bukan spam setelah itu masukan librari CountVektorizer yang digunakan untuk vektorisasi data kemudian dilanjutkan pada bagian In[103] dibuat variabel yang berisi vektorisasi dari data pada data di field content setelah itu variabel tersebut di running hasilnya menunjukan 350 baris di kali 1738 kolom selanjutnya dicoba untuk memunculkan isi record pada baris ke 345 maka akan muncul isian dari baris tersebut. selanjutnya dibuat variabel dk atau daftar yang berisi data hasil vektorisasi setelah yang terdiri dari variabel dshuf yang berisi data komen yang di dalamnya di buat random yang nantinya akan dibut data training dan data testing dengan ketentuan data training 300 dan data testing sebanyak 50 setelah itu data training di lakukan vektorisasi dan data testing juga dilakukan vektorisasi setelah itu kedua data training dan testing tersebut dibuat label dengan parameter field CLASS pada tabel.

```
In [41]: dk_train_label=dk_train['CLASS']
...: print(dk_train_label)
...: dk_test_label=dk_test['CLASS']
...: print(dk_test_label)
228 1
212 1
344 1
326 1
270 1
322 1
304 1
332 1
33 0
361 1
205 1
365 1
195 0
285 1
370 1
124 0
298 1
51 0
333 1
187 1
426 0
215 1
101 0
106 1
```

IPython console History log

Gambar 4.51 hasil

#### 4. klasifikasi SVM

```
1 #import librari svm dari sklearn
2 from sklearn import svm
3 #membuat variabel clfsvm berisikan method svc
4 clfsvm = svm.SVC()
5 #variabel tersebut di berikan method fit dengan isian data
#train vektorisasi dan data training label
6 clfsvm.fit(dk_train_att, dk_train_label)
7 clfsvm.score(dk_test_att, dk_test_label)
```

```
In [45]: from sklearn import svm
...: #membuat variabel clfsvm berisikan method svc
...: clfsvm = svm.SVC()
...: #variabel tersebut di berikan method fit dengan isian data train vektorisasi
dan data training label
...: clfsvm.fit(dk_train_att, dk_train_label)
...: clfsvm.score(dk_test_att, dk_test_label)
Out[45]: 0.855072463768116
```

Gambar 4.52 hasil

#### 5. klasifikasi decision tree

```
1 #import librari tree dari sklearn
2 from sklearn import tree
3 clftree = tree.DecisionTreeClassifier()
```

```

4 clftree.fit(dk_train_att, dk_train_label)
5 clftree.score(dk_test_att, dk_test_label)

```

import librari tree dari sklearn kemudian membuat variabel clftrree berisikan method DecisionTreeClasifier setelah itu variabel tersebut di berikan method fit dengan isian data train vektorissasi dan data training label yang berguna untuk melatih data tersebut agar dapat digunakan pada codingan selanjutnya setelah itu di coba untuk memunculkan score atau akurasi dari data tersebut menggunakan data testing vektorisasi dan data testing label.

```

In [49]: from sklearn import tree
...: clftrree = tree.DecisionTreeClassifier()
...: clftrree.fit(dk_train_att, dk_train_label)
...: clftrree.score(dk_test_att, dk_test_label)
Out[49]: 0.9637681159420289

```

**Gambar 4.53** hasil

## 6. plot confusion matrix

```

1 %%##plot comfusion matrix
2 from sklearn.metrics import confusion_matrix
3 pred_labels = clftrree.predict(dk_test_att)
4 cm = confusion_matrix(dk_test_label, pred_labels)
5 cm

```

import library comfusion matrix selanjutnya dilakukan prediksi pada pada data tes nya kemudian data tersebut di masukan kedalam variabel cm dengan method confusion matrix yang di dalamnya terdapat data dari variabel perd label dan dk test label setelah itu variabel cm tersebut di running maka akan memunculkan nilai matrixnya.

```

In [51]: from sklearn.metrics import confusion_matrix
...: pred_labels = clftrree.predict(dk_test_att)
...: cm = confusion_matrix(dk_test_label, pred_labels)
...: cm
Out[51]:
array([[61, 2],
 [3, 72]], dtype=int64)

```

**Gambar 4.54** hasil

## 7. cross valodation

```

1 from sklearn.model_selection import cross_val_score
2 scores = cross_val_score(clftrree, dk_train_att, dk_train_label,
 cv=5)
3 scorerata2=scores.mean()
4 scorersd=scores.std()
5 %%%

```

```

6 from sklearn.model_selection import cross_val_score
7 scores = cross_val_score(clftree, dk_train_att,
8 dk_train_label, cv=5)
show average score and +/- two standard deviations away (covering 95
9 #%% of scores)
10 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(),
11 scores.std() * 2))
12 #%%:
13 scorestree = cross_val_score(clftree, dk_train_att,
14 dk_train_label, cv=5)
15 print("Accuracy: %0.2f (+/- %0.2f)" % (scorestree.mean(),
16 scorestree.std() * 2))
17 #%%:
18 scoressvm = cross_val_score(clfsvm, dk_train_att,
19 dk_train_label, cv=5)
20 print("Accuracy: %0.2f (+/- %0.2f)" % (scoressvm.mean(),
21 scoressvm.std() * 2))

```

memunculkan nilai akurasi dari tiga metode yaitu random forest, decision tree, dan klasifikasi svm (suport vector machine) diamanakan dibandingkan tingkat akurasi dari semua hasil akurasi mana yang terbaik dan lebih akurat pada hasilnya data yang paling akurat yaitu random forest.

```
In [57]: from sklearn.model_selection import cross_val_score
...: scores = cross_val_score(clftree, dk_train_att, dk_train_label, cv=5)
...: # show average score and +/- two standard deviations away (covering 95
...: #%% of scores)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(),
...: scores.std() * 2))
Accuracy: 0.94 (+/- 0.08)
```

```
In [58]: from sklearn.model_selection import cross_val_score
...: scores = cross_val_score(clftree, dk_train_att, dk_train_label, cv=5)
...: # show average score and +/- two standard deviations away (covering 95
...: #%% of scores)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(),
...: scores.std() * 2))
Accuracy: 0.95 (+/- 0.06)
```

```
In [59]: scorestree = cross_val_score(clftree, dk_train_att, dk_train_label, cv=5)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scorestree.mean(),
...: scorestree.std() * 2))
Accuracy: 0.95 (+/- 0.05)
```

```
In [60]: scoressvm = cross_val_score(clfsvm, dk_train_att, dk_train_label, cv=5)
...: print("Accuracy: %0.2f (+/- %0.2f)" % (scoressvm.mean(),
...: scoressvm.std() * 2))
Accuracy: 0.54 (+/- 0.01)
C:\ProgramData\Anaconda3\lib\site-packages\sklearn\svm\base.py:193: FutureWarning: The
default value of gamma will change from 'auto' to 'scale' in version 0.22 to account
better for unscaled features. Set gamma explicitly to 'auto' or 'scale' to avoid this
```

Gambar 4.55 hasil

## 8. Pengamatan program

```

1 import numpy as np
2 from sklearn.ensemble import RandomForestClassifier
```

```

3 max_features_opts = range(1, 10, 1)
4 n_estimators_opts = range(2, 40, 4)
5 rf_params = np.empty((len(max_features_opts)*len(
6 n_estimators_opts),4) , float)
7 i = 0
8 for max_features in max_features_opts:
9 for n_estimators in n_estimators_opts:
10 clf = RandomForestClassifier(max_features=
11 max_features , n_estimators=n_estimators)
12 scores = cross_val_score(clf , dk_train_att ,
13 dk_train_label , cv=5)
14 rf_params[i,0] = max_features
15 rf_params[i,1] = n_estimators
16 rf_params[i,2] = scores.mean()
17 rf_params[i,3] = scores.std() * 2
18 i += 1
19 print("Max features: %d, num estimators: %d, accuracy
20 : %.02f (+/- %.02f)" %
21 (max_features , n_estimators , scores.mean() , scores.std() *
22))

```

terdapat grafik data yang terdapat dari grafik tersebut di dapat dari codingan dengan cara pengulangan data masing masing 10 kali setelah itu di eksekusi menjadi grafik berbentuk 3D pada gambar tersebut menunjukan rasio dari yang terrendah yaitu data SVM kemudian data decision tree dan hasil random forest.

```

dk_train_label, cv=5)
...: rf_params[i,0] = max_features
...: rf_params[i,1] = n_estimators
...: rf_params[i,2] = scores.mean()
...: rf_params[i,3] = scores.std() * 2
...: i += 1
...: print("Max features: %d, num estimators: %d, accuracy
%0.2f (+/- %.02f)"
...:
...: % (max_features, n_estimators, scores.mean(), scores.std() *
2))
Max features: 1, num estimators: 2, accuracy: 0.85 (+/- 0.08)
Max features: 1, num estimators: 6, accuracy: 0.89 (+/- 0.03)
Max features: 1, num estimators: 10, accuracy: 0.90 (+/- 0.04)
Max features: 1, num estimators: 14, accuracy: 0.93 (+/- 0.04)
Max features: 1, num estimators: 18, accuracy: 0.91 (+/- 0.06)
Max features: 1, num estimators: 22, accuracy: 0.95 (+/- 0.03)
Max features: 1, num estimators: 26, accuracy: 0.93 (+/- 0.06)
Max features: 1, num estimators: 30, accuracy: 0.95 (+/- 0.06)
Max features: 1, num estimators: 34, accuracy: 0.93 (+/- 0.04)
Max features: 1, num estimators: 38, accuracy: 0.95 (+/- 0.03)
Max features: 2, num estimators: 2, accuracy: 0.84 (+/- 0.09)
Max features: 2, num estimators: 6, accuracy: 0.90 (+/- 0.06)
Max features: 2, num estimators: 10, accuracy: 0.93 (+/- 0.03)
Max features: 2, num estimators: 14, accuracy: 0.94 (+/- 0.04)
Max features: 2, num estimators: 18, accuracy: 0.91 (+/- 0.06)
Max features: 2, num estimators: 22, accuracy: 0.93 (+/- 0.05)
Max features: 2, num estimators: 26, accuracy: 0.95 (+/- 0.02)

```

Gambar 4.56 hasil

Berikut adalah untuk grafik

```


1 #%%
2 import matplotlib.pyplot as plt
3 from mpl_toolkits.mplot3d import Axes3D
4 from matplotlib import cm
5 fig = plt.figure()
6 fig.clf()
7 ax = fig.gca(projection='3d')
8 x = rf_params[:,0]
9 y = rf_params[:,1]
10 z = rf_params[:,2]
11 ax.scatter(x, y, z)
12 ax.set_zlim(0.6, 1)
13 ax.set_xlabel('Max features')
14 ax.set_ylabel('Num estimators')
15 ax.set_zlabel('Avg accuracy')

```

```

....: ax = fig.gca(projection='3d')
....: x = rf_params[:,0]
....: y = rf_params[:,1]
....: z = rf_params[:,2]
....: ax.scatter(x, y, z)
....: ax.set_zlim(0.6, 1)
....: ax.set_xlabel('Max features')
....: ax.set_ylabel('Num estimators')
....: ax.set_zlabel('Avg accuracy')
....: plt.show()

```



**Gambar 4.57** hasil

### 4.3.3 Penanganan Error

#### 4.3.3.1 Screenshoot Error

1. Error 1

```
FileNotFoundException: [Errno 2] File b'D:/Data Alit/Kuliah/SEMESTER VI/AI_KB3B/Chapter04/Youtube03-LMFAO.csv' does not exist: b'D:/Data Alit/Kuliah/SEMESTER VI/AI_KB3B/Chapter04/Youtube03-LMFAO.csv'
```

Gambar 4.58 error 1

## 2. Error 2

```
FileNotFoundException: [Errno 2] File b'D:/Data Alit/Kuliah/SEMESTER VI/AI_KB3B/Chapter04/Youtube03-LMFAO.csv' does not exist: b'D:/Data Alit/Kuliah/SEMESTER VI/AI_KB3B/Chapter04/Youtube03-LMFAO.csv'
```

Gambar 4.59 error 1

### 4.3.3.2 Penanganan Error

1. penanganan 1, kesalahan pada alamat direktori yang dituju, jadi harus dipastikan alamat direktori yang benar

```
data=pd.read_csv("D:/Data Alit/Kuliah/SEMESTER VI/AI_KB3B/Python-Artifi
```

Gambar 4.60 penanganan1

2. penanganan 2, RandomForestClassifier belum diimport, sehingga melakukan import library terlebih dahulu agar program jalan

```
import numpy as np
from sklearn.ensemble import RandomForestClassifier
```

Gambar 4.61 penanganan2

## 4.4 Luthfi Muhammad Nabil (1174035)

### 4.4.1 Teori

1. Jelaskan apa itu klasifikasi teks, sertakan gambar illustrasi buatan sendiri.

Klasifikasi teks merupakan sebuah metode untuk memilah setiap kata yang ada dan mengelompokkannya berdasarkan kelompok yang telah ditentukan. Seperti halnya pengelompokan surat ke kategori spam atau sms, memfilter berita sesuai kategori yang ada. Biasanya klasifikasi teks

digunakan untuk memfilter dan mengelompokkan banyak konten menjadi beberapa yang dapat dibedakan berdasarkan kelompok yang sudah ditentukan. Untuk contoh penyaringan yaitu jika ada sekitar sekian persen isi dari konten didominasi dengan kategori tertentu (Misal : Komputer), maka konten yang dikirim merupakan konten dengan tema komputer.

| Bahasa     | OOP   | Berbasis Web | Berbasis Mobile | Menghubungkan Mesin (BOT) |
|------------|-------|--------------|-----------------|---------------------------|
| Assembly   | Tidak | Tidak        | Tidak           | Ya                        |
| Python     | Ya    | Tidak        | Tidak           | Tidak                     |
| C++        | Tidak | Tidak        | Tidak           | Ya                        |
| C#         | Ya    | Tidak        | Tidak           | Tidak                     |
| JavaScript | Ya    | Ya           | Tidak           | Tidak                     |
| Java       | Ya    | Tidak        | Ya              | Tidak                     |
| Android    | Ya    | Tidak        | Ya              | Tidak                     |
| Kotlin     | Ya    | Tidak        | Ya              | Tidak                     |
| Dart       | Ya    | Tidak        | Ya              | Tidak                     |
| PHP        | Ya    | Ya           | Tidak           | Tidak                     |

**Gambar 4.62** Illustrasi Klasifikasi Teks

2. Jelaskan mengapa klasifikasi bunga tidak bisa menggunakan machine learning, sertakan illustrasi sendiri

Klasifikasi bunga tidak dapat menggunakan metode machine learning karena banyaknya jenis - jenis dari bunga yang sama namun makna dari bunga tersebut dapat berbeda - beda. Sehingga akan membingungkan sebuah mesin saat memfilter data yang ada. Jika ada pun akan terjadi ketidak tepatan data karena ciri - ciri dari sebuah bunga yang dominan hampir mirip bahkan bisa sama namun dengan makna yang berbeda - beda.

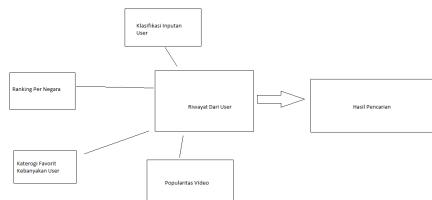


**Gambar 4.63** Maksud klasifikasi bunga tidak bisa

3. Jelaskan bagaimana teknik pembelajaran mesin pada teks pada kata-kata yang digunakan di youtube, jelaskan arti per atribut data csv dan sertakan illustrasi buatan sendiri

Cara youtube mempelajari pemecahan teks untuk dapat membedakan mana yang merupakan sebuah kategori yaitu mengelompokkan kandidat - kandidat yang dimiliki untuk dapat ditampilkan pada user tersebut. Dimulai dari dimana user tinggal, ranking video berdasarkan daerah, riwayat dari pencarian user, dan lain sebagainya. Saat user menginputkan sebuah pencarian, youtube akan merekam pencarian tersebut untuk menjadikan referensi dari apa yang pengguna sering cari sehingga tau apa konteks dari yang dicari pengguna tersebut. Hal itu dilakukan karena terkadang satu kata memiliki banyak makna sehingga youtube akan menyesuaikan makna yang dicari dengan apa yang dimaksud dengan user tersebut.

4. Jelaskan apa yang dimaksud vektorisasi data



**Gambar 4.64** Teknik filtering pada youtube

Vektorisasi data merupakan proses konversi data raster yang diubah menjadi data vektor. Parameter yang digunakan biasanya berupa data beberapa persentase atau kondisi ya/tidak yang berbentuk numerik untuk membedakan setiap data itu memiliki makna apa pada parameter yang dimaksud. Konversi itu wujudnya disebut digitasi. Vektorisasi data perlu dilakukan karena untuk menghitung sebuah nilai pada Artificial Intelligence, diperlukan angka yang dapat dihitung dan kategori dari nilai tersebut sehingga memudahkan dalam menghitung dan menentukan apa yang perlu dilakukan.

5. Jelaskan apa itu bag of words dengan kata-kata yang sederhana dan ilustrasi sendiri.

Bag of Words merupakan model representasi sederhana yang dipakai untuk pengambilan informasi dan pemrosesan bahasa umum atau alami. Pada model ini, sebuah teks akan dikategorikan sebagai bungkusan dari kumpulan kata tanpa perlu diolah ulang sekalipun. Bag of words juga digunakan pada klasifikasi dokumen yang biasanya setiap kata digunakan sebagai fitur dari pelatihan klasifikasi.

| Label      | Total Kata |
|------------|------------|
| Assembly   | 10         |
| Python     | 2          |
| C++        | 5          |
| C#         | 20         |
| JavaScript | 11         |
| Java       | 52         |
| Android    | 22         |
| Kotlin     | 42         |
| Dart       | 35         |
| PHP        | 1          |

**Gambar 4.65** Illustrasi Bag of Words

6. Jelaskan apa itu TF-IDF, illustrasikan dengan gambar sendiri.. TF-IDF merupakan pengukuran statistik yang mengevaluasi seberapa bernilai kata yang dicek di dalam dokumen tersebut. Parameter yang digunakan biasanya yaitu berapa banyak kata tersebut muncul pada sebuah dokumen. Biasanya metode ini digunakan untuk menilai sebuah kata yang digunakan pada algoritma machine learning.

|     | D1  | D2  | D3    | ...   | Dn |
|-----|-----|-----|-------|-------|----|
| t1  | 2)  | 4)  | 5 ... |       | 1  |
| t2  | 1   | 2   | 2 ... |       | 2  |
| t3  |     | 2   | 1     | 5 ... | 2  |
| ... | ... | ... | ...   | ...   |    |
| tn  | 0   | 15  | 2 ... |       | 2  |

Gambar 4.66 Illustrasi TF-IDF

#### 4.4.2 Praktek

1. Buat aplikasi sederhana menggunakan pandas, buat data dummy format csv sebanyak 500 baris dan melakukan load ke dataframe pandas. Jelaskan arti setiap baris kode yang dibuat.

```

1 # In [1]: Import library dari pandas
2 import pandas as pd
3 #Membaca file csv menggunakan pandas
4 data_forest = pd.read_csv('1_praktek.csv')
5 # In [2]: untuk melihat jumlah dari baris data yang telah di
 import
6 print(len(data_forest))
7 # In [3]: untuk melihat lima baris pertama data yang telah di
 import
8 print(data_forest.head())
9 # In [4]: untuk mengetahui banyak baris dan kolom dari data
 yang
10 # telah di import.
11 print(data_forest.shape)

```

2. Dari dataframe tersebut, dipecah menjadi dua dataframe yaitu 450 row pertama dan 50 row sisanya(Harus beda dengan teman sekelas)

```

1 #%%
2 data_450 = data_forest [:450]
3 #%%
4 data_50 = data_forest [450:]

```

3. Praktekkan vektorisasi dan klasifikasi dari data Shakira dengan decision tree. Tunjukkan keluarannya dari komputer sendiri dan artikan maksud dari setiap luaran yang didapatkan.

```

1 npm = 1174035%4
2 print(npm)
3 #%%
4 #Import pandas dan meload file Youtube05-Shakira
5 import pandas as pd
6 data_komentar = pd.read_csv('Youtube05-Shakira.csv')
7
8 #Mengelompokkan spam dan bukan spam ke 2 variabel yang
 berbeda
9 spam=data_komentar.query('CLASS == 1')
10 no_spam=data_komentar.query('CLASS == 0')
11
12 #Melakukan fungsi bag of word dengan cara menghitung semua
 kata yang ada pada file

```

```
13 from sklearn.feature_extraction.text import CountVectorizer
14 vectorizer = CountVectorizer()
15
16 #Membuat variabel dengan perintah untuk memproses kolom
17 # CONTENT pada dataset, lalu membaca variable yang ada
18 data_vektor = vectorizer.fit_transform(data_komentar['CONTENT'
19 ,])
20 data_vektor
21
22 #Menampilkan sampel komentar spam yang didapat
23 print(data_komentar['CONTENT'][304])
24
25 #Menampilkan daftar nama kolom
26 dk=vectorizer.get_feature_names()
27
28 #Untuk melakukan randomisasi dari setiap komentar
29 train_test = data_komentar.sample(frac=1)
30 #Memuat data training dan testing dari data yang sudah ada
31 dk_train=train_test[:300]
32 dk_test=train_test[300:]
33
34 #Melakukan training pada data training dan memvektorisasi
35 # data tersebut
36 dk_train_att = vectorizer.fit_transform(dk_train['CONTENT'])
37 dk_train_att
38
39 #Melakukan Testing pada data testing dan memvektorisasi data
40 # tersebut
41 dk_test_att=vectorizer.transform(dk_test['CONTENT'])
42 dk_test_att
43
44 #Mengambil label spam dan bukan spam
45 dk_train_label=dk_train['CLASS']
46 dk_test_label = dk_test['CLASS']
```

**Gambar 4.67** Melakukan vektorisasi dan mengambil salah satu contoh

4. Cobalah klasifikasikan dari data vektorisasi yang ditentukan di nomor sebelumnya dengan klasifikasi SVM. Tunjukkan keluarannya dari komputer sendiri dan artikan maksud setiap luaran yang didapatkan.

```
1 from sklearn import svm
```

```

2 clfsvm = svm.SVC()
3 clfsvm.fit(dk_train_att, dk_train_label)
4 clfsvm.score(dk_test_att, dk_test_label)

```

```

In [40]: from sklearn import svm
...: clfsvm = svm.SVC()
...: clfsvm.fit(dk_train_att, dk_train_label)
...: clfsvm.score(dk_test_att, dk_test_label)
...: Out[40]: 0.77072429774285

```

**Gambar 4.68** Melakukan prediksi CVM berdasarkan nilai

5. Coba klasifikasikan dari data vektorisasi yang ditentukan di nomor sebelumnya dengan klasifikasi Decision Tree. Tunjukkan kelaurannya dari komputer sendiri dan artikan maksud setiap luaran yang didapatkan.

```

1 #Melakukan klasifikasi Decision Tree
2 from sklearn import tree
3 clftree = tree.DecisionTreeClassifier()
4 clftree.fit(dk_train_att, dk_train_label)
5 clftree.score(dk_test_att, dk_test_label)

```

```

In [41]: from sklearn import tree
...: clftree = tree.DecisionTreeClassifier()
...: clftree.fit(dk_train_att, dk_train_label)
...: clftree.score(dk_test_att, dk_test_label)
...: Out[41]: 0.9142057142057142

```

**Gambar 4.69** Klasifikasi data dari vektorisasi yang ada dengan decision tree

6. Plotlah confusion matrix dari praktek modul ini menggunakan matplotlib. Tunjukkan keluarannya dari komputer sendiri dan artikan maksud setiap luaran yang didapatkan

```

1 %%%
2 #Melakukan confusion matrix
3 from sklearn.metrics import confusion_matrix
4 pred_labels = clftree.predict(dk_test_att)
5 cm = confusion_matrix(dk_test_label, pred_labels)
6 cm

```

```

In [42]:
In [42]: from sklearn.metrics import confusion_matrix
...: pred_labels = clftree.predict(dk_test_att)
...: cm = confusion_matrix(dk_test_label, pred_labels)
...: Out[42]:
array([[30, 1],
 [5, 39]], dtype='int64')

```

**Gambar 4.70** Penggunaan confusion matrix

7. Jalankan program cross validation pada bagian teori bab ini. Tunjukkan keluarannya dari komputer sendiri dan artikan mnaksud setiap luaran yang didapatkan.

```

1 from sklearn.model_selection import cross_val_score
2 scores = cross_val_score(clftree, dk_train_att, dk_train_label,
 cv=5)
3 scorerata2=scores.mean()

```

```

4 scorersd=scores.std()
5
6 from sklearn.model_selection import cross_val_score
7 scores = cross_val_score(clftree, dk_train_att,
8 dk_train_label, cv=5)
9 # show average score and +/- two standard deviations away (
10 # covering 95
11 #%% of scores)
12 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
13 std() * 2))
14
15 scorestree = cross_val_score(clftree, dk_train_att,
16 dk_train_label, cv=5)
17 print("Accuracy: %0.2f (+/- %0.2f)" % (scorestree.mean(),
18 scorestree.std() * 2))
19
20 scoressvm = cross_val_score(clfsvm, dk_train_att,
21 dk_train_label, cv=5)
22 print("Accuracy: %0.2f (+/- %0.2f)" % (scoressvm.mean(),
23 scoressvm.std() * 2))

```

```

In [8]: from sklearn.model_selection import cross_val_score
... scores = cross_val_score(clftree, dk_train_att, dk_train_label, cv=5)
... scorestree = scores.std()
...
... from sklearn.model_selection import cross_val_score
... scores = cross_val_score(clfsvm, dk_train_att, dk_train_label, cv=5)
... scoressvm = scores.std()
... print("Average accuracy of tree classifier: %0.2f (%0.2f)" % (scorestree.mean(),
... scorestree.std() * 2))
... print("Average accuracy of SVM classifier: %0.2f (%0.2f)" % (scoressvm.mean(),
... scoressvm.std() * 2))
... scorestree = cross_val_score(clftree, dk_train_att, dk_train_label,
... cv=5)
... print("Accuracy: %0.2f (%0.2f)" % (scorestree.mean(),
... scorestree.std() * 2))
... scoressvm = cross_val_score(clfsvm, dk_train_att, dk_train_label,
... cv=5)
... print("Accuracy: %0.2f (%0.2f)" % (scoressvm.mean(),
... scoressvm.std() * 2))
... Accuracy: 0.81 (+/- 0.01)
... Accuracy: 0.80 (+/- 0.01)
... Accuracy: 0.80 (+/- 0.01)

```

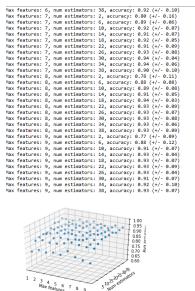
**Gambar 4.71** Mengambil tingkat akurasi dari klasifikasi data dan prediksi

8. Buatlah program pengamatan komponen informasi pada bagian teori bab ini. Tunjukkan keluarannya dari komputer sendiri dan artikan maksud setiap luaran yang didapatkan

```

1 #%%
2 from sklearn.ensemble import RandomForestClassifier
3 import numpy as np
4 max_features_opts = range(1, 10, 1)
5 n_estimators_opts = range(2, 40, 4)
6 rf_params = np.empty((len(max_features_opts)*len(
7 n_estimators_opts),4), float)
8 i = 0
9 for max_features in max_features_opts:
10 for n_estimators in n_estimators_opts:
11 clf = RandomForestClassifier(max_features=
12 max_features,n_estimators=n_estimators)
13 scores = cross_val_score(clf, dk_train_att,
14 dk_train_label, cv=5)
15 rf_params[i,0] = max_features
16 rf_params[i,1] = n_estimators
17 rf_params[i,2] = scores.mean()
18 rf_params[i,3] = scores.std() * 2
19 i += 1
20 print("Max features: %d, num estimators: %d, accuracy
21 : %0.2f (+/- %0.2f)"
```

```
18 % (max_features , n_estimators , scores . mean () , scores . std ()
19 * 2))
20
21 import matplotlib . pyplot as plt
22 from mpl_toolkits . mplot3d import Axes3D
23 from matplotlib import cm
24 fig = plt . figure ()
25 fig . clf ()
26 ax = fig . gca (projection = ' 3d ')
27 x = rf_params [: , 0]
28 y = rf_params [: , 1]
29 z = rf_params [: , 2]
30 ax . scatter (x , y , z)
31 ax . set_zlim (0.6 , 1)
32 ax . set_xlabel (' Max features ')
33 ax . set_ylabel (' Num estimators ')
34 ax . set_zlabel (' Avg accuracy ')
35 plt . show ()
```



**Gambar 4.72** Melakukan regresi data dengan numpy dan mengambil fitur - fitur yang ada

#### **4.4.3 Penanganan Error**

## 1. Skrinsut Error

```

 ... from sklearn import AsealIO
 ... from matlibplot import cm
 ... fig = plt.figure()
 ... fig.clf()
 ... ax = fig.add_subplot(111)
 ... x = np.arange(0, 10, 1)
 ... y = np.sin(x) * np.exp(-x)
 ... z = np.sqrt(x)
 ... ax.plot(x, y, 'r-')
 ... ax.set_xlim(0, 9.5)
 ... ax.set_xlabel('New features')
 ... ax.set_ylabel('New estimators')
 ... ax.set_title('High Accuracy')
 ... plt.show()

File "c:\python\input_50-3.xls", line 16
print("Max feature: %d, num as "
Synaxerror: EOL while scanning string literal

```

**Gambar 4.73** Error

## 2. Tipe Error : EOF

### 3. Penanganan : Meluruskan String

#Awalnya


```
print("Max
features: %d, num estimators: %d, accuracy: %.2f (+/- %.2f)
#Sekarang
print("Max features: %d, num estimators: %d, accuracy: %.2f
```

## 4.5 1174039 - Liyana majdah rahma

### 4.5.1 Teori

#### 1. Klasifikasi Text


Pengolahan teks sangat dibutuhkan pada aplikasi yang memiliki jumlah dokumen yang berukuran besar. klasifikasi teks sendiri merupakan cara dalam memilah data teks berdasarkan parameter serta dengan data yang bersifat dokumen. Data tersebut dapat berupa char atau string.



**Gambar 4.74** Klasifikasi Text

#### 2. Mengapa Klasifikasi Bunga tidak dapat menggunakan Machine Learning

dikarenakan klasifikasi itu menggunakan tipe data yang dimana atributnya memiliki nilai data yang berupa vektor dengan perbandingan masing-masing data yang memiliki sedikit perbedaan. Dapat dilihat pada gambar berikut.



**Gambar 4.75** Klasifikasi Hewan

3. Teknik Pembelajaran machine learning pada teks kata-kata di youtube

Contohnya pada saat kita membuka sebuah video maka di sebelah kanan ada list "berikutnya", pada saat itu mesin melakukan ujicoba dan apabila anda menekan salah satu dari video tersebut maka hal tersebut akan direkam dan disimpan oleh mesin tersebut




**Gambar 4.76** Machine Learning Youtube

4. Jelaskan apa yang dimaksud vektorisasi data.

Vektorisasi data merupakan pemecahan data menjadi bagian-bagian yang lebih sederhana. Contoh ada sebuah paragraf, dari paragraf tersebut akan dibagi-bagi menjadi kalimat, yang nantinya akan dibagi-bagi kembali menjadi perkata.

5. Jelaskan apa itu bag of words dengan kata-kata yang sederhana dan ilustrasi sendiri

Bag of words merupakan penyajian sederhana yang biasanya digunakan pada aplikasi text mining pada saat mengenalkan struktur ke sebuah kumpulan dokumen yang berbasis teks untuk diklasifikasikan kembali menjadi dua atau lebih kelas yang telah ditentukan.



**Gambar 4.77** Bag of Words

6. Jelaskan apa itu TF-IDF, ilustrasikan dengan gambar sendiri.

TF-IDF merupakan metode untuk menghitung bobot dari kata yang sering muncul pada suatu kalimat. metode ini menghitung nilai Term Frequency dan IDF atau Inverse Document Frequency pada setiap kata pada kalimat yang dijadikan acuan kata pada metode ini sering di sebut token adapun rumus dari metode ini dapat dilihat pada gambar.

| Q      | tf |    |    | df | Dj/df | IDF   | IDF+1 | Wt+tf/(IDF+1) |         |         |
|--------|----|----|----|----|-------|-------|-------|---------------|---------|---------|
|        | d1 | d2 | d3 |    |       |       |       | d1            | d2      | d3      |
| gold   | 1  | 0  | 1  | 2  | 1.5   | 0.136 | 1.136 | 1.136         | 0       | 1.136   |
| silver | 0  | 2  | 0  | 1  | 5     | 0.437 | 1.437 | 0             | 2.554   | 0       |
| truck  | 1  | 1  | 1  | 2  | 1.5   | 0.136 | 1.136 | 0             | 1.136   | 1.136   |
|        |    |    |    |    |       |       |       | sum(d1)       | sum(d2) | sum(d3) |
|        |    |    |    |    |       |       |       | 1.136         | 2.554   | 2.352   |

Gambar 4.78 TF-IDF

#### 4.5.2 Praktek

1. import data pandas dan 500 baris data dumy kemudian di jelaskan tiap barisnya.

```
1 # In [1]: Import library dari pandas
2 import pandas as pan
3 #Membaca file csv menggunakan pandas
4 data_forest = pan.read_csv('1174039.csv')
5 # In [2]: untuk melihat jumlah dari baris data yang telah di
 import
6 print(len(data_forest))
```



### Gambar 4.79 Data Dummy

2. memecah data prame menjadi dua yg pertama 450 dan kedua sisanya

```
1 #Mengelompokkan spam dan bukan spam ke 2 variabel yang
2 berbeda
3 spam=data_komentar.query('CLASS == 1')
```

|      |                    |                                                        |
|------|--------------------|--------------------------------------------------------|
| dtes | DataFrame (50, 5)  | Column names: id, first_name, last_name, email, gender |
| dtra | DataFrame (450, 5) | Column names: id, first_name, last_name, email, gender |

**Gambar 4.80** Pisah Data

### 3. praktik vektorisasi

```

1 no_spam=data_komentar.query('CLASS == 0')
2
3 #Melakukan fungsi bag of word dengan cara menghitung semua
4 #kata yang ada pada file
5 from sklearn.feature_extraction.text import CountVectorizer
6 vectorizer = CountVectorizer()
7
8 #Membuat variabel dengan perintah untuk memproses kolom
9 #CONTENT pada dataset, lalu membaca variable yang ada
10 data_vektor = vectorizer.fit_transform(data_komentar['CONTENT'])
11 data_vektor
12
13 #Menampilkan sampel komentar spam yang didapat
14 print(data_komentar['CONTENT'][304])
15
16 #Menampilkan daftar nama kolom
17 dk=vectorizer.get_feature_names()
18
19 #Untuk melakukan randomisasi dari setiap komentar
20 train_test = data_komentar.sample(frac=1)
21 #Memuat data training dan testing dari data yang sudah ada
22 dk_train=train_test[:300]
23 dk_test=train_test[300:]
24
25 #Melakukan training pada data training dan memvektorisasi
26 #data tersebut
27 dk_train_att = vectorizer.fit_transform(dk_train['CONTENT'])
28 dk_train_att
29
30 #Melakukan Testing pada data testing dan memvektorisasi data
31 #tersebut
32 dk_test_att=vectorizer.transform(dk_test['CONTENT'])
33 dk_test_att
34
35 #Mengambil label spam dan bukan spam

```

lakukan import library pandas yang diinisialisasi menjadi pd setelah itu ada dibuat variable data dengan method read\_csv untuk membaca file berekstensi csv yang dimasukan alamatnya pada kurung, lakukan klasifikasi atau pemilihan komentar yang berisi spam atau bukan spam dengan parameter class sama dengan 1 merupakan spam dan class sama dengan 0 bukan spam setelah itu masukan librari CountVektorizer yang digunakan untuk vektorisasi data kemudian dilanjutkan pada bagian In[103] dibuat variabel yang berisi vektorisasi dari data pada data di field content setelah itu variabel tersebut di running hasilnya menunjukkan 350 baris

di kali 1738 kolom selanjutnya dicoba untuk memunculkan isi record pada baris ke 345 maka akan muncul isian dari baris tersebut. selanjutnya dibuat variabel dk atau daftar yang berisi data hasil vektorisasi setelah yang terdiri dari variabel dshuf yang berisi data komen yang di dalamnya di buat random yang nantinya akan dibutuhkan data training dan data testing dengan ketentuan data training 300 dan data testing sebanyak 50 setelah itu data training dilakukan vektorisasi dan data testing juga dilakukan vektorisasi setelah itu kedua data training dan testing tersebut dibuat label dengan parameter field CLASS pada tabel.

**Gambar 4.81** Vektorisasi

#### 4. klasifikasi SVM

```
1 dk_test_label = dk_test['CLASS']
2
3 #%%
4 #Coding untuk melakukan klasifikasi SVM
5 from sklearn import svm
```

import librari svm dari sklearn kemudian membuat variabel clfsvm berisikan method svc setelah itu variabel tersebut di berikan method fit dengan isian data train vektorisasi dan data training label yang berguna untuk melatih data tersebut setelah itu di coba untuk memunculkan score atau akurasi dari data tersebut menggunakan data testing vektorisasi dan data testing label.

```
In [41]: from sklearn import tree
...: clftree = tree.DecisionTreeClassifier()
...: clftree.fit(dk_train_att, dk_train_label)
...: clftree.score(dk_test_att, dk_test_label)
Out[41]: 0.9142857142857143
```

**Gambar 4.82** SVM

## 5. klasifikasi decision tree

```
1 clfsvm.fit(dk_train_att, dk_train_label)
2 clfsvm.score(dk_test_att, dk_test_label)
```

import librari tree dari sklearn kemudian membuat variabel clftree berisikan method DecisionTreeClasifier setelah itu variabel tersebut di berikan method fit dengan isian data train vektorisasi dan data training label yang berguna untuk melatih data tersebut agar dapat digunakan pada codingan selanjutnya setelah itu di coba untuk memunculkan score atau akurasi dari data tersebut menggunakan data testing vektorisasi dan data testing label.

```
In [67]: from sklearn import tree
...: clftree = tree.DecisionTreeClassifier()
...: clftree.fit(dk_train_att, dk_train_label)
...: clftree.score(dk_test_att, dk_test_label)
Out[67]: 0.96
```

**Gambar 4.83** Desicion Tree

## 6. plot comfusion matrix

```
1 from sklearn import tree
2 clftree = tree.DecisionTreeClassifier()
3 clftree.fit(dk_train_att, dk_train_label)
4 clftree.score(dk_test_att, dk_test_label)
```

import library comfusion matrix selanjutnya dilakukan prediksi pada pada data tes nya kemudian data tersebut di masukan kedalam variabel cm dengan method confusion matrix yang di dalamnya terdapat data dari variabel perd label dan dk test label setelah itu variabel cm tersebut di running maka akan memunculkan nilai matrixnya.

```
In [43]:
In [43]: from sklearn.metrics import confusion_matrix
...: pred_labels = clftree.predict(dk_test_att)
...: cm = confusion_matrix(dk_test_label, pred_labels)
Out[43]:
array([[38, 1],
 [5, 26]], dtype=int64)
```

**Gambar 4.84** Confussion Matrix

## 7. cross valodation

```
1 #%%
2 #Melakukan confussion matrix
3 from sklearn.metrics import confusion_matrix
4 pred_labels = clftree.predict(dk_test_att)
5 cm = confusion_matrix(dk_test_label, pred_labels)
6 cm
7
8 #%%
9 from sklearn.model_selection import cross_val_score
10 scores = cross_val_score(clftree, dk_train_att, dk_train_label,
 cv=5)
```

```
11 scorerata2=scores.mean()
12 scorersd=scores.std()
13
14 from sklearn.model_selection import cross_val_score
15 scores = cross_val_score(clftree, dk_train_att,
16 dk_train_label, cv=5)
17 # show average score and +/- two standard deviations away (
18 # covering 95
19 #%% of scores)
20 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
21 std() * 2))
22
23 scorestree = cross_val_score(clftree, dk_train_att,
24 dk_train_label, cv=5)
```

memunculkan nilai akurasi dari tiga metode yaitu random forest, decision tree, dan klasifikasi svm (support vector machine) di mana akan dibandingkan tingkat akurasi dari semua hasil akurasi mana yang terbaik dan lebih akurat pada hasilnya data yang paling akurat yaitu random forest.



**Gambar 4.85** Cross Validation

#### 8. Pengamatan program

```

1 scoressvm = cross_val_score(clfsvm , dk_train_att ,
2 dk_train_label , cv=5)
3 print("Accuracy: %0.2f (+/- %0.2f)" % (scoressvm.mean() ,
4 scoressvm.std() * 2))
5
6 #%%%
7 from sklearn.ensemble import RandomForestClassifier
8 import numpy as np
9 max_features_opts = range(1, 10, 1)
10 n_estimators_opts = range(2, 40, 4)
11 rf_params = np.empty((len(max_features_opts)*len(
12 n_estimators_opts),4) , float)
13 i = 0
14 for max_features in max_features_opts:
15 for n_estimators in n_estimators_opts:
16 clf = RandomForestClassifier(max_features=
17 max_features , n_estimators=n_estimators)
18 scores = cross_val_score(clf , dk_train_att ,
19 dk_train_label , cv=5)
20 rf_params[i,0] = max_features
21 rf_params[i,1] = n_estimators
22 rf_params[i,2] = scores.mean()
23

```


terdapat grafik data yang terdapat dari grafik tersebut di dapat dari codingan dengan cara pengulangan data masing masing 10 kali setelah itu

di eksekusi menjadi grafik berbentuk 3D pada gambar tersebut menunjukkan rasio dari yang terrendah yaitu data SVM kemudian data decision tree dan hasil random forest.

### Gambar 4.86 Pengamatan Program

Berikut adalah untuk grafik

```
1 % (max_features , n_estimators , scores . mean () , scores . std ()
2 * 2))
3
4 import matplotlib . pyplot as plt
5 from mpl_toolkits . mplot3d import Axes3D
6 from matplotlib import cm
7 fig = plt . figure()
8 fig . clf()
9 ax = fig . gca (projection = ' 3d ')
10 x = rf_params [: , 0]
11 y = rf_params [: , 1]
12 z = rf_params [: , 2]
13 ax . scatter (x , y , z)
14 ax . set_zlim (0.6 , 1)
15 ax . set_xlabel (' Max features ')
16 ax . set_ylabel (' Num estimators ')
```



**Gambar 4.87** Grafik

### 4.5.3 Penanganan Error

#### 4.5.3.1 Screenshoot Error

- ## 1. Error 1

```
...
rf_params = np.empty((len(max_features_opts)*len(n_estimators_opts),4) , float)
NameError: name 'rp' is not defined
```

Gambar 4.88 Error1

#### 4.5.3.2 Kode Error dan Jenisnya

1. Kode Error 1 jenis Name Error

```
max_features_opts = range(1, 10, 1)
n_estimators_opts = range(2, 40, 4)
rf_params = np.empty((len(max_features_opts)*len(n_estimators_opts),4) , float)
l = 0
```

Gambar 4.89 Error1

#### 4.5.3.3 Solusi

1. Mengimport library numpy sebagai np

```
import numpy as np
max_features_opts = range(1, 10, 1)
n_estimators_opts = range(2, 40, 4)
rf_params = np.empty((len(max_features_opts)*len(n_estimators_opts),4) , float)
l = 0
```

Gambar 4.90 Solusi 1

## 4.6 1174050 Dika Sukma Pradana

### 4.6.1 Teori

1. Jelaskan apa itu klasifikasi teks, sertakan gambar ilustrasi buatan sendiri.

Klasifikasi teks adalah proses pemberian tag atau kategori ke teks sesuai dengan isinya. Ini salah satu tugas mendasar dalam Natural Language Processing (NLP) dengan aplikasi luas seperti analisis sentimen, pelabelan topik, deteksi spam, dan deteksi maksud.



Gambar 4.91 contoh klasifikasi teks

2. Jelaskan mengapa klasifikasi bunga tidak bisa menggunakan machine learning, sertakan ilustrasi sendiri.

Dikarenakan tidak semua bunga memiliki ciri - ciri yang sama. Atau dalam kata lain terdapat data noise dalam klasifikasi bunga sehingga tidak bisa menggunakan machine learning.

Contohnya Anggrek memiliki warna ungu, dengan jumlah kelopak 5. Kemudian ada bunga warna ungu dengan jumlah kelopak yang sama namun ternyata bukan anggrek dan kategorinya banyak sekali. Bahkan ada

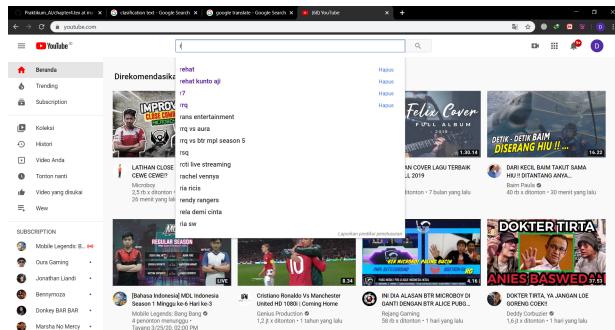


**Gambar 4.92** contoh klasifikasi bunga

bunga yang tidak jelas apakah warnanya sesuai atau tidak, sehingga bisa menyebabkan data noise.

- Jelaskan bagaimana teknik pembelajaran mesin pada teks pada kata-kata yang digunakan di youtube, jelaskan arti per atribut data csv dan sertakan ilustrasi buatan sendiri.

Youtube akan mengingat kata - kata yang sering kita gunakan pada bagian search. seperti pada saat kita menginputkan huruf r maka akan muncul rekomendasi dari youtube baik yang sudah pernah kita cari atau yang belum pernah.




**Gambar 4.93** contoh teknik pembelajaran mesin

- Jelaskan apa yang dimaksud vektorisasi data.

Pembagian dan pemecahan data, kemudian dilakukan perhitungan. Vektorisasi juga dapat dimaksudkan dengan setiap data yang mungkin dipetakan ke integer tertentu. jika kita memiliki array yang cukup besar maka setiap kata / data cocok dengan slot unik dalam array (nilai pada indeks adalah nomor satu kali kata itu muncul).

- Jelaskan apa itu bag of words dengan kata-kata yang sederhana dan ilustrasi sendiri. Bag-of-words ialah sebuah gambaran sederhana digunakan dalam pengolahan bahasa alami dan pencarian informasi. Dikenal sebagai model ruang vektor. Pada model ini, tiap kalimat dalam dokumen

digambarkan sebagai token, mengabaikan tata bahasa dan bahkan urutan kata namun menghitung frekuensi kejadian atau kemunculan kata dari dokumen.



**Gambar 4.94** contoh bag of words

6. Jelaskan apa itu TF-IDF, ilustrasikan dengan gambar sendiri. TF-IDF memberi kita frekuensi kata dalam setiap dokumen dalam korpus atau mengganti data jadi number. Ini adalah rasio berapa kali kata itu muncul dalam dokumen dibandingkan dengan jumlah total kata dalam dokumen itu. Itu meningkat seiring jumlah kemunculan kata itu di dalam dokumen meningkat. Setiap dokumen memiliki tf sendiri.

|       | Kuning | Makan | Racing | Main | Bola |
|-------|--------|-------|--------|------|------|
| Doc 1 | 2      | 1     | 1      | 1    | 1    |
| Doc 2 | 3      | 1     | 1      | 1    | 1    |

**Gambar 4.95** contoh TF-IDF

#### 4.6.2 Praktek Program

1. import data pandas dan 500 baris data dummy kemudian di jelaskan tiap barisnya.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 23 21:14:37 2020
4 @author: User
5 """
6
7 import pandas as pd# untuk membaca file tex atau csv
8 data_forest = pd.read_csv("D:/SEMESTER 6/New folder/
9 datakaryawan.csv")#membaca file csv menggunakan fungsi
10 read_csv dari padas
11 print(len(data_forest))#untuk melihat jumlah dari baris data
12 yang telah di import
13 print(data_forest.head()) #untuk melihat lima baris pertama
14 data yang telah di import
15 print(data_forest.shape)#untuk mengetahui banyak baris dan
16 kolom dari data yang telah di import.

```

2. memecah data prame menjadi dua yang pertama 450 dan kedua sisanya 50

```

1 # -*- coding: utf-8 -*-
2 """

```

```
In [6]: runfile('D:/SEMESTER 6/New folder/1174050/1.py', wdir='D:/SEMESTER 6/New folder/1174050')
148654
 Id EmployeeName ... Agency Status
0 1 NATHANIEL FORD ... San Francisco NaN
1 2 GARY JIMENEZ ... San Francisco NaN
2 3 ALBERT PARDINI ... San Francisco NaN
3 4 CHRISTOPHER CHONG ... San Francisco NaN
4 5 PATRICK GARDNER ... San Francisco NaN

[5 rows x 13 columns]
(148654, 13)
```

Gambar 4.96 hasil

```
3 Created on Mon Mar 23 21:35:59 2020
4
5 @author: User
6 """
7
8 data_train = data_forest [:450] # memasukkan data training
9 sebanyak 450 baris
10
10 data_tes = data_forest [:450] # memasukkan data tes sebanyak 50
```

|               |                        |                                                                            |
|---------------|------------------------|----------------------------------------------------------------------------|
| acak_acak     | DataFrame (448, 5)     | Column names: COMMENT_ID, AUTHOR, DATE, CONTENT, CLASS                     |
| data_forest   | DataFrame (148654, 13) | Column names: Id, EmployeeName, JobTitle, BasePay, OvertimePay, OtherP ... |
| data_komen    | DataFrame (448, 5)     | Column names: COMMENT_ID, AUTHOR, DATE, CONTENT, CLASS                     |
| data_tes      | DataFrame (148204, 13) | Column names: Id, EmployeeName, JobTitle, BasePay, OvertimePay, OtherP ... |
| data_testing  | DataFrame (148204, 13) | Column names: Id, EmployeeName, JobTitle, BasePay, OvertimePay, OtherP ... |
| data_train    | DataFrame (450, 13)    | Column names: Id, EmployeeName, JobTitle, BasePay, OvertimePay, OtherP ... |
| data_komentar | DataFrame (450, 13)    | Column names: Id, EmployeeName, JobTitle, BasePay, OvertimePay, OtherP ... |

Gambar 4.97 hasil

### 3. praktik vektorisasi

berikut merupakan codingan untuk melakukan vektorisasi data berupa teks dalam format csv

```
1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 23 21:49:14 2020
4
5 @author: User
6 """
7
8
9 #melakukan import pandas untuk membaca file csv
10 import pandas as pd
11 data_komen=pd.read_csv("D:\SEMESTER 6\Python-Artificial-
12 Intelligence-Projects-for-Beginners-master\Chapter03\
13 Youtube04-Eminem.csv")
14 #mengelompokkan komentar spam dan bukan spam
15 spam=data_komen.query('CLASS == 1')
16 nospam=data_komen.query('CLASS == 0')
17 # memanggil lib vektorisasi
```

```

16 #melakukan fungsi bag of word dengan cara menghitung semua
 kata
17 #yang terdapat dalam file
18 from sklearn.feature_extraction.text import CountVectorizer
19 vectorizer = CountVectorizer()
20 # memilih colom CONTENT untuk dilakukan vektorisasi
21 #melakukan bag of word pada dataframe pada colom CONTENT
22 data_vektorisasi = vectorizer.fit_transform(data_komen[,
 'CONTENT'])
23 # melihat isi vektorisasi
24 data_vektorisasi
25 # melihat isi data pada baris ke 349
26 print(data_komen['CONTENT'][349])
27 # melihat daftar kata yang di vektorisasi
28 #feature_names merupakan digunakan untuk mengambil nama
29 #kolomnya ada apa saja
30 dk=vectorizer.get_feature_names()
31 # akan melakukan randomisasi pada database nya supaya
32 #semurnya saat melakukan klasifikasi
33 acak_acak = data_komen.sample(frac=1)
34 # membuat data traning dan testing
35 dk_train=acak_acak[:300]
36 dk_test=acak_acak[300:]
37 # melakukan training pada data training dan di vektorisasi
38 dk_train_att=vectorizer.fit_transform(dk_train['CONTENT'])
39 print(dk_train_att)
40 #melakukan testing pada data testing dan di vektorisasi
41 dk_test_att=vectorizer.transform(dk_test['CONTENT'])
42 print(dk_test_att)
43 # Dimana akan mengambil label spam dan bukan spam
44 dk_train_label=dk_train['CLASS']
45 print(dk_train_label)
46 dk_test_label=dk_test['CLASS']
47 print(dk_test_label)

```

---

because we love doing this. We may not have the best recording equipment but if you  
listen to our lyrics and rhymes I think you'll like it. If you do then please  
subscribe and share because we love making these videos and we want you to like them as  
much as possible so feel free to comment and give us pointers! Thank you!

|           |   |
|-----------|---|
| (0, 1012) | 1 |
| (0, 620)  | 1 |
| (0, 111)  | 1 |
| (0, 1043) | 1 |
| (0, 1106) | 1 |
| (0, 746)  | 1 |
| (0, 1195) | 1 |
| (1, 925)  | 1 |
| (1, 622)  | 1 |
| (1, 602)  | 1 |
| (1, 662)  | 1 |
| (1, 395)  | 1 |
| (1, 1179) | 1 |
| (2, 957)  | 1 |
| (2, 536)  | 2 |
| (2, 1169) | 1 |
| (2, 326)  | 1 |
| (2, 21)   | 1 |
| (3, 957)  | 1 |
| (3, 131)  | 1 |

Gambar 4.98 hasil

import library pandas yang di inisialisasi menjadi pd setelah itu ada dibuat class dan method untuk membaca file csv yang di masukan alamat-

nya pada kurung, lakukan klasifikasi samadengan 1 merupakan spam dan class samadengan 0 bukan spam setelah itu masukan librari CountVektorizer yang digunakan untuk vektorisasi data, lalu dilanjutkan pada bagian dibuat variabel yang berisi vektorisasi dari data di field content setelah itu variabel tersebut di running hasilnya menunjukan 350 baris di kali 1738 kolom selanjutnya dicoba untuk memunculkan isi record pada baris ke 349 maka akan muncul isian dari baris tersebut. selanjutnya dibuat variabel yang berisi data hasil vektorisasi setelah yang terdiri dari variabel yang berisi data komen yang di dalamnya di buat random yang nantinya akan dibut data training dan data testing dengan ketentuan data training 300 dan data testing sebanyak 50 setelah itu data training di lakukan vektorisasi dan data testing juga dilakukan vektorisasi setelah itu kedua data training dan testing tersebut dibuat label dengan parameter field CLASS.

#### 4. klasifikasi SVM berikut kodingnya :

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 23 22:00:11 2020
4
5 @author: User
6 """
7
8 #Coding untuk melakukan klasifikasi SVM
9 from sklearn import svm
10 clfsvm = svm.SVC()
11 clfsvm.fit(dk_train_att, dk_train_label)
12 clfsvm.score(dk_test_att, dk_test_label)
```

```

In [19]: runfile('D:/SEMESTER 6/New folder/1174050/4.py', wdir='D:/SEMESTER 6/New
folder/1174050')
In [20]: from sklearn import svm
...: clfsvm = svm.SVC()
...: clfsvm.fit(dk_train_att, dk_train_label)
...: clfsvm.score(dk_test_att, dk_test_label)
Out[20]: 0.9054054054054054
```

**Gambar 4.99** hasil

melakukan verifikasi import librari svm dari sklearn kemudian membuat variabel clfsvm berisikan method svc setelah itu variabel tersebut di berikan method fit dengan isian data train vektorisasi dan data training label yang berguna untuk melatih data tersebut setelah itu di coba untuk memunculkan score atau akurasi dari data tersebut menggunakan data testing vektorisasi dan data testing label.

#### 5. klasifikasi decision tree berikut ini merupakan codingan klasifikasi decision tree

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 23 22:11:57 2020
```

```

4
5 @author: User
6 """
7
8 #Melakukan klasifikasi Decision Tree
9 from sklearn import tree
10 clftree = tree.DecisionTreeClassifier()
11 clftree.fit(dk_train_att, dk_train_label)
12 clftree.score(dk_test_att, dk_test_label)

```

```

In [21]: from sklearn import tree
...: clftree = tree.DecisionTreeClassifier()
...: clftree.fit(dk_train_att, dk_train_label)
...: clftree.score(dk_test_att, dk_test_label)
Out[21]: 0.8986486486486487

```

**Gambar 4.100** hasil

import library tree dari sklearn kemudian membuat variabel clftree berisikan method DecisionTreeClasifier setelah itu variabel tersebut di berikan method fit dengan isian data train vektorisasi dan data training label yang berguna untuk melatih data tersebut agar dapat digunakan pada codingan selanjutnya setelah itu di coba untuk memunculkan score atau akurasi dari data tersebut menggunakan data testing vektorisasi dan data testing label.

6. plot confusion matrix berikut merupakan codingan untuk confusion matrix

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 23 22:13:25 2020
4
5 @author: User
6 """
7
8 #Melakukan confusion matrix
9 from sklearn.metrics import confusion_matrix
10 pred_labels = clftree.predict(dk_test_att)
11 cm = confusion_matrix(dk_test_label, pred_labels)
12 cm

```

```

In [22]: from sklearn.metrics import confusion_matrix
...: pred_labels = clftree.predict(dk_test_att)
...: cm = confusion_matrix(dk_test_label, pred_labels)
...: cm
Out[22]:
array([[66, 2],
 [13, 67]], dtype=int64)

```

**Gambar 4.101** hasil

import library comfusion matrix selanjutnya dilakukan prediksi pada pada data tes nya kemudian data tersebut di masukan kedalam variabel cm dengan method confusion matrix yang di dalamnya terdapat data

dari variabel perd label dan dk test label setelah itu variabel cm tersebut di running maka akan memunculkan nilai matrixnya.

7. cross valodation berikut merupakan code untuk cross validation pada codingan pertama yaitu melakukan split 5 kali yaoti mengitung tingkat akurasi menggunakan data training.

```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 23 22:14:06 2020
4
5 @author: User
6 """
7
8 from sklearn.model_selection import cross_val_score
9 scores = cross_val_score(clftree, dk_train_att, dk_train_label,
10 cv=5)
11 scorerata2=scores.mean()
12 scorsersd=scores.std()
13
14 from sklearn.model_selection import cross_val_score
15 scores = cross_val_score(clftree, dk_train_att,
16 dk_train_label, cv=5)
17 # show average score and +/- two standard deviations away (
18 # covering 95
19 #%% of scores)
20 print("Accuracy: %0.2f (+/- %0.2f)" % (scores.mean(), scores.
21 std() * 2))
22
23 scorestree = cross_val_score(clftree, dk_train_att,
24 dk_train_label, cv=5)
25 print("Accuracy: %0.2f (+/- %0.2f)" % (scorestree.mean(),
26 scorestree.std() * 2))
27
28 scoressvm = cross_val_score(clfsvm, dk_train_att,
29 dk_train_label, cv=5)
30 print("Accuracy: %0.2f (+/- %0.2f)" % (scoressvm.mean(),
31 scoressvm.std() * 2))

```

```

In [24]: runfile('D:/SEMESTER 6/New folder/1174050/7.py', wdir='D:/SEMESTER 6/New
folder/1174050')
Accuracy: 0.96 (+/- 0.03)
Accuracy: 0.95 (+/- 0.02)
Accuracy: 0.94 (+/- 0.03)

```

**Gambar 4.102** hasil

akan di bandingkan tingkat akurasi dari semua hasil akurasiya yang akan memunculkan nilai akurasi dari tiga metode yaitu random forest, decision tree, dan klasifikasi svm (suport vector machine) diamana mana yang terbaik dan lebih akurat pada hasilnya data yang paling akurat yaitu random forest. terdapat grafik data yang terdapat dari grafik tersebut di dapat dari codingan dengan cara pengulangan data masing masing 10 kali setelah itu di eksekusi menjadi grafik berbentuk 3D pada gambar

tersebut menunjukkan rasio dari yang terrendah yaitu data SVM kemudian data decision tree dan hasil random forest.

## 8. Pengamatan program

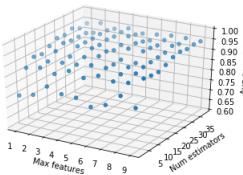
```

1 # -*- coding: utf-8 -*-
2 """
3 Created on Mon Mar 23 22:19:22 2020
4
5 @author: User
6 """
7
8 from sklearn.ensemble import RandomForestClassifier
9 import numpy as np
10 max_features_opts = range(1, 10, 1)
11 n_estimators_opts = range(2, 40, 4)
12 rf_params = np.empty((len(max_features_opts)*len(
13 n_estimators_opts),4), float)
13 i = 0
14 for max_features in max_features_opts:
15 for n_estimators in n_estimators_opts:
16 clf = RandomForestClassifier(max_features=
17 max_features,n_estimators=n_estimators)
18 scores = cross_val_score(clf, dk_train_att,
19 dk_train_label, cv=5)
20 rf_params[i,0] = max_features
21 rf_params[i,1] = n_estimators
22 rf_params[i,2] = scores.mean()
23 rf_params[i,3] = scores.std() * 2
24 i += 1
25 print("Max features: %d, num estimators: %d, accuracy
26 : %0.2f (+/- %0.2f)" %
27 (max_features, n_estimators, scores.mean(), scores.std()
28 * 2))
29
30 import matplotlib.pyplot as plt
31 from mpl_toolkits.mplot3d import Axes3D
32 from matplotlib import cm
33 fig = plt.figure()
34 fig.clf()
35 ax = fig.gca(projection='3d')
36 x = rf_params[:,0]
37 y = rf_params[:,1]
38 z = rf_params[:,2]
39 ax.scatter(x, y, z)
40 ax.set_zlim(0.6, 1)
41 ax.set_xlabel('Max features')
42 ax.set_ylabel('Num estimators')
43 ax.set_zlabel('Avg accuracy')
44 plt.show()
```

### 4.6.3 Penanganan Error

#### 1. screenshoot error

```
Max features: 9, num estimators: 6, accuracy: 0.92 (+/- 0.06)
Max features: 9, num estimators: 10, accuracy: 0.92 (+/- 0.08)
Max features: 9, num estimators: 14, accuracy: 0.91 (+/- 0.03)
Max features: 9, num estimators: 18, accuracy: 0.93 (+/- 0.03)
Max features: 9, num estimators: 22, accuracy: 0.94 (+/- 0.03)
Max features: 9, num estimators: 26, accuracy: 0.95 (+/- 0.02)
Max features: 9, num estimators: 30, accuracy: 0.94 (+/- 0.03)
Max features: 9, num estimators: 34, accuracy: 0.95 (+/- 0.02)
Max features: 9, num estimators: 38, accuracy: 0.94 (+/- 0.03)
```



**Gambar 4.103** hasil

```
Max features: 9, num estimators: 38, accuracy: 0.94 (+/- 0.04)
Traceback (most recent call last):
 File "<ipython-input-28-a024febdaf7>", line 1, in <module>
 runfile('D:/SEMESTER 6/New folder/1174050/8.py', wdir='D:/SEMESTER 6/New folder/1174050')
 File "C:\Users\>User\Anaconda3\lib\site-packages\spyder_kernels\customize\spydercustomize.py", line 827, in runfile
 execfile(filename, namespace)
 File "C:\Users\>User\Anaconda3\lib\site-packages\spyder_kernels\customize\spydercustomize.py", line 110, in execfile
 exec(compile(f.read(), filename, 'exec'), namespace)
 File "D:/SEMESTER 6/New folder/1174050/8.py", line 29, in <module>
 fig = plt.figures()
AttributeError: module 'matplotlib.pyplot' has no attribute 'figures'
```

**Gambar 4.104** hasil

## 2. codingan yang error

```
-*- coding: utf-8 -*-
"""
Created on Mon Mar 23 22:19:22 2020

```

```
@author: User
"""
```

```
from sklearn.ensemble import RandomForestClassifier
import numpy as np
max_features_opts = range(1, 10, 1)
n_estimators_opts = range(2, 40, 4)
rf_params = np.empty((len(max_features_opts)*len(n_estimators_opts),
i = 0
for max_features in max_features_opts:
 for n_estimators in n_estimators_opts:
 clf = RandomForestClassifier(max_features=max_features,n_est
```

```
scores = cross_val_score(clf, dk_train_att, dk_train_label,
rf_params[i,0] = max_features
rf_params[i,1] = n_estimators
rf_params[i,2] = scores.mean()
rf_params[i,3] = scores.std() * 2
i += 1
print("Max features: %d, num estimators: %d, accuracy: %.2f"
% (max_features, n_estimators, scores.mean(), scores.std() * 2))

import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D
from matplotlib import cm
fig = plt.figure()
fig.clf()
ax = fig.gca(projection='3d')
x = rf_params[:,0]
y = rf_params[:,1]
z = rf_params[:,2]
ax.scatter(x, y, z)
ax.set_zlim(0.6, 1)
ax.set_xlabel('Max features')
ax.set_ylabel('Num estimators')
ax.set_zlabel('Avg accuracy')
plt.show()
```

3. solusinya Didalam library matplotlib tidak ada attribute figures tetapi figure makanya pada coding diatas error karena menggunakan figures yang harusnya menggunakan figure.

## BAB 5

---

# CHAPTER 5

---

### 5.1 1174042 Faisal Najib Abdullah

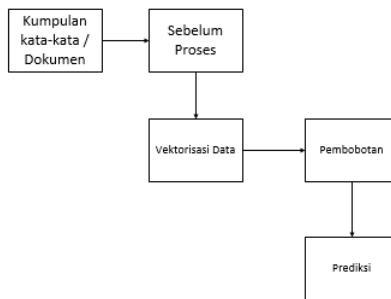
#### 5.1.1 Teori

1. Jelaskan Kenapa Kata-Kata harus dilakukan vektorisasi lengkapi dengan ilustrasi gambar.

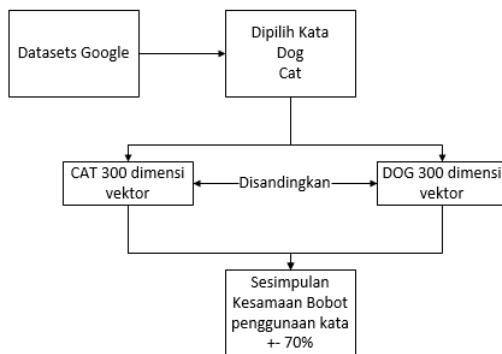
Kata kata harus dilakukan vektorisasi dikarenakan atau bertujuan utk mengukur nilai kemunculan suatau kata yang serupa dari sebuah kalimat sehingga kata-kata tersebut dapat di prediksi kemunculannya. atau juga di buatnya vektorisasi data digunakan untuk memprediksi bobot dari suatu kata misalkan ayam dan kucing sama-sama hewan maka akan dibuat prediksi apakah kata tersebut akan muncul pada kalimat yang kira-kira memiliki bobot yang sama.

2. Jelaskan Mengapa dimensi dari vektor dataset google bisa mencapai 300 lengkapi dengan ilustrasi gambar.

Dimensi dataset dari google bisa mencapai 300 karena dimensi dari vektor tersebut digunakan untuk membandingkan bobot dari setiap kata,

**Gambar 5.1** Teori 1


misalkan terdapat kata dog dan cat pada dataset google tersebut setiap kata tersebut di buat dimensi vektor 300 untuk kata dog dan 300 dimensi vektor juga untuk kata cat kemudian kata tersebut di bandingkan bobot kesamaan katanya maka akan muncul akurasi sekitar 70 persen kesamaan bobot dikarenakan kata dog dan cat sama sama di gunakan untuk hewan priharaan.

**Gambar 5.2** Teori 2

3. Jelaskan Konsep vektorisasi untuk kata . dilengkapi dengan ilustrasi atau gambar.

Vektorisasi untuk kata untuk mengetahui kata tengah dari suatu kalimat atau kata utama atau objek utama pada suatu kalimat contoh ( Jangan lupa subscribe channel saya ya sekian treimakasih ) kata tengah tersebut merupakan channel yang memiliki bobot sebagai kata tengah dari suatu kalimat atau bobot sebagai objek dari suatu kalimat. hal ini sangat berkaitan dengan dimensi vektor pada dataset google yang 300 tadi


karena untuk mendapatkan nilai atau bobot dari kata tengah tersebut di dapatkan dari proses dimensiasi dari kata tersebut.



**Gambar 5.3** Teori 3

4. Jelaskan Konsep vektorisasi untuk dokumen. dilengkapi dengan ilustrasi atau gambar.

Vektorisasi untuk dokumen hampir sama seperti vektorisasi untuk kata hanya saja pemilihan kata utama atau kata tengah terdapat pada satu dokumen jadi mesin akan membuat dimensi vektor 300 untuk dokumen dan nanti kata tengahnya akan di sandingkan pada dokumen yang terdapat pada dokumen tersebut.




**Gambar 5.4** Teori 4

5. Jelaskan apa mean dan standar deviasi, lengkapi dengan ilustrasi atau gambar.

mean merupakan petunjuk terhadap kata-kata yang diolah jika kata-kata itu akurasinya tinggi berarti kata tersebut sering muncul begitu juga sebaliknya, sedangkan standar deviation merupakan standar untuk menimbang kesalahan. sehingga kesalahan tersebut dianggap wajar misalkan


kita memperkirakan kedalaman dari dataset merupakan 2 atau 3 tapi pada kenyataanya merupakan 5 itu merupakan kesalahan tapi masih bisa dianggap wajar karna masih mendekati perkiraan awal.



**Gambar 5.5** Teori 5

6. Jelaskan Apa itu Skip-Gram sertakan contoh ilustrasi.

Skip-Gram adalah kebalikan dari konsep vektorisasi untuk kata dimana kata tengah menjadi acuan terhadap kata-kata pelengkap dalam suatu kalimat.



**Gambar 5.6** Teori 6

### 5.1.2 Praktikum

1. mencoba dataset google dan penjelasan vektor dari kata love, faith, fall, sick, clear, shine, bag, car, wash, motor, dan cycle.
  - berikut merupakan code import gensim digunakan untuk membuat data model atau rangcangan data yang akan dibuat. selanjutnya dibuat variabel gmodel yang berisi data vektor negatif. selanjutnya data tersebut di load agar data tersebut dapat ditampilkan dan diolah.

```
In [2]: import gensim
gmodel = gensim.models.KeyedVectors.load_word2vec_format('GoogleNews-vectors-negative300.bin', binary = True)
```

**Gambar 5.7** Praktek 1

- berikut merupakan hasil lpengolahan kata love pada data google yang di load tadi. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.

```
In [3]: gmodel['love']
```

```
Out[3]: array([0.10302734, -0.15234375, 0.02587891, 0.16503906, -0.16503906,
 0.06689453, 0.29296875, -0.26367188, -0.140625, , 0.20117188,
 -0.02624512, -0.08203125, -0.02770996, -0.04394531, -0.23535156,
 0.16992188, 0.12898625, 0.15722656, 0.00756836, -0.06982422,
 -0.03857422, -0.07958984, 0.22949219, -0.14355469, 0.16796875,
 -0.03515625, 0.05517578, 0.10693359, 0.11181641, -0.16308594,
 -0.11181641, 0.13964844, 0.01556396, 0.12792969, 0.15429688,
 0.07714844, 0.26171875, 0.08642578, -0.02514648, 0.33398438,
 0.18652344, -0.20996094, 0.07080078, 0.02600098, -0.10644531,
 -0.10253906, 0.12304688, 0.04711914, 0.02209473, 0.05834961,
 -0.10986328, 0.14941406, -0.10693359, 0.01556396, 0.08984375,
 0.11230469, -0.04378117, -0.11376953, -0.0037384 , -0.01818848,
 0.24316406, 0.08447266, -0.07080078, 0.18066406, 0.03515625,
 -0.09667969, -0.21972656, -0.00328064, -0.03198242, 0.18457031,
 0.28515625, -0.0859375 , -0.11181641, 0.0213623 , -0.30664062,
 -0.09228516, -0.18945312, 0.01513672, 0.18554688, 0.34375 ,
 -0.31054688, 0.22558594, 0.08740234, -0.2265625 , -0.29492188,
 0.08251953, -0.38476562, 0.25390625, 0.26953125, 0.06298828,
 -0.00958252, 0.23632812, -0.17871094, -0.12451172, -0.17285156,
 -0.11767578, 0.19726562, -0.03466797, -0.104000391, -0.1640625 ,
 -0.19726562, 0.19824219, 0.09521484, 0.00561523, 0.12597656,
 0.00073624, -0.0402832 , -0.030863965, 0.01623535, -0.1640625 ,
 -0.22167969, 0.171875 , 0.12011719, -0.01965332, 0.4453125 ,
 0.06494141, 0.05932617, -0.1640625 , -0.01367188, 0.18945312,
 0.05566406, -0.05004883, -0.01422119, 0.15917969, 0.07421875,
 -0.31640625, -0.0534668 , -0.02355957, -0.16992188, 0.0625 ,
 -0.140625 , -0.13183594, -0.12792969, 0.12060547, 0.05883789,
```

**Gambar 5.8** Praktek 1

- berikut merupakan hasil lpengolahan kata faith pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.
- berikut merupakan hasil lpengolahan kata fall pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.
- berikut merupakan hasil lpengolahan kata sick pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.
- berikut merupakan hasil lpengolahan kata clear pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.

```
In [4]: gmodel['faith']
```

```
Out[4]: array([0.26367188, -0.04150391, 0.1953125 , 0.13476562, -0.14648438,
 0.11962891, 0.04345703, 0.10351562, 0.12207031, 0.13476562,
 0.06640625, 0.18945312, -0.16601562, 0.21679688, -0.27148438,
 0.3203125 , 0.10449219, 0.36132812, -0.1953125 , -0.18164062,
 0.15332031, -0.10839844, 0.10253906, -0.01367188, 0.23144531,
 -0.05957031, -0.22949219, -0.00604248, 0.26171875, 0.10302734,
 -0.1328125 , 0.21484375, 0.01135254, 0.02111816, 0.18554688,
 0.04125977, 0.12011719, 0.17480469, -0.22167969, -0.13476562,
 0.3125 , 0.06640625, -0.17675781, -0.01708984, -0.1640625 ,
 -0.02819824, 0.01257324, -0.09521484, -0.18066406, -0.140625 ,
 -0.02258301, 0.16308594, -0.13183594, -0.08007812, 0.13085938,
 0.27539062, -0.20605469, 0.10351562, -0.20214844, -0.1875 ,
 0.16992188, 0.13574219, 0.13769531, 0.16308594, -0.03881836,
 -0.11132812, 0.05688477, 0.12255859, 0.09814453, -0.04956055,
 -0.02331543, -0.04248047, -0.08203125, 0.16015625, 0.04150391,
 -0.16601562, -0.13671875, 0.09619141, 0.32617188, 0.08251953,
 -0.20800781, 0.04199219, 0.05834961, -0.27734375, 0.09130859,
 -0.17382812, -0.22460938, 0.03466797, 0.19824219, -0.08837891,
 0.18359375, 0.07324219, 0.1171875 , -0.33984375, 0.16796875,
 -0.13574219, -0.30078125, -0.00469971, 0.06005859, -0.29296875,
 0.15234375, 0.02966309, 0.33203125, 0.28320312, 0.09375 ,
 -0.20605469, -0.09082031, 0.0534668 , 0.05834961, -0.03222656,
 -0.29296875, 0.25585938, 0.00430298, 0.140625 , 0.05810547,
 0.21582031, 0.0291748 , 0.02929688, 0.20019531, 0.34960938,
 0.10449219, -0.01940918, 0.04077148, 0.32226562, -0.1953125 ,
 -0.05688477, 0.10498847, -0.04785156, -0.15136719, -0.07714844,
 -0.45898438, -0.29492188, -0.328125 , -0.20996094, 0.38671875,
 0.0039978 . 0.07373047. -0.01220703. 0.22460938. 0.14550781.
```

**Gambar 5.9** Praktek 1

- berikut merupakan hasil lpengolahan kata shine pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.
- berikut merupakan hasil lpengolahan kata bag pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.
- berikut merupakan hasil lpengolahan kata car pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.
- berikut merupakan hasil lpengolahan kata wash pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.
- berikut merupakan hasil lpengolahan kata motor pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.
- berikut merupakan hasil lpengolahan kata cycle pada data google yang di load. Sehingga memunculkan hasil vektor 300 dimensi untuk kata tersebut.
- berikut merupakan hasil dari similaritas kata kata yang di olah menjadi matrix tadi adapun persentase untuk perbandingan setiap katanya

```
In [5]: gmodel['fall']
```

```
Out[5]: array([-0.04272461, 0.10742188, -0.09277344, 0.16894531, -0.1328125 ,
-0.10693359, 0.04321289, 0.01904297, 0.14648438, 0.15039062,
-0.08691406, 0.04492188, 0.0145874, 0.08691406, -0.19824219,
-0.11035156, 0.01092529, -0.08300781, -0.0189209 , -0.1953125 ,
-0.1015625 , 0.13671875, 0.09228516, -0.12109375, 0.12695312,
0.03417969, 0.2109375 , 0.01977539, 0.125 , 0.01544189,
-0.26953125, -0.0098877 , -0.07763672, -0.15527344, -0.03393555,
0.04199219, -0.29828212, -0.18554688, 0.08496094, -0.02087402,
0.13574219, -0.22558594, 0.33789062, -0.03564453, -0.10839844,
-0.19335938, 0.0546875 , -0.04956055, 0.3671875 , -0.03295898,
0.10205078, -0.15136719, -0.00445557, 0.04003906, 0.27539062,
-0.06935949, 0.05834961, 0.01422119, -0.01397705, -0.05395508,
-0.0255127 , 0.06298828, 0.07080078, -0.07617188, 0.06542969,
-0.01672363, -0.047111914, 0.19628906, -0.08984375, 0.078125 ,
0.2189375 , 0.0612793 , 0.08789062, 0.19628906, 0.11376953,
0.06542969, 0.03125 , 0.12988281, 0.02270508, 0.14550781,
-0.06225586, -0.37695312, -0.05737305, -0.06396484, 0.08984375,
0.00448608, -0.14160156, -0.04541016, -0.0703125 , 0.06005859,
0.26757812, 0.02001953, -0.12695312, -0.04882812, 0.18945312,
-0.03466797, 0.04638672, 0.1484375 , 0.01708984, -0.08789062,
-0.14941406, -0.02331543, -0.03955078, -0.10400391, -0.14160156,
-0.18261719, -0.03076172, 0.04589844, -0.2890625 , -0.093540039,
0.12890625, -0.10595783, 0.17578125, 0.06689453, 0.34960938,
0.04296875, 0.09863281, -0.08956641, -0.06298828, 0.12255859,
0.0234375 , -0.06494141, 0.09667969, -0.04589844, 0.04956055,
0.08007812, -0.00482178, -0.1646025 , -0.03271484, 0.0703125 ,
-0.07958984, -0.12890625, -0.01879883, -0.17773438, 0.01293945,
-0.20019531, 0.08886719, -0.18847656, -0.23828125, 0.02758789,
-0.14453125, -0.10058594, -0.0859375 , 0.10205078, -0.00396729,
```

**Gambar 5.10** Praktek 1

yaitu 9 persen untuk kata wash dan clear 7 persen untuk kata bag dan love 48 persen untuk kata motor dan car 12 persen untuk kata sick dan faith dan terakhir yaitu 6 persen untuk kata cycle dan shine.

2. pada code berikut merupakan hasil dari running code untuk ekstrak word dimana pada baris ke tiga dimasukan perintah untuk menghapus tag html yang terdapat dalam file tersebut selanjutnya pada baris ke 4 yaitu perintah untuk menghilangkan tanda kutip satu selanjutnya pada baris ke 5 yaitu perintah untuk menghapus tanda baca pada file tersebut dan yang terakhir yaitu perintah untuk menghapus double sepsi atau sepsi berurutan. setelah itu dibuat class bari dari random yang bertujuan untuk mengkocok data yang ada pada file tersebut kemudian class permute sentence tersebut akan digunakan untuk mengolah data selanjutnya. untuk lebih jelasnya dapat dilihat pada gambar ??.
3. gensim merupakan library untuk memodelkan topik unsupervised atau memodelkan bahasa dengan model unsupervised. Saat ini taget dokumen digunakan untuk TaggetDokumen berarti memasukan dokumen untuk diolah oleh mesin. Kemudian Doc2Vec digunakan untuk membandingkan dokumen apakah isi dari dokumen itu bobotnya sama dengan dokumen yang di sandingkannya. menunjukkan di baris ke satu dilakukan dari librari gensim dokumen mengimport method taggedDocument lalu

```
In [6]: gmodel['sick']
```

```
Out[6]: array([-1.82617188e-01, 1.49414062e-01, -4.05273438e-02, 1.64062500e-01,
-2.59765625e-01, 3.22265625e-01, 1.73828125e-01, -1.47460938e-01,
1.01874219e-01, 5.46875000e-02, 1.66992188e-01, -1.68945312e-01,
2.24304199e-03, 9.66796875e-02, -1.66015625e-01, -1.12304688e-01,
1.66015625e-01, 1.79687500e-01, 5.92041016e-03, 2.45117188e-01,
8.74023438e-02, -2.56347656e-02, 3.41796875e-01, 4.98046875e-02,
1.78710938e-01, -9.91821289e-04, 8.88671875e-02, -1.95312500e-01,
1.81640625e-01, -2.65625000e-01, -1.45597812e-01, 1.00585938e-01,
9.42382812e-02, -3.12500000e-02, 1.98974609e-02, -6.39648438e-02,
1.18652344e-01, 1.23046875e-01, -6.03027344e-02, 4.68750000e-01,
9.13085938e-02, -3.12500000e-01, 1.84570312e-01, -1.51367188e-01,
5.78613281e-02, -1.04980469e-01, -1.68945312e-01, -8.00781250e-02,
-2.01171875e-01, 1.06201172e-02, -1.29882812e-01, -1.25976562e-01,
-5.56640625e-02, 3.14453125e-01, 5.61523438e-02, -1.20117188e-01,
7.12890625e-02, 4.37011719e-02, 2.05078125e-01, 5.71289062e-02,
8.44726562e-02, 2.15820312e-01, -1.26953125e-01, 8.78906250e-02,
2.48846875e-01, -6.54296875e-02, -2.02636719e-02, 1.52343750e-01,
-3.57421875e-01, 3.02124023e-03, -2.08007812e-01, -5.05371094e-02,
2.81982422e-02, 1.73828125e-01, -2.08007812e-01, -5.93261719e-02,
-6.49414062e-02, 3.63769531e-02, 1.91406250e-01, 2.77343750e-01,
3.54003906e-02, 1.56250000e-01, -1.03857422e-02, 2.26562500e-01,
-4.66308594e-02, -5.17578125e-02, -1.63085938e-01, 4.17480469e-02,
2.01171875e-01, -2.01171875e-01, -1.50756836e-02, 2.61718750e-01,
-1.10839844e-01, -4.21875000e-01, 2.22167969e-02, 1.46484375e-01,
4.19921875e-01, -6.88476562e-02, 9.42382812e-02, -1.96289062e-01,
-9.42382812e-02, -3.12500000e-02, 6.34765625e-02, 2.47802734e-02,
-1.61132812e-01, -1.53320312e-01, 1.31835938e-01, -1.81640625e-01,
```

**Gambar 5.11** Praktek 1

pada baris kedua dari librari gensim model melakukan import metod Doc2Vec.

4. cara memasukan data traning file pertama tentukan terlebih dahulu tempat file dokumen tersebut disimpan kemudian import librari os setelah itu buat variabel unsup\_sentences yang berisikan array kosong, lalu tentukan file yang akan dimasukan setelah itu lakukan os.listdir pada data yang akan dimasukan kemudian semua data tersebut di inisialisasi menjadi f kemudian nama f tersebut dimasukan ke variabel unsup. pada codingan tersebut merupakan praktikum untuk memasukan data doc2vec
5. kenapa harus dilakukan pengocokan data atau randomisasi ? hal ini harus dilakukan supaya data lebis gambang untuk di olah dan meningkatkan tingkat akurasi dari proses pengolahan data Doc2Vec. kemudian harus dilakukan pembersihan data agar memori pc atau laptop yang di gunakan untuk mengolah data menjadi ringan dan menambah peforma dari mesin itu sendiri untuk codingan pertama lakukan terlebih dahulu randomisasi. selanjutnya membuat variabel baru dengan nama mute yang di isi data class random dan data unsup\_sentence. kemudian setelah pengolahan data dilakukan pembersihan dengan melakukan code.
6. kenapa model harus di save ? suapaya dalam pengolahan data tidak perlu menjalankan kembali data vektorisasi serta untuk meringankan beban

```
In [7]: gmodel['clear']
```

```
Out[7]: array([-2.44140625e-04, -1.02050781e-01, -1.49414062e-01, -4.24804688e-02,
-1.67968750e-01, -1.46484375e-01, 1.76757812e-01, 1.46484375e-01,
2.26562500e-01, 9.76562500e-02, -2.67578125e-01, -1.29882812e-01,
1.24511719e-01, 2.23632812e-01, -2.13867188e-01, 3.10058594e-02,
2.00195312e-01, -4.76074219e-02, -6.83593750e-02, -1.21093750e-01,
3.22265625e-02, 3.14453125e-01, -1.11816406e-01, 8.00781250e-02,
-2.75878906e-02, -6.04248047e-03, -7.37304688e-02, -1.72851562e-01,
9.66796875e-02, -4.91333008e-03, -1.78710938e-01, -1.40380859e-03,
7.91015625e-02, 1.07910156e-01, -1.10351562e-01, -8.34960938e-02,
1.98974609e-02, -3.14331055e-03, 1.30615234e-02, 3.34472656e-02,
2.55859375e-01, -7.12890625e-02, 2.83203125e-01, -2.75390625e-01,
-8.49689375e-02, -3.73535156e-02, -9.17968750e-02, -1.30859375e-01,
3.49121094e-02, 7.32421875e-02, 2.17773438e-01, 5.00488281e-02,
7.47070312e-02, -1.25000000e-01, -5.73730469e-02, -2.74658203e-02,
-1.37329102e-02, -2.13867188e-01, -1.12792969e-01, -4.98046875e-02,
-1.92382812e-01, 1.32812500e-01, -5.00488281e-02, -1.66015625e-01,
-1.57470703e-02, -1.37695312e-01, 3.88183594e-02, 1.57226562e-01,
-1.52343750e-01, -1.64794922e-02, -2.27539062e-01, 3.34472656e-02,
1.55273438e-01, 1.65039062e-01, -1.66992188e-01, 3.14941406e-02,
2.85156250e-01, 2.69531250e-01, 3.32031250e-02, 2.41210938e-01,
1.39160156e-02, 5.12695312e-02, 9.76562500e-02, 3.14941406e-02,
2.51464844e-02, -2.85156250e-01, -1.24023438e-01, -6.88476562e-02,
-5.29785156e-02, 2.06054688e-01, -2.07031250e-01, -1.60156250e-01,
-2.61230469e-02, -3.01513672e-02, 8.66699219e-03, -1.30859375e-01,
3.88183594e-02, 8.60595703e-03, 5.31005859e-03, -6.05468750e-02,
1.03759766e-02, 1.33789062e-01, -1.89971924e-03, -4.27246094e-02,
-1.14746094e-01, -1.47705078e-02, 9.71679688e-02, -1.66992188e-01,
5.63964844e-02, -2.76184082e-03, -1.05468750e-01, -1.03027344e-01,
```

**Gambar 5.12** Praktek 1

ram. kemudian temporary harus dihapus guna meningkatkan peforma komputer.

7. inver\_code digunakan untuk membandingkan data doc2vec yang telah diolah dengan kata yang baru atau data yang ada dalam perintah vector itu sendiri contoh membandingkan kata (i will go home) untuk lebih jelasnya dapat di lihat pada gambar ???. kemudian untuk hasil running code tersebut dapat di lihat pada gambar ?? pada hasil gambar tersebut terdapat hasil vektor yang rata rata berada pada kisaran 0,2 an yang berarti kata yang dimasukan pada inter\_vec datanya ada pada doc2vec atau ada data yang bobotnya menyamai kata-kata di dalam dokumen tersebut.
8. consine\_simirarity setelah melakukan pengolahan data doc2vec dilakukan consine simirarity yang bertujuan untuk membandingkan data berisikan bahasa inggris dengan data yang telah di olah tadi apakah hasilnya mirip atau tidak untuk caranya yaitu dengan cara mencobacodingan yang terdapat pada gambar ?? berikut maka akan muncul hasilnya berapa persen dengan tulisan 0,4 sekian yang berarti tingkat kemiripan dokumen yang di uji tadi untuk hasilnya dapat dilihat pada gambar ?? berikut.
9. untuk melakukan cross validation pertama masukan terlebih dahulu metode KNeighborsClasifier dan RandomForestClasifier dari library sklearn ke-

```
In [8]: gmodel['shine']
```

```
Out[8]: array([-0.12402344, 0.25976562, -0.15917969, -0.27734375, 0.30273438,
 0.09960938, 0.39257812, -0.22949219, -0.18359375, 0.3671875 ,
 -0.10302734, 0.13671875, 0.25390625, 0.07128906, 0.02539062,
 0.21777344, 0.24023438, 0.5234375 , 0.12304688, -0.19335938,
 -0.05883789, 0.0612793 , -0.01949918, 0.07617188, 0.05102539,
 0.20019531, 0.38085938, 0.00162506, -0.05029297, 0.14648438,
 -0.34765625, 0.02563477, -0.23925781, -0.04516682, -0.00479126,
 -0.24121094, -0.18945312, -0.15234375, -0.05493164, 0.01434326,
 0.390625 , -0.2109375 , 0.1484375 , -0.13183594, 0.24511719,
 -0.24023438, -0.36132812, -0.12792969, 0.10595703, 0.09912109,
 -0.0246582 , 0.32226562, 0.11376953, 0.18164062, 0.04931641,
 -0.10253906, -0.00283813, 0.29882812, -0.171875 , -0.18945312,
 -0.01367188, -0.20898438, -0.07861328, -0.0859375 , 0.05395508,
 -0.14257812, -0.149625 , 0.03027344, -0.14453125, 0.359375 ,
 0.16113281, 0.22265625, 0.265625 , -0.06347656, -0.02807617,
 0.04760742, 0.08837891, -0.04272461, 0.05988203, 0.07128906,
 0.01519775, -0.11621994, 0.07128906, 0.01403889, -0.10644531,
 0.08886719, 0.11523438, 0.09667969, -0.11083984, 0.16015625,
 0.3359375 , -0.1875 , 0.14550781, 0.00463867, 0.07617188,
 -0.09521484, 0.08447266, 0.20117188, 0.11230469, -0.33984375,
 -0.25390625, 0.05200195, 0.27539062, -0.08398438, -0.31054688,
 -0.22949219, 0.14941406, -0.1953125 , 0.08496094, -0.00753784,
 0.078125 , 0.05908203, 0.02355957, 0.06347656, 0.32617188,
 -0.08740234, 0.10058594, -0.11474609, -0.18164062, 0.13378906,
 0.11230469, -0.00080109, 0.08691406, 0.03888594, 0.0300293 ,
 -0.03417969, -0.00830078, 0.14160156, -0.09619141, -0.11328125,
 0.00823975, -0.15234375, 0.19042969, 0.04980469, 0.25 ,
 -0.00171661. 0.04589844. -0.05102539. -0.04052734. -0.03491211.
```

**Gambar 5.13** Praktek 1

mudian dilakukan cross validation setelah itu buat variabel clf dengan isi KNeighborsClasifier dan variabel clfrf dengan isi RandomForestClasifier kemudian di buat skor menggunakan cross validation dengan menggunakan variabel clf dan data sentvecs dan sentiments kemudian dengan numpy dibuat mean dari scores begitu pula untuk variabel clfrf selanjutnya melakukan import metode make\_pipeline yang dilakukan untuk membuat skor dari vektorisasi tfidf dan rf. untuk lebih jelasnya dapat di lihat pada gambar ?? maka akan muncul hasil rata-rata 0,76 sekian atau 76 persen untuk clf yang dapat dilihat pada gambar ?? dan untuk hasil clfrf menghasilkan hasil rata-rata di 71 persen yang dapat dilihat pada gambar ?? dan untuk hasil rata-rata keseluruhan cros validation sebesar 0,74 atau 74 persen yang dapat dilihat pada gambar ??.

```
1 from sklearn.neighbors import KNeighborsClassifier
2 from sklearn.ensemble import RandomForestClassifier
3 from sklearn.model_selection import cross_val_score
4 import numpy as np
5
6 clf = KNeighborsClassifier(n_neighbors=9)
7 clfrf = RandomForestClassifier()
8
9 scores = cross_val_score(clf, sentvecs, sentiments, cv=5)
10 print((np.mean(scores), np.std(scores)))
11
12 scores = cross_val_score(clfrf, sentvecs, sentiments, cv=5)
```

```
In [9]: gmodel['bag']

Out[9]: array([-0.03515625, 0.15234375, -0.12402344, 0.13378906, -0.11328125,
 -0.0133667 , -0.16113281, 0.14648438, -0.06835938, 0.140625 ,
 -0.06005859, -0.3046875 , 0.20996694, -0.04345703, -0.2109375 ,
 -0.05957031, -0.05053711, 0.10253906, 0.19042969, -0.09423828,
 0.18847656, -0.07958984, -0.11035156, -0.07910156, 0.06347656,
 -0.1527344 , -0.18945312, 0.11132812, 0.27539062, -0.06787109,
 0.01806641, 0.06689453, 0.2578125 , 0.0324707 , -0.24609375,
 -0.05541992, 0.01813184, 0.24121094, -0.21875 , 0.07568359,
 -0.09814453, -0.16113281, 0.16503906, -0.09521484, -0.16601562,
 -0.41796875, 0.0300293 , 0.19433594, 0.2890625 , 0.12695312,
 -0.19824219, -0.05517578, 0.04296875, -0.10107422, 0.07324219,
 -0.13378906, 0.265625 , -0.00466919, 0.19628906, -0.10839844,
 0.14941406, 0.1484375 , 0.09619141, 0.21777344, -0.08544922,
 -0.02819824, 0.02539662, -0.03759766, 0.23242188, 0.19628906,
 0.27539062, 0.09130859, 0.23738469, 0.09033203, -0.28515625,
 0.05932617, 0.06591797, -0.01794434, -0.00055313, -0.1796875 ,
 0.05615234, -0.12207831, -0.09863281, -0.05786133, -0.09375 ,
 -0.30273438, -0.06396484, -0.00744629, -0.17871094, 0.08544922,
 -0.20401056, 0.33789062, 0.00228882, -0.39453125, -0.14453125,
 -0.328125 , -0.12695312, -0.08544922, 0.15234375, 0.03662109,
 -0.1484375 , 0.05566406, 0.02844238, 0.07519531, -0.21484375,
 -0.15722656, 0.3359375 , -0.04736328, -0.00405884, -0.19726562,
 0.27929688, 0.05566406, -0.10058594, -0.00811768, -0.20703125,
 0.03295898, -0.14550781, -0.15917969, 0.16503906, 0.234375 ,
 0.03588867, 0.04296875, -0.25 , 0.1171875 , -0.07714844,
 0.00521851, 0.125 , 0.08886719, 0.15527344, -0.02185059,
 -0.15234375, -0.12890625, -0.34765625, -0.13769531, -0.18164062,
```

Gambar 5.14 Praktek 1

```
13 print((np.mean(scores), np.std(scores)))
14
15 # bag-of-words comparison
16 from sklearn.pipeline import make_pipeline
17 from sklearn.feature_extraction.text import CountVectorizer,
 TfIdfTransformer
18 pipeline = make_pipeline(CountVectorizer(), TfIdfTransformer()
 (), RandomForestClassifier())
19 scores = cross_val_score(pipeline, sentences, sentiments, cv
 =5)
20 print((np.mean(scores), np.std(scores)))
```

### 5.1.3 Penanganan Error

## 5.2 1174040 - Hagan Rowlenstino A. S

### 5.2.1 Teori

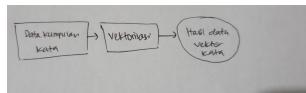
#### 1. Why words need to be Vectorizer

karena kata - kata yang digunakan untuk memproses data agar dapat menjadi bagian dari kumpulan data atau atribut yang dapat dibaca oleh sistem machine learning karena sistem tersebut tidak dapat memproses data text secara langsung dan harus di convert terlebih dahulu kedalam bilangan.untuk ilustrasinya dapat dilihat pada gambar

```
In [10]: gmodel['car']
```

```
Out[10]: array([-0.13085938, 0.00842285, 0.03344727, -0.05883789, 0.04003966,
 -0.14257812, 0.04931641, -0.16894531, 0.20898438, 0.11962891,
 0.18066406, -0.25 , -0.10400391, -0.10742188, -0.01879883,
 0.05200195, -0.00216675, 0.06445312, 0.14453125, -0.04541016,
 0.16113281, -0.01611328, -0.03088379, 0.08447266, 0.16210938,
 0.04467773, -0.15527344, 0.25390625, 0.33984375, 0.00756836,
 -0.25585938, -0.01733398, -0.03295898, 0.16308594, -0.12597656,
 -0.09912109, 0.16503906, 0.06884766, -0.18945312, 0.02832031,
 -0.0534668 , -0.03063965, 0.11083984, 0.24121094, -0.234375 ,
 0.12353516, -0.002944495, 0.1484375 , 0.33203125, 0.05249023,
 -0.20019531, 0.37695312, 0.12255859, 0.11425781, -0.17675781,
 0.10009766, 0.0038365 , 0.26757812, 0.28117188, 0.03710938,
 0.11083984, -0.09814453, -0.3125 , 0.03515625, 0.02832031,
 0.26171875, -0.08642578, -0.02258301, -0.05834961, -0.00787354,
 0.11767578, -0.04296875, -0.17285156, 0.04394531, -0.23046875,
 0.1640625 , -0.11474609, -0.06030273, 0.01196289, -0.24707031,
 0.32617188, -0.04492188, -0.11425781, 0.22851562, -0.01647949,
 -0.15039062, -0.13183594, 0.12597656, -0.17480469, 0.02209473,
 -0.1815625 , -0.00817871, 0.10791816, -0.24609375, -0.109375 ,
 -0.09375 , -0.01623535, -0.20214844, 0.23144531, -0.05444336,
 -0.05541992, -0.20898438, 0.26757812, 0.27929688, 0.17089844,
 -0.17578125, -0.02770996, -0.20410156, 0.02392578, 0.03125 ,
 -0.25390625, -0.125 , -0.05493164, -0.17382812, 0.28515625,
 -0.23242188, 0.0234375 , -0.20117188, -0.13476562, 0.26367188,
 0.00769043, 0.20507812, -0.01708984, -0.12988281, 0.04711914,
 0.22070312, 0.02099609, -0.29101562, -0.02893066, 0.17285156,
 0.04272461, -0.19824219, -0.04003906, -0.16992188, 0.10058594,
 -0.09326172, 0.15820312, -0.16503906, -0.06054688, 0.19433594,
 -0.07080078, -0.06884766, -0.09619141, -0.07226562, 0.04882812,
```

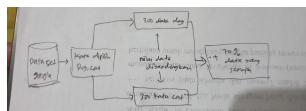
**Gambar 5.15** Praktek 1



**Gambar 5.28** Vektorisasi Kata

## 2. Why Dimension of Google dataset can reach 300

Dimensi dataset dari google bisa mencapai 300 karena dimensi dari vektor tersebut digunakan untuk membandingkan bobot dari setiap data kata yang diproses. ilustrasi dapat dilihat pada gambar



**Gambar 5.29** Dataset Google

## 3. Concept of Vectorizer on words

pada vektorisasi dengan menggunakan Word2Vec memiliki kelebihan yang dapat dibedakan dengan penggunaan bag of words yang biasanya. pada bag of word pemrosesan data tidak dapat menganalisa

```
In [11]: gmodel['wash']
```

```
Out[11]: array([- 9.46004492e-03, 1.41601562e-01, - 5.46875000e-02, 1.34765625e-01,
- 2.38281250e-01, 3.24218750e-01, - 8.44726562e-02, - 1.29882812e-01,
1.07910156e-01, 2.53906250e-01, 1.13525391e-02, - 1.66992188e-01,
- 2.79541016e-02, 2.08007812e-01, - 4.27246094e-02, 1.05468750e-01,
- 7.42187500e-02, 3.04687500e-01, 2.11914062e-01, - 8.88671875e-02,
2.67578125e-01, 2.12890625e-01, 1.74569547e-02, 2.02941895e-03,
6.29882812e-02, 1.62109375e-01, 1.93359375e-01, 2.17285156e-02,
- 2.67028809e-03, - 9.13085938e-02, - 2.38281250e-01, 2.23632812e-01,
- 8.00781250e-02, - 3.80859375e-02, - 1.00097656e-01, - 1.39648438e-01,
1.74804688e-01, 6.78710938e-02, 1.11328125e-01, 1.65039962e-01,
- 1.05468750e-01, 2.30712891e-02, 2.00195312e-01, - 6.03027344e-02,
- 3.43750000e-01, - 1.02050781e-01, - 3.80859375e-01, - 5.05371894e-02,
5.07812500e-02, 1.45507812e-01, 2.81250000e-01, 7.03125000e-02,
2.84423828e-02, - 2.29492188e-01, - 5.81054688e-02, 4.51660156e-02,
- 3.56445312e-02, 1.77734375e-01, 1.22070312e-01, 3.71893750e-02,
- 1.10839844e-01, 6.83593750e-02, - 2.52685547e-02, - 1.27929688e-01,
4.21875000e-01, 5.32226562e-02, - 3.92578125e-01, 1.74804688e-01,
1.77001953e-02, - 2.05078125e-02, 2.21679688e-01, 3.18359375e-01,
1.088398438e-01, - 4.30297852e-03, - 2.45117188e-01, - 2.08984375e-01,
3.58867191e-02, 8.30078125e-02, 1.68945312e-01, 2.79541016e-02,
1.04980469e-01, - 3.47656250e-01, - 5.20019531e-02, 2.24609375e-01,
1.69677734e-02, 1.69921875e-01, - 1.46484375e-01, 2.65625000e-01,
2.17285156e-02, 1.12304688e-02, - 1.14257812e-01, 7.22656250e-02,
4.32128906e-02, 1.11694336e-02, 5.07354736e-04, - 7.91815625e-02,
- 5.98144531e-02, - 5.44433594e-02, 3.73046875e-01, 5.62500000e-01,
- 2.26562500e-01, - 5.39550781e-02, 1.13769531e-01, - 5.83496094e-02,
- 1.53320312e-01, - 4.37500000e-01, 2.59765625e-01, - 1.49414062e-01,
5.66406250e-02, 2.13867188e-01, - 2.86865234e-02, - 1.70898438e-01,
```

**Gambar 5.16** Praktek 1

data yang memiliki makna sama namun penulisannya berbeda, namun pada penggunaan Word2Vec proses tersebut dapat berjalan dengan lebih mudah contohnya adalah penulisan kata please dengan plz. untuk ilustrasi datanya bisa dilihat dalam gambar



**Gambar 5.30** Concept of Vectorizer on words

#### 4. Concept of Vectorizer on documents

vektorisasi pada Doct2Vec dimana data yang terdapat pada file document tersebut diolah dengan melakukan pemrosesan yang mengutamakan nilai data filenamenya atau atribut utama dimana nilai data inputnya tidak terlalu diproses. ilustrasinya dapat dilihat pada gambar



**Gambar 5.31** Concept of Vectorizer on Documents

```
In [12]: gmodel['motor']
```

```
Out[12]: array([5.73730469e-02, 1.50390625e-01, -4.61425781e-02, -1.32812500e-01,
 -2.59765625e-01, -1.77734375e-01, 3.68652344e-02, -4.37500000e-01,
 2.34375000e-02, 2.57812500e-01, 1.74804688e-01, 2.44140625e-02,
 -2.51953125e-01, -5.76171875e-02, 8.15429688e-02, 1.86767578e-02,
 -3.83300781e-02, 1.58203125e-01, -5.85937500e-02, 1.12304688e-01,
 1.56250000e-01, -4.24804688e-02, -1.32812500e-01, 2.11914062e-01,
 1.23046875e-01, 1.69921875e-01, -1.55273438e-01, 4.58984375e-01,
 3.02734375e-01, 1.53320312e-01, -1.69921875e-01, -1.01074219e-01,
 -3.26538806e-03, 2.28515625e-01, 8.98437500e-02, -7.12890625e-02,
 1.54296875e-01, -8.88671875e-02, -2.36328125e-01, 5.61523438e-03,
 -4.46777344e-02, -3.06640625e-01, 7.42187500e-02, 5.58593750e-01,
 -1.30859375e-01, 1.00585938e-01, -3.34472656e-02, 2.10937500e-01,
 3.10058594e-02, -6.50024414e-03, 6.34765625e-02, 4.02832031e-02,
 -2.78320312e-02, 1.07421875e-02, 1.47468938e-01, 2.88761719e-02,
 -1.50390625e-01, -1.37695312e-01, 9.96093750e-02, 1.28906250e-01,
 -3.34472656e-02, -1.08032227e-02, -2.14843750e-01, -9.52148438e-02,
 -6.39648438e-02, 7.51953125e-02, -3.06640625e-01, 2.17773438e-01,
 -2.21679688e-01, 2.33398438e-01, 5.05371094e-02, -3.37890625e-01,
 1.53320312e-01, -7.12890625e-02, -3.68652344e-02, 7.66601562e-02,
 -8.00781250e-02, -1.14257812e-01, -9.71679688e-02, -2.61718750e-01,
 3.84765625e-01, -1.87500000e-01, -1.10351562e-01, 1.00585938e-01,
 1.08398438e-01, 9.57031250e-02, -8.20312500e-02, 1.54296875e-01,
 -2.40234375e-01, 8.34960938e-02, 4.19921875e-02, -1.91650391e-02,
 9.71679688e-02, 2.52685547e-02, -5.46875000e-02, -5.88378906e-02,
 8.20312500e-02, -3.32031250e-01, 3.27148438e-02, 5.71289062e-02,
 1.77734375e-01, -9.57031250e-02, 2.45117188e-01, 6.88476562e-02,
 2.63671875e-01, -8.15429688e-02, 1.25976562e-01, 1.20849609e-02,
 4.00390625e-01, 8.69140625e-02, -3.00781250e-01, -1.99218750e-01,
```

**Gambar 5.17** Praktek 1

## 5. What is mean and deviation standart

Mean adalah nilai rata-rata dari beberapa buah data. Nilai mean dapat ditentukan dengan membagi jumlah data dengan banyaknya data.

Standar deviasi adalah nilai statistik yang digunakan untuk menentukan bagaimana sebaran data dalam sampel, dan seberapa dekat titik data individu ke mean – atau rata-rata – nilai sampel.

untuk ilustrasi data mean dan deviation standart bisa dilihat pada gambar

| Contoh |       |
|--------|-------|
| nama   | nilai |
| budi   | 70    |
| ani    | 80    |
| ina    | 90    |

mean = 80  
 Standar deviasi = 15,275

**Gambar 5.32** Mean and Deviation Standard

```
In [13]: gmodel['cycle']
```

```
Out[13]: array([0.04541015, 0.21679688, -0.02709961, 0.12353516, -0.20783125,
 -0.13281015, 0.26367188, -0.12890625, -0.125 , 0.15332031,
 -0.18261719, -0.15820312, -0.06176758, 0.21972656, -0.15820312,
 0.02563477, -0.07568359, -0.0625 , 0.04614258, -0.31054688,
 -0.13378906, -0.11669922, -0.3359375 , 0.078125 , 0.08447266,
 0.07226562, -0.06445312, 0.05517578, 0.14941406, 0.13671875,
 0.19302734, 0.02172852, -0.10693359, 0.024980234, -0.10644531,
 -0.05541992, -0.29492188, -0.40039062, 0.06347656, -0.08447266,
 0.17871094, 0.01165771, -0.01696777, 0.13671875, -0.1640625 ,
 0.11425781, 0.20800781, -0.06079102, -0.07275391, 0.15039062,
 0.18066406, -0.28515625, -0.04052734, 0.01806641, 0.00331116,
 0.00872803, 0.03564453, -0.29882812, 0.09960938, -0.1484375 ,
 -0.06787109, 0.05957031, -0.05517578, -0.19628906, 0.2265625 ,
 0.03173828, -0.07080078, 0.1484375 , -0.20214844, -0.03393555,
 0.09863281, -0.02038574, -0.08789062, -0.07226562, -0.09423828,
 -0.17089844, 0.1484375 , 0.10546875, 0.06445312, 0.01031494,
 -0.02636719, -0.03686523, -0.125 , 0.06787109, 0.14257812,
 0.37109375, -0.15722656, 0.09326172, 0.34960938, -0.00091553,
 -0.03613281, 0.16894531, -0.02856445, 0.10791016, -0.32421875,
 -0.14355469, 0.03173828, -0.07421875, 0.34179688, 0.140625 ,
 0.00433335, -0.12890625, -0.34960938, -0.02929688, -0.19628906,
 -0.2578125 , -0.3671875 , 0.01483154, 0.20703125, 0.09667969,
 -0.10351562, -0.31054688, 0.02844238, 0.18400391, 0.17773438,
 0.06689453, -0.1796875 , 0.02783203, 0.15625 , 0.02026367,
 0.0324707 , -0.13476562, 0.15527344, 0.11132812, -0.01055908,
 0.07958984, 0.01989746, 0.25585938, 0.13378906, 0.02539062,
 0.10986328, -0.20605469, 0.07275391, -0.35546875, -0.02746582,
```

Gambar 5.18 Praktek 1

```
In [15]: gmodel.similarity('wash', 'clear')
```

```
Out[15]: 0.09019176
```

```
In [16]: gmodel.similarity('bag', 'love')
```

```
Out[16]: 0.07536096
```

```
In [17]: gmodel.similarity('motor', 'car')
```

```
Out[17]: 0.4810173
```

```
In [18]: gmodel.similarity('sick', 'faith')
```

```
Out[18]: 0.123073205
```

```
In [19]: gmodel.similarity('cycle', 'shine')
```

```
Out[19]: 0.061617922
```

Gambar 5.19 Praktek 1

## 6. What is skip-gram

Skip-gram merupakan teknik yang digunakan di area speech processing, dimana n-gram yang dibentuk kemudian ditambahkan juga dengan tindakan “skip” pada token-tokennya. contohnya terdapat pada gambar

```
In [20]: import re
def extract_words(sent):
 sent = sent.lower()
 sent = re.sub(r'<[^>]+>', ' ', sent) #hapus tag html
 sent = re.sub(r'(\w)\\'(\w)', ' ', sent) #hapus petik satu
 sent = re.sub(r'\W', ' ', sent) #hapus tanda baca
 sent = re.sub(r'\s+', ' ', sent) #hapus spasi yang berurutan
 return sent.split()
```

```
In [21]: import random
class PermuteSentences(object):
 def __init__(self, sents):
 self.sents = sents

 def __iter__(self):
 shuffled = list(self.sents)
 random.shuffle(shuffled)
 for sent in shuffled:
 yield sent
```


Gambar 5.20 Praktek 2

```
In [22]: from gensim.models.doc2vec import TaggedDocument
from gensim.models import Doc2Vec
```

```
In []: |
```

Gambar 5.21 Praktek 3



Gambar 5.33 Skip-Gram

## 5.2.2 Praktek

### 1. Try datasets GoogleNews-vectors

- berikut adalah hasil dari code yang digunakan untuk memanggil data library GENSIM dengan menggunakan perintah import, lalu dari library tersebut diambil data yang akan digunakan untuk memproses data dari GoogleNews-vector. ilustrasi dapat dilihat pada gambar

```
In [4]: import gensim
```

```
In [5]: gmodel = gensim.models.KeyedVectors.load_word2vec_format('GoogleNews-vectors-negative300.bin', binary=True)
```

Gambar 5.34 import gensim dan olah data GoogleNews-vector

```
In [53]: import os
unsup_sentences = []

In [54]: for dirname in ["train/pos", "train/neg", "train/unsup", "test/pos", "test/neg"]:
 for fname in sorted(os.listdir("aclimdb/" + dirname)):
 if fname[-4:] == '.txt':
 with open("aclimdb/" + dirname + "/" + fname, encoding='UTF-8') as f:
 sent = f.read()
 words = extract_words(sent)
 unsup_sentences.append(TaggedDocument(words, [dirname + "/" + fname]))

In [55]: for dirname in ["txt_sentoken/pos", "txt_sentoken/neg"]:
 for fname in sorted(os.listdir(dirname)):
 if fname[-4:] == '.txt':
 with open("aclimdb/" + dirname + "/" + fname, encoding='UTF-8') as f:
 for i, sent in enumerate(f):
 words = extract_words(sent)
 unsup_sentences.append(TaggedDocument(words, ["%s/%s-%d" % (dirname, fname, i)]))

In [56]: with open("stanforSentimentTreebank/original_rt_snippets.txt", encoding='UTF-8') as f:
 for i, sent in enumerate(f):
 words = extract_words(sent)
 unsup_sentences.append(TaggedDocument(words, ["rt-%d" % i]))
```

Gambar 5.22 Praktek 4

```
In [77]: import re
def extract_words(sent):
 sent = sent.lower()
 sent = re.sub(r'<[^>]+>', ' ', sent) #hapus tag html
 sent = re.sub(r'(\w)\'(\w)', ' ', sent) #hapus petik satu
 sent = re.sub(r'\W', ' ', sent) #hapus tanda baca
 sent = re.sub(r'\s+', ' ', sent) #hapus spasi yang berurutan
 return sent.split()

import random
class PermuteSentences(object):
 def __init__(self, sents):
 self.sents = sents

 def __iter__(self):
 shuffled = list(self.sents)
 random.choice(shuffled)
 for sent in shuffled:
 yield sent

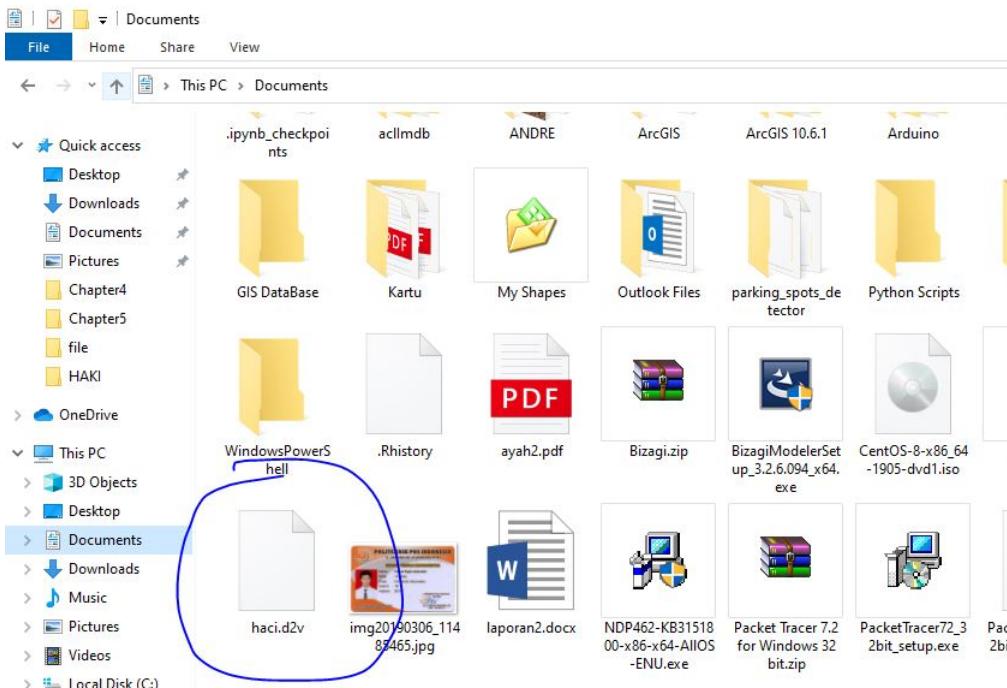
mute=PermuteSentences(unsup_sentences)
model = Doc2Vec(mute, dm=0, hs=1, size=50)
model.delete_temporary_training_data(keep_inference=True)
```

Gambar 5.23 Praktek 5

- lalu pada penggunaan code berikut ini akan mengolah data LOVE yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [78]: model.delete_temporary_training_data(keep_inference=True)
 model.save('haci.d2v')
```

**Gambar 5.24** Praktek 6



### Gambar 5.25 Praktek 6

```
In [8]: genmod['love']
Out[8]: array([0.10307324, -0.15234375, 0.02587891, -0.16503906, -0.16503906,
 0.06884543, 0.2996875, -0.26357188, -0.140625, 0.20171188,
 0.02624512, 0.0383125, -0.05928125, 0.04394081, -0.03535156,
 0.02500001, 0.02500001, 0.02500001, 0.02500001, 0.02500001,
 0.03857422, 0.07859864, 0.22649212, 0.14355469, 0.17679468,
 0.03515625, 0.05175578, 0.10639359, 0.11181641, 0.16505984,
 -0.11181641, 0.13964484, 0.01553693, 0.17292969, 0.15426688,
 0.02635725, 0.02635725, 0.02635725, 0.02635725, 0.02635725,
 0.16552344, 0.23946887, 0.04711914, 0.02929473, 0.05835684])
```

**Gambar 5.35** hasil olah data LOVE pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data FAITH yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [79]: model.infer_vector(extract_words("I will go home"))
```

```
Out[79]: array([-1.7533980e-01, 1.7654952e-01, 8.7283678e-02, 1.7998287e-02,
 6.2501184e-03, -3.2540500e-02, 1.6391091e-01, -1.3786003e-02,
 5.1714227e-02, 4.6473891e-02, 1.6999269e-02, 2.6260551e-02,
 -2.5963100e-02, 7.7627085e-02, -1.5409573e-02, 1.3232067e-01,
 -4.3878101e-02, 4.8159737e-02, -5.1153481e-02, -7.2681673e-02,
 -3.1889844e-02, -2.4982829e-02, 1.1039837e-01, 7.9181477e-02,
 6.1015221e-03, 6.1555382e-02, -2.2586747e-01, 1.3859421e-01,
 1.6294651e-02, -6.1351705e-02, 1.3722880e-01, -7.6827303e-02,
 -1.4081554e-01, 4.0382754e-02, -1.2432394e-01, -3.1883363e-02,
 6.4639568e-02, 7.1126200e-02, -4.4149000e-02, -5.9015196e-02,
 1.0176090e-04, 1.0674181e-02, 6.5928474e-02, 3.7513527e-03,
 5.5374358e-02, -1.3092439e-02, -3.5841893e-02, 4.9701292e-02,
 -1.1787581e-01, 9.5303327e-02], dtype=float32)
```

Gambar 5.26 Praktek 7

```
In [83]: from sklearn.metrics.pairwise import cosine_similarity
cosine_similarity(
 [model.infer_vector(extract_words("she going to school, after wash hand"))],
 [model.infer_vector(extract_words("Services sucks2."))])
```

```
Out[83]: array([[0.04744839]], dtype=float32)
```

```
In [84]: from sklearn.metrics.pairwise import cosine_similarity
cosine_similarity(
 [model.infer_vector(extract_words("Dia pergi ke sekolah tadi siang"))],
 [model.infer_vector(extract_words("Services sucks2."))])
```

```
Out[84]: array([[0.2095491]], dtype=float32)
```

Gambar 5.27 Praktek 8

```
In [9]: genmod(['faith'])
Out[9]:
array([-0.26367188, -0.04150891, 0.1953125, 0.13476562, -0.14648488,
 0.11962891, 0.04345793, 0.10551662, 0.12297931, 0.13476562,
 -0.12297931, 0.10551662, 0.13476562, -0.14648488,
 0.3293125, -0.198449219, 0.36132812, -0.1953125, 0.13476562,
 0.15332831, -0.18839844, 0.18153986, -0.01367188, 0.23144531,
 -0.23144531, 0.01367188, 0.18153986, -0.18839844, 0.15332831,
 -0.1328125, 0.21484375, 0.01135254, 0.02111816, 0.18554688,
 0.04125977, 0.12011719, 0.17480669, -0.22167969, -0.13476562,
 0.01135254, 0.02111816, 0.18554688, -0.18839844, 0.15332831,
 -0.02111816, 0.01257324, -0.09521469, -0.18066469, -0.146825 ,
```

Gambar 5.36 hasil olah data FAITH pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data FALL yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [10]: genmod(['fall'])
Out[10]:
array(-0.04773441, 0.15742189, -0.05977344, -0.14059451, -0.12281125,
 -0.16093359, 0.04121289, 0.01949237, 0.14648488, -0.15898602,
 -0.08691486, 0.04492188, 0.015874, 0.08691486, -0.19824219,
 -0.19824219, 0.04492188, 0.015874, 0.08691486, -0.15898602,
 -0.1615625, 0.13571075, 0.09228516, -0.12139975, 0.12695312,
 0.03417969, 0.21893775, 0.01977539, 0.125, 0.05441078,
 -0.05441078, 0.21893775, 0.01977539, -0.125, -0.15898602,
 0.0499219, -0.29882812, -0.18554688, 0.08696984, -0.02087462,
 0.13574219, -0.22558594, 0.33789862, -0.03564453, -0.18839844,
```

Gambar 5.37 hasil olah data FALL pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data SICK yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [11]: genmed ['sick']
Out[11]:
array([-1.8211758e-01, 1.4691480e-01, -4.9527455e-02, 1.46480250e-01,
 3.5935525e-01, 3.7274552e-01, -1.73958125e-01, -1.43646801e-01,
 1.0187421e-01, 5.4687500e-02, 1.66991250e-01, -1.68945531e-01,
 2.6661525e-01, 1.79687500e-01, 5.92081056e-03, 2.4511718e-01,
 9.7492353e-02, -2.56347056e-02, 3.41798751e-01, 4.0886875e-02,
 1.2661525e-01, 1.79687500e-01, 5.92081056e-03, 2.4511718e-01,
 1.81540025e-01, -2.65025000e-01, -1.45957812e-01, 1.09055935e-01,
 9.42382812e-02, -3.12500000e-02, 1.98974609e-02, -6.39648438e-02],
```

**Gambar 5.38** hasil olah data SICK pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data CLEAR yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [12]: genmed ['clear']
Out[12]:
array([-1.44140825e-01, -1.03959701e-01, -1.49414802e-01, -4.24884688e-01,
 2.16562759e-01, -9.76592350e-02, -2.67578125e-01, -1.29882812e-01,
 2.12562759e-01, -9.76592350e-02, -2.67578125e-01, -1.29882812e-01,
 2.08195131e-01, -6.76674219e-02, -6.83593750e-02, -1.21893750e-01,
 2.08195131e-01, -6.76674219e-02, -6.83593750e-02, -1.21893750e-01,
 -7.7587986e-02, -6.04248487e-03, -7.37394658e-02, -1.72851562e-01,
 9.66796475e-02, -4.9133088e-03, -1.78719938e-01, -1.40388539e-03,
 7.93815252e-02, 1.87918126e-02, -1.18515202e-02, -8.34960933e-02],
```

**Gambar 5.39** hasil olah data CLEAR pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data SHINE yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [13]: genmed ['shine']
Out[13]:
array([-0.12402344, 0.25976562, -0.15917969, -0.27734375, 0.30273438,
 0.09969938, 0.39257812, -0.22949219, -0.18355937, 0.3671875 ,
 0.21277344, 0.24923438, 0.5234375 , 0.12394648, -0.19359938,
 -0.05837879, 0.0512739 , -0.0540918, 0.07617188, 0.05125259,
 0.21277344, 0.24923438, 0.5234375 , 0.12394648, -0.19359938,
 -0.34765625, 0.02563477, -0.23925781, -0.04516602, -0.00479126,
 -0.24121994, -0.18945112, -0.15234375, -0.05493164, 0.01434326,
 0.298623 , -0.23939779, 0.14843775, -0.11328394, 0.24511779],
```

**Gambar 5.40** hasil olah data SHINE pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data BAG yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [14]: genmed ['bag']
Out[14]:
array([-0.05151525, 0.15234375, -0.12402344, 0.13378986, -0.11328125,
 -0.0133667 , -0.16113281, 0.14648438, -0.06835938, 0.140625 ,
 -0.05957031, 0.05953771, 0.10253996, 0.19042969, -0.09423829,
 0.18041556, -0.07950864, 0.11805156, -0.07918156, 0.06814559,
 -0.18041556, 0.07950864, 0.13281356, -0.06771769,
 0.01806441, 0.06689455, 0.257125 , 0.03247097, -0.24609375,
 -0.05541992, 0.01613384, 0.24121994, -0.21877094, 0.07568359,
 -0.09814953, -0.15113281, 0.15939896, -0.09512484, -0.16601562],
```

**Gambar 5.41** hasil olah data BAG pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data CAR yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [15]: genmod ['car']
Out[15]:
array([0.13889393, 0.00842189, 0.03144727, -0.05833799, -0.04803995,
 0.14257812, 0.04093164, -0.15894531, 0.20889458, 0.11962391,
 0.18966406, -0.25, -0.18400351, -0.10742188, -0.03179883,
 0.16112121, 0.01111128, 0.03888379, 0.08447266, 0.16213895,
 0.16112121, -0.01111128, -0.03888379, 0.08447266, 0.16213895,
 0.04467773, -0.15527344, 0.25598625, 0.33964375, 0.89756856,
 0.16112121, 0.01111128, 0.03888379, 0.08447266, 0.16213895,
 -0.09912109, 0.16593996, 0.06847466, -0.18945312, 0.02832031,
 -0.05346688, -0.03803965, 0.11083964, 0.24121094, -0.234375 ,])
```

**Gambar 5.42** hasil olah data CAR pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data WASH yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [16]: genmod ['wash']
Out[16]:
array([0.46622122e-03, 1.14031924e-01, -4.44674900e-02, 1.14765625e-01,
 -2.0792056e-01, 0.24238798e-01, -6.44738502e-02, -1.29482388e-02,
 -2.0792056e-01, 2.53986290e-01, 1.13525391e-02, -1.66992188e-01,
 -2.7954161e-02, 2.00807812e-01, -4.27246948e-02, 1.05463750e-01,
 -2.7954161e-02, 1.05463750e-01, 2.12898625e-02, -1.05463750e-01,
 2.6778155e-01, 2.12898625e-01, 1.74505847e-02, 2.02941895e-03,
 6.29828212e-02, 1.02189575e-01, 1.93359575e-01, 2.17285156e-02,
 -2.67988890e-03, -0.15889338e-02, -2.38212598e-01, 2.38338338e-01,])
```

**Gambar 5.43** hasil olah data WASH pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data MOTOR yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [17]: genmod ['motor']
Out[17]:
array([-3.73784659e-02, 1.58398625e-01, -4.11425781e-02, 1.33811580e-05,
 0.55975025e-01, -3.77734375e-01, 3.48012348e-02, 4.17909000e-01,
 2.34375000e-02, 2.57812500e-01, 1.74884688e-01, 2.41446250e-02,
 -0.83390781e-01, -9.42846667e-01, 1.123846667e-01, 1.123846667e-01,
 -0.83390781e-01, 0.58283125e-01, -5.45937500e-02, 1.123846667e-01,
 1.56250000e-01, -4.24884666e-02, -1.28125000e-01, 2.11934602e+01,
 1.56250000e-01, 0.21250000e-01, -0.19921875e-01, -1.01974219e-01,
 3.02754375e-01, 1.53320312e-01, -1.09921875e-01, -1.01974219e-01,
 -3.26538066e-03, 2.28915625e-01, 8.98457590e-02, -7.12996254e-02,])
```

**Gambar 5.44** hasil olah data MOTOR pada GoogleNews-vector

- lalu pada penggunaan code berikut ini akan mengolah data CYCLE yang terdapat pada file GoogleNews-vector, hasil dari pemrosesannya dapat dilihat pada gambar

```
In [18]: genmod ['cycle']
Out[18]:
array([-0.65541016, 0.21579688, -0.02709961, 0.12335316, -0.28070312,
 -0.1328125, 0.26367188, -0.12890625, -0.125, 0.1532081,
 -0.1328125, 0.26367188, -0.12890625, 0.125, 0.1532081,
 0.02563477, -0.07568359, -0.0625, 0.04614258, -0.01054668,
 -0.13579986, -0.11669922, -0.33951759, 0.01125, 0.01054668,
 0.13579986, 0.11669922, 0.33951759, -0.01125, -0.01054668,
 0.18902734, 0.02127852, -0.10693359, 0.02409234, -0.10644531,
 -0.05541092, -0.29492186, -0.40859982, 0.06347856, -0.10644531,
 0.17873994, 0.03165771, -0.01098777, 0.15871873, -0.16468625,])
```

**Gambar 5.45** hasil olah data CYCLE pada GoogleNews-vector

- dan pada hasil code berikut ini adalah hasil dari proses penggunaan perintah code similarity yang akan menghitung nilai value data yang dibandingkan dengan masing - masing kata seperti pada hasil dari perbandingan kata LOVE disandingkan dengan FAITH menghasilkan nilai 37 persen, sedangkan kata WASH dan SHINE menghasilkan nilai 27 persen dan kata CAR yang disandingkan dengan kata MOTOR menghasilkan 48 persen, dimana kita dapat menyimpulkan bahwa semakin data kata tersebut memiliki tingkat kesamaan yang tinggi maka

nilai hasil yang ditampilkanpun akan semakin tinggi. ilustrasi bisa dilihat pada gambar

```
In [19]: genmod.similarity('love', 'faith')
Out[19]: 0.3705347934587281

In [20]: genmod.similarity('wash', 'shine')
Out[20]: 0.2770128965426825

In [21]: genmod.similarity('car', 'motor')
Out[21]: 0.4810172832001571

In [22]: genmod.similarity('bag', 'cycle')
Out[22]: 0.040672609213443504

In [23]: genmod.similarity('shine', 'fall')
Out[23]: 0.27789493775772145
```

**Gambar 5.46** hasil olah data pada GoogleNews-vector menggunakan SIMILARITY

## 2. extract\_words dan PermutatedSentences

pada penjelasan berikut ini akan menyangkut pembersihan data yang akan digunakan untuk diproses, dimana data akan di EXTRACT dari setiap katanya agar terbebas dari data TAG HTML, APOSTROPHES, TANDA BACA, dan SPASI yang berlebih. dengan menggunakan perintah code STRIP dan SPLIT. lalu penggunaan library random yang akan dibuat untuk melakukan KOCLOK data dengan acuan datanya adalah data yang terdapat pada variable KATA. untuk ilustrasi hasil dari codenya dapat dilihat pada gambar

```
In [28]: import re
...: def extract_words(kata):
...: kata = kata.lower()
...: kata = re.sub(r'([^\w\s]+)', ' ', kata)
...: kata = re.sub(r'(\w)\.(\w)', '\1\2', kata)
...: kata = re.sub(r'\s+', ' ', kata)
...: kata = kata.strip()
...: return kata.split()
...:
...: import random
...: class PermutateSentences(object):
...: def __init__(self, lenght):
...: self.lenght = lenght
...:
...: def __iter__(self):
...: req = list(self.lenght)
...: random.shuffle(req)
...: for kata in req:
...: yield kata
```

**Gambar 5.47** hasil olah data pada GoogleNews-vector menggunakan extract\_words dan PermuteSentences

## 3. TaggedDocument dan Doc2Vec

gensim merupakan open-source model ruang vektor dan toolkit topic modeling, yang diimplementasikan dalam bahasa pemrograman Python. Untuk kinerja Gensim, digunakan NumPy, SciPy dan Cython (opsional). Gensim secara khusus ditujukan untuk menangani koleksi teks besar dengan menggunakan algoritma secara online. Gensim mengimplementasikan tf-idf, latent semantic analysis (LSA), Latent Dirichlet Analysis (LDA), dan lain-lain.

tagged document merupakan sebuah class yang terdapat pada pemrosesan data pada library gensim yang akan mengolah data teks yang ada pada dokumen - dokumen yang dipakai.

Doc2Vec merupakan algoritma doct embedding, yaitu pemetaan dari dokumen menjadi vektor, serta pemetaan data dokumen 1 dan dokumen lainnya. ilustrasi dari tagged document dan Word2Vec ada pada gambar

```
In [2]: from gensim.models.doc2vec import TaggedDocument
...: from gensim.models import Doc2Vec
```

**Gambar 5.48** TaggedDocument dan Doc2Vec

#### 4. Praktek data training

pertama buka data training yang akan diolah pada aplikasi python, import library OS dan membuat data variable unsup\_sentences dengan nilai array kosong. buatkan data direktori untuk memanggil data yang akan diolah dan buatkan juga variabel data nilai fname yang akan memproses data dirname untuk diisikan pada variable unsup\_sentences. code yang digunakan dapat dilihat pada gambar

```
In [2]: import os
unsup_sentences = []
for dirname in ["train/pos", "train/reg", "train/unsup", "test/pos", "test/reg"]:
 for fname in sorted(os.listdir(dirname)):
 if fname[-4:] == ".txt":
 with open(dirname + "/" + fname, encoding='utf-8') as f:
 data = f.read()
 data = data.replace("\n", " ")
 words = extract_words(data)
 unsup_sentences.append(TaggedDocument(words, [dirname + "/" + fname]))
for dirname in ["review_polarity/txt_sentoken/pos", "review_polarity/txt_sentoken/reg"]:
 for fname in sorted(os.listdir(dirname)):
 if fname[-4:] == ".txt":
 with open(dirname + "/" + fname, encoding='utf-8') as f:
 for kata in remove_stopwords(f.read()):
 if kata != "\n":
 words = extract_words(kata)
 unsup_sentences.append(TaggedDocument(words, ["1u/1s/N" % (dirname, fname, 1)]))
for dirname in ["train/pos", "train/reg", "train/unsup", "test/pos", "test/reg"]:
 for fname in sorted(os.listdir(dirname)):
 if fname[-4:] == ".txt":
 with open(dirname + "/" + fname, encoding='utf-8') as f:
 words = extract_words(data)
 unsup_sentences.append(TaggedDocument(words, ["1u/1s/N" % 1]))
```

**Gambar 5.49** data code praktek data training

data pada hasil code digambar berikut ??, menghasilkan data pada gambar ?? yang akan memunculkan data variable DIRNAME, FNAME, KATA dan unsup\_sentences yang memiliki data sebanyak 55 kata dalam file yang diolah tersebut. hasil run dengan menggunakan code pada gambar ??, menghasilkan data nilai yang terdapat pada gambar ???. lalu pada code yang terdapat digambar ??, menghasilkan data ???.

```
In [2]: import os
unsup_sentences = []
for dirname in ["train/pos", "train/reg", "train/unsup", "test/pos", "test/reg"]:
 for fname in sorted(os.listdir(dirname)):
 if fname[-4:] == ".txt":
 with open(dirname + "/" + fname, encoding='utf-8') as f:
 words = extract_words(data)
 unsup_sentences.append(TaggedDocument(words, [dirname + "/" + fname]))
```

**Gambar 5.50** data code praktek data training

**Gambar 5.51** data code praktik data training

```

for docname in ["review_polarity/txt_sentoken/pos", "review_polarity/txt_sentoken/neg"]:
 for fname in sorted(os.listdir(docname)):
 if fname.endswith('.txt'):
 with open(fname, 'r', encoding='UTF-8') as f:
 for i, kata in enumerate(f):
 words = word_tokenize(kata)
 for word in words:
 if word == 'KATA':
 print('KATA', word, document_id, fname, i+1)

```

**Gambar 5.52** data code praktik data training

| Name            | Type | Size   | Value                                                                 |
|-----------------|------|--------|-----------------------------------------------------------------------|
| dname           | str  | 1      | review_polarity/txt_sentoken/neg                                      |
| fname           | str  | 1      | cv999_146036.txt                                                      |
| i               | int  | 1      | 24                                                                    |
| kata            | str  | 1      | any matching up-right_at_the_coxbury_ , you'll be left with maxdist:1 |
| unsup_sentences | list | 130010 | [TaggedDocument, TaggedDocument, TaggedDocument, Tagge ...]           |
| words           | list | 1      | ['.', ',', '...', '']                                                 |

**Gambar 5.53** data code praktik data training

```
In[3]:
with open("StanfordSentimentTreebank/original_rt_snippets.txt", encoding='UTF-8') as f:
 for i, line in enumerate(f):
 words = extract_words(kata)
 ussup_sentences.append(TaggedDocument(words, ["rt-%d" % i]))
```

**Gambar 5.54** data code praktik data training

| Name           | Type | Size   | Value                                                                     |
|----------------|------|--------|---------------------------------------------------------------------------|
| dirname        | str  | 1      | review_polarity/txt_Sentoken/neg                                          |
| filename       | str  | 1      | c999_14656.txt                                                            |
| i              | int  | 1      | 18684                                                                     |
| kata           | str  | 1      | after watching _eight_at_the Roxbury_ , you'll                            |
| line           | str  | 1      | Her fans walked out muttering words like                                  |
| unus_sentences | list | 100000 | [TaggedDocument, TaggedDocument, TaggedDocument, TaggedDocument, Tag ...] |
| words          | list | 9      | ['.', '...', '...']                                                       |

**Gambar 5.55** data code praktik data training

## 5. Why need Shuffled and Clean memory

dilakukan shuffled adalah agar datanya lebih mudah untuk diolah dan untuk menentukan tingkat tinggi akurasi dari hasil pemrosesan. dan dilakukan pembersihan memory adalah agar chace yang disimpan tidak membuat proses pada komputer menjadi lambat dan dapat digunakan untuk memproses data lainnya agar menjadi lebih ringan dan cepat. pada gambar ?? adlah proses untuk melakukan pengoclokan data dan pada gambar ?? adalah proses untuk memasukan data unsup\_sentences kedalam variable muter untuk diproses dengan class PermuterSentences. dan pada gambar ?? adalah code yang digunakan untuk membersihkan data memory.

```
In [28]: import re
.....
....: class PermuteSentences(object):
....: def __init__(self, lenght):
....: self.lenght = lenght
....:
....: def __iter__(self):
....: req = list(self.lenght)
....: random.shuffle(req)
....: for kata in req:
....: yield kata
....:
```

**Gambar 5.56** Shuffled dan Randomisasi data

```
In [18]: muter = PermuteSentences(unsup_sentences)
...: mod = Doc2Vec(muter, dm=0, hs=1, size=50)
```

**Gambar 5.57** pembuatan variable muter untuk memuat data unsup\_sentences

```
mod.delete_temporary_training_data(keep_inference=True)
```

**Gambar 5.58** code untuk membersihkan data memory

## 6. Why model have to be saved

dalam pengolahan data dengan menggunakan proses yang panjang ditakutkan data yang sudah diproses tersebut dapat hilang jika terdapat kejadian atau emergency pada saat pengolahan dan pemrosesan data, misalnya harddisk error atau pun listrik yang padam. dan proses penyimpanan data juga dilakukan agar data yang sudah diolah data dipanggil lagi tanpa harus melakukan proses dari awal sehingga tidak memakan waktu. untuk code yang digunakan dapat dilihat pada gambar

| ④ SentimentAnalysis         | 3/18/2019 3:14 PM  | Python Source File   | 2 KB     |
|-----------------------------|--------------------|----------------------|----------|
| ④ SentimentAnalysisnew.pytb | 3/18/2019 3:22 PM  | Python Source File   | 1 KB     |
| ④ stopword.txt              | 3/18/2019 3:22 PM  | Text File            | 54KB (0) |
| ④ tagger3                   | 3/20/2019 11:41 PM | Python Source File   | 2 KB     |
| ④ word2vec                  | 3/20/2019 12:05 AM | Python Source File   | 6 KB     |
| ④ You tube01-Phi            | 3/18/2019 3:14 PM  | Microsoft Excel C... | 27 KB    |
| ④ You tube01-KeyPeru        | 3/18/2019 3:14 PM  | Microsoft Excel C... | 64 KB    |
| ④ You tube01-LM3Q           | 3/18/2019 3:14 PM  | Microsoft Excel C... | 64 KB    |
| ④ You tube04-Eminem         | 3/18/2019 3:14 PM  | Microsoft Excel C... | 32 KB    |
| ④ You tube05-Shakira        | 3/18/2019 3:14 PM  | Microsoft Excel C... | 72 KB    |

**Gambar 5.59** data code save data

berikut ini adalah hasil file dari penggunaan code save tersebut. bisa dilihat pada gambar

```
In [19]: mod.infer_vector(extract_words("This Place is not worth your time,
let alone Vegas."))
Out[19]: [-0.00374494, -0.00037316, -0.000647218, 0.000074611,
-0.00058244, 0.00033789, -0.000880563, 0.00724112, 0.0020099,
-0.00034863, 0.00034863, 0.00034863, 0.00034863, 0.00034863,
0.00034863, -0.00175985, -0.00996859, -0.00778317, 0.00423807,
0.0006395, 0.00775260, 0.00713274, 0.00674205, 0.00414126,
0.0006395, 0.00775260, 0.00713274, 0.00674205, 0.00414126,
-0.00567081, 0.00647779, 0.007077156, -0.002921268, 0.00395201,
-0.00567081, 0.00647779, 0.007077156, -0.002921268, 0.00395201,
0.0052635, 0.00927048, -0.0021578, -0.00058527, 0.0073598,
0.0006959, -0.00279456, -0.000753236, 0.00646478, -0.00494211],
dtype='float32')
```

**Gambar 5.60** hasil file simpan

## 7. infer\_vector

berfungsi untuk dokumen baru, dan bisa menggunakan data vektor yang dilatih secara massal, seperti yang disimpan dalam model, untuk dokumen yang merupakan bagian dari data training. untuk percobaannya dapat dilihat pada gambar

```
In [12]: from sklearn.metrics.pairwise import cosine_similarity
...: cosine_similarity(
...: [mod.infer_vector(extract_words("highly recommended."))],
...: [mod.infer_vector(extract_words("services sucks."))])
Out[12]: array([[0.206962]], dtype=float32)
```

**Gambar 5.61** code dan hasil infer\_vector

## 8. cosine\_similarity

merupakan sebuah algoritma yang digunakan untuk membandingkan dari dua buah data yang bukan merupakan data vector untuk menguji nilai kemiripan data satu dengan data lainnya. hasil dari percobaan pada tugas no 8 ini dapat dilihat pada gambar ?? yang menghasilkan nilai akurasi sebesar 20 persen dan gambar ?? yang menghasilkan nilai akurasi sebesar 91 persen.

```
In [13]: from sklearn.metrics.pairwise import cosine_similarity
...: cosine_similarity(
...: [mod.infer_vector(extract_words("tolong bantuan."))],
...: [mod.infer_vector(extract_words("tolong bantuan."))])
Out[13]: array([[0.91439525]], dtype=float32)
```

**Gambar 5.62** code dan hasil penggunaan cosine\_similarity

```
In [36]: from sklearn.neighbors import KNeighborsClassifier
...: from sklearn.ensemble import RandomForestClassifier
...: from sklearn.model_selection import cross_val_score
...: import numpy as np
...: ...
...: clf = KNeighborsClassifier(n_neighbors=9)
...: clfrf = RandomForestClassifier()
```

**Gambar 5.63** code dan hasil penggunaan cosine\_similarity

## 9. Cross Validation

pertama melakukan import data dari library KNeighborsClassifier, RandomForestClassifier, cross\_val\_score dan numpy yang digunakan untuk membuat data cross validasi dapat dilihat pada gambar

```
In [40]: scores = cross_val_score(clf, sentvecs, sentiments, cv=5)
...: np.mean(scores), np.std(scores)
Out[40]: (0.5283333333333334, 0.086411794687223791)
```

**Gambar 5.64** memasukan code import library

lalu selanjutnya membuat data variable scores yang akan memuat nilai cross\_val\_score dengan datanya diambil dari KNeighborsClassifier

yang terdiri dari sentvecs, sentiments dan clf dan mengolahnya menggunakan numpy untuk menampilkan data pada gambar yang menghasilkan nilai akurasi sebesar 53 persen.

```
In [41]: scores2 = cross_val_score(cItrf, sentvecs, sentiments, cv=5)
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in version 0.20 to 100 in 0.22.*. FutureWarning
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in version 0.20 to 100 in 0.22.*. FutureWarning
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in version 0.20 to 100 in 0.22.*. FutureWarning
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in version 0.20 to 100 in 0.22.*. FutureWarning
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in version 0.20 to 100 in 0.22.*. FutureWarning
Out[41]: 0.5319999999999999, 0.40044635988804594
```

**Gambar 5.65** perhitungan data KNeighborsClassifier dengan cross validasi

membuat data variable scores yang akan memuat nilai cross\_val\_score dengan datanya diambil dari RandomForestClassifier yang terdiri dari sentvecs, sentiments dan clrf dan mengolahnya menggunakan numpy untuk menampilkan data pada gambar yang menghasilkan nilai akurasi sebesar 53 persen.

```
In [42]: from sklearn.pipeline import make_pipeline
... from sklearn.feature_extraction.text import CountVectorizer,
... RandomForestClassifier
... pipeline = make_pipeline(CountVectorizer(), TfidfTransformer(),
RandomForestClassifier())
... scores1 = cross_val_score(pipeline,sentences,sentiments, cv=5)
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in 0.22.*. FutureWarning
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in 0.22.*. FutureWarning
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in 0.22.*. FutureWarning
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in 0.22.*. FutureWarning
C:\Users\fatih-PC\OneDrive\lib\site-packages\sklearn\ensemble\forest.py:246:
FutureWarning: The default value of n_estimators will change from 10 in version 0.20
to 100 in 0.22.*. FutureWarning
Out[42]: 0.7446666666666667, 0.8234294979311713
```

**Gambar 5.66** perhitungan data RandomForestClassifier dengan cross validasi

penggunaan make\_pipeline adalah untuk membuat data dari KNeighborsClassifier, RandomForestClassifier dan Vectorizer digabungkan untuk menghasilkan data nilai pada gambar menghasilkan nilai akurasi sebesar 74 persen.

| scores1 | float64 (5,) | (0.53333333 0.335 0.53333333 0.51833333)      |
|---------|--------------|-----------------------------------------------|
| scores2 | float64 (5,) | (0.53333333 0.52333333 0.52666667 0.55333333) |
| scores3 | float64 (5,) | (0.74666667 0.77333333 0.71833333 0.71166667) |

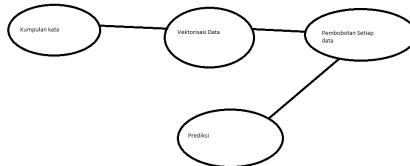
**Gambar 5.67** perhitungan data Cross Validasi untuk nilai keseluruhan dari KNeighborsClassifier, RandomForestClassifier dan Vectorizer

### 5.3 Luthfi Muhammad Nabil (1174035)

#### 5.3.1 Teori

- Jelaskan Kenapa Kata-Kata harus dilakukan vektorisasi lengkapi dengan ilustrasi gambar.


Kata kata harus dilakukan vektorisasi dikarenakan atau bertujuan untuk mengukur nilai sebuah kata yang nantinya setiap kata tersebut akan diprediksi apakah bernilai yang berarti terpakai atau tidak.



**Gambar 5.68** Ilustrasi Vektorisasi Kata-Kata

- Jelaskan Mengapa dimensi dari vektor dataset google bisa mencapai 300 lengkapi dengan ilustrasi gambar.

Dimensi dataset dari google bisa mencapai 300 karena dimensi dari vektor tersebut digunakan untuk membandingkan bobot dari setiap kata, misalkan terdapat kata dog dan cat pada dataset google tersebut setiap kata tersebut dibuat dimensi vektor 300 untuk kata dog dan 300 dimensi vektor juga untuk kata cat kemudian kata tersebut dibandingkan bobot kesamaan katanya maka akan muncul akurasi sekitar 70 persen kesamaan bobot dikarenakan kata dog dan cat sama-sama digunakan untuk hewan priharaan. Untuk lebih jelasnya dapat dilihat pada gambar ??.



**Gambar 5.69** Ilustrasi Vektorisasi Kata-Kata

- Jelaskan Konsep vektorisasi untuk kata . dilengkapi dengan ilustrasi atau gambar.

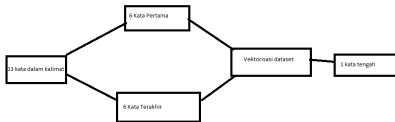
Vektorisasi untuk kata untuk mengetahui kata tengah dari suatu kalimat atau kata utama atau objek utama pada suatu kalimat kata tengah tersebut merupakan channel yang memiliki bobot sebagai kata tengah dari suatu kalimat atau bobot sebagai objek dari suatu kalimat. hal ini sangat berkaitan dengan dimensi vektor pada dataset google yang 300 tadi karena untuk mendapatkan nilai atau bobot dari kata tengah tersebut di dapatkan dari proses dimensiasi dari kata tersebut. untuk lebih jelasnya dapat dilihat pada gambar ?? berikut :



**Gambar 5.70** Ilustrasi Vektorisasi Kata-Kata

4. Jelaskan Konsep vektorisasi untuk dokumen. dilengkapi dengan ilustrasi atau gambar.


Vektorisasi untuk dokumen hampir sama seperti vektorisasi untuk kata hanya saja pemilihan kata utama atau kata tengah terdapat pada satu dokumen jadi mesin akan membuat dimensi vektor 300 untuk dokumen dan nanti kata tengahnya akan di sandingkan pada dokumen yang terdapat pada dokumen tersebut contoh dapat dilihat pada gambar ?? berikut :



**Gambar 5.71** Ilustrasi Vektorisasi Kata-Kata

5. Jelaskan apa mean dan standar deviasi, lengkapi dengan ilustrasi atau gambar.

mean merupakan petunjuk terhadap kata-kata yang di olah jika kata kata itu akurasinya tinggi berarti kata tersebut sering muncul begitu juga sebaliknya untuk lebih jelasnya dapat dilihat pada gambar ?? sedangkan setandard deviation merupakan standar untuk menimbang kesalahan. sehingga kesalahan tersebut di anggap wajar misalkan kita memperkirakan kedalaman dari dataset merupakan 2 atau 3 tapi pada kenyataannya merupakan 5 itu merupakan kesalahan tapi masih bisa dianggap wajar karna masih mendekati perkiraan awal.



**Gambar 5.72** Ilustrasi Vektorisasi Kata-Kata

6. Jelaskan Apa itu Skip-Gram sertakan contoh ilustrasi.

Skip-Gram adalah kebalikan dari konsep vektorisasi untuk kata dimana kata tengah menjadi acuan terhadap kata-kata pelengkap dalam suatu kalimat untuk lebih jelasnya dapat di lihat pada gambar ?? berikut :



**Gambar 5.73** Ilustrasi Vektorisasi Kata-Kata

## **BAB 6**

---

## **CHAPTER 6**

---



## **BAB 7**

---

## **CHAPTER 7**

---

